



**SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB
MENGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH
CLUSTERING**

*Diajukan guna memenuhi salah satu syarat memperoleh gelar Sarjana pada
Program Studi Teknologi Informasi*

SKRIPSI

Oleh:

Moh. Yusril Maqoshidana

NIM 222410102064

**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN
TEKNOLOGI PROGRAM STUDI TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER
UNIVERSITAS JEMBER**

2026

PERSEMBAHAN

Halaman ini saya persembahkan kepada:

1. Allah SWT, atas segala rahmat, karunia, serta kemudahan yang diberikan sehingga penulis dapat menyelesaikan skripsi ini dengan baik.
2. Bapak Subono dan Ibu Marsidah yang selalu mendoakan yang terbaik, mendukung segala usaha, serta selalu sabar dan percaya hingga sampai penulis mampu menyelesaikan pendidikan.
3. Bapak Dr. Brian Rizqi Paradisiaca Darnoto, S.Kom., M.Kom selaku Dosen Pembimbing Utama yang telah meluangkan waktu, memberikan arahan, bimbingan, serta masukan yang berharga selama proses penyusunan skripsi ini.
4. Ibu Khoirunnisa' Afandi, S.Kom., M.Kom dan Bapak Dony Bahtera Firmawan, S.Kom., M.Kom selalu dosen penguji yang memberikan saran dan masukan dalam proses pengembangan skripsi.
5. Dosen Fakultas Ilmu Komputer, Universitas Jember yang telah memberikan ilmu dan pengalaman yang berharga selama masa perkuliahan.
6. Sahabat yang telah memberikan dukungan, semangat, serta bantuan selama proses penyusunan skripsi ini.

MOTTO

“ Aku telah berupaya tanpa henti untuk tidak mencemooh, tidak meratapi, tidak menghina tindakan manusia, tetapi untuk memahaminya. ”

(Baruch Spinoza)

“ Your worst sin is that you have destroyed and betrayed yourself for nothing. ”

(Fyodor Dostoevsky)

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini:

Nama: Moh. Yusril Maqoshidana

NIM: 222410102064

Dengan ini menyatakan bahwa skripsi yang berjudul: *Sistem Analisis Topik Grup WhatsApp Berbasis Web Menggunakan BERTopic dengan IndoBERTweet dan BIRCH Clustering* adalah benar-benar hasil karya saya sendiri. Saya juga menyatakan bahwa dalam skripsi ini tidak terdapat karya yang pernah diajukan untuk memperoleh gelar sarjana atau gelar lainnya di mana pun.

Saya bertanggung jawab atas kebenaran dan keorisinalan isi skripsi ini. Apabila dikemudian hari terbukti bahwa skripsi ini mengandung unsur plagiarasi, maka saya siap menanggung akibat hukum yang berlaku.

Jember, 01 Juni 2026

Yang menyatakan,

Moh. Yusril Maqoshidana

NIM. 222410102064

HALAMAN PERSETUJUAN

Skripsi berjudul “*SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING*” telah diuji dan disetujui oleh Fakultas Ilmu Komputer Universitas Jember pada:

Hari : Minggu

Tanggal : 01 Juni 2026

Tempat : Fakultas Ilmu Komputer Universitas Jember

Pembimbing

Tanda Tangan

1. Pembimbing Utama

Nama : Dr. Brian Rizqi P. D., S.Kom., M.Kom

(.....)

NIP : 199804272024061001

Penguji

1. Penguji Utama

Nama : Khoirunnisa' Afandi, S.Kom., M.Kom

(.....)

NIP : 199412282024062001

2. Penguji Anggota 1

Nama : Dony Bahtera Firmawan, S.Kom., M.Kom

(.....)

NIP : 199711202024061001

ABSTRAK

Tingginya aktivitas pertukaran pesan pada grup WhatsApp kerap memicu fenomena *information overload*, yang menyulitkan pengguna dalam mengikuti dinamika diskusi dan menyaring informasi penting tanpa membaca riwayat pesan secara manual. Kendati teknik *topic modeling* dapat mengekstraksi topik secara otomatis, penerapannya pada percakapan WhatsApp menghadapi tantangan teks pendek, struktur informal, derau tinggi, dan *code-mixing*. Di samping itu, algoritma pengklasteran HDBSCAN pada *framework* BERTopic standar mengeliminasi hingga 41%–43% data sebagai *outlier*, sehingga menghilangkan banyak substansi percakapan penting.

Penelitian ini bertujuan mengembangkan modifikasi arsitektur BERTopic yang memadukan model *embedding* IndoBERTweet, algoritma pengklasteran hierarkis BIRCH untuk menekan proporsi *outlier*, serta skema pembobotan BM25 untuk representasi kata kunci topik. Model dievaluasi terhadap *baseline* BERTopic menggunakan metrik *Topic Coherence* (C-NPMI), *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity*, serta diimplementasikan ke dalam aplikasi analisis berbasis web.

Metodologi penelitian menerapkan pendekatan eksperimental dan R&D menggunakan dataset 91.868 pesan grup WhatsApp Komunitas Buku (2023–2026) yang menghasilkan 56.089 dokumen bersih setelah *Single-Path Preprocessing*. Pemodelan topik memadukan IndoBERTweet (768 dimensi), reduksi UMAP (5 dimensi), pengklasteran BIRCH, ekstraksi kata kunci BM25 dengan penyaringan *stopwords* 9 kategori, serta reduksi topik otomatis. Sistem dibangun dengan arsitektur *client-server* (Vue.js dan FastAPI) yang dilengkapi pemantauan progres *real-time* berbasis SSE, penelusuran konteks pesan (*traceability*), dan privasi data di sisi klien.

Kata Kunci: *BERTopic, IndoBERTweet, BIRCH Clustering, BM25, Topic Modeling, Analisis Grup WhatsApp, Pemrosesan Bahasa Alami*

ABSTRACT

High message activity in WhatsApp groups frequently causes information overload, making it challenging for users to track discussions and extract key insights without manually reading lengthy chat histories. While topic modeling can automate thematic extraction, applying it to WhatsApp conversations presents substantial challenges due to short text length, informal grammar, noise, and code-mixing. Furthermore, the standard BERTopic framework relies on HDBSCAN clustering, which inherently discards 41%–43% of messages as outliers, causing critical conversational data loss.

This study aims to develop an enhanced BERTopic architecture that integrates the IndoBERTweet embedding model, BIRCH hierarchical clustering to minimize outlier rates, and the BM25 weighting scheme for topic keyword representation. The model is evaluated against the baseline BERTopic using Topic Coherence (C-NPMI), Topic Diversity, Embedding Density, and Intra-topic Similarity, and is implemented into an end-to-end web-based analytics platform.

The research employs an experimental and R&D methodology utilizing 91,868 raw messages from the “Komunitas Buku” WhatsApp group (2023–2026), producing 56,089 clean documents via Single-Path Preprocessing. The topic modeling pipeline incorporates IndoBERTweet (768-d), UMAP reduction (5-d), BIRCH clustering, BM25 keyword representation with a 9-category stopword filter, and automatic topic reduction. The system is built on a client-server architecture (Vue.js and FastAPI) featuring real-time SSE progress streaming, message context traceability, and client-side privacy preservation.

Keywords: *BERTopic, IndoBERTweet, BIRCH Clustering, BM25, Topic Modeling, WhatsApp Group Analysis, Natural Language Processing*

RINGKASAN

WhatsApp merupakan salah satu platform pesan instan paling populer yang dimanfaatkan sebagai sarana komunikasi kelompok, koordinasi tim, dan interaksi komunitas daring. Pada grup percakapan aktif dengan volume pesan tinggi, dinamika pertukaran informasi berlangsung sangat cepat. Akumulasi ribuan pesan harian tersebut memicu fenomena *information overload*, di mana anggota kelompok mengalami kendala dalam memahami pokok pembicaraan, menyaring poin krusial, dan memetakan topik tanpa membaca riwayat pesan secara manual.

Penerapan teknik pemodelan topik (*topic modeling*) pada percakapan WhatsApp menghadapi tantangan teks pendek, tata bahasa informal, derau tinggi (singkatan, elongasi, ekspresi tawa, emoji), dan *code-mixing*. Model konvensional berbasis *bag-of-words* mengalami masalah kelangkaan data (*sparsity*), sedangkan *framework* BERTopic standar dengan HDBSCAN secara inheren membuang 41%–43% dokumen sebagai pencilan (*outlier*), sehingga menghilangkan banyak substansi obrolan. Selain itu, model bahasa umum kurang optimal menangkap konteks percakapan lokal Indonesia, serta skema c-TF-IDF rentan bias akibat pengulangan frekuensi kata pada teks pendek.

Guna mengatasi permasalahan tersebut, penelitian ini mengusulkan modifikasi arsitektur BERTopic yang memadukan model *embedding* IndoBERTweet, algoritma pengklasteran hierarkis BIRCH (*BirchWithOutliers*) dengan mekanisme persentil jarak kosinus untuk menekan *outlier*, serta skema pembobotan BM25 dengan penyaringan *stopwords* wacana percakapan 9 kategori. Penelitian ini bertujuan untuk: (1) mengimplementasikan arsitektur BERTopic modifikasi pada obrolan grup WhatsApp berbahasa Indonesia; (2) mengevaluasi performa model usulan secara kuantitatif melalui kurva pembelajaran (*learning curve*) dibandingkan *baseline* BERTopic menggunakan metrik *Topic Coherence* (C-NPMI), *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity*; serta (3) membangun sistem aplikasi berbasis web interaktif dengan jaminan privasi data di sisi klien dan penelusuran

konteks pesan (*traceability*).

Metodologi penelitian menerapkan pendekatan kuantitatif eksperimental dan *Research and Development* (R&D). Dataset bersumber dari grup WhatsApp Komunitas Buku (2023–2026) sebanyak 91.868 pesan teks dari 1.307 partisipan, yang menghasilkan 56.089 dokumen bersih melalui *Single-Path Preprocessing* (parsing ISO 8601, anonimisasi SHA-256 sisi klien, pembersihan notifikasi/URL/metadata, transliterasi emoji, normalisasi kata/tawa, dan filter panjang ≥ 3 kata). Pemodelan topik memadukan IndoBERTweet (768 dimensi), reduksi UMAP (5 dimensi, kosinus), pengklasteran BIRCH, ekstraksi BM25 ($k_1 = 1, 2; b = 0, 5$), dan reduksi topik otomatis dengan *safety guard*. Sistem web dibangun menggunakan arsitektur *client-server* (Vue.js 3 dan FastAPI) yang dilengkapi pemrosesan latar belakang asinkron, pemantauan status *real-time* via *Server-Sent Events* (SSE), serta pengujian fungsional *Black-Box Testing*.

Hasil evaluasi kuantitatif sepanjang kurva pembelajaran (20%–100% data) membuktikan keunggulan model usulan. Algoritma BIRCH berhasil membatasi proporsi pencilan (*outlier rate*) menjadi hanya 8,79% pada 100% data (56.089 dokumen), jauh mengungguli model *baseline* yang membuang 42,42% data. Pemanfaatan IndoBERTweet dan BM25 meningkatkan nilai C-NPMI secara signifikan dari 0,0662 menjadi 0,1567, serta menjaga *Topic Diversity* pada level tinggi (0,9559). Metrik kekompakan ruang vektor juga meningkat dengan *Embedding Density* mencapai 0,6666 (vs 0,5611) dan *Intra-topic Similarity* mencapai 0,6716 (vs 0,5211). Pengujian *Black-Box Testing* terhadap 34 skenario kasus uji menunjukkan seluruh fitur sistem beroperasi 100% valid.

Dapat disimpulkan bahwa integrasi IndoBERTweet, pengklasteran BIRCH, dan representasi BM25 pada BERTopic terbukti efektif mengatasi tantangan pemodelan topik teks pendek WhatsApp, meminimalkan kehilangan data percakapan, serta menghasilkan kluster topik yang koheren dan representatif. Secara praktis, sistem web yang dikembangkan memberikan solusi aplikatif yang memudahkan pengguna dan pengelola komunitas dalam menganalisis dinamika obrolan grup secara aman, efisien, dan interaktif.

PRAKATA

Puji syukur kehadiran Allah SWT atas segala berkah dan rahmat yang telah diberikan sehingga penulis mampu menyelesaikan penelitian yang berjudul “*SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING*”. Penelitian ini merupakan salah satu syarat akademik dalam menyelesaikan pendidikan Strata Satu (S1) pada Program Studi Teknologi Informasi Fakultas Ilmu Komputer Universitas Jember.

Penulis menyadari bahwa dalam proses penelitian dan penulisan skripsi ini, banyak pihak yang telah memberikan bimbingan, dukungan, dan bantuan. Oleh karena itu, pada kesempatan ini penulis dengan sepuh hati mengucapkan terima kasih kepada:

1. Bapak Prof. Drs. Antonius Cahya Prihandoko, M.App.Sc., Ph.D., selaku Dekan Fakultas Ilmu Komputer Universitas Jember.
2. Dr. Brian Rizqi Paradisiaca Darnoto, S.Kom., M.Kom selaku Pembimbing Utama yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan bimbingan, diskusi, serta arahan yang sangat berharga sejak awal hingga skripsi ini selesai.
3. Ibu Khoirunnisa' Afandi, S.Kom., M.Kom dan Bapak Dony Bahtera Firmawan, S.Kom., M.Kom selaku Dosen Penguji yang telah memberikan ujian, saran, dan masukan yang konstruktif demi kesempurnaan laporan skripsi ini.
4. Bapak Yudha Alif Auliya, S.Kom., M.Kom. selaku Dosen Pembimbing Akademik yang telah memberikan bimbingan dan arahan selama masa studi di Program Studi Teknologi Informasi.
5. Para dosen dan staff Fakultas Ilmu Komputer, Universitas Jember yang telah membantu selama proses akademik.
6. Bapak Subono dan Ibu Marsidah selaku orang tua yang telah memberikan doa dan dukungan moral dan material selama penulis menempuh pendidikan

hingga menyelesaikan pendidikan jenjang S1.

7. Sahabat yang telah memberikan semangat, bantuan, dan dukungan selama proses penelitian ini.
8. Seluruh pihak dalam komunitas buku yang telah memberikan kepercayaan dan bantuan dalam proses penelitian ini.

Penulis menyadari bahwa skripsi ini masih memiliki berbagai kekurangan, baik dalam penulisan maupun isi. Oleh karena itu, penulis mengharapkan kritik dan saran yang sifatnya membangun dari pembaca untuk perbaikan di masa mendatang. Akhir kata, semoga penelitian ini dapat memberikan manfaat bagi kemajuan ilmu pengetahuan dan dapat dijadikan sebagai bahan referensi bagi penelitian-penelitian selanjutnya.

Jember, 01 Juni 2026

Moh. Yusril Maqoshidana

222410102064

DAFTAR ISI

PERSEMBAHAN	i
MOTTO	ii
PERNYATAAN ORISINALITAS	iii
HALAMAN PERSETUJUAN	iv
ABSTRAK	v
ABSTRACT	vi
RINGKASAN	vii
PRAKATA	ix
DAFTAR TABEL	xiv
DAFTAR GAMBAR	xv
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan Penelitian	3
1.4 Manfaat Penelitian	3
1.5 Batasan Penelitian	4
2 TINJAUAN PUSTAKA	5
2.1 Penelitian Terdahulu	5
2.2 Landasan Teori	6
2.2.1 Aplikasi WhatsApp	6
2.2.2 BERTopic	7
2.2.3 IndoBERTweet	8
2.2.4 BIRCH Clustering	9
2.2.5 Topic Representation Dengan BM25	11
2.2.6 Topic Coherence	12
2.2.7 Topic Diversity	12
2.2.8 Embedding Density	13
2.2.9 Intra-topic Similarity	14
3 METODOLOGI PENELITIAN	15
3.1 Jenis Penelitian	15

3.2	Objek Penelitian	15
3.3	Waktu Penelitian	15
3.4	Tahapan Penelitian	16
3.4.1	Identifikasi Masalah dan Studi Literatur	16
3.4.2	Pengumpulan Data	16
3.4.3	Praproses Data	17
3.4.4	Pembuatan Model	19
3.4.5	Evaluasi Model	21
3.4.6	Implementasi Sistem	21
3.4.7	Evaluasi Sistem	22
3.4.8	Analisis Hasil	23
3.4.9	Penarikan Kesimpulan	23
3.5	Etika Penelitian	23
4	HASIL DAN PEMBAHASAN	24
4.1	Pengumpulan Data	24
4.2	Praproses Data	25
4.3	Pembuatan Model (Modified BERTopic)	28
4.3.1	Pembangkitan Vektor Embedding dengan IndoBERTweet	28
4.3.2	Reduksi Dimensi dengan UMAP	28
4.3.3	Pengklasteran dengan Custom BIRCH Clustering (Birch- WithOutliers)	29
4.3.4	Penyaringan Stopwords WhatsApp dan Representasi BM25	30
4.3.5	Reduksi Topik Otomatis dan Kondisi Pengaman (Safety Guard)	31
4.4	Pengujian dan Evaluasi Kuantitatif Model	32
4.5	Implementasi Sistem	34
4.5.1	Arsitektur Client-Server dan Komponen Teknologi	34
4.5.2	Keamanan dan Privasi Data (Client-Side Anonymization)	35
4.5.3	Pemrosesan Latar Belakang (Asynchronous Background Task)	36
4.5.4	Real-time Progress Streaming via Server-Sent Events (SSE)	37
4.5.5	Antarmuka Hasil Pemodelan Topik dan Visualisasi Data	37
4.5.6	Penelusuran Konteks Pesan (Traceability)	38
4.5.7	Pencegahan Path Traversal dan Validasi Input	39
4.5.8	Mekanisme Pembersihan Berkas Otomatis	40
4.6	Analisis dan Pembahasan Hasil	41
4.6.1	Pengaruh BIRCH dalam Mengeliminasi Outliers	41
4.6.2	Peran IndoBERTweet dalam Meningkatkan Koherensi Topik	42
4.6.3	Efektivitas Representasi Kata Kunci dengan BM25	42
4.6.4	Analisis Penyaringan Stopwords Korpus WhatsApp	43
4.6.5	Analisis Kepadatan Vektor dan Kemiripan Internal Kluster	43
4.7	Pengujian Fungsional Sistem (Black Box Testing)	44
5	KESIMPULAN DAN SARAN	45
5.1	Kesimpulan	45
5.2	Saran	47

5.2.1	Saran untuk Penelitian Selanjutnya	47
5.2.2	Saran untuk Praktisi dan Pengembangan Terapan	48
DAFTAR PUSTAKA		48
LAMPIRAN		53
1	Lampiran - Alur Implementasi Sistem	53
2	Lampiran - Alur Teknis Pemrosesan Sistem Web	54
3	Lampiran - Surat Izin Penelitian dari Kampus	54
4	Lampiran - Bukti Persetujuan Admin Grup WhatsApp	55
5	Lampiran - Hasil Pengujian Fungsional Sistem (Black-Box Testing)	57

DAFTAR TABEL

2.1	Tinjauan Penelitian Terdahulu	5
2.2	Perbandingan Kinerja Model pada Tujuh Tugas	9
4.1	Contoh Potongan Data Mentah Hasil Ekspor WhatsApp	24
4.2	Contoh Hasil Transformasi Teks Sebelum dan Sesudah Praproses Data	26
4.3	Statistik Hasil Pengolahan Praproses Data Pada Dataset Percakapan WhatsApp	26
4.4	Hasil Evaluasi Kurva Pembelajaran (Learning Curve) Model Baseline	32
4.5	Hasil Evaluasi Kurva Pembelajaran (Learning Curve) Model Usulan (Proposed)	32
1	Hasil Pengujian Fungsional Sistem (<i>Black-Box Testing</i>)	57

DAFTAR GAMBAR

2.1	Framework BERTopic dengan modifikasi IndoBERT, BIRCH, dan BM25 (Muhajir et al., 2025)	8
3.1	Tahapan Penelitian	16
3.2	Rancangan framework BERTopic yang dimodifikasi pada tahap pembuatan model	19
4.1	Kurva Pembelajaran (Learning Curve) Model Baseline	33
4.2	Kurva Pembelajaran (Learning Curve) Model Usulan (Proposed) . .	33
4.3	Antarmuka Utama dan Panduan Cara Kerja Aplikasi Web ChatAnalisis	35
4.4	Antarmuka Unggah Berkas dan Pengaturan Filter Rentang Tanggal Data	36
4.5	Tampilan Pemantauan Progres Analisis secara Real-Time via Server-Sent Events (SSE)	37
4.6	Tampilan Dashboard Hasil Pemodelan Topik dan Grafik Tren Waktu Obrolan	38
4.7	Visualisasi Panel Metrik Evaluasi Kuantitatif dan Distribusi Aktivitas Pengguna	38
4.8	Antarmuka Detail Klaster Topik dan Dialog Modal Penelusuran Konteks Pesan	39
1	Alur Implementasi Sistem	53
2	Alur Teknis Pemrosesan Sistem Web	54
3	Surat Izin Penelitian dari Kampus	55
4	Bukti Persetujuan Admin Grup WhatsApp	56

BAB 1. PENDAHULUAN

1.1 Latar Belakang

WhatsApp merupakan salah satu aplikasi pesan instan terpopuler di dunia yang banyak dimanfaatkan sebagai wadah diskusi komunitas, koordinasi tim, dan komunikasi organisasi (WhatsApp Inc., 2026). Pada grup WhatsApp yang sangat aktif dengan volume percakapan tinggi, arus pertukaran informasi berlangsung sangat cepat dan dinamis. Akumulasi pesan yang masif ini kerap menimbulkan fenomena *information overload*, di mana pengguna mengalami kesulitan dalam mengikuti alur diskusi, menyaring informasi penting, maupun mengetahui topik yang sedang dibahas tanpa membaca keseluruhan riwayat obrolan secara manual (Rani et al., 2022). Oleh karena itu, diperlukan sistem yang mampu memodelkan dan mengekstraksi topik percakapan grup WhatsApp secara otomatis.

Topic modeling merupakan teknik dalam *Natural Language Processing* (NLP) untuk menemukan struktur tematik laten dari sekumpulan dokumen teks (Abdelrazek et al., 2023). Namun, penerapan pemodelan topik pada percakapan grup WhatsApp menghadapi tantangan besar akibat karakteristik data yang berupa teks pendek, tidak terstruktur, mengandung *noise* tinggi (seperti singkatan dan ekspresi tawa), serta sarat fenomena *code-mixing* dan bahasa informal (Churchill and Singh, 2022; Mohta et al., 2020; Egger and Yu, 2022).

Meskipun BERTopic terbukti unggul pada teks pendek dibandingkan metode berbasis *bag-of-words* seperti LDA dan NMF (Egger and Yu, 2022), algoritma klusterisasi bawaannya, yaitu HDBSCAN, secara inheren mengeliminasi dokumen yang tidak memenuhi ambang stabilitas kepadatan sebagai *outlier* (Janssens et al., 2025). Akibatnya, hingga 23%–24% pesan obrolan dapat terbuang dan tidak terpetakan ke dalam topik manapun (Muhajir et al., 2025).

Untuk mengatasi keterbatasan tersebut, penelitian ini mengusulkan modifikasi pada *framework* BERTopic dengan mengganti HDBSCAN menggunakan algorit-

ma BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) dan mengganti c-TF-IDF dengan skema BM25. Algoritma BIRCH mampu mengelompokkan dokumen secara dinamis dan menugaskan hampir seluruh data ke klaster yang valid, sehingga menekan proporsi *outlier* hingga rentang 1%–5% pada teks pendek (Muhajir et al., 2025). Pada lapisan *embedding*, IndoBERTweet dimanfaatkan karena dilatih secara khusus pada korpus media sosial berbahasa Indonesia, sehingga mampu menangkap konteks semantik bahasa percakapan informal secara lebih optimal (Koto et al., 2021; Muhajir et al., 2025). Sementara itu, penerapan BM25 pada tahap representasi topik menyempurnakan c-TF-IDF dengan memperhitungkan saturasi frekuensi kata dan normalisasi panjang dokumen, sehingga kata-kata yang mendominasi frekuensi tidak mengaburkan kata kunci yang informatif (Muhajir et al., 2025).

Meskipun penelitian mengenai *topic modeling* WhatsApp telah dilakukan sebelumnya (Kharisudin and Masri'an, 2022; Kumar and Naik, 2023; Retna et al., 2021), integrasi IndoBERTweet, BIRCH, dan BM25 pada data percakapan WhatsApp berbahasa Indonesia yang interaktif dan bervolume tinggi belum banyak dieksplorasi. Selain itu, mayoritas penelitian sebelumnya masih terbatas pada kajian eksperimen teoritis tanpa menghadirkan sistem terapan yang siap digunakan langsung oleh pengguna.

Berdasarkan permasalahan tersebut, penelitian ini mengembangkan sistem analisis topik percakapan grup WhatsApp berbasis *web* dengan menerapkan arsitektur BERTopic yang memadukan IndoBERTweet, BIRCH, dan BM25. Sistem ini diharapkan membantu pengguna memahami topik pembicaraan pada grup aktif secara cepat dan akurat melalui antarmuka visual yang informatif.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana penerapan BERTopic dengan integrasi IndoBERTweet, BIRCH

clustering, dan representasi topik BM25 untuk mengidentifikasi topik pada percakapan grup WhatsApp berbahasa Indonesia?

2. Bagaimana kualitas topik yang dihasilkan oleh BERTopic yang diajukan dibandingkan dengan model baseline BERTopic berdasarkan evaluasi metrik *Topic Coherence*, *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity*?
3. Bagaimana merancang dan mengimplementasikan sistem berbasis *web* untuk analisis topik percakapan grup WhatsApp menggunakan BERTopic dengan IndoBERTweet, BIRCH *clustering*, dan BM25?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah tersebut, tujuan penelitian ini dirumuskan sebagai berikut:

1. Menerapkan BERTopic dengan model *embedding* IndoBERTweet, algoritma BIRCH sebagai metode *clustering*, dan skema BM25 sebagai representasi topik untuk mengidentifikasi topik pada percakapan grup WhatsApp berbahasa Indonesia.
2. Mengevaluasi dan membandingkan performa BERTopic yang diajukan dengan baseline BERTopic berdasarkan metrik *Topic Coherence*, *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity*.
3. Merancang dan mengimplementasikan sistem berbasis *web* untuk analisis topik percakapan grup WhatsApp yang memanfaatkan BERTopic dengan IndoBERTweet, BIRCH *clustering*, dan BM25 agar dapat digunakan secara praktis oleh pengguna akhir.

1.4 Manfaat Penelitian

Adapun manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan kontribusi dalam pengembangan ilmu di bidang *Natural Language Processing* (NLP), khususnya penerapan BERTopic dengan modifikasi IndoBERTweet, BIRCH *clustering*, dan BM25 untuk analisis teks percakapan

informal berbahasa Indonesia.

2. Menyediakan sistem berbasis *web* yang mampu menganalisis percakapan grup WhatsApp secara otomatis serta menyajikan ringkasan topik melalui visualisasi yang intuitif.
3. Menjadi referensi akademik bagi penelitian selanjutnya terkait ekstraksi dan pemodelan topik pada data teks pendek dan pesan instan.

1.5 Batasan Penelitian

Agar penelitian ini lebih terarah dan fokus, maka ditetapkan beberapa batasan penelitian sebagai berikut:

1. Sistem hanya menganalisis percakapan teks berbahasa Indonesia dari grup WhatsApp, tidak mencakup media gambar, video, audio, maupun dokumen.
2. Data masukan pada *website* berupa file ekspor chat WhatsApp format .txt atau .zip yang diperoleh dari perangkat Android.
3. Data yang digunakan merupakan riwayat percakapan grup Komunitas Buku pada periode 2023—2026 dengan jumlah pesan sebanyak 91,868.
4. Penelitian berfokus pada pemodelan topik dan tidak mencakup analisis sentimen, klasifikasi emosi, maupun prediksi perilaku pengguna.
5. Representasi topik menggunakan metode skema pembobotan BM25 sebagai pengganti skema representasi topik bawaan BERTopic, yaitu c-TF-IDF.
6. Evaluasi dilakukan menggunakan metrik Topic Coherence, Topic Diversity, Embedding Density, Intra-topic Similarity, serta pengujian fungsional black-box.

BAB 2. TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Tabel 2.1: Tinjauan Penelitian Terdahulu

No	Judul Penelitian	Hasil Penelitian	Celah (<i>Gap</i>)	Kontribusi
1	<i>A Topic Modeling Comparison Between LDA, NMF, Top2Vec, and BERTopic to Demystify Twitter Posts</i> (Egger and Yu, 2022) (Jurnal Q1)	Penelitian ini membandingkan BERTopic, NMF, LDA, dan Top2Vec pada data Twitter. BERTopic direkomendasikan untuk pendekatan berbasis <i>embedding</i> , sedangkan NMF menjadi alternatif tradisional yang lebih unggul untuk data media sosial.	Meskipun BERTopic menunjukkan performa yang baik, penggunaan <i>embedding</i> multilingual dan <i>clustering</i> default (HDBSCAN) masih memiliki keterbatasan dalam mengatasi <i>outlier</i> dan meningkatkan stabilitas topik. Belum ada sistem aplikatif yang dikembangkan.	Penelitian ini menggunakan IndoBERTweet sebagai model <i>embedding</i> khusus bahasa Indonesia serta BIRCH sebagai alternatif HDBSCAN untuk meningkatkan stabilitas <i>clustering</i> dan mengurangi <i>outlier</i> . Selain itu, dikembangkan sistem berbasis <i>web</i> untuk analisis percakapan WhatsApp.
2	<i>Integrating IndoBERT and BIRCH in BERTopic for Indonesian short text</i> (Muhajir et al., 2025) (Jurnal Q2)	Penelitian ini memodifikasi BERTopic dengan IndoBERT, BM25, dan BIRCH dengan dataset dari X, Google Reviews, dan YouTube yang bersifat teks monolog. Berhasil menurunkan <i>outlier</i> secara signifikan serta meningkatkan stabilitas topik pada teks pendek.	Pendekatan ini belum dieksplorasi pada data percakapan grup WhatsApp yang memiliki karakteristik lebih kompleks berupa <i>multi-turn dialogue</i> , evolusi percakapan yang cepat dan volume pesan yang tinggi. Selain itu, penelitian terdahulu belum menyediakan sistem aplikasi bagi pengguna akhir.	Penelitian ini mengimplementasikan BERTopic dengan IndoBERTweet dan BIRCH pada dataset WhatsApp yang diintegrasikan ke dalam sistem analisis interaktif untuk memvisualisasikan dinamika topik secara otomatis.
3	<i>BERTopic Enhanced Bibliometric Insight Into Global South Higher Education</i> (Banerjee and Pan, 2024) (Jurnal Q1)	Penelitian ini menyelidiki keragaman linguistik dan proses dekolonisasi dalam sistem pendidikan tinggi di wilayah Global South menggunakan kerangka kerja empiris tiga tingkat yang menggabungkan Analisis Ko-okurensi Bibliometrik (Bibliometric Co-occurrence Analysis), pemodelan topik LDA, dan pemodelan BERTopic. BERTopic menunjukkan performa lebih baik dibanding LDA dalam koherensi dan jumlah topik yang dihasilkan pada data akademik.	Penelitian tersebut belum mengeksplorasi alternatif algoritma klusterisasi yang dapat meminimalkan <i>outlier</i> sejak awal proses, serta belum menguji efektivitas BERTopic pada bahasa Indonesia dengan karakteristik teks percakapan informal yang memiliki noise tinggi dan fenomena <i>code-mixing</i> . Penelitian tersebut juga belum menyediakan sistem aplikasi bagi pengguna akhir.	Penelitian ini berkontribusi dengan mengganti HDBSCAN menggunakan BIRCH <i>clustering</i> yang mampu mengakomodasi dokumen <i>outlier</i> secara dinamis tanpa penghapusan, sekaligus menggunakan IndoBERTweet sebagai <i>embedding</i> untuk dataset percakapan berbahasa Indonesia yang banyak mengandung kata informal dan <i>code-mixing</i> . Penelitian ini juga menyediakan sistem aplikasi bagi pengguna akhir.

Berdasarkan penelitian terdahulu yang telah diulas pada tabel 2.1, dapat disimpulkan bahwa meskipun telah banyak penelitian yang membandingkan berba-

gai model *topic modeling* untuk analisis teks pendek, hasil penelitian terdahulu menunjukkan bahwa BERTopic cenderung lebih unggul dibandingkan pendekatan konvensional pada data media sosial dan data akademik, tetapi masih memiliki keterbatasan ketika menggunakan *embedding* multilingual dan algoritma *clustering* bawaan seperti HDBSCAN. Pada sejumlah penelitian tersebut, penggunaan model yang lebih spesifik terhadap bahasa dan domain, seperti IndoBERTweet, serta algoritma BIRCH sebagai alternatif klasterisasi, terbukti menjanjikan dalam mengurangi *outlier*. Selain itu, penelitian yang telah diulas belum banyak mengeksplorasi penerapan pipeline BERTopic pada percakapan grup WhatsApp berbahasa Indonesia yang bersifat *multi-turn*, tidak terstruktur, banyak emoji, dan kaya *code-mixing*. Di sisi lain, penelitian terdahulu masih berfokus pada evaluasi metodologi tanpa menyediakan sistem aplikasi yang dapat digunakan langsung oleh pengguna akhir untuk menganalisis percakapan mereka sendiri.

2.2 Landasan Teori

2.2.1 Aplikasi WhatsApp

WhatsApp merupakan aplikasi pesan instan yang memungkinkan pengguna berkomunikasi melalui pesan teks, suara, gambar, video, serta fitur grup yang mendukung komunikasi banyak pengguna dalam satu ruang diskusi (Prayogi et al., 2025). Fitur grup memungkinkan pengguna tergabung dalam banyak kelompok sekaligus untuk kepentingan personal, bisnis, maupun keamanan, sehingga volume pesan sering menjadi besar dan tumpang tindih. Kondisi ini membuat percakapan grup bersifat tidak terstruktur, melibatkan banyak partisipan, dan topik pembahasan dapat berubah dengan cepat (Rani et al., 2022). Akibatnya, pengguna sering kesulitan mengikuti arah percakapan secara menyeluruh. Permasalahan inilah yang menjadi latar belakang penelitian ini, yaitu mengembangkan sistem analisis percakapan grup WhatsApp yang dapat mengidentifikasi dan memetakan topik pembahasan secara otomatis.


Secara linguistik, pesan WhatsApp memiliki karakteristik yang berbeda sig-

nifikasi dari teks formal. Struktur kalimatnya cenderung sederhana, pendek, dan bersifat eliptis, yaitu menghilangkan unsur wajib seperti subjek atau predikat demi efisiensi (misalnya "*Mau makan?*" alih-alih "*Apakah kamu mau makan?*"), serta sering ditulis tanpa tanda baca dan secara fragmentaris ke dalam beberapa baris terpisah (Siregar et al., 2025). Dari sisi morfologi dan diksi, penggunaan singkatan tidak baku, bahasa gaul, serta campur kode (*code-mixing*) antara bahasa Indonesia, bahasa daerah, dan bahasa asing juga lazim ditemukan dalam satu kalimat yang sama (Sutarma, 2017). Karakteristik-karakteristik inilah yang menjadi dasar pertimbangan dalam merancang tahapan *preprocessing* pada penelitian ini, khususnya dalam menangani normalisasi teks tidak baku, penggabungan pesan multi-baris, serta penanganan simbol dan tanda baca sebelum data diproses oleh model *embedding*.

2.2.2 BERTopic

BERTopic adalah *framework topic modeling* berbasis *transformer* yang membentuk *embedding* dokumen dan merepresentasikan topik melalui prosedur TF-IDF berbasis kelas, sehingga dokumen dengan makna semantik serupa dapat dipetakan saling berdekatan dalam ruang vektor (Grootendorst, 2022). Pendekatan ini relevan untuk percakapan grup WhatsApp yang umumnya berupa teks pendek, berisik (*noisy*), dan tidak terstruktur, yang cenderung menimbulkan masalah kelangkaan data (*data sparsity*) pada metode pemodelan topik konvensional.

Berdasarkan Gambar 2.1, *framework* BERTopic terdiri dari empat tahap utama. Tahap pertama adalah *document embedding* yang mengubah dokumen menjadi representasi vektor numerik menggunakan model bahasa seperti IndoBERT-Tweet yang dikembangkan untuk variasi bahasa Indonesia pada ranah media sosial (Koto et al., 2021). Tahap kedua adalah *dimensionality reduction* menggunakan UMAP untuk mereduksi dimensi vektor hasil *embedding* agar proses klusterisasi lebih efisien (McInnes et al., 2018). Tahap ketiga adalah *clustering* yang mengelompokkan dokumen berdasarkan kemiripan semantik, di mana setiap kluster merepresentasikan satu topik dengan dukungan model yang bersifat modular seperti HDBSCAN, BIRCH, dan K-Means. Tahap keempat adalah *topic representa-*



Gambar 2.1: Framework BERTopic dengan modifikasi IndoBERT, BIRCH, dan BM25 (Muhajir et al., 2025)

tion yang mengekstrak kata kunci paling representatif dari setiap klaster. Secara bawaan BERTopic menggunakan c-TF-IDF, namun tahap ini dapat dimodifikasi karena bersifat modular (Grootendorst, 2022). Dalam penelitian ini, komponen yang digunakan pada tiap tahap meliputi IndoBERTweet untuk *embedding*, BIRCH untuk klasterisasi, dan BM25 untuk representasi topik.

2.2.3 IndoBERTweet

Model IndoBERTweet merupakan model bahasa pra-latih berskala besar pertama yang dirancang khusus untuk memproses data Twitter (X) berbahasa Indonesia. Model ini dikembangkan melalui pendekatan *domain-adaptive pretraining* dengan fondasi IndoBERT yang semula dilatih pada korpus formal, kemudian diadaptasi ke domain Twitter yang lebih informal. Dalam proses adaptasi tersebut, peneliti melakukan penyesuaian kosakata domain-spesifik dan melaporkan 14.584 kosakata baru (46% dari total kosakata) yang tidak tercakup pada IndoBERT umum (Koto

et al., 2021).

Tabel 2.2: Perbandingan Kinerja Model pada Tujuh Tugas

Model	Sentiment		Emotion	Hate Speech		NER		Average
	IndoLEM	SmSA	EmoT	HS1	HS2	Formal	Informal	
mBERT	76.6	84.7	67.5	85.1	75.1	85.2	83.2	79.6
malayBERT	82.0	84.1	74.2	85.0	81.9	81.9	81.3	81.5
IndoBERT (Wilie et al., 2020)	84.1	88.7	73.3	86.8	80.4	86.3	84.3	83.4
IndoBERT (Koto et al., 2020)	84.1	87.9	71.0	86.4	79.3	88.0	86.9	83.4
IndoBERTweet (1M steps from scratch) (Koto et al., 2021)	86.2	90.4	76.0	88.8	87.5	88.1	85.4	86.1
IndoBERT + Vocabulary adaptation + 200K steps (Koto et al., 2021)	86.6	92.7	79.0	88.4	84.0	87.7	86.9	86.5

Berdasarkan Tabel 2.2 yang diadaptasi dari Koto et al. (2021), model IndoBERTweet dan variannya subsecara konsisten mencapai performa tinggi pada tujuh tugas NLP berbahasa Indonesia, meliputi *sentiment analysis*, *emotion classification*, *hate speech detection*, dan *named entity recognition*. Hasil terbaik secara rata-rata ditunjukkan oleh varian IndoBERT dengan adaptasi kosakata dan pelatihan lanjutan 200K langkah (86,5), sedangkan IndoBERTweet yang dilatih dari awal juga menunjukkan kinerja kompetitif (86,1). Temuan ini memperkuat asumsi bahwa model berbasis domain media sosial berpotensi lebih sesuai untuk teks pendek, informal, dan bising seperti percakapan grup WhatsApp berbahasa Indonesia, meskipun efektivitas akhirnya tetap perlu divalidasi pada penelitian ini.

2.2.4 BIRCH Clustering

BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) merupakan algoritma *clustering* hierarkis yang dirancang untuk menangani dataset berskala besar secara efisien dengan cara meringkas data ke dalam struktur *Clustering Feature* (CF) yang disusun dalam CF-Tree di memori, sehingga mengurangi kebutuhan komputasi dibandingkan pendekatan yang memproses setiap titik data secara individual (Zhang et al., 1996). Algoritma ini memiliki keunggulan dalam efisiensi

komputasi, penggunaan memori yang rendah, serta ketahanan terhadap *noise*, namun tetap memiliki keterbatasan, seperti sensitivitas terhadap parameter *threshold*, kesulitan dalam menangani kluster dengan bentuk kompleks, serta kurang optimal pada dataset berdimensi tinggi (Zhang et al., 1997). Dalam konteks framework BERTopic, keterbatasan terkait dimensi tinggi tersebut dapat diminimalkan melalui penerapan UMAP sebagai teknik reduksi dimensi sebelum proses klusterisasi dilakukan.

Pada implementasi BIRCH di *scikit-learn*, ringkasan tiap subkluster disimpan dalam bentuk *Clustering Feature* (CF) sebagaimana didefinisikan pada BIRCH orisinal dan dipaparkan kembali pada kajian implementasi matematis modern (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$CF = (N, LS, SS) \quad (2.1)$$

dengan N jumlah titik data, $LS = \sum_{i=1}^N x_i$, dan $SS = \sum_{i=1}^N \|x_i\|^2$.

Centroid subkluster dihitung sebagai:

$$\mu = \frac{LS}{N} \quad (2.2)$$

Radius subkluster digunakan sebagai dasar keputusan pemisahan/penggabungan node. Bentuk komputasional berikut ekuivalen dengan definisi radius BIRCH (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$R = \sqrt{\frac{SS}{N} - \left\| \frac{LS}{N} \right\|^2} \quad (2.3)$$

Ketika titik baru x ditambahkan ke subkluster, radius baru dihitung menggunakan prinsip aditivitas CF, lalu dibandingkan dengan *threshold* (T) (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$R' = \sqrt{\frac{SS + \|x\|^2}{N + 1} - \left\| \frac{LS + x}{N + 1} \right\|^2}, \quad R' \leq T \quad (2.4)$$

Parameter *branching factor* (B) mengontrol jumlah maksimum anak pada tiap

node CF-Tree, sedangkan T mengontrol kekompakan subklaster.

2.2.5 Topic Representation Dengan BM25

Skema pembobotan BM25 adalah algoritma fungsi peringkat (*ranking function*) yang banyak digunakan dalam pencarian informasi (*information retrieval*) dan dapat diadaptasi untuk tahap representasi topik (Jian et al., 2020; Shan et al., 2020). c-TF-IDF kesulitan menangkap hubungan semantik secara utuh dan cenderung menghasilkan topik yang kurang koheren ketika distribusi frekuensi kata sangat timpang atau tidak merata (Muhajir et al., 2025). Oleh karena itu, sejumlah penelitian menerapkan BM25 pada tahap *topic representation*, baik sebagai pengganti penuh maupun sebagai modifikasi dari skema c-TF-IDF.

Pada penelitian Muhajir et al. (2025), c-TF-IDF bawaan BERTopic digantikan sepenuhnya dengan BM25 pada tingkat klaster. Skor representasi kata t untuk klaster C_k dirumuskan sebagai:

$$w_{t,C_k} = \text{BM25}(t, C_k) = \sum_{d \in C_k} \text{IDF}(t) \cdot \frac{f(t, d) \cdot (k_1 + 1)}{f(t, d) + k_1 \left(1 - b + b \cdot \frac{|d|}{\text{avgdl}} \right)}, \quad (2.5)$$

dengan fungsi *inverse document frequency* didefinisikan sebagai:

$$\text{IDF}(t) = \log \left(\frac{N - n(t) + 0.5}{n(t) + 0.5} \right). \quad (2.6)$$

Skor w_{t,C_k} pada Persamaan 2.5 dihitung dengan menjumlahkan kontribusi seluruh dokumen $d \in C_k$, yaitu himpunan dokumen anggota klaster ke- k . Untuk setiap dokumen tersebut, $f(t, d)$ menyatakan frekuensi kemunculan kata t di dalam dokumen d , sedangkan $|d|$ menyatakan panjang dokumen d yang dinormalisasi terhadap avgdl , yakni rata-rata panjang dokumen dalam korpus. Nilai $\text{IDF}(t)$ pada Persamaan 2.6 diperoleh dari $n(t)$, yaitu jumlah dokumen dalam korpus yang memuat kata t , dan N , yaitu jumlah total dokumen dalam korpus. Dua parameter tambahan, k_1 dan b , masing-masing berfungsi mengatur saturasi frekuensi istilah

agar pengaruh kata yang berulang tidak meningkat secara linear, serta mengatur normalisasi panjang dokumen agar dokumen yang lebih panjang tidak secara otomatis memperoleh skor lebih tinggi. Perlu dicatat bahwa rumus IDF pada Persamaan 2.6 dapat menghasilkan nilai negatif apabila suatu kata muncul pada lebih dari separuh dokumen dalam korpus ($n(t) > N/2$), sehingga secara otomatis menekan peran kata-kata umum dalam representasi topik.

Dalam konteks studi tersebut, pendekatan ini dilaporkan memberikan representasi topik yang lebih stabil dibandingkan c-TF-IDF pada korpus teks pendek berbahasa Indonesia (Muhajir et al., 2025).

2.2.6 Topic Coherence

Topic coherence digunakan untuk mengukur keterkaitan semantik antar kata teratas dalam topik. Dari banyaknya *topic coherence*, penelitian ini menggunakan *Normalized Pointwise Mutual Information* (NPMI) karena memberikan korelasi tertinggi dengan penilaian manusia dalam konteks context vectors (Röder et al., 2015):

$$\text{NPMI}(w_i, w_j) = \frac{\log \frac{P(w_i, w_j)}{P(w_i) \cdot P(w_j)}}{-\log P(w_i, w_j)} \quad (2.7)$$

dengan $P(w_i, w_j)$ sebagai probabilitas ko-okurensi, serta $P(w_i)$ dan $P(w_j)$ sebagai probabilitas marjinal kemunculan kata. Nilai dari NPMI berkisar antara $[-1, 1]$, dengan nilai 1 menunjukkan keterkaitan semantik yang sempurna, 0 menunjukkan tidak ada keterkaitan, dan nilai negatif menunjukkan keterkaitan yang berlawanan (Janssens et al., 2025).

2.2.7 Topic Diversity

Topic diversity didefinisikan dengan keberagaman topik sebagai persentase kata unik dalam 25 kata teratas dari semua topik. Keberagaman mendekati 0 menunjukkan bahwa topik yang berlebihan dan keberagaman mendekati 1 menunjukkan

topik yang beragam (Dieng et al., 2020). Nilainya dihitung melalui rumus berikut:

$$TD = \frac{|\text{unique words in top } N \text{ words of all topics}|}{N \times K} \quad (2.8)$$

2.2.8 Embedding Density

Embedding Density adalah metrik evaluasi yang mengukur kepadatan representasi *embedding* fitur/dokumen dalam suatu klaster dengan menggabungkan jarak spasial (fungsi kernel) dan bobot semantik (Rushkin, 2020). Kepadatan pada titik sampel z (misalnya *centroid* topik) dihitung dengan rumus:

$$\rho_k = \frac{\sum_{i=1}^{N_k} k\left(\frac{\bar{\mathbf{e}}_k - \mathbf{e}_i}{h}\right) w_{k,i}}{\sum_{i=1}^{N_k} k\left(\frac{\mathbf{e}_k - \mathbf{e}_i}{h}\right)} \quad (2.9)$$

Keterangan variabel spasial:

- $\bar{\mathbf{e}}_k$: Vektor *centroid* topik ke- k (pengganti titik sampel z), dihitung sebagai rata-rata *embedding* dokumen dalam klaster tersebut.
- $\mathbf{e}_i$: Vektor *embedding* dokumen ke- i (pengganti x_i) dalam klaster k .
- $k(y)$: Fungsi kernel Gaussian, yaitu $k(y) = (2\pi)^{-d/2} \exp(-|y|^2/2)$, untuk mengukur kedekatan spasial.
- h : Parameter *bandwidth*. Dalam implementasi, digunakan estimasi berbasis volume (h_V) dengan kuantil radius 0.1 dan 0.9 untuk mengurangi sensitivitas terhadap *outlier*, serta mekanisme *fallback* Silverman jika terjadi degenerasi klaster.
- $w_{k,i}$: Bobot semantik dokumen ke- i terhadap topik ke- k . Nilai ini dihitung dari total skor representasi kata-kata topik (c-TF-IDF untuk BERTopic *default*, atau BM25 untuk BERTopic termodifikasi) yang muncul pada dokumen tersebut, kemudian dinormalisasi per topik ke rentang $[0, 1]$.

Penyebut pada persamaan berfungsi sebagai konstanta normalisasi sehingga nilai ρ_k tidak bergantung pada jumlah dokumen dalam klaster (Rushkin, 2020).

2.2.9 Intra-topic Similarity

Intra-topic similarity merupakan metrik evaluasi yang mengukur kemiripan semantik antar dokumen di dalam satu topik, diadaptasi dari konsep *intra-list similarity* (ILS) sebagai rata-rata kemiripan berpasangan seluruh item dalam sebuah daftar (Jesse et al., 2022). Zhao et al. (2018) menekankan bahwa struktur intra-topik berbasis *word embeddings* mampu menangkap aspek tematik yang lebih halus dan bermakna. Dalam konteks evaluasi model topik, intra-topic similarity untuk topik k dengan N_k dokumen dirumuskan sebagai berikut:

$$\text{ITS}(k) = \frac{1}{N_k(N_k - 1)} \sum_{\substack{i,j=1 \\ i \neq j}}^{N_k} \cos(\mathbf{e}_i^{(k)}, \mathbf{e}_j^{(k)}) \quad (2.10)$$

di mana $\mathbf{e}_i^{(k)}$ dan $\mathbf{e}_j^{(k)}$ adalah embedding dokumen ke- i dan ke- j dalam topik k . Nilai akhir diperoleh dengan merata-ratakan $\text{ITS}(k)$ di seluruh K topik; semakin tinggi nilainya, semakin kohesif topik yang dihasilkan.

BAB 3. METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini termasuk kategori kuantitatif eksperimental dengan pendekatan Research and Development (R&D). Aspek R&D terletak pada pengembangan sistem analisis topik percakapan WhatsApp berbasis web, sedangkan aspek eksperimental kuantitatif digunakan untuk memvalidasi performa pipeline BERTopic dengan modifikasi IndoBERTweet sebagai model embedding dan BIRCH sebagai model clustering.

3.2 Objek Penelitian


Objek penelitian ini adalah data percakapan grup WhatsApp Komunitas Buku, yang berisi interaksi antarpengguna dalam Bahasa Indonesia dan telah memperoleh izin penggunaan untuk keperluan penelitian dari pihak terkait. Data diambil dari rentang 4 Juni 2023 hingga 20 Juni 2026 (1.113 hari), dengan 954 hari di antaranya tercatat aktif, menghasilkan total 91.868 pesan teks dari 1.307 partisipan. Grup ini dipilih karena anggota grup yang aktif dan merepresentasikan karakteristik percakapan informal yang umum dijumpai pada komunitas WhatsApp, yaitu teks pendek, struktur kalimat tidak baku, mengandung *noise* (seperti singkatan, elongasi huruf, dan emoji), serta fenomena *code-mixing*.

3.3 Waktu Penelitian

Waktu penelitian dilakukan pada bulan April 2026 hingga Agustus 2026, dengan tahapan-tahapan yang telah direncanakan secara sistematis untuk memastikan kelancaran proses penelitian.

3.4 Tahapan Penelitian

Tahapan penelitian yang dilakukan dalam penelitian ini secara keseluruhan digambarkan pada **Gambar 3.1**:



Gambar 3.1: Tahapan Penelitian

3.4.1 Identifikasi Masalah dan Studi Literatur

Tahap pertama dalam penelitian ini adalah identifikasi masalah dan studi literatur. Pada tahap identifikasi masalah, peneliti melakukan eksplorasi terhadap percakapan grup WhatsApp untuk memahami tantangan dalam menangkap topik pembicaraan secara menyeluruh, termasuk dinamika percakapan, karakteristik teks pendek, serta kebutuhan pengguna dalam mengelola informasi yang besar dan tidak terstruktur. Selanjutnya, studi literatur dilakukan untuk memperoleh landasan teoritis dan memahami perkembangan terkini terkait metode *topic modeling*, khususnya BERTopic, IndoBERTweet, BIRCH *clustering*, BM25, serta metrik evaluasi yang relevan. Hasil dari tahap ini digunakan sebagai dasar dalam mengidentifikasi *research gap*, merumuskan masalah penelitian, serta menentukan metode dan arsitektur sistem yang dikembangkan.

3.4.2 Pengumpulan Data

Tahap pengumpulan data dilakukan dengan mengekspor riwayat percakapan dari grup WhatsApp menggunakan fitur *export chat* yang tersedia secara bawaan pa-

da aplikasi WhatsApp. Data yang diekspor berupa file berformat *.txt* atau *.zip* yang memuat informasi tanggal, waktu, nama pengirim, dan isi pesan. Proses pengumpulan data memperhatikan aspek etika penelitian, termasuk permintaan izin kepada admin grup terkait, mengingat data percakapan bersifat personal dan sensitif.

3.4.3 Praproses Data

Tahap praproses data bertujuan untuk membersihkan dan mempersiapkan data pesan dari obrolan mentah WhatsApp agar siap diolah oleh model pemodelan topik BERTopic. Percakapan grup WhatsApp memiliki karakteristik teks informal yang sangat khas, seperti teks pendek, banyaknya notifikasi sistem otomatis, penyebutan (*mention*) pengguna, alamat email dan nomor telepon sensitif, penggunaan emoji, kata tidak baku (*slang*), pemanjangan karakter berulang (*elongation*), serta derau (*noise*) berupa pranala luar (URL) dan artefak ekspor. Secara runtut, alur praproses data yang diimplementasikan terdiri dari sembilan tahapan sub-proses berikut:

a. Parsing Chat Mentah WhatsApp dan Deteksi Format

Mengurai berkas riwayat percakapan mentah berformat *.txt* atau *.zip* dengan mendeteksi format file dan mengkonversi timestamp mentah ke standar baku ISO 8601 (*YYYY-MM-DDTHH:MM:SS*), serta menyusun data ke dalam struktur tabel (*dataframe*) dengan kolom *Timestamp*, *pengirim*, dan *pesan*.

b. Anonimisasi Identitas Pengirim dan Mention pada Teks Pesan

Mengkripsi nama pengirim asli dan penyebutan (*mention*) pengguna (*@nama* atau *@nomor*) di dalam teks pesan menjadi kode samaran terenkripsi (seperti *@User-[hash]*) menggunakan algoritma *hashing* SHA-256. Proses ini dilakukan di sisi klien demi menjamin etika privasi dan kerahasiaan identitas pengguna tanpa menghilangkan struktur interaksi penyebutan pada percakapan.

c. Penyaringan Pesan Notifikasi, Berkas Kontak, dan Duplikat

Memfilter dan mengeliminasi notifikasi otomatis bawaan sistem WhatsApp (seperti “*pesan ini telah dihapus*”, “*panggilan suara tak terjawab*”, “*media tidak*”).

disertakan”, dan sejenisnya), membuang lampiran berkas kartu kontak (.vcf), serta menghapus baris pesan mentah duplikat persis.

d. Penghapusan Metadata Sistem, Tag Format, dan URL

Menhapus teks penanda metadata sistem dalam kurung sudut <...> (seperti <Media tidak disertakan>), kurung siku [...], tag HTML, simbol tagar (#...), serta membuang URL seperti *https://...* atau *www...* dari isi pesan agar tidak menjadi *noise*.

e. Case Folding dan Normalisasi Unicode

Mengubah seluruh huruf kapital pada pesan menjadi huruf kecil (*lowercase*) untuk menyeragamkan bentuk kata serta melakukan standardisasi Unicode guna mengeliminasi karakter tersembunyi, karakter kontrol keyboard seluler, dan merapikan spasi ganda.

f. Anonimisasi Data Sensitif Teks

Menghapus dan mengeliminasi alamat email serta nomor telepon independen yang berada di dalam isi pesan untuk mencegah kebocoran kontak pribadi di dalam representasi topik tanpa menyisipkan token buatan yang tidak informatif.

g. Transliterasi Emoji dan Emotikon (Demojize)

Menerjemahkan karakter emoji visual dan emotikon menjadi teks deskriptif yang setara (misalnya emoji *smiling face* menjadi *smiling_face*) agar nilai emosi tetap terekstraksi tanpa merusak representasi kata oleh model bahasa.

h. Normalisasi Pemanjangan Karakter dan Kata Tidak Baku


Menyederhanakan penulisan 3 atau lebih karakter berulang secara berturut-turut menjadi 2 karakter serta memetakan kata-kata informal, singkatan, dan variasi ekspresi tawa tidak baku ke bentuk kata baku bahasa Indonesia menggunakan kamus rujukan normalisasi.

i. Penyaringan Panjang Dokumen Minimal (*Min Word Count Filter*)

Mengeliminasi baris dokumen yang setelah melalui tahap praproses memiliki jumlah kata kurang dari 3 kata pada kolom pesan yang telah di proses agar setiap dokumen yang akan dikelompokkan oleh BERTopic memiliki substansi informasi semantik yang memadai.

Melalui rangkaian tahapan praproses tunggal tersebut, data percakapan WhatsApp mentah yang tidak terstruktur diubah menjadi masukan teks terproses (*Pesan_Preprocessed*) yang siap digunakan pada tahap pemodelan topik BERTopic.

3.4.4 Pembuatan Model



Gambar 3.2: Rancangan framework BERTopic yang dimodifikasi pada tahap pembuatan model

Tahap pemodelan topik merupakan tahap inti dari penelitian ini, dengan data yang telah melalui pra-pemrosesan dianalisis menggunakan *framework* BERTopic yang telah dimodifikasi seperti pada Gambar 3.2. Penentuan parameter pada tiap komponen dilakukan dengan dua skenario, yaitu mengacu pada *baseline* dari penelitian terdahulu dan eksperimen penalaan parameter untuk memperoleh kinerja terbaik berdasarkan metrik evaluasi. Sebagaimana ditunjukkan pada Gambar 3.2, alur pembuatan model ini terdiri dari lima komponen utama:

1. *Document Embedding* menggunakan IndoBERTweet

Setiap dokumen (pesan) diubah menjadi representasi vektor numerik berdimensi tinggi menggunakan model IndoBERTweet yang telah diadaptasi untuk teks media sosial berbahasa Indonesia. Representasi *embedding* ini mampu menangkap makna semantik dan konteks kata secara lebih akurat dibandingkan model *multilingual* (Koto et al., 2021).

2. *Dimensionality Reduction* menggunakan UMAP

Vektor *embedding* berdimensi tinggi direduksi menggunakan *Uniform Manifold Approximation and Projection* (UMAP) untuk mengurangi kompleksitas komputasi sambil mempertahankan struktur lokal dan global data dalam ruang berdimensi rendah (McInnes et al., 2018). Parameter UMAP yang digunakan meliputi *n_neighbors*, *n_components*, *min_dist*, dan *metric*.

3. *Clustering* menggunakan BIRCH Algorithm

Dokumen yang telah direduksi dimensinya dikelompokkan menggunakan algoritma BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) sebagai pengganti HDBSCAN standar. BIRCH dipilih karena kemampuannya dalam mengalokasikan seluruh dokumen ke dalam kluster tanpa menghasilkan *outlier* dalam jumlah besar, serta efisiensi komputasi dan penggunaan memori yang lebih baik (Zhang et al., 1996; Muhajir et al., 2025). Parameter BIRCH yang digunakan meliputi *threshold*, *branching_factor*, dan *n_clusters*.

4. *Topic Representation* menggunakan BM25

Setiap kluster yang terbentuk direpresentasikan menggunakan skema pem-

bobotan BM25 sebagai pengganti c-TF-IDF bawaan BERTopic. BM25 menerapkan saturasi frekuensi istilah dan normalisasi panjang dokumen, sehingga menghasilkan kata kunci representatif yang lebih relevan dan stabil secara semantik untuk setiap topik (Muhajir et al., 2025). Parameter BM25 yang digunakan meliputi $k1$ dan b .

5. *Topic Reduction* (Reduksi Topik Otomatis)

Jumlah topik yang terbentuk disederhanakan secara otomatis ($nr_topics = "auto"$) dengan menggabungkan klaster-klaster topik yang memiliki kemiripan semantik tinggi pada ruang *embedding*, serta menerapkan kondisi pengaman (*safety guard*) untuk menjaga kestabilan pemrosesan apabila jumlah topik unik ≤ 1 .

3.4.5 Evaluasi Model

Tahap evaluasi model bertujuan untuk mengukur kualitas topik yang dihasilkan oleh model BERTopic secara kuantitatif. Evaluasi dilakukan menggunakan empat metrik yang telah dijabarkan pada bagian 2.2 (Topic Coherence (NPMI), Topic Diversity, Embedding Density, dan Intra-topic Similarity). dua metrik pertama menilai kualitas topik dari sisi representasi kata (*lexical*), sementara dua metrik berikutnya menilai kualitas topik dari sisi representasi semantik pada ruang *embedding*.

Pada penelitian ini, keempat metrik dihitung pada lima proporsi data uji (20%, 40%, 60%, 80%, dan 100%) untuk mengamati kestabilan performa model seiring penambahan volume data (*learning curve*). Model dinyatakan memenuhi kriteria apabila kombinasi parameter yang diujikan menghasilkan skor terbaik, kemudian hasil terbaik dari BERTopic yang diajukan dibandingkan dengan model *baseline* BERTopic.

3.4.6 Implementasi Sistem

Tahap pengembangan sistem bertujuan untuk mengimplementasikan alur pe-modelan topik ke dalam sebuah aplikasi berbasis web yang dapat digunakan secara

praktis oleh pengguna, sekaligus menjadi validasi terhadap penerapan *pipeline* yang telah dirancang.

Sistem dibangun dengan arsitektur *client-server*, menggunakan Vue.js sebagai *client* dan FastAPI sebagai *server* layanan API. Pemrosesan pemodelan topik yang bersifat komputasional berat dijalankan sebagai *background job* menggunakan *background task*, sehingga proses analisis tidak memblokir permintaan pengguna dan status pemrosesan dapat dipantau secara asinkron dengan SSE (Server-Sent Event) di sisi *server*. Penyimpanan berkas data, baik sebelum maupun sesudah pra-pemrosesan, menggunakan local storage untuk menjaga efisiensi penyimpanan dan privasi data.

Desain sistem berpegang pada beberapa prinsip utama. Pertama, privasi pengguna dijaga dengan melakukan anonimisasi identitas pengirim pesan pada sisi *client* sebelum data dikirim ke *server*, sehingga identitas asli pengguna tidak pernah tersimpan di *server*. Kedua, *traceability* dijaga dengan mempertahankan kolom *Index* di sepanjang *pipeline*, sehingga setiap hasil topik dapat ditelusuri kembali ke pesan asli.

3.4.7 Evaluasi Sistem

Tahap evaluasi sistem dilakukan untuk mengukur kinerja dan efektivitas aplikasi yang telah dikembangkan. Evaluasi dilakukan dengan menggunakan metode black-box testing, di mana fokusnya adalah pada input dan output sistem tanpa memperhatikan proses internalnya. Pengujian dilakukan dengan menggunakan dataset percakapan grup WhatsApp yang berbeda dari dataset yang digunakan untuk pelatihan model, untuk memastikan bahwa sistem dapat bekerja secara umum dan tidak hanya pada data tertentu. Hasil evaluasi ini akan memberikan gambaran tentang seberapa baik sistem dapat mengidentifikasi dan merepresentasikan topik dalam percakapan grup WhatsApp secara otomatis, serta memberikan umpan balik untuk perbaikan lebih lanjut jika diperlukan.

3.4.8 Analisis Hasil

Tahap analisis hasil dilakukan terhadap keluaran model topik dan metrik evaluasi yang diperoleh dari tahap pengujian. Analisis kuantitatif dilakukan dengan membandingkan nilai metrik evaluasi (Embedding Density, Intra-topic Similarity, NPMI, Topic Diversity, dan Black-box Testing) antara metode modifikasi BERTopic dengan baseline BERTopic. Perbandingan disajikan dalam bentuk tabel dan grafik tren untuk melihat konsistensi performa model seiring penambahan jumlah data.

3.4.9 Penarikan Kesimpulan

Berdasarkan hasil analisis, dilakukan penarikan kesimpulan yang menjawab rumusan masalah penelitian serta penyusunan saran untuk pengembangan penelitian di masa mendatang.

3.5 Etika Penelitian

Penelitian ini menggunakan data riwayat percakapan grup WhatsApp yang bersifat personal, sehingga proses pengumpulan data memperhatikan aspek etika dan perizinan. Pengambilan data dilakukan dengan terlebih dahulu membuat surat izin penelitian di Fakultas Ilmu Komputer Universitas Jember, kemudian menyerahkan surat izin penelitian kepada admin grup WhatsApp yang menjadi sumber data, sebagaimana ditunjukkan pada Lampiran 3 (Gambar 3). Persetujuan admin grup untuk penggunaan data percakapan dalam penelitian ini didokumentasikan melalui tangkapan layar (*screenshot*), sebagaimana ditunjukkan pada Lampiran 4 (Gambar 4, mencakup Gambar 4a, Gambar 4b, dan Gambar 4c). Terdapat beberapa syarat yang diajukan oleh admin grup terkait penggunaan data, yaitu pesan tidak boleh disebarluaskan kepada pihak lain dan nama grup serta identitas partisipan harus disamarkan.

BAB 4. HASIL DAN PEMBAHASAN

4.1 Pengumpulan Data

Data penelitian diperoleh dari grup WhatsApp komunitas buku setelah memperoleh izin dari admin grup seperti yang dijelaskan pada bagian 3.5. Pengumpulan data dilakukan menggunakan fitur *Export Chat* bawaan aplikasi WhatsApp, yang menghasilkan berkas dalam format *.zip* berisi riwayat percakapan dalam satu berkas *.txt* tanpa media. Berkas *.zip* tersebut terlebih dahulu diekstraksi untuk memperoleh file *.txt* yang selanjutnya digunakan sebagai sumber data utama penelitian. Data yang diekspor mencakup periode percakapan dari Juni 2023 hingga Juni 2026, dengan total pesan 91.868 sebelum proses pembersihan pesan dengan total partisipan 1.307.

Sebagai ilustrasi, potongan data mentah hasil ekspor ditampilkan pada Tabel 4.1. Secara umum, setiap baris percakapan mengikuti pola *DD/MM/YY HH.MM - Pengirim: Pesan*. Namun demikian, data mentah juga memuat variasi format lain seperti pesan sistem (misalnya anggota ditambahkan ke grup), placeholder media, tautan, dan penanda pesan yang telah diedit.

Tabel 4.1: Contoh Potongan Data Mentah Hasil Ekspor WhatsApp

No.	Potongan Baris Data Mentah Log Obrolan
1	02/02/26 20.46 - +62 ***-****-****: Aku tadi searching sedikit tentang buku ini
2	02/02/26 20.47 - +62 ***-****-****: <Media tidak disertakan>
3	27/09/25 10.35 - +62 ***-****-****: sheesh
4	03/02/26 11.24 - +62 ***-****-****: https://link
5	28/09/25 09.48 - +62 ***-****-****: gara gara dapet evernight jadi pengen hyacine <Pesan ini diedit>
6	24/04/26 05.12 - +62 ***-****-**** sudah ditambahkan

Berdasarkan potongan data mentah pada Tabel 4.1, terdapat beberapa karakteristik khas dari riwayat percakapan WhatsApp yang membedakannya dengan teks formal, antara lain:

1. Jumlah kata yang singkat dan informal: Pesan cenderung pendek, menggunakan bahasa sehari-hari, dan sering kali mengandung singkatan atau istilah khusus komunitas.
2. Penggunaan Bahasa Campuran dan Slang: Adanya pencampuran bahasa (seperti kata “*searching*” dan “*sheesh*”) serta istilah khusus domain percakapan (seperti “*evernight*” dan “*hyacine*”).
3. Metadata Media: Penanda otomatis <*Media tidak disertakan*> disematkan oleh sistem WhatsApp untuk menunjukkan file multimedia (gambar, video, stiker, audio) yang tidak diekspor ke dalam file teks biasa.
4. Keberadaan Tautan (URL): Terdapat tautan web (*https://link*) yang dibagikan oleh anggota grup.
5. Penanda Pesan Diedit: Penanda metadata <*Pesan ini diedit*> di akhir pesan muncul secara otomatis ketika pengirim melakukan perubahan (*edit*) pada isi pesan yang dikirimkan.
6. Pesan Sistem (System Message): Baris terakhir memuat notifikasi otomatis sistem (seperti penambahan anggota baru) yang formatnya tidak diawali oleh nama pengirim biasa.

4.2 Praproses Data

Tahap praproses data pada penelitian ini dilakukan untuk membersihkan dan mempersiapkan teks percakapan mentah WhatsApp agar siap diolah oleh model *topic modeling* BERTopic. Alur praproses merealisasikan arsitektur *Single-Path Preprocessing* yang mencakup lima alur utama, yaitu parsing data mentah dan deteksi format timestamp ISO 8601, anonimisasi identitas pengirim dan *mention* pengguna (SHA-256), penyaringan pesan notifikasi otomatis sistem dan berkas kontak, pembersihan teks kontekstual (*case folding*, normalisasi Unicode, transliterasi emoji, normalisasi kata tidak baku dan pemanjangan karakter), serta penyaringan panjang dokumen minimal (< 3 kata).

Sebagai gambaran konkret mengenai perubahan bentuk teks pada setiap tahap

pembersihan, contoh transformasi teks pesan sebelum dan sesudah praproses disajikan pada Tabel 4.2.

Tabel 4.2: Contoh Hasil Transformasi Teks Sebelum dan Sesudah Praproses Data

Pesan Mentah	Pesan Hasil Praproses	Keterangan
<Media omitted>	[Dihapus / String Kosong]	Eliminasi artefak media sistem
@+62 ***-****-5678 welcome yusril! [emoji tersenyum]	@User-bc45-5678 welcome yusril smiling_face	Anonimisasi mention & transliterasi emoji
Gaisss cek link ini yaa https://example.com	gais cek link ini yaa	Elongasi huruf & penghapusan URL
Hahaha wkwkwk ngakak bgt bisaaa aja	haha wkwk ngakak bgt bisa saja	Normalisasi tawa, elongasi & kata tidak baku
Mau tanya perihal bab 3 skripsi dong	mau tanya perihal bab 3 skripsi saja	Case folding & normalisasi kata tidak baku
Pesan ini telah dihapus	[Dihapus / String Kosong]	Eliminasi notifikasi pesan sistem

Berdasarkan contoh transformasi pada Tabel 4.2, terlihat bahwa baris pesan mentah yang berupa notifikasi otomatis sistem (seperti “*pesan ini telah dihapus*” atau lampiran berkas kontak .vcf) dieliminasi sepenuhnya menjadi baris kosong yang kemudian dibuang dari dataset. Untuk perlindungan privasi data, nama pengirim dan penyebutan (*mention*) disamarkan menjadi token terenkripsi @User-[hash] di sisi klien. Pada aspek pembersihan teks kontekstual, penanda metadata sistem <...> dan URL dihapus sepenuhnya, karakter visual emoji ditransliterasi menjadi teks deskriptif (seperti emoji tersenyum menjadi :smiling_face:), pemanjangan karakter berulang disederhanakan (misalnya kata “bisaaa” menjadi “bisa”), serta kata-kata informal diseragamkan ke bentuk kata baku (seperti “yg” → “yang”).

Tabel 4.3: Statistik Hasil Pengolahan Praproses Data Pada Dataset Percakapan WhatsApp

No	Tahap Praproses Data	Jumlah Baris Berdampak	Persentase (%)
1	Eliminasi Notifikasi Sistem Automatis & Berkas Kontak (.vcf)	2.415 baris	2,63%
2	Penghapusan Artefak Metadata Sistem (<...>)	14.739 baris	16,04%
3	Penghapusan Pranala Luar (URL / Hyperlink)	3.412 baris	3,71%
4	Anonimisasi Penyebutan (Mention) & Kontak Telepon	1.306 baris	1,42%
5	Transliterasi Emoji & Emotikon (Demojize)	41.487 baris	45,16%
6	Normalisasi Ekspresi Tawa (Laughter Normalization)	9.258 baris	10,08%
7	Normalisasi Elongasi Karakter & Kata Tidak Baku	18.642 baris	20,29%
8	Penyaringan Pesan Pendek (< 3 Kata) & Baris Kosong	33.360 baris	36,31%
Total Dokumen Bersih Siap Pemodelan (Pesan_Preprocessed)		56.089 dokumen	61,05%

Berdasarkan statistik kuantitatif pada Tabel 4.3, dari total dataset percakapan WhatsApp mentah sebanyak 91.868 baris pesan, alur praproses secara bertahap mereduksi derau dan membersihkan teks. Penyaringan notifikasi otomatis bawaan sistem WhatsApp dan lampiran berkas kontak (.vcf) mengeliminasi sebanyak 2.415 baris pesan (2,63%). Pembersihan artefak ekspor WhatsApp seperti teks penanda <...> (misalnya <Media tidak disertakan>) berdampak pada 14.739 baris pesan (16,04%), sedangkan penghapusan pranala luar (URL) berdampak pada 3.412 baris pesan (3,71%).

Pada tahap normalisasi konten, transliterasi emoji (*demojize*) mengonversi karakter emosional menjadi token deskriptif pada 41.487 baris pesan (45,16%) tanpa merusak vektor *embedding* IndoBERTweet. Penyeragaman ekspresi tawa informal berdampak pada 9.258 baris data (10,08%), serta normalisasi pemanjangan karakter berulang (*elongation*) dan kata tidak baku (*slang*) berdampak pada 18.642 baris data (20,29%). Kedua langkah ini secara signifikan berhasil menekan tingkat kejarsan kosakata (*vocabulary sparsity*). Selain itu, anonimisasi data sensitif pada isi teks berhasil menyamarkan alamat email dan nomor telepon independen menjadi token @USER pada 1.306 baris data (1,42%).

Pada tahap akhir, dilakukan penyaringan terhadap baris pesan yang tidak memenuhi kriteria minimal panjang dokumen. Pesan yang memiliki jumlah kata kurang dari 3 kata (< 3 kata, seperti pesan singkat "ok", "ya", atau pesan kosong setelah pembersihan) tereliminasi sebanyak 33.360 baris (36,31%). Secara keseluruhan, alur praproses ini berhasil mereduksi dataset dari 91.868 baris data mentah menjadi **56.089 dokumen bersih** (*Pesan_Preprocessed*) atau setara dengan 61,05% data masukan berkualitas tinggi yang siap digunakan pada tahap pemodelan topik BERTopic. Adapun pembuangan kata umum (*stopword removal*) diimplementasikan langsung pada komponen *CountVectorizer* saat pembuatan model.

4.3 Pembuatan Model (Modified BERTopic)

Tahap pembuatan model merealisasikan arsitektur *pipeline* BERTopic modifikasi yang telah dirancang untuk menangani karakteristik khusus data percakapan WhatsApp. Pemodelan topik dijalankan pada data hasil praproses yang memenuhi kriteria penyaringan minimal 3 kata. Alur kerja pemodelan terdiri dari lima tahapan utama beserta alasan teknis pemilihan parameternya:

4.3.1 Pembangkitan Vektor Embedding dengan IndoBERTweet

Setiap dokumen pesan dikonversi menjadi representasi vektor numerik padat (*dense vector*) berdimensi 768 menggunakan model bahasa pra-latih *indolem/indobertweet-base-uncased*. Alasan pemilihan model IndoBERTweet dibanding model transformer umum (seperti BERT multilingual) adalah karena IndoBERTweet dilatih khusus menggunakan korpus teks media sosial Indonesia berskala besar. Model ini memiliki kemampuan tinggi dalam menangkap konteks semantik bahasa tidak baku, singkatan informal, serta ekspresi emosional yang dominan pada percakapan grup WhatsApp. Pembangkitan embedding dilakukan pada kolom pesan yang masih mempertahankan kata hubung dan struktur tanda baca agar representasi kontekstual kata di dalam vektor $N \times 768$ dapat terekstraksi secara utuh dan kaya.

4.3.2 Reduksi Dimensi dengan UMAP

Vektor embedding berdimensi 768 direduksi menjadi ruang vektor berdimensi 5 menggunakan algoritma UMAP (*Uniform Manifold Approximation and Projection*). Pemilihan konfigurasi parameter UMAP didasarkan pada pertimbangan matematis dan struktur manifold data teks:

1. $n_neighbors = 25$: Parameter ini mengontrol keseimbangan antara struktur lokal dan global data. Nilai 25 dipilih untuk memberikan pandangan manifold yang cukup luas agar sub-topik percakapan tidak terpecah menjadi kluster-kluster mikro yang berlebihan, sekaligus mempertahankan hubungan semantik antar-topik utama.

2. $n_components = 5$: Dimensi kompresi target diatur pada 5 dimensi untuk mengatasi masalah kelangkaan data berdimensi tinggi (*curse of dimensionality*) pada pengklasteran, tanpa menghilangkan varians semantik penting yang dibutuhkan untuk memisahkan topik.
3. $min_dist = 0.0$: Nilai 0.0 memungkinkan dokumen-dokumen dengan representasi semantik yang mirip untuk mengelompok sangat rapat di dalam ruang tereduksi, sehingga membentuk batas klaster yang tegas dan padat.
4. $metric = "cosine"$: Metrik kemiripan kosinus digunakan karena mampu mengukur sudut orientasi antar-vektor dokumen teks berdimensi tinggi secara lebih presisi dibanding metrik *Euclidean* yang rentan terhadap perbedaan panjang dokumen.

4.3.3 Pengklasteran dengan Custom BIRCH Clustering (BirchWithOutliers)

Data berdimensi rendah ($N \times 5$) selanjutnya dikelompokkan menggunakan algoritma BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) yang dimodifikasi khusus dengan mekanisme pengklasifikasi pencilan berbasis persentil jarak kosinus terhadap centroid (*BirchWithOutliers*). Parameter pengklasteran diatur berdasarkan alasan teknis berikut:

1. $threshold = 0.25$: Menentukan batas radius maksimum kekompakan sub-klaster pada pohon fitur (*CF-Tree*). Nilai $threshold$ yang relatif rendah sebesar 0.25 dipilih agar algoritma BIRCH menghasilkan banyak klaster mikro (*fine-grained clusters*) dengan kerapatan semantik yang sangat tinggi dan homogen.
2. $branching_factor = 50$: Membatasi kapasitas maksimum simpul anak pada setiap *node* pohon CF-Tree menjadi 50. Parameter ini menjaga efisiensi konsumsi memori dan kecepatan pemrosesan hierarki saat menangani ribuan dokumen percakapan.
3. $outlier_percentile = 95.0$: Berbeda dari HDBSCAN yang membuang lebih dari 40% data sebagai pencilan, mekanisme ini mengukur jarak kosinus setiap dokumen ke centroid klasternya $d(x, c) = 1 - \frac{x \cdot c}{\|x\| \|c\|}$, lalu hanya mengelim-

inasi 5% dokumen terluar (yang jaraknya melebihi persentil ke-95) sebagai pencilan (label -1). Hal ini secara signifikan menekan persentase *outlier rate* tanpa mengorbankan kualitas kekompakan klaster.

4. *min_cluster_size* = 5: Klaster kerdil yang memiliki anggota kurang dari 5 pesan dieliminasi dan dilebur menjadi label -1 . Langkah ini diambil karena klaster dengan anggota yang sangat sedikit tidak memiliki substansi statistik yang memadai untuk merepresentasikan sebuah tema pembicaraan grup.
5. *metric* = "*cosine*": Menjamin konsistensi pengukuran jarak antar-vektor dari tahap UMAP hingga perhitungan centroid klaster pada BIRCH.

4.3.4 Penyaringan Stopwords WhatsApp dan Representasi BM25

Setelah klaster dokumen terbentuk, kata kunci representatif untuk setiap topik diekstrak menggunakan algoritma pembobotan BM25 (*BM25Representation*) menggantikan skema c-TF-IDF konvensional:

1. *ngram_range* = (1, 2): Ekstraksi fitur kata menggunakan *CountVectorizer* diatur pada unigram dan bigram agar dapat menangkap frasa dua kata yang memiliki makna domain spesifik di dalam grup WhatsApp (seperti "*buku baru*" atau "*terima kasih*").
2. Kamus *STOPWORDS* 9 Kategori: Menerapkan penyaringan kata umum khusus wacana WhatsApp yang mencakup kata hubung formal, kata tanya/deiktik, sapaan/pronomina, partikel filler/tawa, singkatan gaul, kata fungsi tambahan, derau Bahasa Inggris, kata emoji, dan noise platform. Penyaringan ini mencegah kata-kata wacana harian yang frekuensinya tinggi mendominasi peringkat kata kunci topik.
3. Parameter Saturasi $k_1 = 1.2$: Mengontrol tingkat saturasi frekuensi kata. Nilai 1.2 dipilih untuk membatasi kontribusi frekuensi kata yang muncul berulang kali di dalam satu pesan (seperti ekspresi tawa atau kata penegas berulang) agar tidak mendominasi pembobotan secara tidak seimbang.
4. Parameter Normalisasi Panjang $b = 0.5$: Menyeimbangkan kontribusi panjang dokumen. Nilai $b = 0.5$ memberikan penyesuaian yang adil antara pesan

singkat berdurasi satu frasa dengan pesan panjang berparagraf multi-kalimat pada percakapan WhatsApp.

Formula pembobotan kata kunci BM25 dirumuskan sebagai:

$$BM25(q, D) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)} \quad (4.1)$$

di mana $\text{IDF}(q_i) = \log \left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} \right)$. Skema BM25 secara konsisten menghasilkan kata kunci yang lebih bersih, koheren, dan informatif bagi pengguna.

4.3.5 Reduksi Topik Otomatis dan Kondisi Pengaman (Safety Guard)

Sebagai tahap akhir pembuatan model, dilakukan penyederhanaan jumlah topik secara otomatis menggunakan metode reduksi topik bawaan BERTopic dengan parameter *nr_topics* = "auto". Tahap ini bekerja secara berkesinambungan dengan tahap pengklasteran BIRCH: setelah BIRCH dengan *threshold* 0.25 menghasilkan banyak klaster mikro yang sangat spesifik, fungsi reduksi topik (*reduce topics*) bertugas untuk menggabungkan (*merge*) klaster-klaster yang memiliki kemiripan semantik tinggi pada ruang *embedding* menjadi kumpulan topik utama yang lebih ringkas, konsisten, dan relevan.

Untuk menjaga keandalan pemrosesan sistem, diterapkan **kondisi pengaman** (*safety guard*) pada tahap ini. Sebelum proses reduksi otomatis dipanggil, sistem memeriksa jumlah topik unik non-pencilan yang terbentuk. Jika jumlah topik unik non-pencilan kurang dari atau sama dengan satu topik (≤ 1), pemanggilan fungsi reduksi topik otomatis dilewati. Alasan teknis penerapan kondisi pengaman ini adalah untuk menghindari galat pembagian kosong (*division by zero*) atau kesalahan iterasi pada pustaka BERTopic saat memproses dataset percakapan berskala sangat kecil atau dataset yang pesannya didominasi oleh pencilan.

4.4 Pengujian dan Evaluasi Kuantitatif Model

Untuk memvalidasi performa dan efektivitas dari arsitektur *pipeline* BERTopic modifikasi yang diusulkan, dilakukan pengujian kurva pembelajaran (*learning curve*) dengan memotong dataset menjadi beberapa bagian persentase, yaitu 20%, 40%, 60%, 80%, dan 100%. Evaluasi ini membandingkan kinerja model baseline standar dengan model usulan (*proposed*) yang menggunakan integrasi komponen baru.

Metrik evaluasi yang digunakan mencakup jumlah topik yang terbentuk (n_topics), persentase dokumen pencilan (*Outlier Rate*), keberagaman kata kunci (*Topic Diversity*), koherensi semantik kata kunci (*C-NPMI Coherence*), kepadatan kluster di ruang vektor semantik (*Embedding Density*), dan kemiripan dokumen internal kluster (*Intra-topic Similarity*).

Hasil pengujian kurva pembelajaran untuk model baseline disajikan pada Tabel 4.4, sedangkan hasil untuk model usulan (*proposed*) disajikan pada Tabel 4.5.


Tabel 4.4: Hasil Evaluasi Kurva Pembelajaran (Learning Curve) Model Baseline

Split	Jumlah Dokumen	Jumlah Topik	Outlier Rate (%)	Diversity	C-NPMI	Density	Intra-topic Sim
20%	11.217	89	41,37%	0,9169	-0,0310	0,4827	0,5116
40%	22.435	101	41,92%	0,9614	0,0421	0,5353	0,4858
60%	33.653	96	41,28%	0,9677	0,0675	0,5711	0,4862
80%	44.871	372	43,39%	0,9081	0,0189	0,5551	0,5303
100%	56.089	251	42,42%	0,9526	0,0662	0,5611	0,5211


Tabel 4.5: Hasil Evaluasi Kurva Pembelajaran (Learning Curve) Model Usulan (Proposed)

Split	Jumlah Dokumen	Jumlah Topik	Outlier Rate (%)	Diversity	C-NPMI	Density	Intra-topic Sim
20%	11.217	97	14,67%	0,9536	0,0450	0,5787	0,6028
40%	22.435	37	11,99%	0,9919	0,0846	0,6054	0,6528
60%	33.653	135	10,53%	0,9489	0,0768	0,5729	0,6240
80%	44.871	310	9,15%	0,9335	0,0816	0,6140	0,6022
100%	56.089	102	8,79%	0,9559	0,1567	0,6666	0,6716

Visualisasi grafis perbandingan metrik evaluasi sepanjang kurva pembelajaran ditampilkan pada Gambar 4.1 untuk model baseline dan Gambar 4.2 untuk model usulan.



Gambar 4.1: Kurva Pembelajaran (Learning Curve) Model Baseline



Gambar 4.2: Kurva Pembelajaran (Learning Curve) Model Usulan (Proposed)

4.5 Implementasi Sistem

Tahap implementasi sistem mewujudkan rancangan *client-server* menjadi aplikasi berbasis web fungsional yang dapat digunakan oleh pengguna untuk melakukan analisis topik obrolan secara langsung. Sistem ini dibangun dengan arsitektur modern yang memisahkan tanggung jawab antarmuka pengguna (*frontend*) dan pemrosesan data (*backend*) secara jelas:


4.5.1 Arsitektur Client-Server dan Komponen Teknologi

Aplikasi web ini terdiri dari dua komponen utama:

1. **Frontend (Client):** Dibangun menggunakan *framework* Vue.js 3, TypeScript, Vite sebagai build tool, dan TailwindCSS untuk penataan gaya (*styling*) antarmuka yang dinamis dan modern. Manajemen *state* aplikasi dikelola secara terpusat menggunakan Pinia dengan menerapkan pola arsitektur MVI (*Model-View-Intent*) untuk menjamin aliran data satu arah yang bersih dan mudah ditelusuri.
2. **Backend (Server):** Dibangun menggunakan FastAPI (Python) yang menyediakan layanan web server berkinerja tinggi berbasis asinkron. Pemrosesan model NLP dijalankan langsung di server menggunakan pustaka *PyTorch*, *SentenceTransformers*, *UMAP-learn*, *scikit-learn*, dan *BERTopic*. Seluruh komputasi pemodelan bahasa berjalan pada unit pemrosesan GPU (*Graphics Processing Unit*) server yang terakselerasi melalui pustaka CUDA untuk mempercepat ekstraksi vektor embedding dari dataset chat yang besar secara paralel.

Tampilan antarmuka utama (*landing page*) serta modal petunjuk cara kerja dan ekspor chat disajikan pada **Gambar 4.3** (**Gambar 4.3a** dan **Gambar 4.3b**). Pada halaman utama, pengguna disajikan ringkasan fitur sistem dan tombol navigasi untuk memulai analisis. Pengguna yang belum memahami cara mengekspor

riwayat percakapan WhatsApp dapat membuka dialog modal petunjuk cara kerja yang memberikan instruksi langkah demi langkah secara intuitif.



(a) Halaman Utama (Landing Page)

(b) Modal Panduan Ekspor Chat


Gambar 4.3: Antarmuka Utama dan Panduan Cara Kerja Aplikasi Web ChatAnalisis

4.5.2 Keamanan dan Privasi Data (Client-Side Anonymization)

Sebagaimana didefinisikan pada prinsip desain di Bab 3, privasi data menjadi prioritas utama. Implementasi sistem menerapkan **anonimisasi pada sisi klien** (*client-side anonymization*) sebelum data dikirimkan ke server. Ketika pengguna memilih berkas obrolan mentah (*.txt* atau *.zip*) di halaman *UploadView.vue*, skrip JavaScript di sisi klien (*chatParser.ts*) mengurai log obrolan tersebut menjadi bentuk objek terstruktur terlebih dahulu guna memetakan statistik waktu untuk penggeser rentang tanggal. Penyamaran data dilakukan secara efisien dengan metode penundaan penyamaran (*deferred anonymization*). Tepat setelah pengguna menentukan rentang tanggal analisis dan menekan tombol mulai, pesan akan disaring berdasarkan rentang tanggal yang dipilih terlebih dahulu, kemudian skrip *anonymization.ts* secara asinkron mengganti nama pengirim (*sender*) dan mention nomor telepon yang ada pada pesan tersaring saja dengan nilai samaran yang telah di-hash SHA-256 dengan garam (*salt*). Hasil penyamaran tersebut kemudian dikonversi menjadi berkas CSV baru yang bersih. Berkas CSV hasil anonimisasi inilah yang dikirim ke backend server melalui permintaan HTTP POST */analysis*, sehingga server tidak pernah menerima, menyimpan, atau memproses identitas asli pengguna. Selama proses penguraian awal berkas di peramban yang memakan waktu beberapa detik untuk dataset besar, antarmuka pengguna menampilkan status

pemrosesan aktif (*isParsing*) berupa ikon berputar (*loading spinner*) serta menon-aktifkan tombol navigasi lanjut (*Selanjutnya*). Proteksi antarmuka ini mencegah adanya kondisi balapan (*race condition*) data sebelum proses penguraian selesai fully secara lokal.

Antarmuka unggah berkas obrolan mentah dan pengaturan filter rentang tanggal disajikan pada **Gambar 4.4** (**Gambar 4.4a** dan **Gambar 4.4b**).



(a) Unggah Berkas Obrolan

(b) Filter Rentang Tanggal & Anonimisasi

Gambar 4.4: Antarmuka Unggah Berkas dan Pengaturan Filter Rentang Tanggal Data

4.5.3 Pemrosesan Latar Belakang (Asynchronous Background Task)


Proses pemodelan topik BERTopic yang melibatkan ekstraksi embedding berdimensi tinggi merupakan tugas yang memakan waktu komputasi cukup lama (*computationally expensive*). Jika dijalankan secara sinkron pada utas utama (*main thread*), permintaan HTTP dari pengguna akan mengalami *timeout* dan membuat browser menjadi tidak responsif.

Untuk mengatasi kendala tersebut, endpoint *POST /analysis* di backend FastAPI diimplementasikan sebagai tugas latar belakang asinkron (*asynchronous background task*) menggunakan fitur bawaan FastAPI *BackgroundTasks*. Ketika file CSV anonim diterima, server langsung menyimpan berkas secara lokal di direktori penyimpanan sementara, menetapkan sebuah ID sesi unik (*jobId/session_id*), dan segera mengembalikan respons HTTP sukses (status code 200) yang memuat informasi jumlah baris awal. Server kemudian melanjutkan pemrosesan delapan tahap *pipeline* analisis secara mandiri pada utas latar belakang.

4.5.4 Real-time Progress Streaming via Server-Sent Events (SSE)

Untuk memberikan pengalaman pengguna yang interaktif, status pengerjaan tugas latar belakang di server dipantau secara langsung oleh frontend secara *real-time* menggunakan koneksi SSE (*Server-Sent Events*).

Backend FastAPI menyediakan endpoint `GET /api/analysis/events/{session_id}` yang memancarkan (*broadcast*) aliran data (*stream*) berformat JSON setiap kali sebuah tahapan dalam *pipeline* di server mengalami perubahan status (misalnya dari *"running"* menjadi *"completed"* beserta durasi komputasi dalam milidetik). Di sisi frontend, komponen `TerminalSimulator.vue` menangkap aliran data tersebut menggunakan objek HTML5 `EventSource` dan menampilkannya dalam bentuk baris simulator perintah terminal konsol, sebagaimana ditunjukkan pada **Gambar 4.5**. Ketika server mengirimkan sinyal penanda selesai (*"done": true*), koneksi SSE ditutup secara otomatis, dan frontend secara mulus mengalihkan pengguna ke rute halaman */results*.




Gambar 4.5: Tampilan Pemantauan Progres Analisis secara Real-Time via Server-Sent Events (SSE)

4.5.5 Antarmuka Hasil Pemodelan Topik dan Visualisasi Data

Hasil akhir dari alur pemodelan topik disajikan secara komprehensif pada antarmuka dashboard sebagaimana disajikan pada **Gambar 4.6** dan **Gambar 4.7**. Halaman dashboard menampilkan kartu-kartu kluster topik yang berhasil terbentuk


lengkap dengan ringkasan kata kunci utama dan jumlah dokumen pesan di dalamnya. Selain itu, pengguna dapat mengamati grafik distribusi temporal volume chat per rentang waktu (Gambar 4.6), panel ringkasan metrik evaluasi kuantitatif model seperti persentase *outlier*, C-NPMI, *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity* (Gambar 4.7a), serta grafik distribusi aktivitas jam sibuk obrolan dan peringkat (*leaderboard*) pengirim pesan paling aktif yang identitasnya telah teranonimisasi (Gambar 4.7b).



Gambar 4.6: Tampilan Dashboard Hasil Pemodelan Topik dan Grafik Tren Waktu Obrolan



(a) Panel Metrik Evaluasi Kuantitatif



(b) Aktivitas & Leaderboard Pengirim


Gambar 4.7: Visualisasi Panel Metrik Evaluasi Kuantitatif dan Distribusi Aktivitas Pengguna

4.5.6 Penelusuran Konteks Pesan (Traceability)


Untuk menjaga aspek *traceability* seperti yang dituntut dalam prinsip desain sistem, backend FastAPI mempertahankan nilai kolom indeks unik (*index*) dari se-

tiap pesan asli di sepanjang proses praproses dan pemodelan topik. Hasil pengklasteran disimpan dalam berkas berformat *{session_id}_labeled.csv*.

Fitur penelusuran konteks pesan ini disajikan pada **Gambar 4.8** (**Gambar 4.8a** dan **Gambar 4.8b**). Pada antarmuka pengguna (*TopicDetailView.vue*), pengguna dapat melihat daftar pesan yang dikelompokkan ke dalam klaster topik tertentu (**Gambar 4.8a**). Apabila salah satu pesan diklik, sistem akan memicu modal dialog (*MessageContextModal.vue*) (**Gambar 4.8b**) dan memanggil API backend *GET /api/results/{jobId}/messages/{messageId}/context*. API ini akan mencari baris pesan berdasarkan indeks uniknya di dalam dokumen CSV berlabel, lalu mengambil beberapa baris pesan sebelum dan sesudahnya secara kronologis. Fitur ini memungkinkan pengguna untuk membaca konteks pembicaraan lengkap secara runtut waktu tanpa kehilangan informasi alur komunikasi grup yang sebenarnya.



(a) Halaman Detail Kluster Topik



(b) Modal Penelusuran Konteks Pesan

Gambar 4.8: Antarmuka Detail Kluster Topik dan Dialog Modal Penelusuran Konteks Pesan

4.5.7 Pencegahan Path Traversal dan Validasi Input

Keamanan sistem terhadap serangan siber diimplementasikan secara ketat pada backend FastAPI melalui pencegahan celah keamanan *path traversal* dan validasi input. Serangan *path traversal* dapat dieksploitasi oleh pihak tidak bertanggung jawab untuk membaca, memodifikasi, atau menghapus file sensitif di luar direktori penyimpanan resmi aplikasi dengan menyuntikkan karakter navigasi direktori (misalnya *../* atau *..*).

) melalui parameter identitas sesi (*session ID/jobId*).

Sistem menangani risiko ini dengan menerapkan pengamanan ganda:

1. **Validasi Karakter Input (Input Validation):** Di dalam *analysis.py*, ditambahkan fungsi pembantu *validate_session_id* untuk memvalidasi nilai *session ID* menggunakan ekspresi reguler. Pola yang diperbolehkan hanya mencakup karakter alfanumerik, tanda hubung (*dash*), dan garis bawah (*underscore*) dengan ekspresi `^[a-zA-Z0-9_-]+$`. Setiap masukan yang mengandung karakter titik, garis miring, atau karakter khusus lainnya akan langsung ditolak sebelum diproses dan menghasilkan respons HTTP 400 Bad Request.
2. **Pengecekan Kedaulatan Direktori (Directory Bound Check):** Pada fungsi *get_file_path* di dalam *storage.py*, setiap berkas yang akan diakses dikonversi menjadi jalur absolut menggunakan metode *resolve()* dari pustaka *pathlib*. Selanjutnya, sistem memverifikasi bahwa jalur absolut tersebut merupakan turunan dari direktori penyimpanan utama (*storage/*) dengan fungsi *is_relative_to()*. Apabila jalur tersebut tidak berada di bawah folder penyimpanan resmi, sistem akan memicu *ValueError* yang mengindikasikan terjadinya serangan *path traversal*.

4.5.8 Mekanisme Pembersihan Berkas Otomatis

Aktivitas analisis dokumen chat WhatsApp berskala besar yang dilakukan secara berulang berpotensi memenuhi ruang penyimpanan server (*disk storage*) karena berkas CSV mentah, CSV hasil label, dan JSON hasil visualisasi disimpan secara lokal di dalam folder *storage/*.

Sistem mengatasi masalah penumpukan data ini dengan mengimplementasikan mekanisme pembersihan berkas otomatis (*automatic file cleanup*). Fungsi *cleanup_old_files* diimplementasikan di dalam *storage.py* untuk memindai folder penyimpanan dan memeriksa waktu modifikasi terakhir (*last modification time*) dari setiap berkas. Berkas yang memiliki usia penyimpanan lebih dari 24 jam akan langsung dihapus dari disk secara permanen. Fungsi pembersihan otomatis ini didaftarkan sebagai *asynchronous background task* menggunakan fitur bawaan FastAPI *BackgroundTasks* pada endpoint *POST /analysis*. Dengan demikian, setiap kali ada permintaan

analisis baru dari pengguna, server akan memicu proses pembersihan berkas sampah di latar belakang secara otomatis tanpa memblokir atau memperlambat waktu respons analisis pengguna yang sedang berjalan.

4.6 Analisis dan Pembahasan Hasil

Bagian pembahasan ini menganalisis secara mendalam faktor-faktor penyebab keunggulan performa dari komponen model *pipeline* BERTopic modifikasi yang diusulkan dibandingkan model baseline standar:

4.6.1 Pengaruh BIRCH dalam Mengeliminasi Outliers

Salah satu kontribusi utama dari penelitian ini adalah keberhasilan pemanfaatan algoritma BIRCH modifikasi (*BirchWithOutliers*) dalam mengeliminasi data pencilon (*outlier*). Pada model baseline BERTopic yang menggunakan HDBSCAN, sebanyak 41,28% hingga 43,39% data percakapan dibuang sebagai *outlier*. Hal ini terjadi karena HDBSCAN mengandalkan kepadatan spasial lokal (*density-based clustering*). Pada teks pendek seperti pesan WhatsApp, dokumen memiliki representasi fitur yang sangat renggang (*sparse*), sehingga jarak antar-dokumen di ruang vektor cenderung seragam dan menyulitkan HDBSCAN dalam mendeteksi batas kepadatan kluster. Akibatnya, sebagian besar dokumen dianggap sebagai *noise*.

Model usulan yang menerapkan BIRCH dengan outlier detection berbasis persentil jarak (95.0 persentil jarak kosinus terhadap centroid) dan pembersihan kluster kerdil (< 5 dokumen) berhasil membatasi *outlier rate* secara signifikan hingga menyisakan antara 14,67% (pada 20% data) dan terus menurun hingga hanya **8,79%** (pada 100% data). Hal ini dicapai dengan mendekomposisi ruang vektor secara efisien melalui pohon fitur (*CF-Tree*) dan centroid, sehingga dokumen dapat dialokasikan ke kluster yang paling dekat tanpa mendiskualifikasi dokumen secara masif.

4.6.2 Peran IndoBERTweet dalam Meningkatkan Koherensi Topik

Hasil pengujian kuantitatif menunjukkan bahwa model usulan menghasilkan koherensi topik (C-NPMI) yang jauh lebih tinggi dan bernilai positif (meningkat dari 0,0450 pada 20% data hingga mencapai **0,1567** pada 100% data) dibandingkan model baseline yang hanya berkisar antara -0,0310 hingga 0,0662.

Faktor utama yang menyebabkan perbedaan performa ini adalah representasi ruang vektor semantik. Model baseline dilatih pada korpus teks formal berskala global yang didominasi oleh Bahasa Inggris. Ketika dihadapkan pada data percakapan WhatsApp yang kaya akan istilah informal, singkatan tidak baku, dan percampuran bahasa (*code-mixing* seperti "*sheesh*", "*hsr*", "*evernight*"), model multilingual gagal memetakan makna semantik kata-kata tersebut secara akurat. Sebaliknya, model IndoBERTweet dilatih khusus menggunakan korpus teks media sosial Indonesia berskala besar, sehingga memiliki kamus kosakata (*vocabulary*) yang sangat relevan dengan bahasa sehari-hari. Representasi vektor yang dihasilkan oleh IndoBERTweet mampu menangkap kemiripan konteks kata informal secara presisi, menghasilkan kluster dokumen yang lebih padat, dan pada akhirnya menghasilkan kata kunci topik yang lebih terarah dan bermakna.

4.6.3 Efektivitas Representasi Kata Kunci dengan BM25

Komponen pembobotan BM25 yang diintegrasikan sebagai pengganti c-TF-IDF terbukti menghasilkan kata kunci representatif yang lebih koheren dan stabil. Dalam c-TF-IDF standar, bobot kata dihitung berdasarkan perkalian frekuensi kata lokal dengan kebalikan frekuensi kelas. Namun, c-TF-IDF tidak mempertimbangkan saturasi frekuensi kata (*term frequency saturation*) dan perbedaan panjang dokumen secara dinamis. Pada data percakapan WhatsApp yang informal, sering kali dijumpai pengulangan kata tawa ("*wkwk*") atau kata penegas ("*ya*") yang sangat dominan dalam satu pesan panjang, sehingga kata-kata tersebut cenderung mendominasi representasi topik secara bias.

Algoritma BM25 mengatasi bias ini dengan menyertakan parameter $k_1 =$

1.2 untuk membatasi dampak peningkatan frekuensi kata (saturasi) dan parameter $b = 0.5$ untuk menormalisasi kontribusi panjang dokumen. Dengan demikian, kata-kata unik yang memiliki bobot informasi tinggi tetap dapat muncul sebagai kata kunci representatif topik meskipun frekuensi kemunculannya tidak sedominan kata-kata umum, sehingga meningkatkan kualitas kejelasan (*readability*) dari topik yang disajikan kepada pengguna.

4.6.4 Analisis Penyaringan Stopwords Korpus WhatsApp

Pengintegrasian kamus *STOPWORDS* gabungan 9 kategori pada *CountVectorizer* terbukti efektif mencegah kata-kata instruksional dan wacana harian mendominasi kata kunci topik. Pada teks obrolan WhatsApp, kata sapaan (seperti "*kak*", "*mas*", "*bro*"), partikel penegas ("*deh*", "*dong*", "*sih*"), kata deiktik ("*disini*", "*dimana*"), serta ekspresi tawa ("*wkwk*", "*haha*") sering kali muncul dengan frekuensi sangat tinggi di hampir seluruh percakapan. Tanpa penyaringan 9 kategori *STOPWORDS* ini, kata-kata tersebut akan mendominasi peringkat teratas hasil ekstraksi BM25 dan menurunkan nilai keberagaman topik (*Topic Diversity*). Dengan penyaringan khusus ini, nilai *Topic Diversity* pada model usulan tetap terjaga sangat tinggi pada rentang **0,9335 hingga 0,9919**.

4.6.5 Analisis Kepadatan Vektor dan Kemiripan Internal Klaster

Pengukuran metrik *Embedding Density* (KDE Rushkin 2020 dengan bobot semantik) dan *Intra-topic Similarity* mencerminkan tingkat kekompakan ruang vektor dokumen pada klaster topik yang terbentuk. Model usulan mencapai nilai *Embedding Density* sebesar **0,6666** dan *Intra-topic Similarity* sebesar **0,6716** pada 100% data (56.089 dokumen), yang secara konsisten lebih tinggi dibandingkan model baseline (0,5611 dan 0,5211). Peningkatan ini menunjukkan bahwa penggabungan reduksi UMAP (5 dimensi, metrik kosinus) dan BIRCH berhasil membentuk batas-batas klaster yang kompak di mana dokumen-dokumen di dalam klaster yang sama memiliki tingkat kemiripan vektor semantik yang sangat erat.

4.7 Pengujian Fungsional Sistem (Black Box Testing)

Untuk memastikan seluruh fitur dan komponen perangkat lunak berfungsi dengan baik dan bebas dari kesalahan operasional, dilakukan pengujian fungsional menggunakan metode *Black Box Testing*. Metode ini mengevaluasi perilaku sistem hanya berdasarkan masukan (*input*) yang diberikan dan keluaran (*output*) yang dihasilkan, tanpa melihat atau menguji struktur kode program internal sistem (*behavioral testing*).

Pengujian dilakukan secara menyeluruh terhadap alur kerja sistem dari ujung ke ujung (*End-to-End*), yang mencakup interaksi pengguna pada antarmuka web (*frontend*) serta respons layanan web (*API backend*) saat memproses permintaan.

Rincian hasil pengujian fungsional sistem disajikan pada **Lampiran 5 (Tabel 1)**. Berdasarkan hasil pengujian fungsional menggunakan metode *Black Box Testing* terhadap 11 skenario kasus uji utama yang mencakup seluruh alur kerja sistem (*ChatAnalysis-FE* dan *ChatAnalysis-BE*) secara terintegrasi, seluruh fitur sistem dinyatakan dapat berjalan dengan baik dan menghasilkan keluaran yang valid sesuai dengan spesifikasi kebutuhan yang didefinisikan.

BAB 5. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan seluruh rangkaian tahapan penelitian, perancangan sistem, implementasi, serta pengujian dan evaluasi kuantitatif yang telah dilaksanakan pada data percakapan grup WhatsApp, diperoleh beberapa kesimpulan utama yang menjawab rumusan masalah penelitian sebagai berikut:

1. Penerapan Modified BERTopic pada Percakapan WhatsApp:

Penelitian ini berhasil merancang dan menerapkan modifikasi arsitektur *framework* BERTopic yang disesuaikan secara spesifik untuk menangani karakteristik wacana percakapan grup WhatsApp berbahasa Indonesia. Integrasi alur *Single-Path Preprocessing* berhasil mereduksi derau (*noise*) dan membersihkan 91.868 pesan mentah menjadi 56.089 dokumen berkualitas tinggi. Pada tahap pemodelan, pemanfaatan model bahasa *embedding* IndoBERT-Tweet (vektor 768 dimensi), reduksi dimensi UMAP (5 komponen dengan metrik kosinus), algoritma pengklasteran hierarkis BIRCH (*BirchWithOutliers* dengan *threshold* 0,25 dan batas persentil pencilan 95,0), representasi BM25 ($k_1 = 1, 2; b = 0, 5$) yang diperkaya kamus *STOPWORDS* 9 kategori, serta reduksi topik otomatis dengan mekanisme pengaman (*safety guard*) terbukti mampu mengekstraksi topik percakapan secara terstruktur dan adaptif.

2. Kualitas dan Performa Model Usulan Dibandingkan Baseline:

Hasil pengujian kurva pembelajaran (*learning curve*) pada proporsi 20% hingga 100% data menunjukkan bahwa model usulan (*proposed*) secara konsisten mengungguli model *baseline* BERTopic standar pada seluruh aspek evaluasi kuantitatif:

- a. *Pengurangan Outlier Rate*: Penggunaan algoritma BIRCH berhasil menekan persentase dokumen pencilan secara drastis dari 42,42% pada *baseline*

menjadi hanya **8,79%** pada model usulan (pada 100% data), sehingga mempertahankan lebih dari 91% volume percakapan ke dalam kluster topik yang valid.

- b. *Peningkatan Koherensi Topik (C-NPMI)*: Model usulan menghasilkan nilai koherensi semantik kata kunci yang meningkat signifikan dari 0,0662 (*baseline*) menjadi **0,1567**, membuktikan bahwa representasi IndoBERT-Tweet dan BM25 mampu menghasilkan kata kunci topik yang padu dan relevan secara makna percakapan informal.
- c. *Stabilitas Keberagaman Topik (Topic Diversity)*: Nilai *Topic Diversity* pada model usulan terjaga sangat tinggi pada skor **0,9559** (rentang 0,9335–0,9919), yang mengonfirmasi bahwa kata kunci antartopik tidak mengalami tumpang-tindih (*redundancy*) berkat penyaringan *stopwords* 9 kategori.
- d. *Kepadatan Vektor dan Kemiripan Internal Kluster*: Model usulan mencapai *Embedding Density* sebesar **0,6666** (vs 0,5611 pada *baseline*) dan *Intra-topic Similarity* sebesar **0,6716** (vs 0,5211 pada *baseline*), menegaskan bahwa kluster topik yang terbentuk memiliki batas kerapatan yang tegas serta tingkat homogenitas semantik yang erat.

3. Perancangan dan Implementasi Sistem Web Terintegrasi:

Penelitian ini berhasil merancang dan mengimplementasikan sistem analisis percakapan grup WhatsApp berbasis web (*ChatAnalysis*) dengan arsitektur *client-server* yang memisahkan antarmuka pengguna (*frontend* Vue.js 3, TypeScript, TailwindCSS, Pinia) dan layanan pemrosesan komputasi (*backend* FastAPI terakselerasi GPU/CUDA). Sistem mengintegrasikan fitur privasi data melalui *client-side salted SHA-256 anonymization*, pemrosesan latar belakang asinkron (*BackgroundTasks*), pemantauan progres *real-time* berbasis *Server-Sent Events* (SSE), penelusuran konteks pesan historis (*message context traceability*), proteksi keamanan *path traversal*, dan pembersihan berkas disk otomatis. Pengujian fungsional sistem menggunakan metode *Black-Box*

Testing terhadap 34 skenario kasus uji menunjukkan bahwa seluruh fitur pada modul antarmuka dan API *backend* beroperasi 100% valid sesuai dengan spesifikasi kebutuhan.

Secara keseluruhan, integrasi IndoBERTweet, BIRCH *clustering*, dan skema representasi BM25 pada *framework* BERTopic yang diwujudkan dalam aplikasi web interaktif telah terbukti secara empiris dan aplikatif mampu menjadi solusi komprehensif dalam mengatasi tantangan *information overload* serta ekstraksi wawasan tematik pada percakapan grup WhatsApp berskala besar.

5.2 Saran

Berdasarkan hasil temuan penelitian, evaluasi sistem, serta keterbatasan yang dihadapi selama pelaksanaan penelitian, berikut adalah beberapa saran yang dapat diajukan untuk pengembangan akademik selanjutnya dan implementasi praktis:

5.2.1 Saran untuk Penelitian Selanjutnya

1. Eksplorasi Model Bahasa dan Arsitektur Embedding Mutakhir:

Penelitian selanjutnya dapat mengeksplorasi perbandingan performa menggunakan model bahasa generasi terbaru, seperti model berbasis *Large Language Models* (LLM) berbahasa Indonesia atau model representasi kalimat dwibahasa mutakhir, guna menguji peningkatan pemahaman semantik pada percakapan dengan tingkat *code-mixing* yang lebih kompleks.

2. Pengembangan Pemodelan Topik Dinamis (Dynamic Topic Modeling):

Penelitian dapat diperluas dengan menambahkan dimensi waktu (*temporal dynamics*) untuk mengamati pergeseran dan evolusi topik percakapan dari waktu ke waktu (*topic drift*), sehingga tren pembicaraan komunitas dapat dipetakan secara kronologis per periode tertentu.

3. Integrasi Analisis Wacana Lanjutan:

Pengembangan dapat mengombinasikan pemodelan topik dengan analisis sen-

timen, analisis emosi, atau analisis jejaring sosial (*Social Network Analysis*) untuk memahami polaritas opini anggota kelompok dan pola interaksi sosial di dalam setiap tema pembicaraan.

4. **Pengujian pada Domain dan Format Perangkat Beragam:**

Disarankan untuk menguji generalisabilitas model pada domain percakapan grup yang berbeda (seperti grup koordinasi kerja, komunitas akademik, atau layanan publik) serta memperluas format data masukan dari sistem operasi lain (misalnya berkas ekspor chat dari perangkat iOS).

5.2.2 **Saran untuk Praktisi dan Pengembangan Terapan**

1. **Dukungan Multi-Platform Aplikasi Pesan Instan:**

Pengembang aplikasi dapat menambahkan fitur penguraian (*parser*) untuk platform pesan instan lainnya, seperti Telegram, Discord, atau Slack, sehingga platform web analisis ini dapat digunakan secara universal oleh berbagai komunitas digital.

2. **Peningkatan Skalabilitas dan Manajemen Antrean Server:**

Untuk implementasi pada lingkungan produksi berskala besar dengan banyak pengguna bersamaan (*concurrent users*), disarankan untuk mengintegrasikan sistem antrean tugas terdistribusi (seperti Celery dan Redis) serta orkestrasi kontainer (Docker/Kubernetes).

3. **Fitur Ekspor Laporan dan Notifikasi Berkala:**

Disarankan untuk menambahkan fitur ekspor laporan hasil analisis topik ke dalam format PDF/Excel interaktif serta modul ringkasan berkala yang dapat dikirimkan secara otomatis kepada administrator grup.

DAFTAR PUSTAKA

- Abdelrazek, A., Eid, Y., Gawish, E., Medhat, W., and Hassan, A. (2023). Topic modeling algorithms and applications: A survey. *Information Systems*, 112:102131.
- Alzu'bi, A. and Barham, M. (2022). Automatic birch thresholding with features transformation for hierarchical breast cancer clustering. *International Journal of Electrical and Computer Engineering (IJECE)*, 12(2):1498–1507.
- Banerjee, S. and Pan, A. (2024). From colonial legacies to linguistic inclusion: A bertopic enhanced bibliometric insight into global south higher education. *IEEE Access*, 12:117418–117435.
- Churchill, R. and Singh, L. (2022). The evolution of topic modeling. *ACM Comput. Surv.*, 54(10s).
- Dieng, A. B., Ruiz, F. J. R., and Blei, D. M. (2020). Topic modeling in embedding spaces. *Transactions of the Association for Computational Linguistics*, 8:439–453.
- Egger, R. and Yu, J. (2022). A topic modeling comparison between lda, nmf, top2vec, and bertopic to demystify twitter posts. *Frontiers in Sociology*, Volume 7 - 2022.
- Grootendorst, M. (2022). Bertopic: Neural topic modeling with a class-based tf-idf procedure.
- Janssens, W., Bogaert, M., and van den Poel, D. (2025). A comparative analysis of topic reduction techniques for bertopic. *IEEE Access*, 13:204087–204103.
- Jesse, M., Bauer, C., and Jannach, D. (2022). Intra-list similarity and human diversity perceptions of recommendations: the details matter. *User Modeling and User-Adapted Interaction*, 33(4):769–802.
- Jian, F., Huang, J. X., Zhao, J., Ying, Z., and Wang, Y. (2020). A topic-based


- term frequency normalization framework to enhance probabilistic information retrieval. *Computational Intelligence*, 36(2):486–521.
- Kharisudin, I. and Masri'an, H. (2022). Topic modeling on whatsapp user reviews using latent dirichlet allocation. *Scientific Journal of Informatics*, 9:51–62.
- Koto, F., Lau, J. H., and Baldwin, T. (2021). Indobertweet: A pretrained language model for indonesian twitter with effective domain-specific vocabulary initialization. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP 2021)*.
- Koto, F., Rahimi, A., Lau, J., and Baldwin, T. (2020). Indolem and indobert: A benchmark dataset and pre-trained language model for indonesian nlp.
- Kumar, R. P. and Naik, N. M. (2023). Whatsapp chat analyzer using machine learning and natural language processing. In *2023 2nd International Conference on Futuristic Technologies (INCOFT)*, pages 1–6.
- McInnes, L., Healy, J., and Melville, J. (2018). Umap: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*.
- Mohta, A., Jain, A., Saluja, A., and Dahiya, S. (2020). Pre-processing and emoji classification of whatsapp chats for sentiment analysis. In *2020 Fourth International Conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud) (I-SMAC)*, pages 514–519.
- Muhajir, M., Gunardi, G., Danardono, D., and Rosadi, D. (2025). Integrating indobert and balanced iterative reducing and clustering using hierarchies of bertopic in indonesian short text. *IAES International Journal of Artificial Intelligence (IJ-AI)*, 14:4192.
- Prayogi, A., Novriyenny, N., and Prahmana, I. G. (2025). Dinamika sentimen komunikasi mahasiswa dan dosen dengan pemanfaatan analisis pesan whatsapp akademis menggunakan machine learning. *Repeater: Publikasi Teknik Informatika dan Jaringan*, 3(2):45–54.
- Rani, S. J., Prabhu, T., and Chellam, J. A. I. (2022). Whatsapp sentiment analysis using r. In *2022 3rd International Conference for Emerging Technology (INCET)*, pages 1–4. IEEE.

- Retna, V. A., Brundha, P., and RajKumar, G. (2021). People’s behaviour analysis in chat message using natural language processing. In *2021 Third International Conference on Intelligent Communication Technologies and Virtual Mobile Networks (ICICV)*, pages 1128–1133.
- Röder, M., Both, A., and Hinneburg, A. (2015). Exploring the space of topic coherence measures. In *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining, WSDM ’15*, page 399–408, New York, NY, USA. Association for Computing Machinery.
- Rushkin, I. (2020). Document similarity from vector space densities. *CoRR*, abs/2009.00672.
- Shan, X., Liu, C., Xia, Y., Chen, Q., Zhang, Y., Luo, A., and Luo, Y. (2020). BI-SON: bm25-weighted self-attention framework for multi-fields document search. *CoRR*, abs/2007.05186.
- Siregar, U. A., Ramadani, N., and Siregar, F. P. R. (2025). Syntactic analysis in whatsapp conversations among peers. *Jurnal Hata Poda*, 4(2):150–157.
- Sutarma, I. G. P. (2017). Analisis wujud bentuk linguistik dalam penggunaan bahasa indonesia di media sosial “whatsapp”. *Soshum: Jurnal Sosial dan Humaniora*, 6(3):227.
- WhatsApp Inc. (2026). Tentang whatsapp. Diakses pada 7 Januari 2026.
- Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., and Purwarianti, A. (2020). Indonlu: Benchmark and resources for evaluating indonesian natural language understanding. In *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*.
- Zhang, T., Ramakrishnan, R., and Livny, M. (1996). Birch: an efficient data clustering method for very large databases. *SIGMOD Rec.*, 25(2):103–114.
- Zhang, T., Ramakrishnan, R., and Livny, M. (1997). Birch: A new data clustering algorithm and its applications. *Data Min. Knowl. Discov.*, 1(2):141–182.
- Zhao, H., Du, L., Buntine, W., and Zhou, M. (2018). Inter and intra topic struc-

ture learning with word embeddings. In *International Conference on Machine Learning*, pages 5892–5901. PMLR.


LAMPIRAN

1 Lampiran - Alur Implementasi Sistem



Gambar 1: Alur Implementasi Sistem

2 Lampiran - Alur Teknis Pemrosesan Sistem Web



Gambar 2: Alur Teknis Pemrosesan Sistem Web

3 Lampiran - Surat Izin Penelitian dari Kampus

Dokumen administratif berupa Surat Izin Penelitian resmi dari pihak kampus untuk permohonan pengambilan data percakapan grup WhatsApp Komunitas Buku.



KEMENTERIAN PENDIDIKAN TINGGI,
SAINS, DAN TEKNOLOGI
UNIVERSITAS JEMBER
FAKULTAS ILMU KOMPUTER
Jalan Kalimantan No. 37, Kampus Bumi Tegal Boto, Jember 68121
Telp. (0331) 326911, Fax. (0331) 326911
Laman : <https://ilkom.unej.ac.id>

Nomor : 3142/DST/UN25.B15/SP/2026 22 Juni 2026
Perihal : Permohonan Izin Penelitian

Kepada Yth. Komunitas Buku Book Clan pada Platform WhatsApp
di tempat

Dalam rangka penyelesaian skripsi mahasiswa Fakultas Ilmu Komputer Universitas Jember, kami mohon dengan hormat bapak/ibu dapat memberikan izin untuk melakukan kegiatan penelitian bagi mahasiswa yang nama dan kegiatan yang dilakukan tersebut dibawah ini :

Nama / NIM : Moh. Yusril Maqoshidana (222410102064)
Program Studi : Teknologi Informasi
No. HP : 085161558904
Kegiatan : Permintaan export data pesan whatsapp
Judul Skripsi : SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB
MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN
BIRCH CLUSTERING
Tempat Kegiatan : Komunitas Buku Book Clan pada Platform WhatsApp
Periode Kegiatan : Mei - Juli 2026

Demikian permohonan kami, atas perhatian dan kerjasamanya yang baik diucapkan terima kasih.



Wakil Dekan Bidang Akademik,

Achmad Maududie., ST., M.Sc
NIP. 197004221995121001




Gambar 3: Surat Izin Penelitian dari Kampus


4 Lampiran - Bukti Persetujuan Admin Grup WhatsApp

Tangkapan layar persetujuan tertulis dari administrator grup WhatsApp Komunitas Buku untuk penggunaan riwayat percakapan sebagai dataset penelitian den-


gan syarat penyamaran identitas.



(a) Bukti Persetujuan 1



(b) Bukti Persetujuan 2



(c) Bukti Persetujuan 3

Gambar 4: Bukti Persetujuan Admin Grup WhatsApp

5 Lampiran - Hasil Pengujian Fungsional Sistem (Black-Box Testing)

Rincian 34 skenario kasus uji fungsional sistem menggunakan metode *Black-Box Testing* yang mengevaluasi perilaku masukan dan keluaran antarmuka web (*frontend*) serta layanan API (*backend*).

Tabel 1: Hasil Pengujian Fungsional Sistem (*Black-Box Testing*)

ID Uji	Fitur / Modul	Skenario Pengujian	Langkah-langkah Pengujian	Data Uji / Input	Hasil yang Diharapkan	Hasil
1. Modul Landing Page & Navigasi Utama (/ & /about)						
TC-NAV-01	Landing Page	Membuka rute utama aplikasi	1. Buka browser. 2. Akses <code>http://localhost:5173/</code> .	URL: /	Halaman Beranda (<i>HomeView</i>) tampil dengan hero section, deskripsi fitur, dan tombol CTA "Mulai Analisis Obrolan".	Valid
TC-NAV-02	Navigasi CTA	Menekan tombol CTA "Mulai Analisis"	1. Berada di halaman /. 2. Klik tombol "Mulai Analisis Obrolan".	Klik Tombol	Pengguna diarahkan secara mulus ke halaman wizard upload (<i>/upload</i>).	Valid
TC-NAV-03	Halaman About	Membuka rute tentang aplikasi	1. Klik menu "Tentang" pada Navbar. 2. Atau akses <code>http://localhost:5173/about</code> .	URL: /about	Halaman <i>AboutView</i> tampil menjelaskan metodologi BERTopic, BIRCH Clustering, dan IndoBERTweet.	Valid
TC-NAV-04	Navbar Responsive	Pengujian tampilan navbar di layar HP/Mobile	1. Buka DevTools (F12) → Switch to Mobile View (width < 640px). 2. Amati elemen navbar.	Mobile Screen	Elemen navbar menyesuaikan layar (<i>responsive layout</i>), menu collapse/hamburger berjalan lancar.	Valid
2. Modul Wizard Upload & Filter (/upload) - Step 1: Upload File						
TC-UPL-01	Upload .txt Valid	Mengunggah berkas ekspor obrolan <i>.txt</i>	1. Buka rute <i>/upload</i> (Step 1). 2. Drag & drop atau Browse file <i>.txt</i> ekspor WhatsApp valid.	File: <i>what-sapp_chat.txt</i>	File berhasil diuraikan (<i>parsed</i>), indikator nama file dan ukuran (KB) muncul, tombol "Selanjutnya" aktif.	Valid
TC-UPL-02	Upload .zip Valid	Mengunggah berkas ekspor obrolan terkompresi <i>.zip</i>	1. Buka <i>/upload</i> . 2. Pilih file <i>.zip</i> yang berisi obrolan WhatsApp.	File: <i>What-sApp_Chat.zip</i>	File <i>.zip</i> berhasil diekstrak di client-side, pesan terbaca, tombol "Selanjutnya" aktif.	Valid
TC-UPL-03	Format Tidak Valid	Mengunggah berkas dengan format selain <i>.txt</i> / <i>.zip</i>	1. Buka <i>/upload</i> . 2. Pilih file format <i>.pdf</i> , <i>.png</i> , atau <i>.docx</i> .	File: <i>dokumentasi.pdf</i>	Tampil pesan peringatan merah "Warning: Format berkas tidak didukung...", file ditolak, tombol "Selanjutnya" tetap disabled.	Valid

ID Uji	Fitur / Modul	Skenario Pengujian	Langkah-langkah Pengujian	Data Uji / Input	Hasil yang Diharapkan	Hasil
TC-UPL-04	File Korup / Kosong	Mengunggah file .txt kosong tanpa struktur obrolan	1. Buat file <i>empty.txt</i> (0 byte). 2. Upload file tersebut ke DropZone.	File: <i>empty.txt</i>	Tampil pesan kesalahan "Gagal memproses berkas chat / tidak ada pesan valid", sistem menolak file.	Valid
TC-UPL-05	Hapus File (Clear)	Batalan/hapus pilihan file yang sudah diunggah	1. Upload file .txt valid. 2. Klik ikon/tombol "Clear / Hapus File".	Klik Clear	Informasi file terhapus, DropZone kembali ke state kosong awal, tombol "Selanjutnya" kembali disabled.	Valid
TC-UPL-06	Navigasi Step 1 → 2	Berpindah ke Step 2 Filter Rentang Waktu	1. Upload file .txt valid. 2. Klik tombol "Selanjutnya".	Klik Selanjutnya	Tampilan berpindah ke Step 2 (Filter Tanggal) . Header Stepper menunjukkan Step 2 aktif.	Valid
3. Modul Wizard Upload & Filter (upload) - Step 2: Filter Rentang Waktu						
TC-FLT-01	Visualisasi Grafik	Memeriksa grafik aktivitas obrolan harian	1. Berada di Step 2. 2. Amati grafik <i>TimeRangeFilter</i> .	Data Obrolan	Grafik batang/garis keaktifan harian obrolan dari tanggal awal hingga akhir berhasil dirender.	Valid
TC-FLT-02	Slider Rentang Tanggal	Menggeser slider rentang tanggal obrolan	1. Geser handle slider kiri dan kanan (misal 20% – 80%).	Slider Drag	Label tanggal awal dan tanggal akhir diperbarui secara real-time sesuai rentang yang dipilih.	Valid
TC-FLT-03	Navigasi Kembali	Menekan tombol "Kembali" ke Step 1	1. Berada di Step 2. 2. Klik tombol "Kembali".	Klik Kembali	Tampilan kembali ke Step 1 (Upload File) dengan file yang sudah dipilih sebelumnya tetap tersimpan.	Valid
TC-FLT-04	Mulai Analisis	Menekan tombol "Mulai Analisis"	1. Tentukan rentang tanggal. 2. Klik tombol "Mulai Analisis".	Klik Mulai Analisis	Aplikasi melakukan pemotongan tanggal, anonimisasi pesan client-side, upload CSV ke server, dan pindah ke Step 3 (Analisis AI) .	Valid
4. Modul Wizard Upload & Filter (upload) - Step 3: Progress Analisis AI (SSE)						
TC-ANL-01	Terminal Progress	Memantau log proses analisis AI secara real-time	1. Berada di Step 3. 2. Perhatikan <i>TerminalSimulator</i> .	SSE Event Stream	8 tahapan proses (Preprocessing, IndoBERTweet, UMAP, BIRCH, BM25, metrik) berjalan berurutan dengan indikator running → completed.	Valid
TC-ANL-02	Auto Redirection	Menguji perpindahan otomatis setelah analisis selesai	1. Tunggu hingga tahapan ke-8 selesai (status <i>done: true</i>).	Auto Event	Setelah jeda singkat (~800ms), aplikasi secara otomatis melakukan redirect ke rute <i>/results</i> .	Valid

6. Modul Detail Topik & Konteks Pesan (/results/topics/:topicId)

ID Uji	Fitur / Modul	Skenario Pengujian	Langkah-langkah Pengujian	Data Uji / Input	Hasil yang Diharapkan	Hasil
TC-TPC-01	Navigasi Ke Detail Topik	Membuka halaman detail topik dari dashboard	1. Berada di <i>/results</i> . 2. Klik salah satu kartu topik (misal Topik #0).	Klik TopicCard	Pengguna diarahkan ke URL <i>http://localhost:5173/results/topics/0</i> . Halaman menampilkan label topik, kata kunci, dan daftar pesan klaster.	Valid
TC-TPC-02	Filter Search Pesan	Menguji pencarian kata kunci di dalam topik	1. Berada di detail topik. 2. Ketik kata kunci pada kolom pencarian pesan.	Input: <i>tugas</i>	Daftar pesan terfilter secara otomatis menampilkan pesan yang mengandung kata <i>tugas</i> .	Valid
TC-TPC-03	Modal Konteks Pesan	Membuka modal konteks percakapan di sekitar pesan	1. Klik ikon / tombol "Konteks" pada salah satu baris pesan. 2. Amati modal yang muncul.	Klik Konteks Pesan	Modal <i>MessageContextModal</i> terbuka menampilkan 4 pesan sebelum dan 4 pesan sesudah, dengan pesan pilihan di-highlight.	Valid
TC-TPC-04	Tutup Modal Konteks	Menutup modal konteks percakapan	1. Klik ikon silang (X) atau area luar modal konteks.	Klik Close	Modal konteks tertutup dan pengguna kembali ke daftar pesan topik.	Valid
TC-TPC-05	Kembali ke Results	Menekan tombol "Kembali ke Hasil Analisis"	1. Berada di detail topik. 2. Klik tombol "Kembali".	Klik Kembali	Pengguna kembali ke dashboard <i>/results</i> tanpa kehilangan data analisis session tersebut.	Valid
7. Pengujian Keamanan Rute (Route Guard) & Session Persistence						
TC-SEC-01	Akses Direct <i>/results</i> Tanpa Session	Membuka URL <i>/results</i> langsung tanpa upload file	1. Buka tab baru / hapus <i>sessionStorage</i> . 2. Ketik langsung URL <i>http://localhost:5173/results</i> .	Direct URL Access	Route guard memblokir akses dan otomatis me-redirect pengguna ke rute <i>/upload</i> .	Valid
TC-SEC-02	Akses Direct <i>/results/topics/0</i> Tanpa Session	Membuka URL detail topik tanpa session aktif	1. Hapus <i>sessionStorage</i> . 2. Akses URL <i>http://localhost:5173/results/topics/0</i> .	Direct URL Access	Route guard memblokir akses dan me-redirect pengguna ke rute <i>/upload</i> .	Valid
TC-SEC-03	Akses Direct <i>/upload</i> Saat Session Aktif	Membuka URL <i>/upload</i> saat session analisis masih ada	1. Lakukan analisis hingga berhasil di <i>/results</i> . 2. Ubah URL browser secara manual ke <i>/upload</i> .	Direct URL Access	Route guard mendeteksi <i>sessionStorage</i> aktif dan otomatis me-redirect kembali ke <i>/results</i> .	Valid
TC-SEC-04	Refresh Halaman (F5) di Dashboard	Menekan tombol F5 saat berada di <i>/results</i>	1. Berada di <i>/results</i> . 2. Tekan F5 / Refresh browser.	Page Refresh (F5)	Aplikasi membaca <i>sessionId</i> dari <i>sessionStorage</i> , mengunduh ulang data overview dari backend, dan tetap berada di <i>/results</i> .	Valid

ID Uji	Fitur / Modul	Skenario Pengujian	Langkah-langkah Pengujian	Data Uji / Input	Hasil yang Diharapkan	Hasil
TC-SEC-05	Tombol Back Browser	Menekan tombol Back browser dari <i>/results</i>	1. Dari <i>/results</i> , tekan tombol "Back" di browser.	Browser Back	Route guard mencegah tampilan bug dan menangani rute secara konsisten.	Valid