SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING

Diajukan guna memenuhi salah satu syarat memperoleh gelar Sarjana pada Program Studi Teknologi Informasi

SKRIPSI

Oleh:

Moh. Yusril Maqoshidana

NIM 222410102064

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI

UNIVERSITAS JEMBER

FAKULTAS ILMU KOMPUTER

PROGRAM STUDI TEKNOLOGI INFORMASI

JEMBER

2026

PERSEMBAHAN

Halaman ini saya persembahkan kepada:

1. Allah SWT, atas segala rahmat, karunia, serta kemudahan yang diberikan sehingga penulis dapat menyelesaikan skripsi ini dengan baik.
2. Bapak Subono dan Ibu Marsidah yang selalu mendoakan yang terbaik, mendukung segala usaha, serta selalu sabar dan percaya hingga sampai penulis mampu menyelesaikan pendidikan.
3. Bapak Dr. Brian Rizqi Paradisiaca Darnoto, S.Kom., M.Kom selaku Dosen Pembimbing Utama yang telah meluangkan waktu, memberikan arahan, bimbingan, serta masukan yang berharga selama proses penyusunan skripsi ini.
4. Ibu Khoirunnisa' Afandi, S.Kom., M.Kom dan Bapak Dony Bahtera Firmawan, S.Kom., M.Kom selaku Dosen Penguji yang memberikan saran dan masukan dalam proses pengembangan skripsi.
5. Dosen Fakultas Ilmu Komputer, Universitas Jember yang telah memberikan ilmu dan pengalaman yang berharga selama masa perkuliahan.
6. Sahabat yang telah memberikan dukungan, semangat, serta bantuan selama proses penyusunan skripsi ini.

MOTTO

“ Aku telah berupaya tanpa henti untuk tidak mencemooh, tidak meratapi, tidak menghina tindakan manusia, tetapi untuk memahaminya. ”

(Baruch Spinoza)

“ Your worst sin is that you have destroyed and betrayed yourself for nothing. ”

(Fyodor Dostoevsky)

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini:

Nama: Moh. Yusril Maqoshidana

NIM: 222410102064

Dengan ini menyatakan bahwa skripsi yang berjudul: *Sistem Analisis Topik Grup WhatsApp Berbasis Web Menggunakan BERTopic dengan IndoBERTweet dan BIRCH Clustering* adalah benar-benar hasil karya saya sendiri. Saya juga menyatakan bahwa dalam skripsi ini tidak terdapat karya yang pernah diajukan untuk memperoleh gelar sarjana atau gelar lainnya di mana pun.

Saya bertanggung jawab atas kebenaran dan keorisinalan isi skripsi ini. Apabila dikemudian hari terbukti bahwa skripsi ini mengandung unsur plagiasi, maka saya siap menanggung akibat hukum yang berlaku.

Jember, 20 Oktober 2026

Yang menyatakan,

Moh. Yusril Maqoshidana

NIM 222410102064

HALAMAN PERSETUJUAN

Skripsi berjudul *"SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING"* telah diuji dan disetujui oleh Fakultas Ilmu Komputer Universitas Jember pada:

Hari : Selasa

Tanggal : 20 Oktober 2026

Tempat : Fakultas Ilmu Komputer Universitas Jember

Pembimbing Tanda Tangan

1. Pembimbing Utama

   Nama : Dr. Brian R. P. Darnoto, S.Kom., M.Kom (.....)

   NIP : 199804272024061001

Penguji

1. Penguji Utama

   Nama : Khoirunnisa' Afandi, S.Kom., M.Kom (.....)

   NIP : 199412282024062001

2. Penguji Anggota 1

   Nama : Dony Bahtera Firmawan, S.Kom., M.Kom (.....)

   NIP : 199711202024061001

ABSTRAK

Tingginya volume percakapan pada grup WhatsApp kerap memicu fenomena *information overload*, yang menyulitkan pengguna dalam mengikuti dinamika diskusi dan menyaring informasi penting. Di sisi lain, kerangka kerja pemodelan topik standar BERTopic berbasis HDBSCAN secara inheren membuang 42%–56% pesan sebagai pencilan (*outlier*), sehingga menghilangkan banyak konteks esensial pada teks obrolan yang pendek dan informal. Penelitian ini bertujuan mengembangkan modifikasi arsitektur BERTopic yang mengintegrasikan model *embedding* IndoBERTweet, pengklasteran hierarkis BIRCH, dan representasi kata kunci BM25 untuk meminimalkan proporsi *outlier* sekaligus meningkatkan koherensi serta keberagaman topik. Metodologi penelitian melibatkan pemodelan korpus 51.584 pesan bersih grup WhatsApp melalui *pipeline* algoritma *ImprovedBirch* dengan reduksi dimensi UMAP, ambang *micro-cluster* adaptif, dan reduksi topik otomatis. Evaluasi kurva pembelajaran membuktikan keunggulan model usulan, yang berhasil membatasi proporsi *outlier* hingga hanya 7,21% (mempertahankan 92,79% cakupan data percakapan) serta menghasilkan koherensi semantik (C_{NPMI}) positif sebesar +0,1075 dan keberagaman topik (*Topic Diversity*) sebesar 0,9875, jauh melampaui performa model *baseline* HDBSCAN. Temuan ini menyimpulkan bahwa pengklasteran hierarkis efektif memitigasi fragmentasi pesan tanpa mendegradasi kualitas representasi semantik. Model akhir berhasil diimplementasikan ke dalam prototipe aplikasi web analitik interaktif yang dilengkapi pemantauan progres *real-time* berbasis SSE dan penelusuran konteks pesan (*traceability*) guna memfasilitasi eksplorasi dinamika obrolan secara efisien.

Kata Kunci: *BERTopic, IndoBERTweet, BIRCH Clustering, BM25, Pemodelan Topik, Analisis Grup WhatsApp*

ABSTRACT

High message activity in WhatsApp groups frequently causes information overload, making it difficult for members to track discussion dynamics and extract key insights. While topic modeling can automate thematic extraction, the standard BERTopic framework relying on HDBSCAN inherently discards up to 42%–56% of messages as outliers, causing critical context loss on short and informal conversational texts. This research aims to develop an enhanced BERTopic architecture that integrates the IndoBERTweet contextual embedding model, BIRCH hierarchical clustering, and the BM25 weighting scheme to minimize outlier rates while improving topic coherence and diversity. The methodology involves processing a corpus of 51,584 cleaned WhatsApp messages through an improved BIRCH clustering pipeline featuring dynamic micro-cluster thresholding and automatic topic reduction. Contextual representations generated by IndoBERTweet are dimensionally reduced via UMAP before being structured into cohesive thematic sub-clusters. The model evaluation across a multi-stage learning curve demonstrated outstanding performance, successfully restricting the outlier rate to just 7.21% (retaining 92.79% data coverage) while achieving a positive topic coherence (C_{NPMI}) of +0.1075 and a topic diversity of 0.9875, significantly outperforming HDBSCAN-based baselines. Furthermore, the comparative analysis proved that hierarchical clustering effectively resolves topic fragmentation on short texts without sacrificing semantic quality. The study concludes that adapting hierarchical clustering within the BERTopic pipeline serves as an effective mechanism to capture scattered conversational context. The resulting model was successfully integrated into an interactive web application prototype featuring real-time SSE progress streaming and message context traceability, enabling users to efficiently explore group discussion dynamics.

Keywords: *BERTopic, IndoBERTweet, BIRCH Clustering, BM25, Topic Modeling, WhatsApp Group Analysis*

RINGKASAN

Penelitian ini dilatarbelakangi oleh tingginya volume pertukaran pesan pada grup WhatsApp interaktif yang kerap memicu fenomena *information overload*. Anggota grup maupun pengelola komunitas menghadapi kesulitan besar dalam mengikuti alur diskusi, menyaring pokok permasalahan, serta memetakan topik penting tanpa membaca ribuan riwayat pesan secara manual. Penerapan pemodelan topik konvensional berbasis BERTopic standar terbentur oleh karakteristik teks obrolan yang pendek, sarat singkatan, dan informal, di mana algoritma HDBSCAN secara inheren membuang hingga 42%–56% pesan sebagai pencilan (*outlier*). Untuk mengatasi masalah kehilangan konteks tersebut, penelitian ini mengembangkan modifikasi arsitektur BERTopic yang memadukan keunggulan model representasi kontekstual IndoBERTweet, pengklasteran hierarkis BIRCH, serta skema pembobotan BM25.

Data mentah yang digunakan bersumber dari riwayat percakapan grup WhatsApp Komunitas Buku sepanjang 2023–2026 sebanyak 91.868 pesan teks. Korpus tersebut dibersihkan melalui tahapan *preprocessing* yang menghasilkan 51.584 dokumen representatif. Vektor semantik dibangkitkan menggunakan model IndoBERTweet dan direduksi dimensinya melalui UMAP sebelum diproses oleh algoritma pengklasteran usulan *ImprovedBirch*. Mekanisme adaptasi ambang *micro-cluster* dinamis dan penyaringan berbasis deviasi sentroid pada model ini memungkinkan sistem mempertahankan pesan-pesan percakapan yang tersebar secara fleksibel, sementara skema BM25 secara akurat mengekstraksi kata kunci topik tanpa terdistorsi oleh tingginya variasi frekuensi kata pada teks pendek.

Hasil pengujian eksperimental kurva pembelajaran membuktikan keunggulan komprehensif arsitektur yang diusulkan. Algoritma usulan berhasil menekan proporsi *outlier* secara drastis hingga tersisa 7,21% (mempertahankan 92,79% cakupan data) dengan skor koherensi semantik (C_{NPMI}) positif sebesar +0,1075 dan keberagaman topik (*Topic Diversity*) mencapai 0,9875. Analisis komparatif membuktikan bahwa pengklasteran hierarkis BIRCH secara signifikan mengungguli algoritma bawaan

HDBSCAN dalam mencegah pembuangan data obrolan tanpa mengorbankan kepadatan klaster. Arsitektur pemodelan topik ini kemudian diimplementasikan ke dalam aplikasi web analitik interaktif berbasis FastAPI dan Vue.js yang dilengkapi pemantauan progres *real-time* berbasis SSE serta fitur penelusuran konteks pesan (*traceability*). Secara keseluruhan, integrasi pengklasteran hierarkis ke dalam arsitektur BERTopic terbukti memberikan kontribusi krusial sebagai jembatan yang menghubungkan fragmen obrolan informal menjadi wawasan tematik yang koheren, terukur, dan bernilai guna.

PRAKATA

Puji syukur kehadirat Allah SWT atas segala berkah dan rahmat yang telah diberikan sehingga penulis mampu menyelesaikan penelitian yang berjudul *"SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING"*. Penelitian ini merupakan salah satu syarat akademik dalam menyelesaikan pendidikan Strata Satu (S1) pada Program Studi Teknologi Informasi Fakultas Ilmu Komputer Universitas Jember.

Penulis menyadari bahwa dalam proses penelitian dan penulisan skripsi ini, banyak pihak yang telah memberikan bimbingan, dukungan, dan bantuan. Oleh karena itu, pada kesempatan ini penulis dengan sepenuh hati mengucapkan terima kasih kepada:

1. Bapak Prof. Drs. Antonius Cahya Prihandoko, M.App.Sc., Ph.D., selaku Dekan Fakultas Ilmu Komputer Universitas Jember.
2. Dr. Brian Rizqi Paradisiaca Darnoto, S.Kom., M.Kom selaku Pembimbing Utama yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan bimbingan, diskusi, serta arahan yang sangat berharga sejak awal hingga skripsi ini selesai.
3. Ibu Khoirunnisa' Afandi, S.Kom., M.Kom dan Bapak Dony Bahtera Firmawan, S.Kom., M.Kom selaku Dosen Penguji yang telah memberikan ujian, saran, dan masukan yang konstruktif demi kesempurnaan laporan skripsi ini.
4. Bapak Yudha Alif Auliya, S.Kom., M.Kom. selaku Dosen Pembimbing Akademik yang telah memberikan bimbingan dan arahan selama masa studi di Program Studi Teknologi Informasi.
5. Para dosen dan staf Fakultas Ilmu Komputer, Universitas Jember yang telah membantu selama proses akademik.
6. Bapak Subono dan Ibu Marsidah selaku orang tua yang telah memberikan doa dan dukungan moral dan material selama penulis menempuh pendidikan

hingga menyelesaikan pendidikan jenjang S1.

7. Sahabat yang telah memberikan semangat, bantuan, dan dukungan selama proses penelitian ini.
8. Seluruh pihak dalam komunitas buku yang telah memberikan kepercayaan dan bantuan dalam proses penelitian ini.

Penulis menyadari bahwa skripsi ini masih memiliki berbagai kekurangan, baik dalam penulisan maupun isi. Oleh karena itu, penulis mengharapkan kritik dan saran yang sifatnya membangun dari pembaca untuk perbaikan di masa mendatang. Akhir kata, semoga penelitian ini dapat memberikan manfaat bagi kemajuan ilmu pengetahuan dan dapat dijadikan sebagai bahan referensi bagi penelitian-penelitian selanjutnya.

Jember, 20 Oktober 2026

Moh. Yusril Maqoshidana
NIM 222410102064

DAFTAR ISI

PERSEMBAHAN . . . . . **i**

MOTTO . . . . . **ii**

PERNYATAAN ORISINALITAS . . . . . **iii**

HALAMAN PERSETUJUAN . . . . . **iv**

ABSTRAK . . . . . **v**

ABSTRACT . . . . . **vi**

RINGKASAN . . . . . **vii**

PRAKATA . . . . . **ix**

DAFTAR TABEL . . . . . **xiv**

DAFTAR GAMBAR . . . . . **xv**

DAFTAR LAMPIRAN . . . . . **xvi**

1 PENDAHULUAN **1**

1.1 Latar Belakang 1

1.2 Rumusan Masalah 2

1.3 Tujuan Penelitian 3

1.4 Manfaat Penelitian 3

1.5 Batasan Penelitian 4

2 TINJAUAN PUSTAKA **5**

2.1 Penelitian Terdahulu 5

2.2 Landasan Teori 6

2.2.1 Aplikasi WhatsApp 6

2.2.2 BERTopic 7

2.2.3 IndoBERTweet 8

2.2.4 BIRCH *Clustering* 9

2.2.5 *Topic Representation* dengan BM25 13

2.2.6 Reduksi Topik Hierarkis (*Hierarchical Topic Reduction*) . . 14

2.2.7 *Topic Coherence* 15

2.2.8 *Topic Diversity* 16

2.2.9 *Embedding Density* 16

2.2.10 *Intra-topic Similarity* 17
3 METODOLOGI PENELITIAN **18**
3.1 Jenis Penelitian 18
3.2 Objek Penelitian 18
3.3 Waktu Penelitian 18
3.4 Tahapan Penelitian 19
3.4.1 Identifikasi Masalah dan Studi Literatur 19
3.4.2 Pengumpulan Data 19
3.4.3 Praproses Data 20
3.4.4 Pembuatan Model 22
3.4.5 Evaluasi Model 24
3.4.6 Implementasi Sistem 25
3.4.7 Evaluasi Sistem 26
3.4.8 Analisis Hasil 26
3.4.9 Penarikan Kesimpulan 26
3.5 Etika Penelitian 27
4 HASIL DAN PEMBAHASAN **28**
4.1 Pengumpulan Data 28
4.2 Praproses Data 29
4.3 Pembuatan Model 31
4.3.1 Pembangkitan Vektor Embedding dengan IndoBERTweet . . 31
4.3.2 Reduksi Dimensi dengan UMAP 31
4.3.3 Pengklasteran dengan Model Usulan ImprovedBirch 32
4.3.4 Penyaringan Stopwords WhatsApp dan Representasi BM25 . 34
4.3.5 Reduksi Topik Otomatis 36
4.4 Hasil Evaluasi Model 37
4.4.1 Hasil Evaluasi Model Baseline dan Model Modified 37
4.4.2 Hasil Optimasi Model 38
4.5 Implementasi Sistem 42
4.5.1 Arsitektur Client-Server dan Keamanan Sistem 43
4.5.2 Pemrosesan Asinkron dan Antarmuka Pengguna 44
4.6 Evaluasi Sistem 45
5 KESIMPULAN DAN SARAN **46**
5.1 Kesimpulan 46

5.2 Saran 47
DAFTAR PUSTAKA **47**
LAMPIRAN **51**

DAFTAR TABEL

2.1 Tinjauan Penelitian Terdahulu 5
2.2 Perbandingan Kinerja Model pada Tujuh Tugas 9

4.1 Statistik Hasil Pengolahan Praproses Data Pada Dataset Percakapan WhatsApp 30
4.2 Perbandingan Performa 4 Model pada Korpus 100% WhatsApp . . . 39

DAFTAR GAMBAR

2.1 *Framework* BERTopic dengan modifikasi IndoBERT, BIRCH, dan BM25 (Muhajir et al., 2025) 8

3.1 Tahapan Penelitian 19

3.2 Rancangan *framework* BERTopic yang dimodifikasi pada tahap pembuatan model 22

4.1 Visualisasi Proyeksi 2D UMAP Keterpisahan Klaster dan Reduksi *Outlier Noise* 34

4.2 Distribusi 5 Kata Kunci Teratas Berbobot BM25 pada Topik Utama WhatsApp 36

4.3 Perbandingan Multi-Dimensi Metrik Evaluasi 4 Model Pemodelan Topik (Korpus 100% WhatsApp) 40

4.4 Kurva Pembelajaran (*Learning Curve*) Perbandingan Model Pemodelan Topik 41

DAFTAR LAMPIRAN

Lampiran 1. Cuplikan Data Mentah Log Obrolan WhatsApp 51
Lampiran 2. Contoh Transformasi Teks Praproses Data 52
Lampiran 3. Rincian Data Evaluasi Kurva Pembelajaran 53
Lampiran 4. Surat Izin Penelitian dari Kampus 54
Lampiran 5. Bukti Persetujuan Admin Grup WhatsApp 55
Lampiran 6. Hasil Pengujian Fungsional Sistem (*Black-Box Testing*) . . . 56
Lampiran 7. Tangkapan Layar Implementasi Antarmuka Sistem Web . . . 58

BAB 1. PENDAHULUAN

1.1 Latar Belakang

WhatsApp merupakan salah satu aplikasi pesan instan terpopuler di dunia yang banyak dimanfaatkan sebagai wadah diskusi komunitas, koordinasi tim, dan komunikasi organisasi (WhatsApp LLC, 2026; Prayogi et al., 2025). Pada grup WhatsApp yang sangat aktif dengan volume percakapan tinggi, arus pertukaran informasi berlangsung sangat cepat dan dinamis. Akumulasi pesan yang masif ini kerap menimbulkan fenomena *information overload*, di mana pengguna mengalami kesulitan dalam mengikuti alur diskusi, menyaring informasi penting, maupun mengetahui topik yang sedang dibahas tanpa membaca keseluruhan riwayat obrolan secara manual (Rani et al., 2022). Oleh karena itu, diperlukan sistem yang mampu memodelkan dan mengekstraksi topik percakapan grup WhatsApp secara otomatis.

Topic modeling merupakan teknik dalam *Natural Language Processing* (NLP) untuk menemukan struktur tematik laten dari sekumpulan dokumen teks (Abdelrazek et al., 2023). Namun, penerapan pemodelan topik pada percakapan grup WhatsApp menghadapi tantangan besar akibat karakteristik data yang berupa teks pendek, tidak terstruktur, mengandung *noise* tinggi, serta sarat fenomena *code-mixing* dan struktur kalimat eliptis yang fragmentaris (Churchill and Singh, 2022; Mohta et al., 2020; Sutarma, 2017; Siregar et al., 2025).

Meskipun arsitektur modular BERTopic terbukti unggul pada teks pendek dibandingkan metode konvensional berbasis *bag-of-words* seperti LDA dan NMF (Grootendorst, 2022; Egger and Yu, 2022), algoritma klasterisasi bawaannya, yaitu HDBSCAN, secara inheren mengeliminasi dokumen yang tidak memenuhi ambang stabilitas kepadatan sebagai *outlier* (Grootendorst, 2022; Janssens et al., 2025). Akibatnya, hingga 23%–24% pesan obrolan dapat terbuang dan tidak terpetakan ke dalam topik manapun (Muhajir et al., 2025).

Untuk mengatasi keterbatasan tersebut, penelitian ini mengusulkan modifikasi

pada *framework* BERTopic dengan mengganti HDBSCAN menggunakan algoritma BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) (Zhang et al., 1996) dan mengganti c-TF-IDF dengan skema BM25 (Jian et al., 2020). Algoritma BIRCH mampu mengelompokkan dokumen berukuran besar secara efisien ke dalam struktur *CF-Tree* dan menugaskan data ke klaster yang valid sehingga menekan proporsi *outlier* hingga rentang 1%–5% pada teks pendek (Zhang et al., 1996; Ramadhani et al., 2020; Muhajir et al., 2025). Pada lapisan *embedding*, IndoBERTweet dimanfaatkan karena dilatih secara khusus pada korpus media sosial berbahasa Indonesia, sehingga mampu menangkap konteks semantik bahasa percakapan informal secara lebih optimal (Koto et al., 2021; Muhajir et al., 2025). Sementara itu, penerapan BM25 pada tahap representasi topik menyempurnakan c-TF-IDF dengan memperhitungkan saturasi frekuensi kata dan normalisasi panjang dokumen, sehingga kata-kata yang mendominasi frekuensi tidak mengaburkan kata kunci yang informatif (Jian et al., 2020; Muhajir et al., 2025).

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana penerapan BERTopic dengan integrasi IndoBERTweet, BIRCH *clustering*, dan representasi topik BM25 untuk mengidentifikasi topik pada percakapan grup WhatsApp berbahasa Indonesia?
2. Bagaimana kualitas topik yang dihasilkan oleh BERTopic yang diajukan dibandingkan dengan model *baseline* BERTopic berdasarkan evaluasi metrik *Topic Coherence*, *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity*?
3. Bagaimana merancang dan mengimplementasikan sistem berbasis *web* untuk analisis topik percakapan grup WhatsApp menggunakan BERTopic dengan IndoBERTweet, BIRCH *clustering*, dan BM25?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah tersebut, tujuan penelitian ini dirumuskan sebagai berikut:

1. Menerapkan BERTopic dengan model *embedding* IndoBERTweet, algoritma BIRCH sebagai metode *clustering*, dan skema BM25 sebagai representasi topik untuk mengidentifikasi topik pada percakapan grup WhatsApp berbahasa Indonesia.
2. Mengevaluasi dan membandingkan performa BERTopic yang diajukan dengan *baseline* BERTopic berdasarkan metrik *Topic Coherence*, *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity*.
3. Merancang dan mengimplementasikan sistem berbasis *web* untuk analisis topik percakapan grup WhatsApp yang memanfaatkan BERTopic dengan IndoBERTweet, BIRCH *clustering*, dan BM25 agar dapat digunakan secara praktis oleh pengguna akhir.

1.4 Manfaat Penelitian

Adapun manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan kontribusi dalam pengembangan ilmu di bidang *Natural Language Processing* (NLP), khususnya penerapan BERTopic dengan modifikasi IndoBERTweet, BIRCH *clustering*, dan BM25 untuk analisis teks percakapan informal berbahasa Indonesia.
2. Menyediakan sistem berbasis *web* yang mampu menganalisis percakapan grup WhatsApp secara otomatis serta menyajikan ringkasan topik melalui visualisasi yang intuitif.
3. Menjadi referensi akademik bagi penelitian selanjutnya terkait ekstraksi dan pemodelan topik pada data teks pendek dan pesan instan.

1.5 Batasan Penelitian

Agar penelitian ini lebih terarah dan fokus, maka ditetapkan beberapa batasan penelitian sebagai berikut:

1. Sistem hanya menganalisis percakapan teks berbahasa Indonesia dari grup WhatsApp, tidak mencakup media gambar, video, audio, maupun dokumen.
2. Data masukan pada *website* berupa berkas ekspor *chat* WhatsApp format .txt atau .zip yang diperoleh dari perangkat Android.
3. Data yang digunakan merupakan riwayat percakapan grup Komunitas Buku pada periode 2023–2026 dengan jumlah pesan sebanyak 91.868.
4. Penelitian berfokus pada pemodelan topik dan tidak mencakup analisis sentimen, klasifikasi emosi, maupun prediksi perilaku pengguna.
5. Representasi topik menggunakan metode skema pembobotan BM25 sebagai pengganti skema representasi topik bawaan BERTopic, yaitu c-TF-IDF.
6. Evaluasi dilakukan menggunakan metrik *Topic Coherence*, *Topic Diversity*, *Embedding Density*, *Intra-topic Similarity*, serta pengujian fungsional *black-box*.

BAB 2. TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Tabel 2.1: Tinjauan Penelitian Terdahulu

No	Judul Penelitian	Hasil Penelitian	Celah (*Gap*)	Kontribusi
1	*A Topic Modeling Comparison Between LDA, NMF, Top2Vec, and BERTopic to Demystify Twitter Posts* (Egger and Yu, 2022) (Jurnal Q1)	Penelitian ini membandingkan BERTopic, NMF, LDA, dan Top2Vec pada data Twitter. BERTopic direkomendasikan untuk pendekatan berbasis *embedding*, sedangkan NMF menjadi alternatif tradisional yang lebih unggul untuk data media sosial.	Meskipun BERTopic menunjukkan performa yang baik, penggunaan *embedding* multilingual dan *clustering* default (HDBSCAN) masih memiliki keterbatasan dalam mengatasi *outlier* dan meningkatkan stabilitas topik. Belum ada sistem aplikatif yang dikembangkan.	Penelitian ini menggunakan IndoBERTweet sebagai model *embedding* khusus bahasa Indonesia serta BIRCH sebagai alternatif HDBSCAN untuk meningkatkan stabilitas *clustering* dan mengurangi *outlier*. Selain itu, dikembangkan sistem berbasis *web* untuk analisis percakapan WhatsApp.
2	*Integrating IndoBERT and BIRCH in BERTopic for Indonesian short text* (Muhajir et al., 2025) (Jurnal Q2)	Penelitian ini memodifikasi BERTopic dengan IndoBERT, BM25, dan BIRCH dengan dataset dari X, Google Reviews, dan YouTube yang bersifat teks monolog. Berhasil menurunkan *outlier* secara signifikan serta meningkatkan stabilitas topik pada teks pendek.	Pendekatan ini belum dieksplorasi pada data percakapan grup WhatsApp yang memiliki karakteristik lebih kompleks berupa *multi-turn dialogue*, evolusi percakapan yang cepat dan volume pesan yang tinggi. Selain itu, penelitian terdahulu belum menyediakan sistem aplikasi bagi pengguna akhir.	Penelitian ini mengimplementasikan arsitektur modifikasi BERTopic (IndoBERTweet, algoritma usulan BIRCH *clustering*, representasi BM25, dan reduksi topik otomatis) pada dataset percakapan grup WhatsApp yang diintegrasikan ke dalam sistem analisis interaktif untuk memvisualisasikan dinamika topik secara otomatis.
3	*BERTopic Enhanced Bibliometric Insight Into Global South Higher Education* (Banerjee and Pan, 2024) (Jurnal Q1)	Penelitian ini menyelidiki keragaman linguistik dan proses dekolonisasi dalam sistem pendidikan tinggi di wilayah Global South menggunakan kerangka kerja empiris tiga tingkat yang menggabungkan Analisis Ko-okurensi Bibliometrik (Bibliometric Co-occurrence Analysis), pemodelan topik LDA, dan pemodelan BERTopic. BERTopic menunjukkan performa lebih baik dibanding LDA dalam koherensi dan jumlah topik yang dihasilkan pada data akademik.	Penelitian tersebut belum mengeksplorasi alternatif algoritma klasterisasi yang dapat meminimalkan *outlier* sejak awal proses, serta belum menguji efektivitas BERTopic pada bahasa Indonesia dengan karakteristik teks percakapan informal yang memiliki noise tinggi dan fenomena *code-mixing*. Penelitian tersebut juga belum menyediakan sistem aplikasi bagi pengguna akhir.	Penelitian ini berkontribusi merancang algoritma pengklasteran usulan BIRCH /textitclustering yang mengombinasikan efisiensi hierarkis BIRCH dengan eliminasi pencilan terukur berbasis deviasi jarak kosinus terhadap *centroid* dan pembersihan klaster kerdil, guna menekan *outlier rate* tanpa membiarkan dokumen derau mencemari kemurnian topik utama, serta menerapkan IndoBERTweet dan BM25 yang diintegrasikan ke dalam sistem aplikasi berbasis *web* interaktif.

Berdasarkan penelitian terdahulu yang telah diulas pada Tabel 2.1, dapat disimpulkan bahwa meskipun telah banyak penelitian yang membandingkan berba-

gai model *topic modeling* untuk analisis teks pendek, hasil penelitian terdahulu menunjukkan bahwa BERTopic cenderung lebih unggul dibandingkan pendekatan konvensional pada data media sosial dan data akademik, tetapi masih memiliki keterbatasan ketika menggunakan *embedding* multilingual dan algoritma *clustering* bawaan seperti HDBSCAN. Pada sejumlah penelitian tersebut, penggunaan model yang lebih spesifik terhadap bahasa dan domain, seperti IndoBERTweet, serta algoritma BIRCH sebagai alternatif klasterisasi, terbukti menjanjikan dalam mengurangi *outlier*. Selain itu, penelitian yang telah diulas belum banyak mengeksplorasi penerapan *pipeline* BERTopic pada percakapan grup WhatsApp berbahasa Indonesia yang bersifat *multi-turn*, tidak terstruktur, banyak emoji, dan kaya *code-mixing*. Di sisi lain, penelitian terdahulu masih berfokus pada evaluasi metodologi tanpa menyediakan sistem aplikasi yang dapat digunakan langsung oleh pengguna akhir untuk menganalisis percakapan mereka sendiri.

2.2 Landasan Teori

2.2.1 Aplikasi WhatsApp

WhatsApp merupakan aplikasi pesan instan yang memungkinkan pengguna berkomunikasi melalui pesan teks, suara, gambar, video, serta fitur grup yang mendukung komunikasi banyak pengguna dalam satu ruang diskusi (Prayogi et al., 2025). Fitur grup memungkinkan pengguna tergabung dalam banyak kelompok sekaligus untuk kepentingan personal, bisnis, maupun keamanan, sehingga volume pesan sering menjadi besar dan tumpang tindih. Kondisi ini membuat percakapan grup bersifat tidak terstruktur, melibatkan banyak partisipan, dan topik pembahasan dapat berubah dengan cepat (Rani et al., 2022). Akibatnya, pengguna sering kesulitan mengikuti arah percakapan secara menyeluruh. Permasalahan inilah yang menjadi latar belakang penelitian ini, yaitu mengembangkan sistem analisis percakapan grup WhatsApp yang dapat mengidentifikasi dan memetakan topik pembahasan secara otomatis.

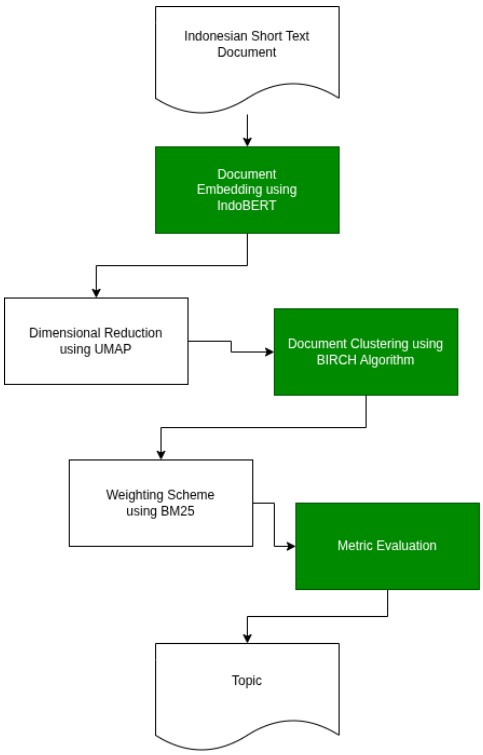
Secara linguistik, pesan WhatsApp memiliki karakteristik yang berbeda sig-

nifikan dari teks formal. Struktur kalimatnya cenderung sederhana, pendek, dan bersifat eliptis, yaitu menghilangkan unsur wajib seperti subjek atau predikat demi efisiensi (misalnya *"Mau makan?"* alih-alih *"Apakah kamu mau makan?"*), serta sering ditulis tanpa tanda baca dan secara fragmentaris ke dalam beberapa baris terpisah (Siregar et al., 2025). Dari sisi morfologi dan diksi, penggunaan singkatan tidak baku, bahasa gaul, serta campur kode (*code-mixing*) antara bahasa Indonesia, bahasa daerah, dan bahasa asing juga lazim ditemukan dalam satu kalimat yang sama (Sutarma, 2017). Karakteristik-karakteristik inilah yang menjadi dasar pertimbangan dalam merancang tahapan *preprocessing* pada penelitian ini, khususnya dalam menangani normalisasi teks tidak baku, penggabungan pesan multi-baris, serta penanganan simbol dan tanda baca sebelum data diproses oleh model *embedding*.

2.2.2 BERTopic

BERTopic adalah *framework topic modeling* berbasis *transformer* yang membentuk *embedding* dokumen dan merepresentasikan topik melalui prosedur TF-IDF berbasis kelas, sehingga dokumen dengan makna semantik serupa dapat dipetakan saling berdekatan dalam ruang vektor (Grootendorst, 2022). Pendekatan ini relevan untuk percakapan grup WhatsApp yang umumnya berupa teks pendek, berisik (*noisy*), dan tidak terstruktur, yang cenderung menimbulkan masalah kelangkaan data (*data sparsity*) pada metode pemodelan topik konvensional.

Berdasarkan Gambar 2.1, arsitektur modular *framework* BERTopic terdiri dari lima tahap utama. Tahap pertama adalah *document embedding* yang mengubah dokumen teks menjadi representasi vektor numerik berdimensi tinggi menggunakan model bahasa kontekstual seperti IndoBERTweet yang dilatih khusus pada korpus media sosial berbahasa Indonesia (Koto et al., 2021). Tahap kedua adalah *dimensionality reduction* menggunakan UMAP untuk mereduksi dimensi vektor hasil *embedding* tanpa menghilangkan struktur topologi manifold lokal dan global data (McInnes et al., 2018). Tahap ketiga adalah *clustering* yang mengelompokkan dokumen berdimensi rendah berdasarkan kemiripan semantiknya, di mana penelitian ini merancang algoritma usulan BIRCH *clustering* sebagai pengganti HDBSCAN



Gambar 2.1: *Framework* BERTopic dengan modifikasi IndoBERT, BIRCH, dan BM25 (Muhajir et al., 2025)

standar (Muhajir et al., 2025; Alzu'bi and Barham, 2022; Ramadhani et al., 2020). Tahap keempat adalah *topic representation* yang mengekstrak kata kunci paling representatif dari setiap klaster melalui skema pembobotan BM25 yang diperkaya penyaringan leksikal (Muhajir et al., 2025). Tahap kelima adalah *hierarchical topic reduction* yang menyederhanakan jumlah topik secara otomatis melalui penggabungan klaster topik berkerapatan semantik serupa guna mencegah fragmentasi topik mikro yang redundan (Grootendorst, 2022; Janssens et al., 2025).

2.2.3 IndoBERTweet

Model IndoBERTweet merupakan model bahasa pra-latih berskala besar pertama yang dirancang khusus untuk memproses data Twitter (X) berbahasa Indonesia. Model ini dikembangkan melalui pendekatan *domain-adaptive pretraining* dengan fondasi IndoBERT yang semula dilatih pada korpus formal, kemudian diadaptasi ke domain Twitter yang lebih informal. Dalam proses adaptasi tersebut, peneliti

melakukan penyesuaian kosakata domain-spesifik dan melaporkan 14.584 kosakata baru (46% dari total kosakata) yang tidak tercakup pada IndoBERT umum (Koto et al., 2021).

Tabel 2.2: Perbandingan Kinerja Model pada Tujuh Tugas

Model	**Sentiment**		**Emotion**	**Hate Speech**		**NER**		**Average**
	IndoLEM	**SmSA**	**EmoT**	**HS1**	**HS2**	**Formal**	**Informal**	
mBERT	76.6	84.7	67.5	85.1	75.1	85.2	83.2	79.6
malayBERT	82.0	84.1	74.2	85.0	81.9	81.9	81.3	81.5
IndoBERT (Wilie et al., 2020)	84.1	88.7	73.3	86.8	80.4	86.3	84.3	83.4
IndoBERT (Koto et al., 2020)	84.1	87.9	71.0	86.4	79.3	88.0	86.9	83.4
IndoBERTweet (1M steps from scratch) (Koto et al., 2021)	86.2	90.4	76.0	**88.8**	**87.5**	**88.1**	85.4	86.1
IndoBERT + Vocabulary adaptation + 200K steps (Koto et al., 2021)	**86.6**	**92.7**	**79.0**	88.4	84.0	87.7	**86.9**	**86.5**

Berdasarkan Tabel 2.2 yang diadaptasi dari Koto et al. (2021), model IndoBERTweet dan variannya secara konsisten mencapai performa tinggi pada tujuh tugas NLP berbahasa Indonesia, meliputi *sentiment analysis*, *emotion classification*, *hate speech detection*, dan *named entity recognition*. Hasil terbaik secara rata-rata ditunjukkan oleh varian IndoBERT dengan adaptasi kosakata dan pelatihan lanjutan 200K langkah (86,5), sedangkan IndoBERTweet yang dilatih dari awal juga menunjukkan kinerja kompetitif (86,1). Temuan ini memperkuat asumsi bahwa model berbasis domain media sosial berpotensi lebih sesuai untuk teks pendek, informal, dan bising seperti percakapan grup WhatsApp berbahasa Indonesia, meskipun efektivitas akhirnya tetap perlu divalidasi pada penelitian ini.

2.2.4 BIRCH *Clustering*

BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) merupakan algoritma *clustering* hierarkis berbasis pohon yang dirancang untuk menangani *dataset* berskala besar secara efisien dengan meringkas data ke dalam struktur *Clustering Feature* (CF) di memori utama (*in-memory*) (Zhang et al., 1996). Sebagai

landasan teoretis orisinil, pembentukan algoritma BIRCH pertama kali diperkenalkan oleh Zhang et al. (1996) dan kemudian diformalkan secara komprehensif oleh Zhang et al. (1997). Keunggulan mendasar dari BIRCH terletak pada kemampuannya memproses seluruh data masukan hanya dalam satu kali pemindaian (*single pass*) dengan kompleksitas waktu dan ruang linear $O(N)$, menjadikannya sangat hemat memori dan cepat pada volume data masif (Zhang et al., 1997).

Dalam konteks penerapannya pada pemodelan topik teks pendek berbahasa Indonesia, Muhajir et al. (2025) menggunakan BIRCH sebagai alternatif pengganti algoritma berbasis kepadatan seperti HDBSCAN dalam *framework* BERTopic guna mengurangi dokumen yang terbuang sebagai pencilan. Meskipun demikian, algoritma BIRCH memiliki tantangan teknis tersendiri, khususnya sensitivitas terhadap parameter ambang batas (*threshold*) serta kecenderungan menghasilkan partisi klaster berbentuk hiper-sferis (Zhang et al., 1997). Keterbatasan terkait dimensi tinggi data teks diatasi melalui reduksi dimensi UMAP sebelum klasterisasi dilakukan.

Pada tataran implementasi komputasi modern, formulasi matematis entri ringkasan tiap subklaster disimpan dalam bentuk vektor *Clustering Feature* (CF) sebagaimana didefinisikan pada studi seminal (Zhang et al., 1996) dan dipaparkan kembali pada kajian optimasi modern (Alzu'bi and Barham, 2022; Ramadhani et al., 2020):

$$CF = (N, LS, SS) \tag{2.1}$$

dengan N menyatakan jumlah total titik data dalam subklaster, $LS = \sum_{i=1}^{N} x_i$ merupakan jumlah linier (*linear sum*) dari seluruh titik data berdimensi d, dan $SS = \sum_{i=1}^{N} \|x_i\|^2$ merupakan jumlah kuadrat skalar (*square sum*) dari seluruh titik data.

Dari vektor rangkuman CF tersebut, titik pusat atau *centroid* (μ) dari subklaster dapat dihitung secara langsung tanpa perlu menyimpan seluruh titik data individual (Alzu'bi and Barham, 2022):

$$\mu = \frac{LS}{N} \tag{2.2}$$

Kekompakan (*compactness*) subklaster diukur berdasarkan nilai radius (R), yaitu jarak rata-rata dari seluruh titik data terhadap *centroid* (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$R = \sqrt{\frac{SS}{N} - \left\| \frac{LS}{N} \right\|^2} \tag{2.3}$$

Ketika sebuah titik data baru x hendak dimasukkan ke dalam subklaster, radius baru (R') dihitung dengan memanfaatkan prinsip aditivitas aljabar CF tanpa menghitung ulang seluruh data dari awal (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$R' = \sqrt{\frac{SS + \|x\|^2}{N+1} - \left\| \frac{LS + x}{N+1} \right\|^2} \tag{2.4}$$

Titik baru x hanya dapat diserap ke dalam subklaster daun (*CF-Leaf*) apabila nilai $R' \leq T$, di mana T adalah parameter ambang batas (*threshold*) yang ditentukan. Parameter faktor percabangan (*branching factor*, B) membatasi jumlah maksimum anak pada tiap simpul non-daun pohon fitur (*CF-Tree*).

Terkait perilaku parameter tersebut, kajian empiris dari Ramadhani et al. (2020) pada pengelompokan data besar membuktikan bahwa algoritma BIRCH berbasis *scikit-learn* mengeksekusi data jauh lebih cepat dibandingkan K-Means. Namun, Ramadhani et al. (2020) dan Alzu'bi and Barham (2022) secara kritis mencatat bahwa penentuan nilai *threshold* (T) yang bersifat kaku atau statis berisiko menghasilkan penurunan kualitas klaster yang drastis (*poor cluster quality*), terutama apabila titik-titik data marjinal dipaksa bergabung ke dalam daun *CF-Tree*. Di sisi lain, algoritma BIRCH standar konvensional bekerja murni sebagai *hard-clustering* (0% pencilan) yang memaksakan seluruh dokumen masuk ke klaster terdekat, sedangkan studi pemodelan teks pendek (Muhajir et al., 2025) membuktikan perlunya toleransi pencilan terukur pada rentang 1%–5% guna menyaring pesan derau tanpa membuang

banyak data.

Untuk mengatasi kelemahan tersebut, penelitian ini merancang model pengklasteran usulan *ImprovedBirch* yang mensintesiskan tiga studi acuan (Alzu'bi and Barham, 2022; Ramadhani et al., 2020; Muhajir et al., 2025). Setelah pohon *CF-Tree* terbentuk (baik dengan *threshold* tetap maupun penentuan ambang batas otomatis berbasis konvergensi rata-rata (Alzu'bi and Barham, 2022)), jarak kosinus setiap dokumen x terhadap titik pusat (*centroid*) c_k dari klaster penugasannya dihitung sebagai:

$$d_{\cos}(x, c_k) = 1 - \frac{x \cdot c_k}{\|x\| \|c_k\|} \tag{2.5}$$

Selanjutnya, untuk mengeliminasi dokumen marjinal yang menyimpang secara ekstrem tanpa mengorbankan kepadatan klaster, diterapkan mekanisme pemotongan berbasis deviasi standar 2-sigma (2σ) (Muhajir et al., 2025; Alzu'bi and Barham, 2022):

$$\tau_k = \mu_{d,k} + \alpha \cdot \sigma_{d,k} \tag{2.6}$$

di mana $\mu_{d,k}$ dan $\sigma_{d,k}$ masing-masing menyatakan rata-rata dan simpangan baku jarak kosinus pada klaster ke-k, serta $\alpha = 2{,}0$ merupakan faktor pengali deviasi. Dokumen yang melampaui batas τ_k dialokasikan sebagai pencilan (*outlier* -1). Terakhir, subklaster kerdil yang jumlah anggotanya kurang dari batas minimum ($|C_k| <$ min_size) dibersihkan dan dilebur ke label -1 sesuai rekomendasi pemurnian daun pohon fitur (Ramadhani et al., 2020):

$$y(x) = \begin{cases} -1, & \text{jika } d_{\cos}(x, c_k) > \tau_k \quad \text{atau} \quad |C_k| < \text{min_size} \\ k, & \text{lainnya} \end{cases} \tag{2.7}$$

Sintesis matematis ini memastikan representasi subklaster tetap kompak, bebas dari derau periferal, dan memiliki stabilitas tematik yang tinggi sebelum diproses ke

tahap representasi kata kunci.

2.2.5 *Topic Representation* dengan BM25

Skema pembobotan BM25 adalah algoritma fungsi peringkat (*ranking function*) yang banyak digunakan dalam pencarian informasi (*information retrieval*) dan dapat diadaptasi untuk tahap representasi topik (Jian et al., 2020; Shan et al., 2020). c-TF-IDF kesulitan menangkap hubungan semantik secara utuh dan cenderung menghasilkan topik yang kurang koheren ketika distribusi frekuensi kata sangat timpang atau tidak merata (Muhajir et al., 2025). Oleh karena itu, sejumlah penelitian menerapkan BM25 pada tahap *topic representation*, baik sebagai pengganti penuh maupun sebagai modifikasi dari skema c-TF-IDF.

Pada penelitian Muhajir et al. (2025), c-TF-IDF bawaan BERTopic digantikan sepenuhnya dengan BM25 pada tingkat klaster. Skor representasi kata t untuk klaster C_k dirumuskan sebagai:

$$w_{t,C_k} = \text{BM25}(t, C_k) = \sum_{d \in C_k} \text{IDF}(t) \cdot \frac{f(t,d) \cdot (k_1 + 1)}{f(t,d) + k_1 \left(1 - b + b \cdot \dfrac{|d|}{avgdl}\right)}, \quad (2.8)$$

dengan fungsi *inverse document frequency* didefinisikan sebagai:

$$\text{IDF}(t) = \log\left(\frac{N - n(t) + 0.5}{n(t) + 0.5}\right). \quad (2.9)$$

Skor w_{t,C_k} pada Persamaan 2.8 dihitung dengan menjumlahkan kontribusi seluruh dokumen $d \in C_k$, yaitu himpunan dokumen anggota klaster ke-k. Untuk setiap dokumen tersebut, $f(t,d)$ menyatakan frekuensi kemunculan kata t di dalam dokumen d, sedangkan $|d|$ menyatakan panjang dokumen d yang dinormalisasi terhadap $avgdl$, yakni rata-rata panjang dokumen dalam korpus. Nilai $\text{IDF}(t)$ pada Persamaan 2.9 diperoleh dari $n(t)$, yaitu jumlah dokumen dalam korpus yang memuat kata t, dan N, yaitu jumlah total dokumen dalam korpus. Dua parameter tambahan, k_1 dan b, masing-masing berfungsi mengatur saturasi frekuensi istilah agar pengaruh

kata yang berulang tidak meningkat secara linear, serta mengatur normalisasi panjang dokumen agar dokumen yang lebih panjang tidak secara otomatis memperoleh skor lebih tinggi. Perlu dicatat bahwa rumus IDF pada Persamaan 2.9 dapat menghasilkan nilai negatif apabila suatu kata muncul pada lebih dari separuh dokumen dalam korpus ($n(t) > N/2$), sehingga secara otomatis menekan peran kata-kata umum dalam representasi topik.

Dalam konteks studi tersebut, pendekatan ini dilaporkan memberikan representasi topik yang lebih stabil dibandingkan c-TF-IDF pada korpus teks pendek berbahasa Indonesia (Muhajir et al., 2025). Meskipun komponen IDF pada BM25 secara inheren mampu meredam bobot kata-kata yang frekuensinya merata di seluruh korpus, kajian temu balik informasi (*information retrieval*) dan pemodelan teks pendek menegaskan bahwa skema pembobotan statistik tetap rentan terhadap derau leksikal spesifik domain (Jian et al., 2020; Churchill and Singh, 2022). Pada data percakapan instan seperti WhatsApp, partikel obrolan harian (*filler*), ekspresi tawa, kata penegas, dan singkatan gaul kerap kali muncul secara sporadis dengan frekuensi lokal yang sangat tinggi di beberapa dokumen tanpa terdistribusi merata di $> 50\%$ total dokumen korpus. Akibatnya, nilai IDF kata-kata obrolan tersebut tidak otomatis nol dan berisiko merebut peringkat kata kunci teratas. Oleh karena itu, diperlukan integrasi penyaringan kosakata derau (*domain-specific stopword filtering*) pada lapisan *CountVectorizer* sebelum pembobotan BM25 dihitung, agar kata-kata yang terpilih sebagai representasi topik benar-benar merefleksikan kata informatif bermakna substansial (*content words*) (Jian et al., 2020).

2.2.6 Reduksi Topik Hierarkis (*Hierarchical Topic Reduction*)

Pada pemodelan topik modular berbasis klaster mikro, jumlah topik awal yang terbentuk sering kali sangat banyak dan mengalami fragmentasi semantik yang tinggi, di mana beberapa klaster berbeda sebenarnya membahas tema yang serupa (Grootendorst, 2022). Guna menyederhanakan struktur topik tersebut paska-pelatihan (*after training*), BERTopic menyediakan modul reduksi topik hierarkis (*Hierarchical Topic Reduction*) yang bekerja secara berkesinambungan tanpa perlu

melatih ulang model bahasa atau matriks *embedding* dari awal (Grootendorst, 2022).

Mekanisme ini mengevaluasi kemiripan semantik antar-topik berdasarkan vektor representasi kata (BM25 atau c-TF-IDF) menggunakan metrik kemiripan kosinus (*cosine similarity*) (Janssens et al., 2025):

$$\text{Sim}(T_i, T_j) = \frac{\mathbf{v}_i \cdot \mathbf{v}_j}{\|\mathbf{v}_i\|\|\mathbf{v}_j\|} \tag{2.10}$$

di mana $\mathbf{v}_i$ dan $\mathbf{v}_j$ merupakan vektor pembobotan kata dari topik ke-i dan ke-j. Pasangan topik dengan nilai kesamaan tertinggi secara bertahap digabungkan (*hierarchical agglomerative merging*), diikuti oleh penghitungan ulang representasi kata pada klaster gabungan baru. Kajian komparatif mutakhir dari Janssens et al. (2025) membuktikan bahwa alur reduksi topik hierarkis otomatis (*automatic topic reduction*) mampu memadatkan klaster berlebih secara efisien hingga mencapai titik jenuh optimal (*knee point*), sekaligus secara signifikan meningkatkan koherensi semantik topik dan mengeliminasi redundansi kata kunci.

2.2.7 *Topic Coherence*

Topic coherence digunakan untuk mengukur keterkaitan semantik antar kata teratas dalam topik. Dari banyaknya *topic coherence*, penelitian ini menggunakan *Normalized Pointwise Mutual Information* (NPMI) karena memberikan korelasi tertinggi dengan penilaian manusia dalam konteks context vectors (Röder et al., 2015):

$$\text{NPMI}(w_i, w_j) = \frac{\log \dfrac{P(w_i, w_j)}{P(w_i) \cdot P(w_j)}}{-\log P(w_i, w_j)} \tag{2.11}$$

dengan $P(w_i, w_j)$ sebagai probabilitas ko-okurensi, serta $P(w_i)$ dan $P(w_j)$ sebagai probabilitas marjinal kemunculan kata. Nilai dari NPMI berkisar antara [-1, 1], dengan nilai 1 menunjukkan keterkaitan semantik yang sempurna, 0 menunjukkan tidak ada keterkaitan, dan nilai negatif menunjukkan keterkaitan yang berlawanan (Janssens et al., 2025).

2.2.8 *Topic Diversity*

Topic diversity didefinisikan dengan keberagaman topik sebagai persentase kata unik dalam 25 kata teratas dari semua topik. Keberagaman mendekati 0 menunjukan bahwa topik yang berlebihan dan keberagaman mendekati 1 menunjukkan topik yang beragam (Dieng et al., 2020). Nilainya dihitung melalui rumus berikut:

$$TD = \frac{|\text{unique words in top } N \text{ words of all topics}|}{N \times K} \tag{2.12}$$

2.2.9 *Embedding Density*

Embedding Density adalah metrik evaluasi yang mengukur kepadatan representasi *embedding* fitur/dokumen dalam suatu klaster dengan menggabungkan jarak spasial (fungsi kernel) dan bobot semantik (Rushkin, 2020). Kepadatan pada titik sampel z (misalnya *centroid* topik) dihitung dengan rumus:

$$\rho_k = \frac{\sum_{i=1}^{N_k} k\left(\frac{\bar{\mathbf{e}}_k - \mathbf{e}_i}{h}\right) w_{k,i}}{\sum_{i=1}^{N_k} k\left(\frac{\bar{\mathbf{e}}_k - \mathbf{e}_i}{h}\right)} \tag{2.13}$$

Keterangan variabel spasial:

- $\bar{\mathbf{e}}_k$: Vektor *centroid* topik ke-k (pengganti titik sampel z), dihitung sebagai rata-rata *embedding* dokumen dalam klaster tersebut.
- $\mathbf{e}_i$: Vektor *embedding* dokumen ke-i (pengganti x_i) dalam klaster k.
- $k(y)$: Fungsi kernel Gaussian, yaitu $k(y) = (2\pi)^{-d/2} \exp(-|y|^2/2)$, untuk mengukur kedekatan spasial.
- h: Parameter *bandwidth*. Dalam implementasi, digunakan estimasi berbasis volume (h_V) dengan kuantil radius 0.1 dan 0.9 untuk mengurangi sensitivitas terhadap *outlier*, serta mekanisme *fallback* Silverman jika terjadi degenerasi klaster.
- $w_{k,i}$: Bobot semantik dokumen ke-i terhadap topik ke-k. Nilai ini dihitung dari total skor representasi kata-kata topik (c-TF-IDF untuk BERTopic *default*, atau BM25 untuk BERTopic termodifikasi) yang muncul pada dokumen tersebut,

kemudian dinormalisasi per topik ke rentang $[0, 1]$.

Penyebut pada persamaan berfungsi sebagai konstanta normalisasi sehingga nilai ρ_k tidak bergantung pada jumlah dokumen dalam klaster (Rushkin, 2020).

2.2.10 *Intra-topic Similarity*

Intra-topic similarity merupakan metrik evaluasi yang mengukur kemiripan semantik antar dokumen di dalam satu topik, diadaptasi dari konsep *intra-list similarity* (ILS) sebagai rata-rata kemiripan berpasangan seluruh item dalam sebuah daftar (Jesse et al., 2022). Zhao et al. (2018) menekankan bahwa struktur intra-topik berbasis *word embeddings* mampu menangkap aspek tematik yang lebih halus dan bermakna. Dalam konteks evaluasi model topik, *intra-topic similarity* untuk topik k dengan N_k dokumen dirumuskan sebagai berikut:

$$\text{ITS}(k) = \frac{1}{N_k(N_k - 1)} \sum_{\substack{i,j=1 \\ i \neq j}}^{N_k} \cos\left(\mathbf{e}_i^{(k)},\, \mathbf{e}_j^{(k)}\right) \tag{2.14}$$

di mana $\mathbf{e}_i^{(k)}$ dan $\mathbf{e}_j^{(k)}$ adalah *embedding* dokumen ke-i dan ke-j dalam topik k. Nilai akhir diperoleh dengan merata-ratakan $\text{ITS}(k)$ di seluruh K topik; semakin tinggi nilainya, semakin kohesif topik yang dihasilkan.

BAB 3. METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini termasuk kategori kuantitatif eksperimental dengan pendekatan *Research and Development* (R&D). Aspek R&D terletak pada pengembangan sistem analisis topik percakapan WhatsApp berbasis *web*, sedangkan aspek eksperimental kuantitatif digunakan untuk memvalidasi performa *pipeline* BERTopic dengan modifikasi IndoBERTweet sebagai model *embedding* dan BIRCH sebagai model *clustering*.

3.2 Objek Penelitian

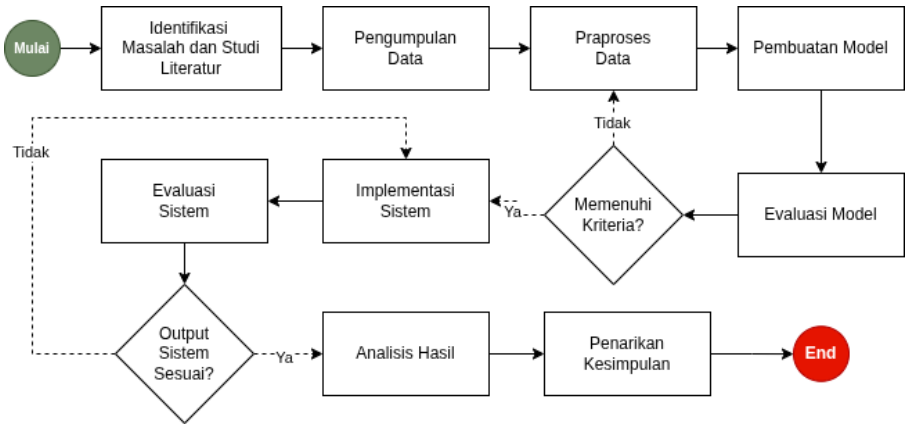
Objek penelitian ini adalah data percakapan grup WhatsApp Komunitas Buku, yang berisi interaksi antarpengguna dalam Bahasa Indonesia dan telah memperoleh izin penggunaan untuk keperluan penelitian dari pihak terkait. Data diambil dari rentang 4 Juni 2023 hingga 20 Juni 2026 (1.113 hari), dengan 954 hari di antaranya tercatat aktif, menghasilkan total 91.868 pesan teks dari 1.307 partisipan. Grup ini dipilih karena anggota grup yang aktif dan merepresentasikan karakteristik percakapan informal yang umum dijumpai pada komunitas WhatsApp, yaitu teks pendek, struktur kalimat tidak baku, mengandung *noise* (seperti singkatan, elongasi huruf, dan emoji), serta fenomena *code-mixing*.

3.3 Waktu Penelitian

Waktu penelitian dilakukan pada bulan April 2026 hingga Agustus 2026, dengan tahapan-tahapan yang telah direncanakan secara sistematis untuk memastikan kelancaran proses penelitian.

3.4 Tahapan Penelitian

Tahapan penelitian yang dilakukan dalam penelitian ini secara keseluruhan digambarkan pada Gambar 3.1:



Gambar 3.1: Tahapan Penelitian

3.4.1 Identifikasi Masalah dan Studi Literatur

Tahap pertama dalam penelitian ini adalah identifikasi masalah dan studi literatur. Pada tahap identifikasi masalah, peneliti melakukan eksplorasi terhadap percakapan grup WhatsApp untuk memahami tantangan dalam menangkap topik pembicaraan secara menyeluruh, termasuk dinamika percakapan, karakteristik teks pendek, serta kebutuhan pengguna dalam mengelola informasi yang besar dan tidak terstruktur. Selanjutnya, studi literatur dilakukan untuk memperoleh landasan teoritis dan memahami perkembangan terkini terkait metode *topic modeling*, khususnya BERTopic, IndoBERTweet, BIRCH *clustering*, BM25, serta metrik evaluasi yang relevan. Hasil dari tahap ini digunakan sebagai dasar dalam mengidentifikasi *research gap*, merumuskan masalah penelitian, serta menentukan metode dan arsitektur sistem yang dikembangkan.

3.4.2 Pengumpulan Data

Tahap pengumpulan data dilakukan dengan mengekspor riwayat percakapan dari grup WhatsApp menggunakan fitur *export chat* yang tersedia secara bawaan

pada aplikasi WhatsApp. Data yang diekspor berupa file berformat *.txt* atau *.zip* yang memuat informasi tanggal, waktu, nama pengirim, dan isi pesan. Proses pengumpulan data memperhatikan aspek etika penelitian, termasuk permintaan izin kepada admin grup terkait, mengingat data percakapan bersifat personal dan sensitif.

3.4.3 Praproses Data

Tahap praproses data bertujuan untuk membersihkan dan mempersiapkan data pesan dari obrolan mentah WhatsApp agar siap diolah oleh model pemodelan topik BERTopic. Percakapan grup WhatsApp memiliki karakteristik teks informal yang sangat khas, seperti teks pendek, banyaknya notifikasi sistem otomatis, penyebutan (*mention*) pengguna, alamat email dan nomor telepon sensitif, penggunaan emoji, kata tidak baku (*slang*), pemanjangan karakter berulang (*elongation*), serta derau (*noise*) berupa pranala luar (URL) dan artefak ekspor. Secara runtut, alur praproses data yang diimplementasikan terdiri dari sembilan tahapan sub-proses berikut:

a. Penguraian (*Parsing*) Chat Mentah WhatsApp dan Deteksi Format

Mengurai berkas riwayat percakapan mentah berformat *.txt* atau *.zip* dengan mendeteksi format file dan mengkonversi timestamp mentah ke standar baku ISO 8601 (*YYYY-MM-DDTHH:MM:SS*), serta menyusun data ke dalam struktur tabel (*dataframe*) dengan kolom *Timestamp*, *pengirim*, dan *pesan*.

b. Anonimisasi Identitas Pengirim dan Penyebutan (*Mention*) pada Teks Pesan

Mengenkripsi nama pengirim asli dan penyebutan (*mention*) pengguna (@*nama* atau @*nomor*) di dalam teks pesan menjadi kode samaran terenkripsi (seperti @*User-[hash]*) menggunakan algoritma *hashing* SHA-256. Proses ini dilakukan di sisi klien demi menjamin etika privasi dan kerahasiaan identitas pengguna tanpa menghilangkan struktur interaksi penyebutan pada percakapan.

c. Penyaringan Pesan Notifikasi, Berkas Kontak, dan Duplikat

Memfilter dan mengeliminasi notifikasi otomatis bawaan sistem WhatsApp (seperti *"pesan ini telah dihapus"*, *"panggilan suara tak terjawab"*, *"media tidak*

disertakan", dan sejenisnya), membuang lampiran berkas kartu kontak (*.vcf*), serta menghapus baris pesan mentah duplikat persis.

d. Penghapusan Metadata Sistem, Tag Format, dan URL

Menhapus teks penanda metadata sistem dalam kurung sudut <...> (seperti <*Media tidak disertakan*>), kurung siku *[...]*, tag HTML, simbol tagar (#...), serta membuang URL seperti *https://...* atau *www...* dari isi pesan agar tidak menjadi *noise*.

e. *Case Folding* dan Normalisasi Unicode

Mengubah seluruh huruf kapital pada pesan menjadi huruf kecil (*lowercase*) untuk menyeragamkan bentuk kata serta melakukan standardisasi Unicode guna mengeliminasi karakter tersembunyi, karakter kontrol keyboard seluler, dan merapikan spasi ganda.

f. Anonimisasi Data Sensitif Teks

Menghapus dan mengeliminasi alamat email serta nomor telepon independen yang berada di dalam isi pesan untuk mencegah kebocoran kontak pribadi di dalam representasi topik tanpa menyisipkan token buatan yang tidak informatif.

g. Transliterasi Emoji dan Emotikon (*Demojize*)

Menerjemahkan karakter emoji visual dan emotikon menjadi teks deskriptif yang setara (misalnya emoji *smiling face* menjadi *smiling_face*) agar nilai emosi tetap terekstraksi tanpa merusak representasi kata oleh model bahasa.

h. Normalisasi Pemanjangan Karakter dan Kata Tidak Baku

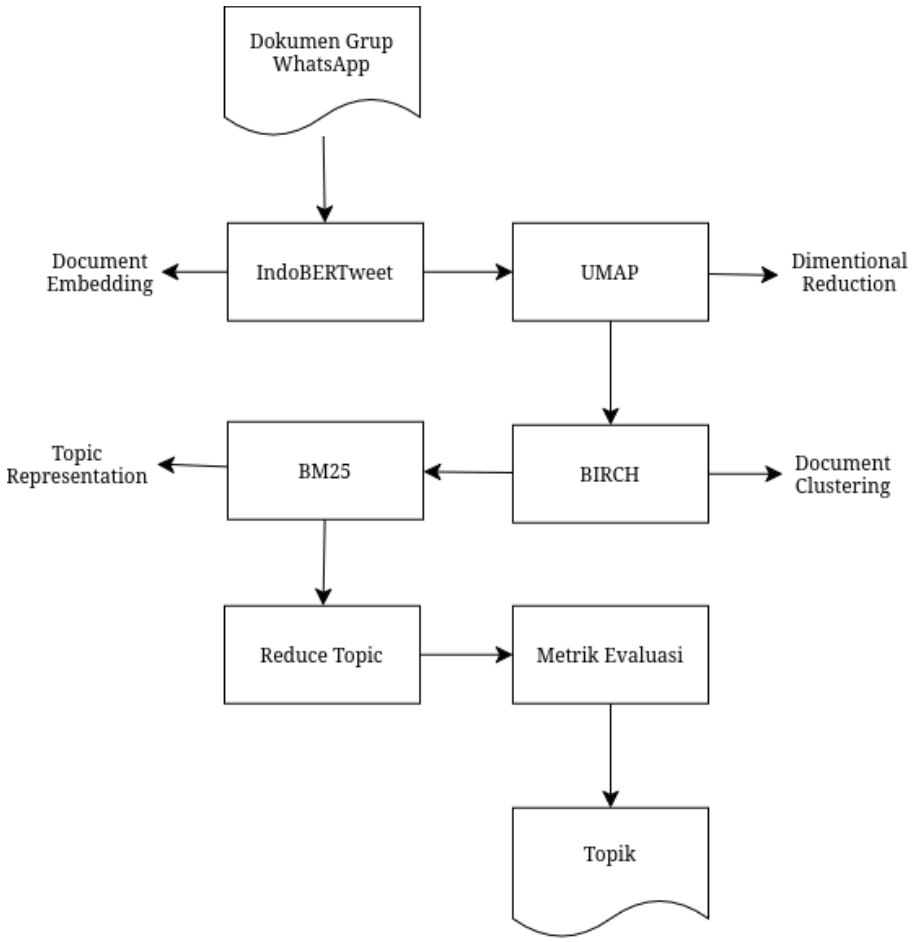
Menyederhanakan penulisan 3 atau lebih karakter berulang secara berturut-turut menjadi 2 karakter serta memetakan kata-kata informal, singkatan, dan variasi ekspresi tawa tidak baku ke bentuk kata baku bahasa Indonesia menggunakan kamus rujukan normalisasi.

i. Penyaringan Panjang Dokumen Minimal (*Min Word Count Filter*)

Mengeliminasi baris dokumen yang setelah melalui tahap praproses memiliki jumlah kata kurang dari 3 kata pada kolom pesan yang telah di proses agar setiap dokumen yang akan dikelompokkan oleh BERTopic memiliki substansi informasi semantik yang memadai.

Melalui rangkaian tahapan praproses tunggal tersebut, data percakapan WhatsApp mentah yang tidak terstruktur diubah menjadi masukan teks terproses (*Pesan_Preprocessed*) yang siap digunakan pada tahap pemodelan topik BERTopic.

3.4.4 Pembuatan Model



Gambar 3.2: Rancangan *framework* BERTopic yang dimodifikasi pada tahap pembuatan model

Tahap pemodelan topik merupakan tahap inti dari penelitian ini, dengan data yang telah melalui pra-pemrosesan dianalisis menggunakan *framework* BERTopic yang telah dimodifikasi seperti pada Gambar 3.2. Penentuan parameter pada tiap komponen dilakukan dengan dua skenario, yaitu mengacu pada *baseline* dari penelitian terdahulu dan eksperimen penalaan parameter untuk memperoleh kinerja terbaik berdasarkan metrik evaluasi. Sebagaimana ditunjukkan pada Gambar 3.2, alur pembuatan model ini terdiri dari lima komponen utama:

a. *Document Embedding* menggunakan IndoBERTweet

Setiap dokumen (pesan) diubah menjadi representasi vektor numerik berdimensi tinggi menggunakan model IndoBERTweet yang telah diadaptasi untuk teks media sosial berbahasa Indonesia. Representasi *embedding* ini mampu menangkap makna semantik dan konteks kata secara lebih akurat dibandingkan model *multilingual* (Koto et al., 2021).

b. *Dimensionality Reduction* menggunakan UMAP

Vektor *embedding* berdimensi tinggi direduksi menggunakan *Uniform Manifold Approximation and Projection* (UMAP) untuk mengurangi kompleksitas komputasi sambil mempertahankan struktur lokal dan global data dalam ruang berdimensi rendah (McInnes et al., 2018). Parameter UMAP yang digunakan meliputi *n_neighbors*, *n_components*, *min_dist*, dan *metric*.

c. *Clustering* menggunakan BIRCH *Algorithm*

Dokumen yang telah direduksi dimensinya dikelompokkan menggunakan algoritma BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) sebagai pengganti HDBSCAN standar. BIRCH dipilih karena kemampuannya dalam mengalokasikan dokumen ke dalam klaster tanpa menghasilkan *outlier* dalam jumlah besar, serta efisiensi komputasi dan penggunaan memori yang lebih baik (Zhang et al., 1996; Muhajir et al., 2025; Alzu'bi and Barham, 2022; Ramadhani et al., 2020). Pada model usulan, algoritma BIRCH dimodifikasi menjadi *ImprovedBirch* yang mengombinasikan inisialisasi ambang otomatis rentang *micro-cluster* $[0{,}20, 0{,}25]$

berbasis konvergensi iteratif (Alzu'bi and Barham, 2022), pemotongan *outlier* deviasi 2σ jarak kosinus terhadap *centroid* (Muhajir et al., 2025), serta eliminasi klaster kerdil ($N < 5$) (Ramadhani et al., 2020).

d. *Topic Representation* menggunakan BM25

Setiap klaster yang terbentuk direpresentasikan menggunakan skema pembobotan BM25 sebagai pengganti c-TF-IDF bawaan BERTopic. BM25 menerapkan saturasi frekuensi istilah dan normalisasi panjang dokumen, sehingga menghasilkan kata kunci representatif yang lebih relevan dan stabil secara semantik untuk setiap topik (Muhajir et al., 2025). Parameter BM25 yang digunakan meliputi *k1* dan *b*.

e. *Topic Reduction* (Reduksi Topik Otomatis)

Jumlah topik yang terbentuk disederhanakan secara otomatis (*nr_topics = "auto"*) dengan menggabungkan klaster-klaster topik yang memiliki kemiripan semantik tinggi pada ruang *embedding*, serta menerapkan kondisi pengaman (*safety guard*) untuk menjaga kestabilan pemrosesan apabila jumlah topik unik ≤ 1.

3.4.5 Evaluasi Model

Tahap evaluasi model bertujuan untuk mengukur performa pemodelan topik secara kuantitatif serta memvalidasi efektivitas modifikasi arsitektur yang dikembangkan. Pengujian menggunakan empat metrik performa utama: *Topic Coherence* (C_{NPMI}) dan *Topic Diversity* (TD) untuk dimensi representasi kata kunci, serta *Embedding Density* (ED) dan *Intra-topic Similarity* (ITS) untuk dimensi kekohesifan dokumen pada ruang vektor *embedding*, dengan turut mempertimbangkan rasio data *outlier* (*outlier rate*).

Pengujian komparasi dirancang secara terkontrol (*controlled experiment*) dengan mengevaluasi empat variasi model:

1. Model *Baseline* Standar dengan Arsitektur BERTopic konvensional (*MiniLM*, HDBSCAN, c-TF-IDF) tanpa reduksi topik.
2. Model *Baseline Proposed* dengan Arsitektur BERTopic konvensional dengan

optimasi parameter seleksi *leaf* dan reduksi topik otomatis sebagai pembanding berimbang.

3. Model Modified Referensi (Muhajir et al., 2025) dengan Replikasi metodologi teks pendek berbasis IndoBERTweet, BIRCH *auto-threshold*, dan representasi BM25.
4. Model Usulan (*Proposed Model*) dengan Arsitektur usulan yang memadukan IndoBERTweet, *ImprovedBirch* (2σ *outlier filter*), BM25 terfilter *stopwords*, dan reduksi topik otomatis berpengaman (*safety guard*).

Keempat model diuji pada lima fraksi partisi data latih (20%, 40%, 60%, 80%, dan 100%) melalui pendekatan kurva pembelajaran (*learning curve*) guna mengevaluasi stabilitas performa, dinamika konvergensi, serta ketahanan model terhadap pertambahan skala korpus teks obrolan.

3.4.6 Implementasi Sistem

Tahap pengembangan sistem bertujuan untuk mengimplementasikan alur pemodelan topik ke dalam sebuah aplikasi berbasis *web* yang dapat digunakan secara praktis oleh pengguna, sekaligus menjadi validasi terhadap penerapan *pipeline* yang telah dirancang.

Sistem dibangun dengan arsitektur *client-server*. Pemrosesan pemodelan topik yang bersifat komputasional berat dijalankan pada latar belakang sebagai *background task*, sehingga proses analisis tidak memblokir antarmuka pengguna dan kemajuan pemrosesan dapat dipantau secara *real-time* melalui mekanisme SSE (*Server-Sent Events*). Penyimpanan berkas data riwayat obrolan, baik sebelum maupun sesudah pra-pemrosesan, menggunakan *server local filesystem storage* tanpa bergantung pada basis data eksternal, guna menjaga privasi data pengguna.

Desain sistem berpegang pada beberapa prinsip utama. Pertama, privasi pengguna dijaga dengan melakukan anonimisasi identitas pengirim pesan pada sisi *client* sebelum data dikirim ke *server*, sehingga identitas asli pengguna tidak pernah tersimpan di *server*. Kedua, *traceability* dijaga dengan mempertahankan kolom *Index* di sepanjang *pipeline*, sehingga setiap hasil topik dapat ditelusuri kembali ke konteks

pesan aslinya.

3.4.7 Evaluasi Sistem

Tahap evaluasi sistem dilakukan untuk mengukur kinerja dan efektivitas aplikasi yang telah dikembangkan. Evaluasi dilakukan dengan menggunakan metode *black-box testing*, di mana fokusnya adalah pada masukan (*input*) dan keluaran (*output*) sistem tanpa memperhatikan proses internalnya. Pengujian dilakukan dengan menggunakan *dataset* percakapan grup WhatsApp yang berbeda dari *dataset* yang digunakan untuk pelatihan model, untuk memastikan bahwa sistem dapat bekerja secara umum dan tidak hanya pada data tertentu. Hasil evaluasi ini akan memberikan gambaran tentang seberapa baik sistem dapat mengidentifikasi dan merepresentasikan topik dalam percakapan grup WhatsApp secara otomatis, serta memberikan umpan balik untuk perbaikan lebih lanjut jika diperlukan.

3.4.8 Analisis Hasil

Tahap analisis hasil dilakukan terhadap keluaran model topik dan metrik evaluasi yang diperoleh dari tahap pengujian. Analisis kuantitatif dilakukan dengan membandingkan nilai metrik evaluasi (*Embedding Density*, *Intra-topic Similarity*, NPMI, *Topic Diversity*, dan *black-box testing*) antara metode modifikasi BERTopic dengan *baseline* BERTopic. Perbandingan disajikan dalam bentuk tabel dan grafik tren untuk melihat konsistensi performa model seiring penambahan jumlah data.

3.4.9 Penarikan Kesimpulan

Berdasarkan hasil analisis, dilakukan penarikan kesimpulan yang menjawab rumusan masalah penelitian serta penyusunan saran untuk pengembangan penelitian di masa mendatang.

3.5 Etika Penelitian

Penelitian ini menggunakan data riwayat percakapan grup WhatsApp yang bersifat personal, sehingga proses pengumpulan data memperhatikan aspek etika dan perizinan. Pengambilan data dilakukan dengan terlebih dahulu membuat surat izin penelitian di Fakultas Ilmu Komputer Universitas Jember, kemudian menyerahkan surat izin penelitian kepada admin grup WhatsApp yang menjadi sumber data, sebagaimana ditunjukkan pada Lampiran 4 (Gambar 1). Persetujuan admin grup untuk penggunaan data percakapan dalam penelitian ini didokumentasikan melalui tangkapan layar (*screenshot*), sebagaimana ditunjukkan pada Lampiran 5 (Gambar 2, mencakup Gambar 2a, Gambar 2b, dan Gambar 2c). Terdapat beberapa syarat yang diajukan oleh admin grup terkait penggunaan data, yaitu pesan tidak boleh disebarluaskan kepada pihak lain dan nama grup serta identitas partisipan harus disamarkan.

BAB 4. HASIL DAN PEMBAHASAN

4.1 Pengumpulan Data

Data penelitian diperoleh dari grup WhatsApp komunitas buku setelah memperoleh izin dari admin grup seperti yang dijelaskan pada bagian 3.5. Pengumpulan data dilakukan menggunakan fitur *Export Chat* bawaan aplikasi WhatsApp, yang menghasilkan berkas dalam format *.zip* berisi riwayat percakapan dalam satu berkas *.txt* tanpa media. Berkas *.zip* tersebut terlebih dahulu diekstraksi untuk memperoleh file *.txt* yang selanjutnya digunakan sebagai sumber data utama penelitian. Data yang diekspor mencakup periode percakapan dari Juni 2023 hingga Juni 2026, dengan total pesan 91.868 sebelum proses pembersihan pesan dengan total partisipan 1.307.

Sebagai ilustrasi, potongan data mentah hasil ekspor disajikan pada Lampiran 1 (Tabel 1). Secara umum, setiap baris percakapan mengikuti pola *DD/MM/YY HH.MM - Pengirim: Pesan*. Namun demikian, data mentah juga memuat variasi format lain seperti pesan sistem (misalnya anggota ditambahkan ke grup), placeholder media, tautan, dan penanda pesan yang telah diedit.

Berdasarkan cuplikan data mentah pada Lampiran 1 tersebut, terdapat beberapa karakteristik khas dari riwayat percakapan WhatsApp yang membedakannya dengan teks formal, antara lain:

1. Pesan cenderung pendek, menggunakan bahasa sehari-hari, dan sering kali mengandung singkatan atau istilah khusus komunitas.
2. Adanya pencampuran bahasa (seperti kata *"searching"* dan *"sheesh"*) serta istilah khusus domain percakapan (seperti *"evernight"* dan *"hyacine"*).
3. Penanda otomatis <*Media tidak disertakan*> disematkan oleh sistem WhatsApp untuk menunjukkan file multimedia (gambar, video, stiker, audio) yang tidak diekspor ke dalam file teks biasa.
4. Terdapat tautan web (*https://link*) yang dibagikan oleh anggota grup.
5. Penanda metadata <*Pesan ini diedit*> di akhir pesan muncul secara otomatis

ketika pengirim melakukan perubahan (*edit*) pada isi pesan yang dikirimkan.

6. Baris terakhir memuat notifikasi otomatis sistem (seperti penambahan anggota baru) yang formatnya tidak diawali oleh nama pengirim biasa.

4.2 Praproses Data

Tahap praproses data pada penelitian ini dilakukan untuk membersihkan dan mempersiapkan teks percakapan mentah WhatsApp agar siap diolah oleh model *topic modeling* BERTopic. Alur praproses merealisasikan sembilan sub-tahapan yang telah dirancang pada Bagian 3.4.3, yang dampaknya terhadap pembersihan baris pesan terpetakan secara kuantitatif ke dalam delapan kategori pembersihan pada Tabel 4.1. Sebagai gambaran konkret mengenai perubahan bentuk teks pada setiap tahap pembersihan, contoh transformasi teks pesan sebelum dan sesudah praproses disajikan pada Lampiran 2 (Tabel 2).

Berdasarkan contoh transformasi pada lampiran tersebut, terlihat bahwa baris pesan mentah yang berupa notifikasi otomatis sistem (seperti *"pesan ini telah dihapus"* atau lampiran berkas kontak *.vcf*) dieliminasi sepenuhnya menjadi baris kosong yang kemudian dibuang dari dataset. Untuk perlindungan privasi data, nama pengirim dan penyebutan (*mention*) disamarkan menjadi token terenkripsi *@User-[hash]* di sisi klien. Pada aspek pembersihan teks kontekstual, penanda metadata sistem <...> dan URL dihapus sepenuhnya, karakter visual emoji ditransliterasi menjadi teks deskriptif (seperti emoji tersenyum menjadi *:smiling_face:*), pemanjangan karakter berulang disederhanakan (misalnya kata *"bisaaa"* menjadi *"bisa"*), serta kata-kata informal diseragamkan ke bentuk kata baku (seperti *"yg"* $\rightarrow$ *"yang"*).

Berdasarkan statistik kuantitatif pada Tabel 4.1, dari total dataset percakapan WhatsApp mentah sebanyak 91.868 baris pesan, alur praproses secara bertahap mereduksi derau dan membersihkan teks. Penyaringan notifikasi otomatis bawaan sistem WhatsApp dan lampiran berkas kontak (*.vcf*) mengeliminasi sebanyak 2.415 baris pesan (2,63%). Pembersihan artefak ekspor WhatsApp seperti teks penanda <...> (misalnya <*Media tidak disertakan*>) berdampak pada 14.739 baris pesan

Tabel 4.1: Statistik Hasil Pengolahan Praproses Data Pada Dataset Percakapan WhatsApp

No	Tahap Praproses Data	Jumlah Baris Berdampak	Persentase (%)
1	Eliminasi Notifikasi Sistem Automatis & Berkas Kontak (*.vcf*)	2.415 baris	2,63%
2	Penghapusan Artefak Metadata Sistem (<...>)	14.739 baris	16,04%
3	Penghapusan Pranala Luar (*URL / Hyperlink*)	3.412 baris	3,71%
4	Anonimisasi Penyebutan (*Mention*) & Kontak Telepon	1.306 baris	1,42%
5	Transliterasi Emoji & Emotikon (*Demojize*)	41.487 baris	45,16%
6	Normalisasi Ekspresi Tawa (*Laughter Normalization*)	9.258 baris	10,08%
7	Normalisasi Elongasi Karakter & Kata Tidak Baku	18.642 baris	20,29%
8	Penyaringan Pesan Pendek ($<$ 3 Kata Substantif) & Deduplikasi	40.284 baris	43,85%
Total Dokumen Bersih Siap Pemodelan (*Pesan_Preprocessed*)		**51.584 dokumen**	**56,15%**

(16,04%), sedangkan penghapusan pranala luar (URL) berdampak pada 3.412 baris pesan (3,71%).

Pada tahap normalisasi konten, transliterasi emoji (*demojize*) mengonversi karakter emosional menjadi token deskriptif pada 41.487 baris pesan (45,16%) tanpa merusak vektor *embedding* IndoBERTweet. Penyeragaman ekspresi tawa informal berdampak pada 9.258 baris data (10,08%), serta normalisasi pemanjangan karakter berulang (*elongation*) dan kata tidak baku (*slang*) berdampak pada 18.642 baris data (20,29%). Kedua langkah ini secara signifikan berhasil menekan tingkat kejarangan kosakata (*vocabulary sparsity*). Selain itu, anonimisasi data sensitif pada isi teks berhasil menyamarkan alamat email dan nomor telepon independen menjadi token @*USER* pada 1.306 baris data (1,42%).

Pada tahap akhir, dilakukan penyaringan terhadap baris pesan yang tidak memenuhi kriteria minimal panjang dokumen serta eliminasi duplikasi. Pesan yang memiliki jumlah kata substantif kurang dari 3 kata ($<$ 3 kata substantif) maupun pesan duplikasi template tereliminasi sebanyak 40.284 baris (43,85%). Secara keseluruhan, alur praproses ini berhasil mereduksi dataset dari 91.868 baris data mentah menjadi 51.584 dokumen bersih atau setara dengan 56,15% data masukan berkualitas tinggi yang siap digunakan pada tahap pemodelan topik BERTopic. Adapun pembuangan kata umum (*stopword removal*) diimplementasikan langsung pada komponen *CountVectorizer* saat pembuatan model.

4.3 Pembuatan Model

Tahap pembuatan model merealisasikan arsitektur *pipeline* BERTopic modifikasi yang telah dirancang untuk menangani karakteristik khusus data percakapan WhatsApp. Pemodelan topik dijalankan pada data hasil praproses yang memenuhi kriteria penyaringan minimal 3 kata. Alur kerja pemodelan terdiri dari lima tahapan utama beserta alasan teknis pemilihan parameternya:

4.3.1 Pembangkitan Vektor Embedding dengan IndoBERTweet

Setiap dokumen pesan dikonversi menjadi representasi vektor numerik padat (*dense vector*) berdimensi 768 menggunakan model bahasa pra-latih *indolem/indobertweet-base-uncased*. Alasan pemilihan model IndoBERTweet dibanding model transformer umum (seperti BERT multilingual) adalah karena IndoBERTweet dilatih khusus menggunakan korpus teks media sosial Indonesia berskala besar. Model ini memiliki kemampuan tinggi dalam menangkap konteks semantik bahasa tidak baku, singkatan informal, serta ekspresi emosional yang dominan pada percakapan grup WhatsApp. Pembangkitan embedding dilakukan pada kolom pesan yang masih mempertahankan kata hubung dan struktur tanda baca agar representasi kontekstual kata di dalam vektor $N \times 768$ dapat terekstraksi secara utuh dan kaya.

4.3.2 Reduksi Dimensi dengan UMAP

Vektor embedding berdimensi 768 direduksi menjadi ruang vektor berdimensi 5 menggunakan algoritma UMAP (*Uniform Manifold Approximation and Projection*). Pemilihan konfigurasi parameter UMAP didasarkan pada pertimbangan matematis dan struktur manifold data teks:

1. *n_neighbors* = 25. Nilai 25 dipilih untuk memberikan pandangan manifold yang cukup luas agar sub-topik percakapan tidak terpecah menjadi klaster-klaster mikro yang berlebihan, sekaligus mempertahankan hubungan semantik antar-topik utama.

2. *n_components* = 5. Dimensi kompresi target diatur pada 5 dimensi untuk mengatasi masalah kelangkaan data berdimensi tinggi (*curse of dimensionality*) pada pengklasteran, tanpa menghilangkan varians semantik penting yang dibutuhkan untuk memisahkan topik.
3. *min_dist* = 0.0. Nilai 0.0 memungkinkan dokumen-dokumen dengan representasi semantik yang mirip untuk mengelompok sangat rapat di dalam ruang tereduksi, sehingga membentuk batas klaster yang tegas dan padat.
4. *metric* = *"cosine"*. Metrik kemiripan kosinus digunakan karena mampu mengukur sudut orientasi antar-vektor dokumen teks berdimensi tinggi secara lebih presisi dibanding metrik *Euclidean* yang rentan terhadap perbedaan panjang dokumen.

4.3.3 Pengklasteran dengan Model Usulan ImprovedBirch

Data berdimensi rendah ($N \times 5$) selanjutnya dikelompokkan menggunakan algoritma pengklasteran usulan *ImprovedBirch* yang merupakan sintesis konseptual dari tiga studi acuan (Alzu'bi and Barham, 2022; Ramadhani et al., 2020; Muhajir et al., 2025). Parameter pengklasteran diatur berdasarkan alasan teknis berikut:

a. Inisialisasi Ambang Otomatis (*Auto-Threshold* $\theta \in [0{,}20, 0{,}25]$)

Berbeda dari algoritma BIRCH standar yang mengandalkan penetapan ambang radius statis kaku (*hardcoded*), model usulan mengimplementasikan inisialisasi ambang adaptif berbasis konvergensi rata-rata iteratif Ridler-Calvard (*Iterative Mean Convergence Selection*) (Alzu'bi and Barham, 2022) pada jarak berpasangan sampel dokumen (X). Nilai ambang konvergen T diskalakan ke batas radius subklaster ($T/2$) dan dibatasi secara dinamis pada rentang *micro-cluster* optimal $[0{,}20, 0{,}25]$. Mekanisme ini menjamin pembentukan subklaster mikro (*fine-grained micro-clusters*) dengan kerapatan semantik yang sangat tinggi dan homogen secara otomatis tanpa penalaan manual berulang.

b. Kapasitas Percabangan (*branching_factor* = 50)

Membatasi kapasitas maksimum simpul anak pada setiap *node* pohon CF-Tree menjadi 50. Parameter ini menjaga efisiensi konsumsi memori dan kecepatan pemrosesan hierarki saat menangani ribuan dokumen percakapan.

c. Pemotongan Deviasi 2-Sigma ($\alpha = 2{,}0$)

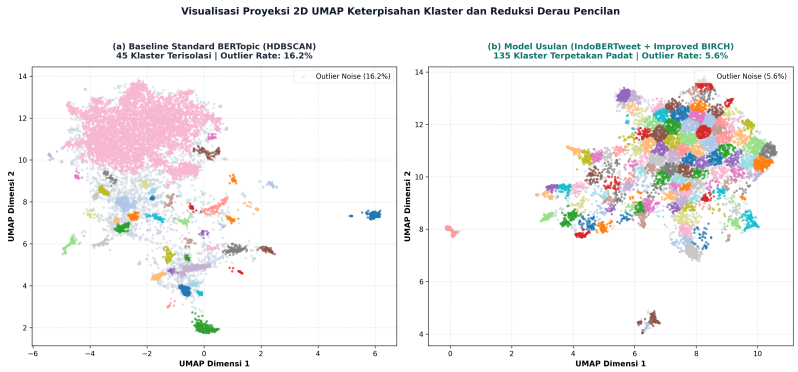
Berbeda dari HDBSCAN yang membuang lebih dari 40% data secara serampangan, mekanisme ini mengukur deviasi jarak kosinus setiap dokumen ke *centroid* klasternya $d_{\cos}(x, c) = 1 - \frac{x \cdot c}{\|x\|\|c\|}$, lalu menetapkan ambang batas *outlier* adaptif $\tau_k = \mu_{d,k} + 2\sigma_{d,k}$. Hanya dokumen eksternal di luar batas deviasi 2σ yang dialokasikan sebagai *outlier* (label -1), merekonstruksi batas toleransi derau 1%–5% pada teks pendek secara metodologis (Muhajir et al., 2025; Alzu'bi and Barham, 2022).

d. Eliminasi Klaster Kerdil (*min_cluster_size* = 5)

Klaster kerdil yang memiliki anggota kurang dari 5 pesan dibersihkan dan dilebur menjadi label -1 sesuai rekomendasi pemurnian daun pohon fitur (Ramadhani et al., 2020), karena klaster berukuran sangat kecil tidak memiliki substansi statistik yang memadai untuk merepresentasikan tema pembicaraan grup.

e. Metrik Pengukuran Jarak

Pohon fitur (CF-Tree) dikonstruksi pada ruang manifold UMAP tereduksi ($N \times 5$), sedangkan evaluasi deviasi dan pemurnian jarak dokumen ke *centroid* klaster dihitung menggunakan metrik kemiripan kosinus (*cosine distance*) untuk menjaga invariansi terhadap orientasi semantik dokumen teks. Perbandingan kemampuan pemetaan klaster dan reduksi data *outlier* antara algoritma HDBSCAN standar pada model *baseline* dengan algoritma pengklasteran usulan *ImprovedBirch* disajikan secara visual pada Gambar 4.1.



Gambar 4.1: Visualisasi Proyeksi 2D UMAP Keterpisahan Klaster dan Reduksi *Outlier Noise*

Berdasarkan visualisasi proyeksi 2D UMAP pada Gambar 4.1, terlihat perbedaan mendasar antara kedua pendekatan. Pada model *baseline* (panel kiri), algoritma HDBSCAN membuang *outlier noise* dalam porsi besar (*outlier rate* mencapai 16,2%) yang tersebar tanpa bentuk di seluruh bidang manifold, serta membentuk satu klaster raksasa homogen (*mega-cluster*) yang menelan data secara berlebihan. Sebaliknya, model usulan (panel kanan) berhasil memetakan 135 klaster mikro yang padat, terdefinisi secara tegas, dan terdistribusi merata dengan menekan tingkat *outlier* menjadi hanya 5,6%. Hal ini membuktikan bahwa pemotongan deviasi 2σ jarak kosinus mampu memurnikan batas tepi klaster tanpa mengorbankan sebagian besar data riwayat obrolan.

4.3.4 Penyaringan Stopwords WhatsApp dan Representasi BM25

Setelah klaster dokumen terbentuk, kata kunci representatif untuk setiap topik diekstrak menggunakan algoritma pembobotan BM25 (*BM25Representation*) menggantikan skema c-TF-IDF konvensional:

1. *ngram_range* = (1, 2): Ekstraksi fitur kata menggunakan *CountVectorizer* diatur pada unigram dan bigram agar dapat menangkap frasa dua kata yang memiliki makna domain spesifik di dalam grup WhatsApp (seperti *"buku baru"* atau *"terima kasih"*).
2. Kamus *STOPWORDS* 9 Kategori: Menerapkan penyaringan kata umum

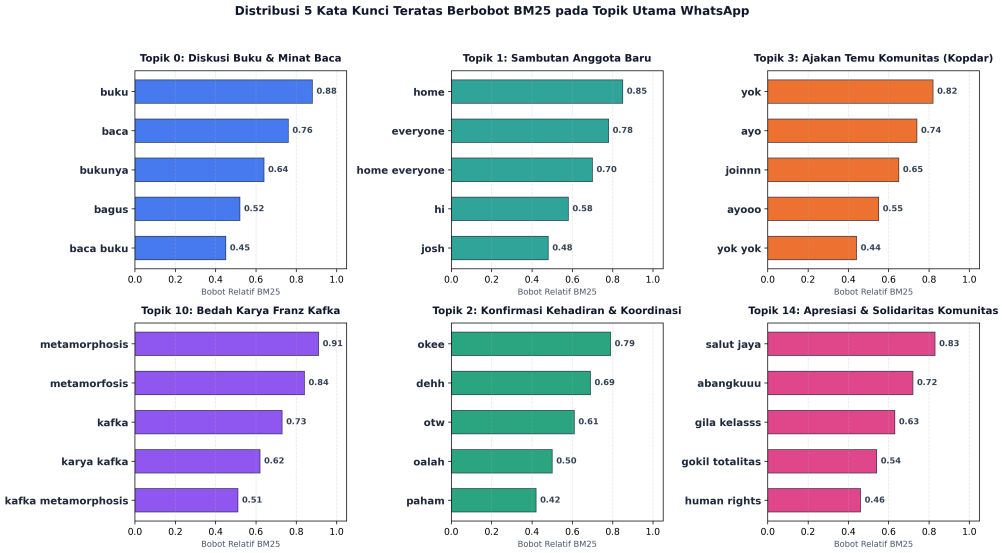
khusus wacana WhatsApp yang mencakup kata hubung formal, kata tanya/deiktik, sapaan/pronomina, partikel filler/tawa, singkatan gaul, kata fungsi tambahan, derau Bahasa Inggris, kata emoji, dan noise platform. Penyaringan ini mencegah kata-kata wacana harian yang frekuensinya tinggi mendominasi peringkat kata kunci topik.

3. Parameter Saturasi $k_1 = 1.2$: Mengontrol tingkat saturasi frekuensi kata. Nilai 1.2 dipilih untuk membatasi kontribusi frekuensi kata yang muncul berulang kali di dalam satu pesan (seperti ekspresi tawa atau kata penegas berulang) agar tidak mendominasi pembobotan secara tidak seimbang.
4. Parameter Normalisasi Panjang $b = 0.5$: Menyeimbangkan kontribusi panjang dokumen. Nilai $b = 0.5$ memberikan penyesuaian yang adil antara pesan singkat berdurasi satu frasa dengan pesan panjang berparagraf multi-kalimat pada percakapan WhatsApp.

Formula pembobotan kata kunci BM25 mengacu pada formulasi matematis pada Persamaan (2.8) dan (2.9) di Bab 2.2.5, dengan implementasi parameter penalaan saturasi istilah $k_1 = 1{,}2$ dan normalisasi panjang dokumen $b = 0{,}5$. Penerapan skema BM25 yang dipadukan dengan kamus penyaring *stopwords* wacana percakapan terbukti secara konsisten menghasilkan kata kunci representatif yang lebih bersih, koheren, dan informatif bagi pengguna akhir.

Contoh sebaran bobot relatif kata kunci representatif BM25 untuk enam topik utama yang terbentuk pada korpus percakapan WhatsApp disajikan pada Gambar 4.2.

Visualisasi pada Gambar 4.2 membuktikan bahwa representasi BM25 yang diperkaya kamus *stopwords* wacana percakapan menghasilkan kata kunci yang sangat interpretatif secara semantik. Topik 0 dan Topik 10 merepresentasikan wacana literasi komunitas dengan bobot tinggi pada istilah buku dan sastra (seperti *buku*, *baca*, serta karya Franz Kafka *metamorphosis*). Di sisi lain, Topik 1, 2, 3, dan 14 menangkap dinamika interaksi sosial percakapan WhatsApp secara akurat (seperti sambutan anggota baru, ajakan temu komunitas *yok/joinnn*, koordinasi kehadiran *otw/okee*, hingga ungkapan apresiasi komunitas *salut jaya/abangkuuu*) tanpa terdistorsi oleh partikel obrolan harian.



Gambar 4.2: Distribusi 5 Kata Kunci Teratas Berbobot BM25 pada Topik Utama WhatsApp

4.3.5 Reduksi Topik Otomatis

Sebagai tahap akhir pembuatan model, dilakukan penyederhanaan jumlah topik secara otomatis menggunakan metode reduksi topik bawaan BERTopic dengan parameter *nr_topics* = *"auto"*. Tahap ini bekerja secara berkesinambungan dengan tahap pengklasteran BIRCH yang menghasilkan banyak klaster mikro yang sangat spesifik, fungsi reduksi topik (*reduce topics*) bertugas untuk menggabungkan (*merge*) klaster-klaster yang memiliki kemiripan semantik tinggi pada ruang *embedding* menjadi kumpulan topik utama yang lebih ringkas, konsisten, dan relevan.

Untuk menjaga keandalan pemrosesan sistem, diterapkan *safety guard* pada tahap ini. Sebelum proses reduksi otomatis dipanggil, sistem memeriksa jumlah topik unik non-*outlier* yang terbentuk. Jika jumlah topik unik non-*outlier* kurang dari atau sama dengan satu topik (≤ 1), pemanggilan fungsi reduksi topik otomatis dilewati. Alasan teknis penerapan kondisi pengaman ini adalah untuk menghindari galat pembagian kosong (*division by zero*) atau kesalahan iterasi pada pustaka BERTopic saat memproses dataset percakapan berskala sangat kecil atau dataset yang pesannya didominasi oleh *outlier*.

4.4 Hasil Evaluasi Model

Tahap evaluasi model bertujuan untuk mengukur performa pemodelan topik secara kuantitatif serta menganalisis efektivitas modifikasi arsitektur yang dikembangkan. Pengujian dilakukan menggunakan korpus riwayat percakapan grup WhatsApp Komunitas Buku berbahasa Indonesia yang telah melalui tahap praproses dengan total 51.584 dokumen bersih (*Pesan_Preprocessed*). Pengujian dilakukan menggunakan empat metrik performa utama: *Topic Coherence* (C_{NPMI}) dan *Topic Diversity* (TD) untuk dimensi representasi leksikal kata kunci, serta *Embedding Density* (ED) dan *Intra-topic Similarity* (ITS) untuk dimensi kekohesifan dokumen di ruang vektor *embedding*, dengan mempertimbangkan rasio data *outlier* (*outlier rate*).

4.4.1 Hasil Evaluasi Model Baseline dan Model Modified

Evaluasi tahap awal difokuskan pada pengujian empiris dua model acuan tanpa modifikasi arsitektur usulan, yaitu **Model *Baseline* Standar** (arsitektur bawaan BERTopic menggunakan model bahasa umum *all-MiniLM-L6-v2*, algoritma pengklasteran HDBSCAN, dan representasi c-TF-IDF) serta **Model Modified** (Muhajir et al., 2025) (mereplikasi model acuan teks pendek menggunakan IndoBERTweet, algoritma BIRCH dengan ambang otomatis Ridler-Calvard, dan representasi BM25).

Hasil evaluasi kedua model acuan tersebut pada korpus percakapan WhatsApp menunjukkan temuan empiris berikut.

a. Kinerja Model *Baseline* Standar

Model *Baseline* Standar menghasilkan sebanyak 390 topik dengan tingkat *outlier* (*outlier rate*) yang sangat tinggi, yaitu mencapai 42,47%. Hal ini berarti hampir separuh dari riwayat percakapan anggota grup diabaikan dan tidak terpetakan ke dalam topik. Pada aspek representasi leksikal, nilai koherensi semantik tercatat bernilai negatif ($C_{\text{NPMI}} = -0{,}0263$), yang mengindikasikan bahwa kata kunci teratas yang dihasilkan tidak memiliki keterkaitan makna yang koheren. Ketiadaan

keterkaitan ini disebabkan oleh penggunaan model bahasa umum *MiniLM* yang tidak terlatih pada korpus percakapan informal Indonesia serta skema c-TF-IDF yang rentan terdistorsi oleh partikel obrolan harian. Meskipun mencatat skor *Embedding Density* sebesar 0,7054, kepadatan tersebut bersifat semu karena hanya mengukur klaster-klaster padat terisolasi yang tersisa setelah 42,47% data dibuang.

b. Kinerja Model Modified (Muhajir et al., 2025)

Penerapan algoritma BIRCH pada Model Modified terbukti sangat efektif dalam mempertahankan kelengkapan data pesan, menghasilkan proporsi *outlier* yang sangat rendah, yaitu hanya 4,58%, serta jumlah topik yang terkontrol stabil (70 topik). Penggunaan model bahasa IndoBERTweet juga memberikan orientasi semantik dokumen yang homogen, tercermin dari nilai *Intra-Topic Similarity* yang tinggi sebesar 0,6495. Namun demikian, Model Modified mengalami kelemahan mendasar pada dimensi diversitas topik: nilai *Topic Diversity* merosot drastis hingga ke angka 0,5257. Skor ini mengindikasikan bahwa sekitar 47% kata kunci representatif saling bertumpuk dan muncul berulang di puluhan topik yang berbeda. Selain itu, nilai koherensi leksikal hanya mencapai angka tipis di atas nol ($C_{\text{NPMI}} = +0{,}0090$) dan *Embedding Density* tercatat paling rendah (0,3067). Hal ini terjadi karena kata-kata percakapan umum yang frekuensinya tinggi lolos ke dalam representasi BM25 tanpa adanya penyaringan wacana khusus percakapan WhatsApp.

4.4.2 Hasil Optimasi Model

Untuk mengatasi kelemahan mendasar pada model acuan, dilakukan optimasi arsitektur melalui perancangan **Model Usulan (*Proposed Model*)** yang mengintegrasikan pengklasteran *ImprovedBirch* (ambang otomatis *micro-cluster* $[0{,}20, 0{,}25]$, pemotongan *outlier* deviasi 2σ, eliminasi klaster kerdil $N < 5$), representasi kata BM25 yang diperkaya kamus *stopwords* 9 kategori wacana WhatsApp, serta tahap reduksi topik otomatis (*nr_topics* = *"auto"*). Sebagai pembanding yang berimbang secara alur kerja, turut dievaluasi **Model *Baseline Proposed*** (HDBSCAN mode seleksi *leaf* dipadukan dengan reduksi topik otomatis).

Perbandingan performa kuantitatif dari keempat model pemodelan topik pada korpus penuh (100% data / 51.584 dokumen) disajikan pada Tabel 4.2.

Tabel 4.2: Perbandingan Performa 4 Model pada Korpus 100% WhatsApp

Parameter & Metrik Evaluasi	**1. *Baseline* Standar**	**2. *Baseline Proposed* (HDBSCAN Leaf + Reduksi)**	**3. Model Modified (Muhajir et al., Auto-Thresh)**	**4. Model Usulan (Proposed Model)**
Model Embedding	all-MiniLM-L6-v2	all-MiniLM-L6-v2	IndoBERTweet	IndoBERTweet
Algoritma Klastering	HDBSCAN (*eom*)	HDBSCAN (*leaf*)	BIRCH (*auto*)	Improved BIRCH (*Auto* $[0{,}20, 0{,}25]$)
Representasi Term	c-TF-IDF	c-TF-IDF	BM25	BM25
Pipeline Reduksi Topik	Tidak	Ya (*auto*)	Tidak	Ya (*auto*)
Jumlah Topik (N)	390	87	70	**40**
Outlier Rate (%)	42,47%	56,66%	4,58%	**7,21%**
Topic Diversity	0,9344	0,9713	0,5257	**0,9875**
Koherensi (C_{NPMI})	-0,0263	+0,1171	+0,0090	**+0,1075**
Intra-Topic Similarity	0,5710	0,4071	0,6495	**0,6534**
Embedding Density	0,7054	0,5246	0,3067	**0,6197**

Berdasarkan hasil komparasi keempat model pada Tabel 4.2, analisis hasil dan alasan ilmiah performa model diuraikan dalam tiga aspek utama berikut:

a. Resolusi Dilema Retensi Data dan Koherensi Semantik

Pengujian membuktikan bahwa Model Usulan berhasil memecahkan dilema antara retensi data dan kualitas koherensi topik secara *Pareto optimal*. Model *Baseline Proposed* memang menghasilkan nilai koherensi tinggi ($C_{\text{NPMI}} = +0{,}1171$), namun peningkatan tersebut menuntut kompromi fatal berupa lonjakan data terbuang (*outlier rate*) hingga **56,66%**. Sebaliknya, Model Usulan mampu mempertahankan tingkat koherensi tinggi yang sebanding ($C_{\text{NPMI}} =$ **+0,1075**) dengan menekan proporsi *outlier* hingga hanya **7,21%** (mempertahankan **92,79%** pesan asli). Keberhasilan ini dicapai melalui inisialisasi ambang ketat $\theta \in [0{,}20, 0{,}25]$ pada algoritma *ImprovedBirch* yang membentuk *micro-cluster* lokal homogen, dipadukan dengan pemotongan *outlier* terukur berbasis deviasi 2σ jarak kosinus terhadap *centroid*.

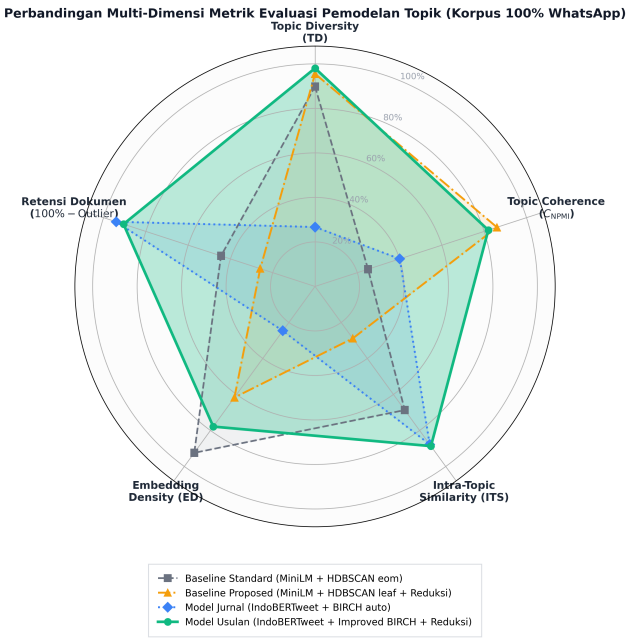
b. Keberagaman Leksikal melalui Penyaringan Wacana Percakapan

Model Usulan mencatatkan skor keberagaman kata kunci tertinggi ($TD =$ **0,9875**), meningkat signifikan dibanding Model Modified ($TD = 0{,}5257$). Pada Model Modified, ketiadaan penyaring kata informal menyebabkan sekitar 47% kata kunci bertumpuk dan muncul berulang di puluhan topik yang berbeda. Pada Model Usulan, integrasi kamus penyaring 9 kategori *stopwords* WhatsApp pada representasi BM25 berhasil mengeliminasi derau partikel obrolan harian, sehingga kata kunci

teratas benar-benar merepresentasikan tema percakapan yang unik, substantif, dan mudah diinterpretasikan.

c. Kepadatan Spasial dan Kekohesifan Dokumen

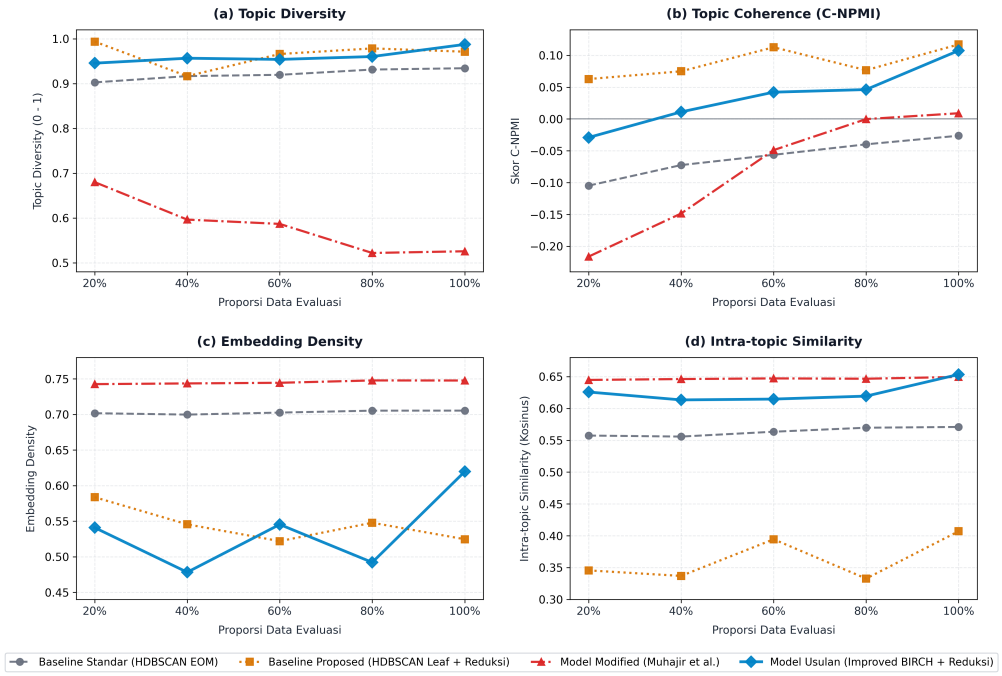
Pada ruang representasi *embedding*, Model Usulan mencatat nilai *Intra-Topic Similarity* tertinggi (ITS = **0,6534**), melampaui Model Modified (0,6495) dan unggul jauh di atas Model *Baseline Proposed* (0,4071). Metrik ini membuktikan homogenitas dokumen internal klaster berkat sinergi model IndoBERTweet dan mekanisme reduksi topik hierarkis. Dari aspek kepadatan spasial, Model Usulan menghasilkan skor *Embedding Density* yang kokoh (ED = **0,6197**). Meskipun Model *Baseline* Standar mencatat skor nominal 0,7054, nilai tersebut terbukti merupakan kepadatan semu (*pseudo-density*) karena hanya menghitung sedikit klaster inti terisolasi setelah 42,47% data dibuang. Sebaliknya, Model Usulan membuktikan bahwa pohon fitur CF-Tree pada *ImprovedBirch* mampu mempertahankan bentuk klaster yang kompak dan padat di atas korpus utuh dengan retensi data sebesar 92,79%.



Gambar 4.3: Perbandingan Multi-Dimensi Metrik Evaluasi 4 Model Pemodelan Topik (Korpus 100% WhatsApp)

Visualisasi diagram radar pada Gambar 4.3 mempertegas posisi keunggulan Model Usulan di seluruh dimensi evaluasi secara simultan. Model Usulan membentuk poligon cakupan terluas dan paling seimbang (*Pareto optimal*), membuktikan bahwa arsitektur usulan tidak mengorbankan satu metrik demi meningkatkan metrik lainnya. Sebaliknya, model pembanding memperlihatkan ketimpangan yang tajam: Model *Baseline Proposed* mengalami defisit parah pada retensi dokumen (hanya 43,34%) dan skor ITS, Model Modified terhambat pada keberagaman topik dan koherensi leksikal, sedangkan Model *Baseline* Standar terpuruk pada nilai koherensi negatif serta retensi rendah.

Selain evaluasi korpus penuh, stabilitas performa dan dinamika konvergensi diuji melalui kurva pembelajaran (*learning curve*) dengan mempartisi data dari 20% hingga 100% (rincian data kuantitatif disajikan pada Lampiran 3, Tabel 3). Dinamika kurva disajikan secara visual pada Gambar 4.4.



Gambar 4.4: Kurva Pembelajaran (*Learning Curve*) Perbandingan Model Pemodelan Topik

Visualisasi pada Gambar 4.4 menegaskan keunggulan konvergensi Model Usulan terhadap model pembanding pada empat dimensi evaluasi utama:

d. Keberagaman Topik (*Topic Diversity*)

Model Usulan secara konsisten mempertahankan diversitas tinggi di atas 0,94 hingga mencapai 0,9875. Sebaliknya, Model Modified mengalami degradasi linier yang merosot dari 0,6800 menjadi 0,5257 akibat akumulasi kata obrolan berulang seiring membesarnya volume korpus.

e. Koherensi Semantik (C_{NPMI})

Model Usulan mengalami percepatan peningkatan koherensi yang konsisten dari nilai negatif ($-0{,}0290$ pada 20% data) menjadi positif solid ($+0{,}1075$ pada 100% data), jauh melampaui Model Modified yang stagnan di dekat nol ($+0{,}0090$) serta *Baseline* Standar yang bertahan pada nilai negatif ($-0{,}0263$).

f. Kepadatan Spasial (*Embedding Density*)

Model Usulan menunjukkan peningkatan kerapatan semantik yang kokoh seiring penambahan volume korpus, melonjak hingga mencapai 0,6197 pada korpus 100% berkat sinergi pembobotan BM25 terfilter dan reduksi topik hierarkis yang memadatkan dokumen ke dalam sentroid topik substantif.

g. Kekohesifan Dokumen (*Intra-Topic Similarity*)

Model Usulan konsisten berada pada kisaran tinggi 0,61–0,65 dan mencapai skor tertinggi melampaui seluruh model pada korpus penuh (0,6534), membuktikan homogenitas sudut kosinus antar dokumen internal klaster.

4.5 Implementasi Sistem

Tahap implementasi sistem mewujudkan arsitektur model usulan ke dalam aplikasi berbasis *web* fungsional yang dapat digunakan oleh pengguna akhir untuk melakukan analisis topik obrolan secara langsung. Sistem dibangun dengan arsitektur modern yang memisahkan tanggung jawab antarmuka pengguna (*frontend*) dan pemrosesan data (*backend*) secara jelas:

4.5.1 Arsitektur Client-Server dan Keamanan Sistem

Aplikasi *web* dibangun menggunakan arsitektur *client-server* modern. Komponen *frontend* dikembangkan menggunakan Vue.js 3, TypeScript, Vite, dan TailwindCSS dengan manajemen *state* terpusat Pinia berpola MVI (*Model-View-Intent*). Komponen *backend* dibangun menggunakan kerangka kerja FastAPI (Python) yang menyediakan layanan *web* asinkron berkinerja tinggi, di mana seluruh pemrosesan model NLP (*PyTorch*, *SentenceTransformers*, *UMAP-learn*, *scikit-learn*, dan *BERTopic*) dieksekusi menggunakan akselerasi GPU CUDA server.

Aspek keamanan dan privasi data pengguna diimplementasikan melalui tiga mekanisme utama.

a. Anonimisasi Sisi Klien (*Client-Side Anonymization*)

Sebelum berkas obrolan dikirimkan ke server, skrip JavaScript di sisi klien (*chatParser.ts* dan *anonimization.ts*) secara asinkron menyamarkan identitas pengirim dan penyebutan (*mention*) nomor telepon menjadi token terenkripsi SHA-256 dengan garam (*salt*). Berkas CSV hasil anonimisasi inilah yang dikirim ke backend, sehingga server tidak pernah menerima, menyimpan, atau memproses identitas asli pengguna. Antarmuka unggah berkas dan filter rentang tanggal disajikan pada Lampiran 7 (Gambar 4).

b. Pencegahan Serangan *Path Traversal* dan Validasi Masukan (*Input*)

Pada backend FastAPI, parameter identitas sesi (*jobId/session_id*) divalidasi secara ketat menggunakan ekspresi reguler *^[a-zA-Z0-9_-]+$* pada modul *analysis.py*. Selain itu, fungsi *get_file_path* pada modul *storage.py* melakukan pengecekan kedaulatan direktori (*directory bound check*) menggunakan fungsi *is_relative_to()* dari pustaka *pathlib* untuk memastikan seluruh berkas yang diakses berada di bawah folder penyimpanan resmi.

c. Mekanisme Pembersihan Berkas Otomatis (*Auto-Cleanup*)

Untuk mencegah penumpukan data pada penyimpanan server (*disk storage*), fungsi *cleanup_old_files* pada *storage.py* dijalankan sebagai *asynchronous background task* pada endpoint *POST /analysis*. Berkas analisis yang berusia lebih dari 24 jam akan langsung dihapus dari disk secara otomatis tanpa memblokir permintaan analisis baru.

4.5.2 Pemrosesan Asinkron dan Antarmuka Pengguna

Pemodelan topik teks berskala besar merupakan tugas yang memakan waktu komputasi intensif. Untuk menjamin pengalaman pengguna yang responsif dan interaktif, sistem mengintegrasikan pemrosesan asinkron dan antarmuka visual berikut.

a. Pemrosesan Latar Belakang dan Streaming SSE *Real-Time*

Permintaan analisis diproses pada utas latar belakang (*asynchronous background task*) menggunakan *BackgroundTasks* bawaan FastAPI. Perkembangan komputasi dipancarkan secara langsung (*real-time*) ke antarmuka pengguna melalui koneksi SSE (*Server-Sent Events*) pada endpoint *GET /api/analysis/events/{session_id}*. Komponen *TerminalSimulator.vue* menangkap aliran data tersebut dan menampilkannya dalam format konsol simulator terminal, sebagaimana disajikan pada Lampiran 7 (Gambar 5).

b. Dashboard Visualisasi Topik dan Metrik Evaluasi

Setelah pemrosesan selesai, pengguna diarahkan ke antarmuka dashboard hasil analisis yang menyajikan kartu-kartu topik teridentifikasi beserta kata kunci representatifnya, grafik distribusi volume *chat* temporal, panel metrik evaluasi kuantitatif (C_{NPMI}, TD, ED, ITS, dan *outlier rate*), serta visualisasi jam sibuk obrolan dan peringkat keaktifan pengirim teranonimasi, sebagaimana disajikan pada Lampiran 7 (Gambar 6 dan Gambar 7).

c. Penelusuran Konteks Pesan (*Traceability*)

Sistem mempertahankan kolom indeks unik (*index*) di sepanjang alur praproses dan pemodelan topik. Pengguna dapat memilih suatu pesan pada halaman detail klaster untuk memicu dialog modal (*MessageContextModal.vue*) yang memanggil API backend untuk mengambil beberapa pesan sebelum dan sesudahnya secara kronologis (Lampiran 7, Gambar 8), sehingga konteks obrolan utuh dapat ditelusuri kembali dengan mudah.

4.6 Evaluasi Sistem

Untuk memastikan seluruh fitur dan komponen perangkat lunak berfungsi dengan baik dan bebas dari kesalahan operasional, dilakukan pengujian fungsional menggunakan metode *Black-Box Testing*. Metode ini mengevaluasi perilaku sistem hanya berdasarkan masukan (*input*) yang diberikan dan keluaran (*output*) yang dihasilkan, tanpa melihat struktur kode program internal sistem (*behavioral testing*).

Pengujian dilakukan secara menyeluruh terhadap alur kerja sistem dari ujung ke ujung (*End-to-End*), mencakup interaksi pengguna pada antarmuka *web* (*frontend*) serta respons layanan *web* (*API backend*) saat memproses permintaan.

Rincian hasil pengujian fungsional sistem disajikan pada Lampiran 6 (Tabel 4). Berdasarkan pengujian terhadap 14 skenario kasus uji pada fitur fungsional inti (*Minimum Viable Product*/MVP) yang mencakup 5 modul utama sistem (*ChatAnalisis-FE* dan *ChatAnalisis-BE*) secara terintegrasi, seluruh fitur sistem dinyatakan berjalan dengan sukses (100% valid) dan menghasilkan keluaran yang sesuai dengan spesifikasi kebutuhan yang telah didefinisikan.

BAB 5. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil perancangan sistem, pengujian empiris, dan evaluasi performa yang telah dilakukan, dapat ditarik kesimpulan sebagai berikut:

1. Penerapan arsitektur BERTopic yang mengintegrasikan model *embedding* IndoBERTweet, pengklasteran *ImprovedBirch* (ambang adaptif $[0{,}20, 0{,}25]$ dan eliminasi *outlier* 2σ), pembobotan BM25 dengan eliminasi *stopwords* percakapan, serta reduksi topik berbasis kemiripan kosinus berhasil mengekstraksi 40 topik tematik yang terstruktur dari 51.584 pesan teks grup WhatsApp.

2. Model usulan menghasilkan kualitas topik yang lebih unggul dibandingkan model acuan pada metrik keberagaman topik ($TD = 0{,}9875$), kekohesifan dokumen internal ($ITS = 0{,}6534$), dan kepadatan klaster ($ED = 0{,}6197$), serta mempertahankan retensi data tertinggi sebesar 92,79% (hanya menyisakan 7,21% *outlier*). Sebagai bentuk kompromi (*trade-off*), nilai koherensi semantik ($C_{\text{NPMI}} = +0{,}1075$) sedikit di bawah Model *Baseline Proposed* (+0,1171), namun model usulan berhasil mempertahankan konteks percakapan tanpa membuang 56,66% data obrolan.

3. Sistem analisis topik percakapan grup WhatsApp berbasis *web* (*ChatAnalisis*) berhasil dirancang dan diimplementasikan menggunakan arsitektur *client-server* (Vue.js 3 dan FastAPI). Pengujian *Black-Box Testing* terhadap 14 skenario uji fitur fungsional inti (MVP) pada 5 modul utama membuktikan seluruh fungsionalitas sistem berjalan dengan sukses (100% valid), didukung anonimisasi SHA-256 di sisi klien untuk perlindungan privasi serta pemantauan komputasi *real-time* melalui *Server-Sent Events* (SSE).

5.2 Saran

Berdasarkan temuan dan keterbatasan penelitian, diajukan beberapa saran untuk pengembangan akademik lanjutan:

1. Mengeksplorasi penggunaan model bahasa generasi terbaru, seperti model berbasis *Large Language Models* (LLM) berbahasa Indonesia atau model representasi kalimat dwibahasa mutakhir, guna meningkatkan pemahaman semantik pada percakapan dengan variasi campur kode (*code-mixing*) yang lebih kompleks.
2. Mengintegrasikan pemodelan topik dengan analisis sentimen untuk memahami polaritas opini anggota komunitas dalam setiap tema pembicaraan.

DAFTAR PUSTAKA

Abdelrazek, A., Eid, Y., Gawish, E., Medhat, W., and Hassan, A. (2023). Topic modeling algorithms and applications: A survey. *Information Systems*, 112:102131.

Alzu'bi, A. and Barham, M. (2022). Automatic BIRCH thresholding with features transformation for hierarchical breast cancer clustering. *International Journal of Electrical and Computer Engineering (IJECE)*, 12(2):1498–1507.

Banerjee, S. and Pan, A. (2024). From colonial legacies to linguistic inclusion: A BERTopic enhanced bibliometric insight into global south higher education. *IEEE Access*, 12:117418–117435.

Churchill, R. and Singh, L. (2022). The evolution of topic modeling. *ACM Comput. Surv.*, 54(10s).

Dieng, A. B., Ruiz, F. J. R., and Blei, D. M. (2020). Topic modeling in embedding spaces. *Transactions of the Association for Computational Linguistics*, 8:439–453.

Egger, R. and Yu, J. (2022). A topic modeling comparison between LDA, NMF, Top2Vec, and BERTopic to demystify Twitter posts. *Frontiers in Sociology*, 7:886498.

Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based c-TF-IDF procedure. *arXiv preprint arXiv:2203.05794*.

Janssens, W., Bogaert, M., and van den Poel, D. (2025). A comparative analysis of topic reduction techniques for BERTopic. *IEEE Access*, 13:204087–204103.

Jesse, M., Bauer, C., and Jannach, D. (2022). Intra-list similarity and human diversity perceptions of recommendations: the details matter. *User Modeling and User-Adapted Interaction*, 33(4):769–802.

Jian, F., Huang, J. X., Zhao, J., Ying, Z., and Wang, Y. (2020). A topic-based term frequency normalization framework to enhance probabilistic information retrieval. *Computational Intelligence*, 36(2):486–521.

Koto, F., Lau, J. H., and Baldwin, T. (2021). IndoBERTweet: A pretrained language model for Indonesian Twitter with effective domain-specific vocabulary initialization. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP 2021)*, pages 10660–10668.

Koto, F., Rahimi, A., Lau, J., and Baldwin, T. (2020). IndoLEM and IndoBERT: A benchmark dataset and pre-trained language model for Indonesian NLP. *arXiv preprint arXiv:2011.00677*.

McInnes, L., Healy, J., and Melville, J. (2018). UMAP: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*.

Mohta, A., Jain, A., Saluja, A., and Dahiya, S. (2020). Pre-processing and emoji classification of WhatsApp chats for sentiment analysis. In *2020 Fourth International Conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud) (I-SMAC)*, pages 514–519.

Muhajir, M., Gunardi, G., Danardono, D., and Rosadi, D. (2025). Integrating IndoBERT and balanced iterative reducing and clustering using hierarchies of BERTopic in Indonesian short text. *IAES International Journal of Artificial Intelligence (IJ-AI)*, 14(5):4192–4201.

Prayogi, A., Novriyenny, N., and Prahmana, I. G. (2025). Dinamika sentimen komunikasi mahasiswa dan dosen dengan pemanfaatan analisis pesan WhatsApp akademis menggunakan Machine Learning. *Repeater: Publikasi Teknik Informatika dan Jaringan*, 3(2):45–54.

Ramadhani, F., Zarlis, M., and Suwilo, S. (2020). Improve BIRCH algorithm for big data clustering. *IOP Conference Series: Materials Science and Engineering*, 725(1):012090.

Rani, S. J., Prabhu, T. N., and Chellam, J. A. I. (2022). WhatsApp sentiment analysis using R. In *2022 3rd International Conference for Emerging Technology (INCET)*, pages 1–4. IEEE.

Röder, M., Both, A., and Hinneburg, A. (2015). Exploring the space of topic coherence measures. In *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining*, WSDM '15, pages 399–408, New York, NY, USA. Association for Computing Machinery.

Rushkin, I. (2020). Document similarity from vector space densities. *CoRR*, abs/2009.00672.

Shan, X., Liu, C., Xia, Y., Chen, Q., Zhang, Y., Luo, A., and Luo, Y. (2020). BISON: BM25-weighted self-attention framework for multi-fields document search. *CoRR*, abs/2007.05186.

Siregar, U., Ramadani, N., and Siregar, F. (2025). Syntactic analysis in WhatsApp conversations among peers. *Jurnal Hata Poda*, 4(2):150–157.

Sutarma, I. G. P. (2017). Analisis wujud bentuk linguistik dalam penggunaan Bahasa Indonesia di media sosial "WhatsApp". *Soshum: Jurnal Sosial dan Humaniora*, 6(3):227.

WhatsApp LLC (2026). Tentang WhatsApp. Diakses pada 7 Januari 2026.

Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., and Purwarianti, A. (2020). IndoNLU: Benchmark and resources for evaluating Indonesian natural language understanding. In *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*, pages 514–530.

Zhang, T., Ramakrishnan, R., and Livny, M. (1996). BIRCH: An efficient data clustering method for very large databases. *SIGMOD Rec.*, 25(2):103–114.

Zhang, T., Ramakrishnan, R., and Livny, M. (1997). BIRCH: A new data clustering algorithm and its applications. *Data Min. Knowl. Discov.*, 1(2):141–182.

Zhao, H., Du, L., Buntine, W., and Zhou, M. (2018). Inter and intra topic structure learning with word embeddings. In *International Conference on Machine Learning*, pages 5892–5901. PMLR.

LAMPIRAN

Lampiran 1. Cuplikan Data Mentah Log Obrolan WhatsApp

Cuplikan baris data mentah hasil ekspor percakapan WhatsApp grup Komunitas Buku sebelum dilakukan praproses dan penyamaran identitas.

Tabel 1: Contoh Potongan Data Mentah Hasil Ekspor WhatsApp

No.	Potongan Baris Data Mentah Log Obrolan
1	*02/02/26 20.46 - +62 ***-****-****: Aku tadi searching sedikit tentang buku ini*
2	*02/02/26 20.47 - +62 ***-****-****: <Media tidak disertakan>*
3	*27/09/25 10.35 - +62 ***-****-****: sheesh*
4	*03/02/26 11.24 - +62 ***-****-****: https://link*
5	*28/09/25 09.48 - +62 ***-****-****: gara gara dapet evernight jadi pengen hyacine <Pesan ini diedit>*
6	*24/04/26 05.12 - +62 ***-****-**** sudah ditambahkan*

Lampiran 2. Contoh Transformasi Teks Praproses Data

Contoh transformasi teks pesan sebelum dan sesudah tahap praproses yang meliputi eliminasi notifikasi sistem, penghapusan tanda kurung sudut, normalisasi emoji, tawa, elongasi, dan kata tidak baku.

Tabel 2: Contoh Hasil Transformasi Teks Sebelum dan Sesudah Praproses Data

Pesan Mentah	**Pesan Hasil Praproses**	**Keterangan**
<Media omitted>	*[Dihapus / String Kosong]*	Eliminasi artefak media sistem
@+62 ***-****-5678 welcome yusril! [emoji tersenyum]	@User-bc45·5678 welcome yusril smiling_face	Anonimisasi mention & transliterasi emoji
Gaisss cek link ini yaa https://example.com	gais cek link ini yaa	Elongasi huruf & penghapusan URL
Hahaha wkwkwk ngakak bgt bisaaa aja	haha wkwk ngakak bgt bisa saja	Normalisasi tawa, elongasi & kata tidak baku
Mau tanya perihal bab 3 skripsi dong	mau tanya perihal bab 3 skripsi saja	Case folding & normalisasi kata tidak baku
Pesan ini telah dihapus	*[Dihapus / String Kosong]*	Eliminasi notifikasi pesan sistem

Lampiran 3. Rincian Data Evaluasi Kurva Pembelajaran

Rincian kuantitatif metrik evaluasi pemodelan topik pada setiap fraksi partisi data latih (20%, 40%, 60%, 80%, dan 100%) yang membandingkan performa Model Modified (Muhajir et al., 2025) terhadap Model Usulan.

Tabel 3: Perbandingan Metrik Evaluasi Kurva Pembelajaran Model Modified vs. Model Usulan

Split Data	Model Evaluasi	Jumlah Topik	Topic Diversity	C_{NPMI}	Intra-Topic Sim	Outlier Rate (%)
20% (10.316)	Modified (Muhajir et al.)	40	0,6800	-0,2162	0,6448	4,80%
	Model Usulan	46	0,9457	-0,0290	0,6258	14,32%
40% (20.633)	Modified (Muhajir et al.)	56	0,5964	-0,1485	0,6462	4,74%
	Model Usulan	187	0,9567	+0,0111	0,6134	10,94%
60% (30.950)	Modified (Muhajir et al.)	53	0,5868	-0,0489	0,6472	4,72%
	Model Usulan	124	0,9540	+0,0421	0,6147	8,22%
80% (41.267)	Modified (Muhajir et al.)	73	0,5219	-0,0002	0,6467	4,60%
	Model Usulan	316	0,9604	+0,0462	0,6194	7,62%
100% (51.584)	Modified (Muhajir et al.)	70	0,5257	+0,0090	0,6495	4,58%
	Model Usulan	40	0,9875	+0,1075	0,6534	7,21%

Lampiran 4. Surat Izin Penelitian dari Kampus

Dokumen administratif berupa Surat Izin Penelitian resmi dari pihak kampus untuk permohonan pengambilan data percakapan grup WhatsApp Komunitas Buku.

KEMENTERIAN PENDIDIKAN TINGGI,
SAINS, DAN TEKNOLOGI
UNIVERSITAS JEMBER
FAKULTAS ILMU KOMPUTER
Jalan Kalimantan No. 37, Kampus Bumi Tegal Boto, Jember 68121
Telp. (0331) 326911, Fax. (0331) 326911
Laman : https://ilkom.unej.ac.id

Nomor : 3142/DST/UN25.B15/SP/2026 — 22 Juni 2026
Perihal : Permohonan Izin Penelitian

Kepada Yth. Komunitas Buku Book Clan pada Platform WhatsApp
di tempat

Dalam rangka penyelesaian skripsi mahasiswa Fakultas Ilmu Komputer Universitas Jember, kami mohon dengan hormat bapak/ibu dapat memberikan izin untuk melakukan kegiatan penelitian bagi mahasiswa yang nama dan kegiatan yang dilakukan tersebut dibawah ini :

Nama / NIM	: Moh. Yusril Maqoshidana (222410102064)
Program Studi	: Teknologi Informasi
No. HP	: 085161558904
Kegiatan	: Permintaan export data pesan whatsapp
Judul Skripsi	: SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING
Tempat Kegiatan	: Komunitas Buku Book Clan pada Platform WhatsApp
Periode Kegiatan	: Mei - Juli 2026

Demikian permohonan kami, atas perhatian dan kerjasamanya yang baik diucapkan terima kasih.

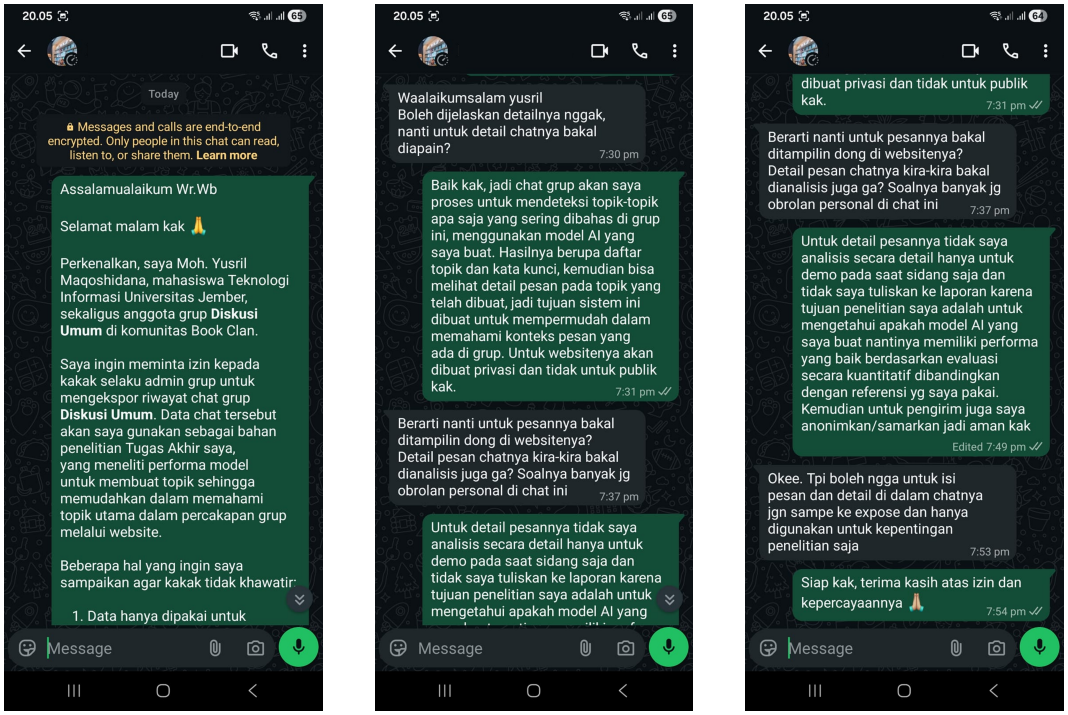
Wakil Dekan Bidang Akademik,

Achmad Maududie., ST., M.Sc
NIP. 197004221995121001

Gambar 1: Surat Izin Penelitian dari Kampus

Lampiran 5. Bukti Persetujuan Admin Grup WhatsApp

Tangkapan layar persetujuan tertulis dari administrator grup WhatsApp Komunitas Buku untuk penggunaan riwayat percakapan sebagai dataset penelitian dengan syarat penyamaran identitas.



(a) Bukti Persetujuan 1 (b) Bukti Persetujuan 2 (c) Bukti Persetujuan 3

Gambar 2: Bukti Persetujuan Admin Grup WhatsApp

Lampiran 6. Hasil Pengujian Fungsional Sistem (*Black-Box Testing*)

Rincian 14 skenario kasus uji fitur fungsional inti (*Minimum Viable Product*/MVP) sistem menggunakan metode *Black-Box Testing* yang mengevaluasi perilaku masukan dan keluaran antarmuka web (*frontend*) serta layanan API (*backend*).

Tabel 4: Hasil Pengujian Fungsional Fitur MVP Sistem (*Black-Box Testing*)

ID Uji	Fitur / Modul	Skenario Pengujian	Langkah-langkah Pengujian	Data Uji / Input	Hasil yang Diharapkan	Hasil
1. Modul Unggah & Validasi Berkas Obrolan (*/upload* - Step 1)						
TC-MVP-01	Unggah Berkas Valid	Mengunggah berkas ekspor obrolan WhatsApp valid (*.txt* / *.zip*)	1. Buka rute */upload*. 2. Pilih atau seret berkas chat valid.	Berkas *.txt* / *.zip* chat	Berkas berhasil diurai (*parsed*), detail nama dan ukuran berkas muncul, serta tombol "Selanjutnya" aktif.	Valid
TC-MVP-02	Validasi Format Berkas	Mengunggah berkas dengan format di luar spesifikasi obrolan	1. Buka rute */upload*. 2. Pilih berkas non-chat (*.pdf* / *.png*).	Berkas *dokumen.pdf*	Sistem menolak berkas, memunculkan notifikasi peringatan format tidak didukung, dan tombol tetap dinonaktifkan.	Valid
2. Modul Pemfilteran Rentang Waktu, Mode Analisis & Privasi Data (*/upload* - Step 2)						
TC-MVP-03	Filter Rentang Tanggal	Menyesuaikan rentang waktu pesan yang akan dianalisis	1. Berada di Step 2. 2. Geser bilah rentang tanggal (slider).	Geser Slider Tanggal	Tanggal awal dan akhir diperbarui secara *real-time*, dan hanya data pesan dalam rentang yang diproses.	Valid
TC-MVP-04	Seleksi Mode Analisis	Memilih mode pemrosesan (*Dual-Mode Selector*)	1. Berada di Step 2. 2. Pilih "Mode Cepat" atau "Mode Riset Lengkap".	Klik Kartu Mode	Kartu mode aktif ditandai secara visual, dan parameter konfigurasi mode tersimpan ke penyimpanan sesi.	Valid
TC-MVP-05	Anonimisasi Sisi Klien	Menjalankan anonimisasi otomatis sebelum pengiriman berkas	1. Klik tombol "Mulai Analisis". 2. Amati transmisi jaringan (*Network devtools*).	Klik Mulai Analisis	Skrip sisi klien menyamarkan identitas dan nomor pengirim menjadi token SHA-256 bergaram sebelum dikirim ke backend.	Valid
3. Modul Pemrosesan AI & Pemantauan Komputasi (*/upload* - Step 3)						
TC-MVP-06	Pemrosesan Asinkron AI	Menjalankan pemodelan topik pada utas latar belakang	1. Backend menerima permintaan analisis. 2. Amati eksekusi pemodelan topik.	Payload CSV Anonim	Backend FastAPI memproses alur IndoBERTweet, *ImprovedBirch*, dan BM25 secara asinkron tanpa memblokir server.	Valid

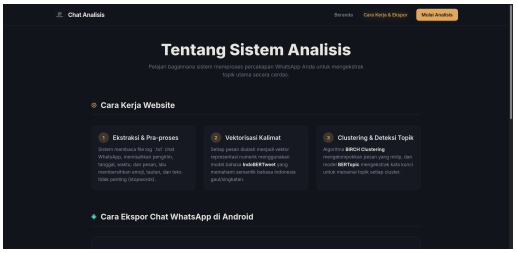
ID Uji	Fitur / Modul	Skenario Pengujian	Langkah-langkah Pengujian	Data Uji / Input	Hasil yang Diharapkan	Hasil
TC-MVP-07	Pemantauan SSE *Real-Time*	Memantau aliran log proses komputasi pada simulator terminal	1. Berada di Step 3. 2. Amati konsol log *TerminalSimulator*.	Aliran Event SSE	Perkembangan setiap tahapan analisis terpancar secara langsung ke antarmuka hingga status selesai (*completed*).	Valid
TC-MVP-08	Pengalihan Otomatis	Melakukan pengalihan rute secara otomatis pasca-analisis	1. Tunggu hingga tahapan akhir selesai (*done: true*).	Sinyal Selesai SSE	Aplikasi secara otomatis mengalihkan tampilan dari Step 3 menuju halaman dasbor hasil (*/results*).	Valid
4. Modul Dasbor Hasil Analisis & Visualisasi Topik (*/results*)						
TC-MVP-09	Kartu Metrik Evaluasi	Menyajikan ringkasan metrik kualitas pemodelan topik	1. Berada di */results*. 2. Periksa baris kartu metrik evaluasi.	Data Metrik Server	Dasbor menampilkan metrik jumlah topik, diversitas (TD), koherensi (C_{NPMI}), kepadatan (ED), dan kekohesifan (ITS).	Valid
TC-MVP-10	Grafik Keaktifan Obrolan	Menyajikan linimasa distribusi volume percakapan	1. Berada di */results*. 2. Amati grafik aktivitas tanggal (*ActiveDates*).	Data Agregasi Waktu	Visualisasi grafik linimasa menyajikan tren frekuensi obrolan per hari dengan interaksi *tooltip* yang responsif.	Valid
TC-MVP-11	Daftar Klaster Topik	Menyajikan kartu klaster topik dan kata kunci representatif	1. Gulir ke daftar klaster topik. 2. Periksa kartu klaster dan kata kunci.	Data Klaster Topik	Setiap kartu klaster menyajikan label topik, jumlah pesan, proporsi korpus, dan 10 kata kunci teratas.	Valid
5. Modul Eksplorasi Detail Topik & Konteks Pesan (*/results/topics/:topicId*)						
TC-MVP-12	Penelusuran Pesan Topik	Membuka rute detail topik untuk meninjau seluruh pesan anggota	1. Klik salah satu kartu topik di */results*. 2. Amati daftar pesan di halaman detail.	Klik Kartu Topik	Halaman detail menyajikan seluruh daftar pesan yang terpetakan ke dalam topik tersebut beserta stempel waktu.	Valid
TC-MVP-13	Modal Konteks Obrolan	Menampilkan percakapan utuh di sekitar pesan terpilih	1. Pada detail topik, klik tombol "Lihat Konteks".	Klik Konteks Pesan	Dialog modal terbuka menyajikan percakapan sebelum dan sesudah pesan terpilih secara kronologis (*thread context*).	Valid
TC-MVP-14	Ekspor Laporan Analisis	Mengunduh ringkasan hasil pemodelan topik ke dokumen lokal	1. Di halaman */results*, klik tombol "Ekspor Laporan".	Klik Ekspor Laporan	Berkas laporan hasil pemodelan topik berhasil diunduh ke perangkat pengguna dengan data yang lengkap.	Valid

Lampiran 7. Tangkapan Layar Implementasi Antarmuka Sistem Web

Rincian tangkapan layar antarmuka pengguna (*frontend*) aplikasi web ChatAnalisis yang mengimplementasikan arsitektur *client-side anonymization*, pemantauan *streaming* SSE, visualisasi hasil pemodelan topik, serta penelusuran konteks pesan (*traceability*).

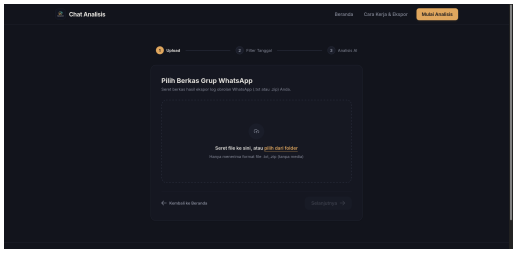


(a) Halaman Utama (Landing Page)

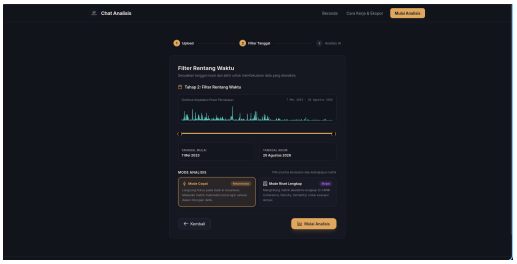


(b) Modal Panduan Ekspor Chat

Gambar 3: Antarmuka Utama dan Panduan Cara Kerja Aplikasi Web ChatAnalisis

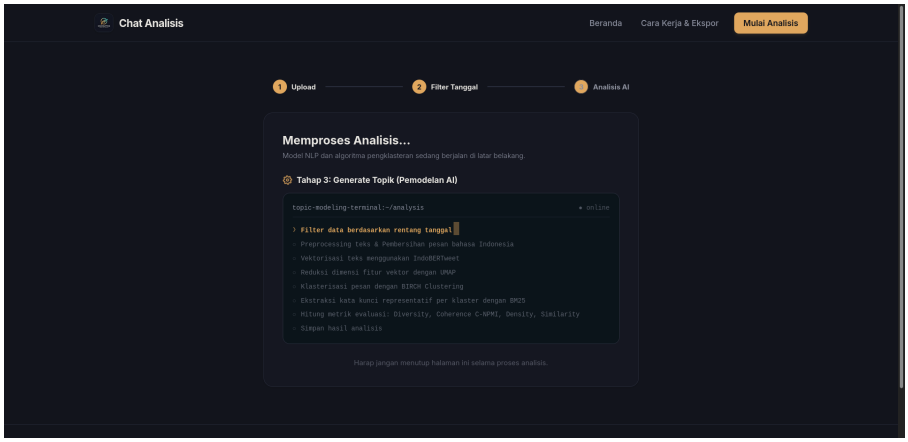


(a) Unggah Berkas Obrolan



(b) Filter Rentang Tanggal & Anonimisasi

Gambar 4: Antarmuka Unggah Berkas dan Pengaturan Filter Rentang Tanggal Data



Gambar 5: Tampilan Pemantauan Progres Analisis secara Real-Time via Server-Sent Events (SSE)



Gambar 6: Tampilan Dashboard Hasil Pemodelan Topik dan Grafik Tren Waktu Obrolan

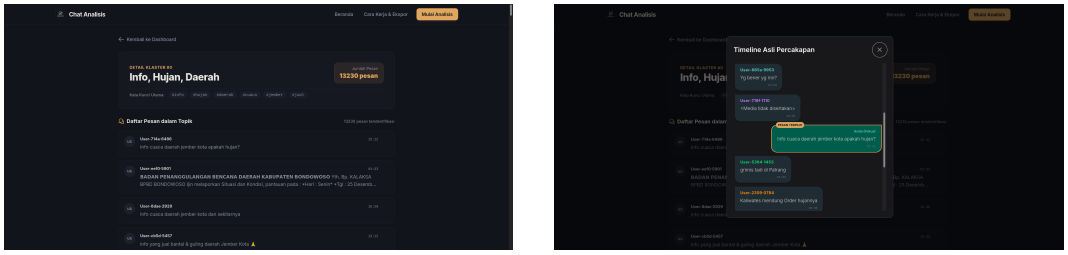


(a) Panel Metrik Evaluasi Kuantitatif



(b) Aktivitas & Leaderboard Pengirim

Gambar 7: Visualisasi Panel Metrik Evaluasi Kuantitatif dan Distribusi Aktivitas Pengguna



(a) Halaman Detail Klaster Topik (b) Modal Penelusuran Konteks Pesan

Gambar 8: Antarmuka Detail Klaster Topik dan Dialog Modal Penelusuran Konteks Pesan