



**SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB
MENGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH
CLUSTERING**

*Diajukan guna memenuhi salah satu syarat penelitian untuk memenuhi kelulusan
Program Studi Teknologi Informasi*

SKRIPSI

Oleh:

Moh. Yusril Maqoshidana

NIM 222410102064

**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN
TEKNOLOGI PROGRAM STUDI TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER
UNIVERSITAS JEMBER**

2026

PERSEMBAHAN

Halaman ini saya persembahkan kepada:

1. Orang tua tercinta, yang telah memberikan doa, dukungan, dan inspirasi
2. Keluarga besar, yang selalu ada dalam setiap langkah saya
3. Para pendidik dan dosen, yang telah membimbing perjalanan akademis saya
4. Semua orang yang telah berkontribusi dalam perjalanan ini

MOTTO

*“Tiada kekayaan yang lebih utama daripada akal,
tiada keadaan yang lebih menyedihkan daripada kebodohan,
dan tiada warisan yang lebih baik daripada pendidikan”*

(Ali bin Abi Thalib)

“When you’re afraid of something, learn as much as you can about it.

Knowledge overcomes fear”

(Edmund Burke)

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini:

Nama: Moh. Yusril Maqoshidana

NIM: 222410102064

Dengan ini menyatakan bahwa skripsi yang berjudul: *Sistem Analisis Topik Grup WhatsApp Berbasis Web Menggunakan BERTopic dengan IndoBERTweet dan BIR-CH Clustering*

adalah benar-benar hasil karya saya sendiri. Saya juga menyatakan bahwa dalam skripsi ini tidak terdapat karya yang pernah diajukan untuk memperoleh gelar sarjana atau gelar lainnya di mana pun.

Saya bertanggung jawab atas kebenaran dan keorisinalan isi skripsi ini. Apabila dikemudian hari terbukti bahwa skripsi ini mengandung unsur plagiasi, maka saya siap menanggung akibat hukum yang berlaku.

Jember, 01 Juni 2026

Yang menyatakan,

Moh. Yusril Maqoshidana

NIM. 222410102064

HALAMAN PERSETUJUAN

Skripsi berjudul “*SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING*” telah diuji dan disetujui oleh Fakultas Ilmu Komputer Universitas Jember pada:

Hari : Minggu

Tanggal : 01 Juni 2026

Tempat : Fakultas Ilmu Komputer Universitas Jember

Pembimbing

Tanda Tangan

1. Pembimbing Utama

Nama : Dr. Brian Rizqi P. D., S.Kom., M.Kom

(.....)

NIP : 199804272024061001

Penguji

1. Penguji Utama

Nama : Khoirunnisa' Afandi, S.Kom., M.Kom

(.....)

NIP : 199412282024062001

2. Penguji Anggota 1

Nama : Dony Bahtera Firmawan, S.Kom., M.Kom

(.....)

NIP : 199711202024061001

ABSTRAK

Latar belakang penelitian ini adalah ... (Jelaskan konteks dan motivasi penelitian Anda di sini, minimal 2-3 kalimat).

Rumusan masalah dalam penelitian ini adalah ... (Jelaskan masalah utama yang ingin dipecahkan).

Tujuan penelitian ini adalah untuk ... (Jelaskan tujuan yang ingin dicapai dari penelitian Anda).

Metode penelitian yang digunakan adalah ... (Jelaskan metode penelitian secara ringkas: jenis penelitian, sampel, instrumen, teknik analisis).

Hasil penelitian menunjukkan bahwa ... (Jelaskan temuan utama dari penelitian Anda).

Kesimpulannya adalah ... (Berikan kesimpulan singkat dan implikasi dari penelitian).

Kata Kunci: *Kata Kunci Satu, Kata Kunci Dua, Kata Kunci Tiga*

ABSTRACT

The background of this research is ... (Explain the context and motivation of your research here, at least 2-3 sentences).

The research problem investigated in this study is ... (Explain the main problem to be solved).

The purpose of this research is to ... (Explain the objectives to be achieved from your research).

The research method used is ... (Explain the research method briefly: research type, sample, instruments, analysis techniques).

The research results show that ... (Explain the main findings from your research).

The conclusion is that ... (Provide a brief conclusion and implications of the research).

Keywords: *Kata Kunci Satu, Kata Kunci Dua, Kata Kunci Tiga*

RINGKASAN

Penelitian ini dilakukan dengan latar belakang ... (Jelaskan konteks, motivasi, dan pentingnya penelitian secara lebih detail dibanding abstrak.)

Dalam era ... (Tambahkan konteks temporal dan kontekstual penelitian Anda).

Masalah yang dihadapi adalah ... (Jelaskan masalah penelitian dan mengapa penting untuk diteliti). Oleh karena itu, penelitian ini bertujuan untuk ... (Jelaskan tujuan utama penelitian).

Metode penelitian yang digunakan adalah ... (Jelaskan dengan detail: pendekatan, design, populasi/sampel, instrumen, teknik pengumpulan data, dan analisis data).

Temuan penelitian menunjukkan bahwa ... (Jelaskan hasil utama, temuan penting, dan interpretasi awal).

Berdasarkan hasil penelitian, dapat disimpulkan bahwa ... (Berikan kesimpulan yang comprehensive). Penelitian ini diharapkan dapat memberikan manfaat bagi ... (Jelaskan kontribusi praktis dan akademis).

PRAKATA

Puji syukur ke hadirat Tuhan Yang Maha Esa atas segala berkah dan rahmat yang telah diberikan sehingga penelitian ini dapat diselesaikan dengan baik dan tepat pada waktunya.

Penelitian yang berjudul “*SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING*” ini merupakan salah satu persyaratan untuk memperoleh gelar Sarjana Komputer (S.Kom) pada Program Studi Informatika, Fakultas Ilmu Komputer, Universitas Jember.

Penulis menyadari bahwa dalam proses penelitian dan penulisan skripsi ini, banyak pihak yang telah memberikan bimbingan, dukungan, dan bantuan. Oleh karena itu, pada kesempatan ini penulis dengan sepenuh hati mengucapkan terima kasih kepada:

1. Dr. Brian Rizqi Paradisiaca Darnoto, S.Kom., M.Kom selaku Pembimbing Pertama yang telah memberikan bimbingan, arahan, dan motivasi
2. Para dosen dan staf Program Studi Informatika yang telah membantu selama proses akademik
3. Keluarga besar yang telah memberikan doa dan dukungan moral
4. Rekan-rekan peneliti dan teman-teman yang telah memberikan masukan dan semangat

Penulis menyadari bahwa skripsi ini masih memiliki berbagai kekurangan, baik dalam penulisan maupun isi. Oleh karena itu, penulis mengharapkan kritik dan saran yang sifatnya membangun dari pembaca untuk perbaikan di masa mendatang.

Akhir kata, semoga penelitian ini dapat memberikan manfaat bagi kemajuan ilmu pengetahuan dan dapat dijadikan sebagai bahan referensi bagi penelitian-penelitian selanjutnya.

Jember, 01 Juni 2026

Moh. Yusril Maqoshidana

222410102064

DAFTAR ISI

PERSEMBAHAN	i
MOTTO	ii
PERNYATAAN ORISINALITAS	iii
HALAMAN PERSETUJUAN	iv
ABSTRAK	v
ABSTRACT	vi
RINGKASAN	vii
PRAKATA	viii
DAFTAR TABEL	xiii
DAFTAR GAMBAR	xiv
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	4
1.4 Manfaat Penelitian	4
1.5 Batasan Penelitian	5
2 TINJAUAN PUSTAKA	6
2.1 Penelitian Terdahulu	6
2.2 Landasan Teori	7
2.2.1 Aplikasi WhatsApp	7
2.2.2 BERTopic	8
2.2.3 IndoBERTweet	9
2.2.4 BIRCH Clustering	10
2.2.5 Topic Representation Dengan BM25	11
2.2.6 Topic Coherence	12
2.2.7 Topic Diversity	13
2.2.8 Embedding Density	13
2.2.9 Intra-topic Similarity	14
3 METODOLOGI PENELITIAN	15
3.1 Jenis Penelitian	15

3.2	Objek Penelitian	15
3.3	Waktu Penelitian	15
3.4	Tahapan Penelitian	15
3.4.1	Identifikasi Masalah dan Studi Literatur	16
3.4.2	Pengumpulan Data	16
3.4.3	Praproses Data	17
3.4.4	Pembuatan Model	17
3.4.5	Evaluasi Model	19
3.4.6	Implementasi Sistem	20
3.4.7	Evaluasi Sistem	21
3.4.8	Analisis Hasil	21
3.4.9	Penarikan Kesimpulan	21
3.5	Etika Penelitian	21
4	HASIL DAN PEMBAHASAN	23
4.1	Pengumpulan Data	23
4.2	Praproses Data	24
4.3	Pembuatan Model	24
4.3.1	Embedding dan Reduksi Dimensi	24
4.3.2	Clustering dan Representasi Topik	24
4.3.3	Evaluasi Kuantitatif Model	24
4.3.4	Perbandingan Eksperimen (Baseline vs Modifikasi)	25
4.3.5	Uji Asumsi dan Analisis Inferensial	25
4.3.6	Implementasi Sistem dan Evaluasi Fungsional	25
4.3.7	Analisis Hasil	25
4.4	Pembahasan	25
4.4.1	Interpretasi Temuan Utama	25
4.4.2	Analisis Kualitatif Topik	26
4.4.3	Implikasi Praktis dan Rekomendasi Implementasi	26
4.4.4	Keterbatasan Penelitian	26
4.4.5	Saran dan Pekerjaan Lanjutan	26
4.4.6	Ringkasan Hasil Utama	26
5	KESIMPULAN DAN SARAN	27
5.1	Kesimpulan	27
5.2	Saran	27
5.2.1	Saran untuk Penelitian Selanjutnya	27
5.2.2	Saran untuk Praktisi dan Pengambil Kebijakan	28
	DAFTAR PUSTAKA	28
A	LAMPIRAN	33
A.1	Lampiran A - Data Mentah	33
A.2	Lampiran B - Instrumen Penelitian	34
A.2.1	Lampiran B.1 - Kuesioner	34

A.3	Lampiran C - Output Analisis Statistik	35
A.4	Lampiran D - Kode Sumber	36
A.5	Lampiran E - Dokumen Pendukung	37

DAFTAR TABEL

2.1	Tinjauan Penelitian Terdahulu	6
2.2	Perbandingan Kinerja Model pada Tujuh Tugas	9

DAFTAR GAMBAR

2.1	Framework BERTopic dengan modifikasi IndoBERT, BIRCH, dan BM25 (Muhajir et al., 2025)	8
3.1	Tahapan Penelitian	16
3.2	Rancangan framework BERTopic yang dimodifikasi pada tahap pembuatan model	18
3.3	Alur implementasi sistem analisis topik WhatsApp	20

BAB 1. PENDAHULUAN

1.1 Latar Belakang

WhatsApp telah menjadi salah satu aplikasi pesan instan paling populer di dunia, dengan lebih dari 3 miliar pengguna aktif di lebih dari 180 negara (WhatsApp Inc., 2026). Selain digunakan untuk komunikasi personal, fitur grup pada WhatsApp berperan penting sebagai wadah diskusi komunitas, koordinasi tim, pembelajaran daring, serta komunikasi organisasi. Percakapan yang terjadi dalam grup WhatsApp menghasilkan data teks yang sangat potensial untuk dianalisis guna memahami topik diskusi, pola komunikasi, dan dinamika interaksi antaranggota. Namun, seiring meningkatnya volume pesan dalam grup, pengguna sering mengalami kesulitan dalam mengikuti alur percakapan, menemukan informasi penting, maupun memahami topik yang sedang dibahas (Rani et al., 2022). Oleh karena itu, diperlukan suatu sistem yang mampu menganalisis topik percakapan grup WhatsApp secara otomatis.

Topic modeling sudah banyak digunakan pada penelitian terdahulu untuk menganalisis percakapan grup WhatsApp untuk menghasilkan atau menyimpulkan topik yang paling sesuai dari seluruh dokumen obrolan tersebut, sehingga pengguna dapat memahami secara garis besar apa yang sedang dibicarakan (Retna et al., 2021). *Topic modeling* merupakan teknik fundamental dalam pemrosesan bahasa alami (*natural language processing*) yang bertujuan untuk mengidentifikasi struktur tematik laten dalam sekumpulan dokumen melalui ekstraksi pola kemunculan kata yang sering muncul bersama dalam konteks yang bermakna di dalam dokumen (Abdelrazek et al., 2023). Kompleksitas analisis percakapan grup WhatsApp semakin meningkat mengingat karakteristik data yang berupa teks pendek, tidak terstruktur, mengandung noise tinggi, disertai fenomena code-mixing yang masif, volume data yang besar, serta dinamika evolusi topik yang berlangsung cepat (Churchill and Singh, 2022; Mohta et al., 2020; Egger and Yu, 2022). Kondisi tersebut

mengakibatkan pemilihan model *topic modeling* yang tepat menjadi faktor krusial dalam menghasilkan kluster topik yang akurat dan koheren.

Penelitian sebelumnya membandingkan beberapa model *topic modeling* seperti LDA, NMF, Top2Vec, dan BERTopic untuk menganalisis data social media Twitter (X) yang banyak mengandung teks pendek, dan menemukan bahwa BERTopic memberikan performa terbaik untuk model berbasis *embedding* (Egger and Yu, 2022). Namun, penelitian tersebut juga menunjukkan bahwa model berbasis *embedding* memiliki masalah dalam menghadapi *outlier* (dokumen bising yang tidak masuk ke kluster manapun). Hal ini karena HDBSCAN sebagai algoritma klasterisasi berbasis kepadatan dalam BERTopic secara inheren mengklasifikasikan dokumen yang tidak memenuhi kriteria stabilitas kluster sebagai *outlier* (Janssens et al., 2025).

Pada penelitian Muhajir et al. (2025), penulis mengusulkan modifikasi BERTopic dengan mengganti model *HDBSCAN* dengan BIRCH untuk mengatasi masalah *outlier* dan menggunakan IndoBERTweet sebagai model *embedding*. Algoritma BIRCH dipilih sebagai metode *clustering* karena kemampuannya membentuk kluster secara dinamis dan menugaskan hampir seluruh dokumen ke dalam kluster yang valid, sehingga mampu menekan proporsi *outlier* hingga 1%–5%, jauh lebih rendah dibandingkan HDBSCAN yang dapat membuang hingga 23%–24% dokumen sebagai data bising pada teks pendek yang bersifat *sparse*. IndoBERTweet dipilih karena model bahasa pra-latih (*pretrained language model*) berskala besar pertama yang dirancang dan dilatih secara khusus untuk menangani dan memproses data X (Twitter) berbahasa Indonesia (Koto et al., 2021). Model ini dibangun melalui pendekatan *domain-adaptive pretraining* dengan fondasi IndoBERT/IndoLEM sebagai model *domain-general* berbahasa Indonesia (Koto et al., 2020, 2021). Pendekatan ini memungkinkan model memahami karakteristik linguistik unik, bahasa sehari-hari, dan kosakata spesifik domain yang umum pada teks pendek berbahasa Indonesia, sehingga menghasilkan contextualized embeddings berkualitas tinggi untuk meningkatkan pemahaman semantik pada percakapan grup WhatsApp (Muhajir et al., 2025). Dengan demikian, kombinasi BIRCH dan IndoBERTweet me-

memiliki landasan metodologis yang kuat untuk digunakan pada analisis topik percakapan WhatsApp yang cenderung berteks pendek, bising, dan tidak terstruktur. BIRCH berperan dalam menekan *outlier* pada data *sparse*, sedangkan IndoBERTweet membantu merepresentasikan konteks bahasa media sosial secara lebih baik dibandingkan model yang hanya dilatih pada korpus formal.

Meskipun penelitian mengenai *topic modeling* pada percakapan grup WhatsApp telah dilakukan sebelumnya (Kharisudin and Masri'an, 2022; Kumar and Naik, 2023; Retna et al., 2021), masih terdapat beberapa *research gap*. Pertama, penggunaan IndoBERTweet sebagai model *embedding* dalam *framework* BERTopic untuk percakapan grup WhatsApp berbahasa Indonesia masih terbatas. Kedua, pemanfaatan BIRCH sebagai pengganti HDBSCAN pada BERTopic belum banyak dieksplorasi, padahal berpotensi meningkatkan stabilitas *clustering* dan mengurangi *outlier*. Ketiga, mayoritas penelitian sebelumnya berfokus pada eksperimen metodologis tanpa menyediakan sistem yang dapat digunakan langsung oleh pengguna akhir.

Berdasarkan permasalahan tersebut, penelitian ini bertujuan mengembangkan sistem analisis topik percakapan grup WhatsApp berbasis *web* dengan fokus pada integrasi IndoBERTweet dan algoritma BIRCH dalam *framework* BERTopic. Sistem ini diharapkan membantu pengguna memahami topik utama percakapan grup secara otomatis tanpa harus membaca seluruh pesan secara manual. Selain memberikan kontribusi akademik pada pengembangan metode *topic modeling* untuk data percakapan berbahasa Indonesia, penelitian ini juga menghasilkan solusi praktis yang dapat dimanfaatkan oleh administrator grup, komunitas, peneliti sosial, maupun pengguna umum melalui antarmuka *web* yang mudah diakses dan informatif.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut berikut merupakan masalah yang dapat dirumuskan dalam penelitian ini:

1. Bagaimana penerapan BERTopic dengan IndoBERTweet dan BIRCH *cluste-*

ring untuk menganalisis topik percakapan grup WhatsApp berbahasa Indonesia?

2. Bagaimana kinerja BERTopic dengan IndoBERTweet dan BIRCH *clustering* dalam menghasilkan representasi semantik teks percakapan grup WhatsApp berbahasa Indonesia?
3. Bagaimana mengimplementasikan sistem analisis topik percakapan grup WhatsApp berbasis *web* menggunakan BERTopic dengan IndoBERTweet dan BIRCH *clustering*?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah tersebut, berikut adalah tinjauan penelitian yang mampu dirumuskan, diantaranya:

1. Menerapkan BERTopic dengan menggunakan model IndoBERTweet sebagai model *embedding* dan algoritma BIRCH sebagai metode *clustering* untuk menganalisis topik percakapan grup WhatsApp berbahasa Indonesia.
2. Menganalisis hasil kinerja metode BERTopic dengan menggunakan model IndoBERTweet dan algoritma BIRCH *clustering* dalam menghasilkan representasi semantik pada teks percakapan grup WhatsApp berbahasa Indonesia.
3. Mengimplementasikan sistem analisis topik percakapan grup WhatsApp berbasis *web* yang memanfaatkan BERTopic dengan IndoBERTweet dan BIRCH *clustering* agar dapat digunakan secara langsung oleh *end-user*.

1.4 Manfaat Penelitian

Adapun manfaat yang diharapkan dari penelitian ini dapat diuraikan sebagai berikut:

1. Memberikan kontribusi dalam pengembangan ilmu di bidang *Natural Language Processing* (NLP), khususnya penerapan BERTopic dengan IndoBERTweet dan BIRCH *clustering* untuk analisis topik pada teks percakapan berbahasa Indonesia.

2. Menyediakan sistem berbasis *web* yang mampu menganalisis percakapan grup WhatsApp secara otomatis dan menyajikan hasil dalam bentuk visualisasi topik yang mudah dipahami.
3. Menjadi referensi bagi penelitian selanjutnya terkait penerapan *topic modeling* pada data teks pendek dan percakapan informal berbahasa Indonesia.

1.5 Batasan Penelitian

Agar penelitian ini lebih terarah dan fokus, maka ditetapkan beberapa batasan penelitian sebagai berikut:

1. Sistem hanya menganalisis percakapan teks berbahasa Indonesia dari grup WhatsApp, tidak mencakup media gambar, video, audio, maupun dokumen.
2. Data masukan berupa file ekspor chat WhatsApp format .txt atau .zip.
3. Penelitian ini dibatasi pada analisis data percakapan grup WhatsApp Diskusi Umum Komunitas Book Clan dengan rentang riwayat data selama tiga tahun, yaitu dari tahun 2022 hingga 2025.
4. Penelitian berfokus pada pemodelan topik dan tidak mencakup analisis sentimen, klasifikasi emosi, maupun prediksi perilaku pengguna.
5. Tahap preprocessing mencakup pembersihan pesan sistem, normalisasi teks, transliterasi emotikon, normalisasi slang word, serta stopword removal menggunakan kamus manual dan Sastrawi.
6. Representasi topik menggunakan BM25 sebagai pengganti c-TF-IDF.
7. Evaluasi dilakukan menggunakan metrik Topic Coherence, Topic Diversity, Embedding Density, Intra-topic Similarity, serta pengujian fungsional black-box.

BAB 2. TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Tabel 2.1: Tinjauan Penelitian Terdahulu

No	Judul Penelitian	Hasil Penelitian	Celah (<i>Gap</i>)	Kontribusi
1	<i>A Topic Modeling Comparison Between LDA, NMF, Top2Vec, and BERTopic to Demystify Twitter Posts</i> (Egger and Yu, 2022) (Jurnal Q1)	Penelitian ini membandingkan BERTopic, NMF, LDA, dan Top2Vec pada data Twitter. BERTopic direkomendasikan untuk pendekatan berbasis <i>embedding</i> , sedangkan NMF menjadi alternatif tradisional yang lebih unggul untuk data media sosial.	Meskipun BERTopic menunjukkan performa yang baik, penggunaan <i>embedding</i> multilingual dan <i>clustering</i> default (HDBSCAN) masih memiliki keterbatasan dalam mengatasi <i>outlier</i> dan meningkatkan stabilitas topik. Belum ada sistem aplikatif yang dikembangkan.	Penelitian ini menggunakan IndoBERTweet sebagai model <i>embedding</i> khusus bahasa Indonesia serta BIRCH sebagai alternatif HDBSCAN untuk meningkatkan stabilitas <i>clustering</i> dan mengurangi <i>outlier</i> . Selain itu, dikembangkan sistem berbasis <i>web</i> untuk analisis percakapan WhatsApp.
2	<i>Integrating IndoBERT and BIRCH in BERTopic for Indonesian short text</i> (Muha-jir et al., 2025) (Jurnal Q2)	Penelitian ini memodifikasi BERTopic dengan IndoBERT, BM25, dan BIRCH dengan dataset dari X, Google Reviews, dan YouTube yang bersifat teks monolog. Berhasil menurunkan <i>outlier</i> secara signifikan serta meningkatkan stabilitas topik pada teks pendek.	Pendekatan ini belum dieksplorasi pada data percakapan grup WhatsApp yang memiliki karakteristik lebih kompleks berupa <i>multi-turn dialogue</i> , evolusi percakapan yang cepat dan volume pesan yang tinggi. Selain itu, penelitian terdahulu belum menyediakan sistem aplikasi bagi pengguna akhir.	Penelitian ini mengimplementasikan BERTopic dengan IndoBERTweet dan BIRCH pada dataset WhatsApp yang diintegrasikan ke dalam sistem analisis interaktif untuk memvisualisasikan dinamika topik secara otomatis.
3	<i>BERTopic Enhanced Bibliometric Insight Into Global South Higher Education</i> (Banerjee and Pan, 2024) (Jurnal Q1)	Penelitian ini menyelidiki keragaman linguistik dan proses dekolonisasi dalam sistem pendidikan tinggi di wilayah Global South menggunakan kerangka kerja empiris tiga tingkat yang menggabungkan Analisis Ko-occurensi Bibliometrik (Bibliometric Co-occurrence Analysis), pemodelan topik LDA, dan pemodelan BERTopic. BERTopic menunjukkan performa lebih baik dibanding LDA dalam koherensi dan jumlah topik yang dihasilkan pada data akademik.	Penelitian tersebut belum mengeksplorasi alternatif algoritma klasterisasi yang dapat meminimalkan <i>outlier</i> sejak awal proses, serta belum menguji efektivitas BERTopic pada bahasa Indonesia dengan karakteristik teks percakapan informal yang memiliki noise tinggi dan fenomena <i>code-mixing</i> . Penelitian tersebut juga belum menyediakan sistem aplikasi bagi pengguna akhir.	Penelitian ini berkontribusi dengan mengganti HDBSCAN menggunakan BIRCH <i>clustering</i> yang mampu mengakomodasi dokumen <i>outlier</i> secara dinamis tanpa penghapusan, sekaligus menggunakan IndoBERTweet sebagai <i>embedding</i> untuk dataset percakapan berbahasa Indonesia yang banyak mengandung kata informal dan <i>code-mixing</i> . Penelitian ini juga menyediakan sistem aplikasi bagi pengguna akhir.

Berdasarkan penelitian terdahulu yang telah diulas pada tabel 2.1, dapat disimpulkan bahwa meskipun telah banyak penelitian yang membandingkan berbagai model *topic modeling* untuk analisis teks pendek, hasil penelitian terdahulu

menunjukkan bahwa BERTopic cenderung lebih unggul dibandingkan pendekatan konvensional pada data media sosial dan data akademik, tetapi masih memiliki keterbatasan ketika menggunakan *embedding* multilingual dan algoritma *clustering* bawaan seperti HDBSCAN. Pada sejumlah penelitian tersebut, penggunaan model yang lebih spesifik terhadap bahasa dan domain, seperti IndoBERT, serta algoritma BIRCH sebagai alternatif klasterisasi, terbukti menjanjikan dalam mengurangi *outlier* dan meningkatkan stabilitas topik pada teks pendek. Selain itu, penelitian yang telah diulas belum banyak mengeksplorasi penerapan pipeline BERTopic pada percakapan grup WhatsApp berbahasa Indonesia yang bersifat *multi-turn*, tidak terstruktur, dan kaya *code-mixing*. Di sisi lain, mayoritas penelitian masih berfokus pada evaluasi metodologi tanpa menyediakan sistem aplikasi yang dapat digunakan langsung oleh pengguna akhir untuk menganalisis percakapan mereka sendiri.


2.2 Landasan Teori

2.2.1 Aplikasi WhatsApp

WhatsApp merupakan aplikasi pesan instan yang memungkinkan pengguna berkomunikasi melalui pesan teks, suara, gambar, video, serta fitur grup yang mendukung komunikasi banyak pengguna dalam satu ruang diskusi (Prayogi et al., 2025). Fitur grup memungkinkan pengguna tergabung dalam banyak kelompok sekaligus untuk kepentingan personal, bisnis, maupun keamanan, sehingga volume pesan sering menjadi besar dan tumpang tindih. Kondisi ini membuat percakapan grup bersifat tidak terstruktur, melibatkan banyak partisipan, dan topik pembahasan dapat berubah dengan cepat (Rani et al., 2022). Akibatnya, pengguna sering kesulitan mengikuti arah percakapan secara menyeluruh. Permasalahan inilah yang menjadi latar belakang penelitian ini, yaitu mengembangkan sistem analisis percakapan grup WhatsApp yang dapat mengidentifikasi dan memetakan topik pembahasan secara otomatis.

2.2.2 BERTopic

BERTopic adalah *framework topic modeling* berbasis *transformer* yang membentuk *embedding* dokumen dan merepresentasikan topik melalui prosedur TF-IDF berbasis kelas, sehingga dokumen dengan makna semantik serupa dapat dipetakan saling berdekatan dalam ruang vektor (Grootendorst, 2022). Pendekatan ini relevan untuk percakapan grup WhatsApp yang umumnya berupa teks pendek, berisik (*noisy*), dan tidak terstruktur, yang cenderung menimbulkan masalah kelangkaan data (*data sparsity*) pada metode pemodelan topik konvensional.



Gambar 2.1: Framework BERTopic dengan modifikasi IndoBERT, BIRCH, dan BM25 (Muhajir et al., 2025)

Berdasarkan Gambar 2.1, *framework* BERTopic terdiri dari empat tahap utama. Tahap pertama adalah *document embedding* yang mengubah dokumen menjadi representasi vektor numerik menggunakan model bahasa seperti IndoBERTweet yang dikembangkan untuk variasi bahasa Indonesia pada ranah media sosial (Koto et al., 2021). Tahap kedua adalah *dimensionality reduction* menggunakan UMAP untuk mereduksi dimensi vektor hasil *embedding* agar proses klasterisasi lebih efi-

sien (McInnes et al., 2018). Tahap ketiga adalah *clustering* yang mengelompokkan dokumen berdasarkan kemiripan semantik, di mana setiap kluster merepresentasikan satu topik dengan dukungan model yang bersifat modular seperti HDBSCAN, BIRCH, dan K-Means. Tahap keempat adalah *topic representation* yang mengekstrak kata kunci paling representatif dari setiap kluster. Secara bawaan BERTopic menggunakan c-TF-IDF, namun tahap ini dapat dimodifikasi karena bersifat modular (Grootendorst, 2022). Dalam penelitian ini, komponen yang digunakan pada tiap tahap meliputi IndoBERTweet untuk *embedding*, BIRCH untuk klusterisasi, dan BM25 untuk representasi topik.

2.2.3 IndoBERTweet

Model IndoBERTweet merupakan model bahasa pra-latih berskala besar pertama yang dirancang khusus untuk memproses data Twitter (X) berbahasa Indonesia. Model ini dikembangkan melalui pendekatan *domain-adaptive pretraining* dengan fondasi IndoBERT yang semula dilatih pada korpus formal, kemudian diadaptasi ke domain Twitter yang lebih informal. Dalam proses adaptasi tersebut, peneliti melakukan penyesuaian kosakata domain-spesifik dan melaporkan 14.584 kosakata baru (46% dari total kosakata) yang tidak tercakup pada IndoBERT umum (Koto et al., 2021).

Tabel 2.2: Perbandingan Kinerja Model pada Tujuh Tugas

Model	Sentiment		Emotion	Hate Speech		NER		Average
	IndoLEM	SmSA	EmoT	HS1	HS2	Formal	Informal	
mBERT	76.6	84.7	67.5	85.1	75.1	85.2	83.2	79.6
malayBERT	82.0	84.1	74.2	85.0	81.9	81.9	81.3	81.5
IndoBERT (Wilie et al., 2020)	84.1	88.7	73.3	86.8	80.4	86.3	84.3	83.4
IndoBERT (Koto et al., 2020)	84.1	87.9	71.0	86.4	79.3	88.0	86.9	83.4
IndoBERTweet (1M steps from scratch) (Koto et al., 2021)	86.2	90.4	76.0	88.8	87.5	88.1	85.4	86.1
IndoBERT + Vocabulary adaptation + 200K steps (Koto et al., 2021)	86.6	92.7	79.0	88.4	84.0	87.7	86.9	86.5

Berdasarkan Tabel 2.2 yang diadaptasi dari Koto et al. (2021), model IndoBERTweet dan variannya secara konsisten mencapai performa tinggi pada tujuh tugas NLP berbahasa Indonesia, meliputi *sentiment analysis*, *emotion classification*, *hate speech detection*, dan *named entity recognition*. Hasil terbaik secara rata-rata ditunjukkan oleh varian IndoBERT dengan adaptasi kosakata dan pelatihan lanjutan 200K langkah (86,5), sedangkan IndoBERTweet yang dilatih dari awal juga menunjukkan kinerja kompetitif (86,1). Temuan ini memperkuat asumsi bahwa model berbasis domain media sosial berpotensi lebih sesuai untuk teks pendek, informal, dan bising seperti percakapan grup WhatsApp berbahasa Indonesia, meskipun efektivitas akhirnya tetap perlu divalidasi pada penelitian ini.

2.2.4 BIRCH Clustering

BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) merupakan algoritma *clustering* hierarkis yang dirancang untuk menangani dataset berskala besar secara efisien dengan cara meringkas data ke dalam struktur *Clustering Feature* (CF) yang disusun dalam CF-Tree di memori, sehingga mengurangi kebutuhan komputasi dibandingkan pendekatan yang memproses setiap titik data secara individual (Zhang et al., 1996). Algoritma ini memiliki keunggulan dalam efisiensi komputasi, penggunaan memori yang rendah, serta ketahanan terhadap *noise*, namun tetap memiliki keterbatasan, seperti sensitivitas terhadap parameter *threshold*, kesulitan dalam menangani klaster dengan bentuk kompleks, serta kurang optimal pada dataset berdimensi tinggi (Zhang et al., 1997). Dalam konteks framework BERTopic, keterbatasan terkait dimensi tinggi tersebut dapat diminimalkan melalui penerapan UMAP sebagai teknik reduksi dimensi sebelum proses klasterisasi dilakukan.

Pada implementasi BIRCH di *scikit-learn*, ringkasan tiap subklaster disimpan dalam bentuk *Clustering Feature* (CF) sebagaimana didefinisikan pada BIRCH orisinal dan dipaparkan kembali pada kajian implementasi matematis modern (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$CF = (N, LS, SS) \quad (2.1)$$

dengan N jumlah titik data, $LS = \sum_{i=1}^N x_i$, dan $SS = \sum_{i=1}^N \|x_i\|^2$.

Centroid subklaster dihitung sebagai:

$$\mu = \frac{LS}{N} \quad (2.2)$$

Radius subklaster digunakan sebagai dasar keputusan pemisahan/penggabungan node. Bentuk komputasional berikut ekuivalen dengan definisi radius BIRCH (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$R = \sqrt{\frac{SS}{N} - \left\| \frac{LS}{N} \right\|^2} \quad (2.3)$$

Ketika titik baru x ditambahkan ke subklaster, radius baru dihitung menggunakan prinsip aditivitas CF, lalu dibandingkan dengan *threshold* (T) (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$R' = \sqrt{\frac{SS + \|x\|^2}{N + 1} - \left\| \frac{LS + x}{N + 1} \right\|^2}, \quad R' \leq T \quad (2.4)$$

Parameter *branching factor* (B) mengontrol jumlah maksimum anak pada tiap node CF-Tree, sedangkan T mengontrol kekompakan subklaster.

2.2.5 Topic Representation Dengan BM25

Skema pembobotan BM25 adalah algoritma fungsi peringkat (ranking function) yang banyak digunakan dalam pencarian informasi (information retrieval) dan dapat diadaptasi untuk tahap representasi topik (Jian et al., 2020; Shan et al., 2020). c-TF-IDF kesulitan menangkap hubungan semantik secara utuh dan cenderung menghasilkan topik yang kurang koheren ketika distribusi frekuensi kata sangat timpang atau tidak merata (Muhajir et al., 2025). Oleh karena itu, sejumlah penelitian menerapkan BM25 pada tahap *topic representation*, baik sebagai pengganti penuh maupun sebagai modifikasi dari skema c-TF-IDF.

Pada penelitian (Muhajir et al., 2025), c-TF-IDF bawaan BERTopic digantikan sepenuhnya dengan BM25 pada level klaster, dengan skor kata dirumuskan sebagai:

$$w_{t,C_k} = \sum_{d \in C_k} IDF(t) \cdot \frac{f(t,d)(k_1 + 1)}{f(t,d) + k_1 \left(1 - b + b \cdot \frac{|d|}{avgdl}\right)}, \quad (2.5)$$

dengan fungsi *inverse document frequency* didefinisikan sebagai $IDF(t) = \log \left(\frac{N - n(t) + 0.5}{n(t) + 0.5} \right)$.

dengan:

- C_k = himpunan dokumen pada klaster ke- k
- $f(t, d)$ = frekuensi kata t pada dokumen d
- $|d|$ = panjang dokumen d
- $avgdl$ = rata-rata panjang dokumen dalam korpus
- $n(t)$ = jumlah dokumen yang memuat kata t
- N = jumlah total dokumen
- k_1 dan b = parameter pengatur saturasi frekuensi istilah dan normalisasi panjang dokumen

Dalam konteks studi tersebut, pendekatan ini dilaporkan memberikan representasi topik yang lebih stabil dibandingkan c-TF-IDF pada korpus teks pendek berbahasa Indonesia (Muhajir et al., 2025).

2.2.6 Topic Coherence

Topic coherence mengukur keterkaitan semantik antar kata teratas dalam topik. Dalam penelitian ini, koherensi dievaluasi menggunakan *Normalized Pointwise Mutual Information* (NPMI) (Rahimi et al., 2024):

$$NPMI(w_i, w_j) = \frac{\ln \left(\frac{P(w_i, w_j)}{P(w_i) \cdot P(w_j)} \right)}{-\ln(P(w_i, w_j))} \quad (2.6)$$

dengan $P(w_i, w_j)$ sebagai probabilitas ko-okurensi, serta $P(w_i)$ dan $P(w_j)$ sebagai probabilitas marjinal kemunculan kata. Nilai NPMI model diperoleh dari rata-rata

pasangan kata pada tiap topik dan dirata-ratakan lagi antar topik. Skor yang lebih tinggi menunjukkan topik lebih koheren dan umumnya lebih mudah diinterpretasikan, meskipun metrik ini tetap sensitif terhadap pola ko-okurensi pada korpus (Lau et al., 2014; Doogan and Buntine, 2021).

2.2.7 Topic Diversity

Topic diversity menilai seberapa unik kata-kata representatif antar topik, sehingga dapat menggambarkan tingkat perbedaan topik yang dihasilkan model (Dieng et al., 2020). Nilainya dihitung sebagai proporsi kata unik pada himpunan kata teratas seluruh topik (Terragni et al., 2021):

$$TD = \frac{|\text{unique words in top } N \text{ words of all topics}|}{N \times K} \quad (2.7)$$

dengan rentang nilai 0–1. Nilai yang mendekati 1 menunjukkan tumpang tindih kata antar topik lebih rendah, sedangkan nilai kecil mengindikasikan topik cenderung redundan (Abdelrazek et al., 2023). Meskipun sederhana dan intuitif, nilai diversitas tinggi tidak selalu berarti kualitas topik lebih baik, sehingga perlu dibaca bersama metrik lain (Dieng et al., 2020).

2.2.8 Embedding Density

Embedding density mengukur kekompakan dokumen dalam kluster topik pada ruang embedding. Semakin dekat dokumen terhadap pusat kluster, semakin tinggi kepadatan yang menunjukkan konsistensi semantik internal yang lebih baik (Rushkin, 2020). Salah satu formulasi yang digunakan adalah:

$$ED_k = \frac{1}{1 + \frac{1}{|C_k|} \sum_{x_i \in C_k} \|x_i - \mu_k\|_2} \quad (2.8)$$

dengan C_k himpunan dokumen pada topik ke- k , x_i vektor dokumen, dan μ_k centroid kluster. Nilai lebih tinggi berarti kluster lebih padat. Kelebihan metrik ini adalah kemampuannya menangkap kualitas pengelompokan pada teks pendek, tetapi ia ha-

nya merefleksikan aspek geometris dan tidak langsung menjamin topik lebih mudah dipahami manusia (Muhajir et al., 2025; Khodorchenko et al., 2022).

2.2.9 Intra-topic Similarity

Intra-topic similarity mengukur rata-rata kesamaan semantik antar dokumen dalam satu topik, sehingga merepresentasikan homogenitas internal klaster (Zhao et al., 2018; Muhajir et al., 2025). Pengukuran umumnya menggunakan *co-sine similarity*:

$$\text{sim}(x_i, x_j) = \frac{x_i \cdot x_j}{\|x_i\| \|x_j\|} \quad (2.9)$$

Skor topik ke- k dihitung dari rata-rata seluruh pasangan dokumen dalam klaster:

$$\text{ITS}_k = \frac{2}{|C_k|(|C_k| - 1)} \sum_{i < j, x_i, x_j \in C_k} \text{sim}(x_i, x_j) \quad (2.10)$$

Nilai ITS yang lebih tinggi menunjukkan dokumen dalam topik makin seragam secara semantik. Metrik ini efektif untuk menangkap kedekatan makna pada teks pendek, namun sangat bergantung pada kualitas model embedding yang digunakan (Jesse et al., 2022; Muhajir et al., 2025).

BAB 3. METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini termasuk kategori kuantitatif eksperimental dengan pendekatan Research and Development (R&D). Aspek R&D terletak pada pengembangan sistem analisis topik percakapan WhatsApp berbasis web, sedangkan aspek eksperimental kuantitatif digunakan untuk memvalidasi performa pipeline BERTopic dengan modifikasi IndoBERTweet sebagai model embedding dan BIRCH sebagai model clustering.

3.2 Objek Penelitian


Objek penelitian fokus pada data percakapan grup WhatsApp dari komunitas *Book Clan* dengan nama grup *Diskusi Umum*, yang berisi interaksi antar pengguna dalam bahasa Indonesia. Data ini dipilih karena memiliki volume percakapan yang tinggi dan dapat mewakili karakteristik percakapan yang umumnya berupa teks pendek, tidak terstruktur, mengandung *noise*, serta fenomena *code-mixing*.

3.3 Waktu Penelitian

Waktu penelitian dilakukan pada bulan April 2026 hingga Juni 2026, dengan tahapan-tahapan yang telah direncanakan secara sistematis untuk memastikan kelancaran proses penelitian.

3.4 Tahapan Penelitian

Tahapan penelitian yang dilakukan dalam penelitian ini secara keseluruhan digambarkan pada **Gambar 3.1**:



Gambar 3.1: Tahapan Penelitian

3.4.1 Identifikasi Masalah dan Studi Literatur

Tahap pertama dalam penelitian ini adalah identifikasi masalah dan studi literatur. Peneliti melakukan eksplorasi awal terhadap fenomena percakapan grup WhatsApp untuk memahami tantangan dalam menangkap topik pembicaraan secara menyeluruh, mencakup dinamika percakapan, karakteristik teks, serta kebutuhan pengguna dalam mengelola informasi yang besar dan tidak terstruktur.

Studi literatur kemudian dilakukan untuk membangun landasan teori dan memahami perkembangan terkini di bidang *topic modeling* berbahasa Indonesia melalui kajian jurnal ilmiah dan dokumentasi teknis terkait BERTopic, IndoBERT-Tweet, BIRCH *clustering*, BM25, serta metrik evaluasi pemodelan topik. Hasil gabungan tahap ini digunakan untuk mengidentifikasi *research gap*, merumuskan masalah penelitian secara spesifik, dan menentukan metode serta arsitektur sistem yang akan dikembangkan.

3.4.2 Pengumpulan Data

Tahap pengumpulan data dilakukan dengan mengeksplor riwayat percakapan dari grup WhatsApp menggunakan fitur *export chat* yang tersedia secara bawaan pada aplikasi WhatsApp. Data yang diekspor berupa file teks (.txt) atau format .zip yang memuat informasi tanggal, waktu, nama pengirim, dan isi pesan. Data percakapan yang dikumpulkan hanya bersumber dari satu grup WhatsApp, dengan

rentang waktu maksimal satu tahun data terbaru untuk memastikan relevansi topik dan menjaga fokus analisis pada dinamika percakapan yang aktual.

3.4.3 Praproses Data


Tahap praproses data bertujuan membersihkan dan mempersiapkan data mentah agar siap diolah oleh model *embedding* dengan tetap mempertahankan makna semantik. Prosesnya meliputi:

1. Pemfilteran pesan sistem, yaitu menghapus notifikasi bawaan WhatsApp seperti pesan bergabung, keluar grup, perubahan keamanan, serta pesan media yang tidak disertakan.
2. Konversi teks menjadi huruf kecil (*lower-case*).
3. Normalisasi *mention* dan URL, dengan mengganti nama pengguna menjadi *@USER* dan URL menjadi *HTTP*.
4. Transliterasi emotikon.
5. Normalisasi kata slang dan pemanjangan kata.

Apabila hasil evaluasi model menunjukkan performa yang kurang optimal, maka dilakukan eksperimen tambahan pada tahap praproses data. Eksperimen tersebut dapat berupa penambahan, pengurangan, maupun modifikasi teknik praproses untuk mengetahui pengaruhnya terhadap kualitas representasi teks dan peningkatan performa model. Dengan demikian, proses praproses dilakukan secara iteratif hingga diperoleh hasil evaluasi model yang lebih baik.

3.4.4 Pembuatan Model

Tahap pemodelan topik merupakan tahap inti dari penelitian ini, di mana data yang telah melalui pra-pemrosesan dianalisis menggunakan *framework* BER-Topic yang telah dimodifikasi. Penentuan parameter pada tiap komponen dilakukan dengan dua skenario, yaitu mengacu pada *baseline* dari penelitian terdahulu dan eksperimen penalaan parameter untuk memperoleh kinerja terbaik berdasarkan metrik evaluasi. Alur pembuatan model ini terdiri dari empat komponen utama:



Gambar 3.2: Rancangan framework BERTopic yang dimodifikasi pada tahap pembuatan model

1. *Document Embedding* menggunakan IndoBERTweet

Setiap dokumen (pesan) diubah menjadi representasi vektor numerik berdimensi tinggi menggunakan model IndoBERTweet yang telah diadaptasi untuk teks media sosial berbahasa Indonesia. Representasi *embedding* ini mampu menangkap makna semantik dan konteks kata secara lebih akurat dibandingkan model *multilingual* (Koto et al., 2021).

2. *Dimensionality Reduction* menggunakan UMAP

Vektor *embedding* berdimensi tinggi direduksi menggunakan *Uniform Manifold Approximation and Projection* (UMAP) untuk mengurangi kompleksitas komputasi sambil mempertahankan struktur lokal dan global data da-

lam ruang berdimensi rendah. Parameter UMAP yang digunakan meliputi *n_neighbors*, *n_components*, *min_dist*, dan *metric*.

3. Clustering menggunakan BIRCH Algorithm

Dokumen yang telah direduksi dimensinya dikelompokkan menggunakan algoritma BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) sebagai pengganti HDBSCAN standar. BIRCH dipilih karena kemampuannya dalam mengalokasikan seluruh dokumen ke dalam kluster tanpa menghasilkan *outlier* dalam jumlah besar, serta efisiensi komputasi dan penggunaan memori yang lebih baik. Parameter BIRCH yang digunakan meliputi *threshold*, *branching_factor*, dan *n_clusters*.

4. Topic Representation menggunakan BM25

Setiap kluster yang terbentuk direpresentasikan menggunakan skema pembobotan BM25 sebagai pengganti c-TF-IDF bawaan BERTopic. BM25 menerapkan saturasi frekuensi istilah dan normalisasi panjang dokumen, sehingga menghasilkan kata kunci representatif yang lebih relevan dan stabil secara semantik untuk setiap topik. Parameter BM25 yang digunakan meliputi *k1* dan *b*.

3.4.5 Evaluasi Model

Tahap evaluasi model bertujuan untuk mengukur kualitas topik yang dihasilkan oleh model BERTopic secara kuantitatif. Evaluasi dilakukan menggunakan empat metrik utama, yaitu:

1. Topic Coherence

Topic Coherence digunakan untuk mengukur sejauh mana kata-kata teratas dalam setiap topik memiliki hubungan semantik satu sama lain. Nilai yang lebih tinggi menunjukkan topik yang lebih koheren.

2. Topic Diversity

Topic Diversity digunakan untuk mengukur keunikan kata-kata teratas antar topik. Nilai mendekati 1 menunjukkan tidak ada tumpang tindih kata antar topik.

3. *Embedding Density*


Embedding Density digunakan untuk mengukur tingkat kekompakan dokumen dalam tiap klaster pada ruang *embedding*. Nilai yang lebih tinggi menunjukkan klaster yang semakin padat.

4. *Intra-topic Similarity*

Intra-topic Similarity digunakan untuk mengukur rata-rata kesamaan semantik antar dokumen dalam satu topik. Nilai yang lebih tinggi menunjukkan homogenitas topik yang lebih baik.

3.4.6 Implementasi Sistem

Tahap pengembangan sistem bertujuan untuk mengimplementasikan seluruh alur pemodelan topik ke dalam sebuah aplikasi berbasis web yang dapat digunakan secara praktis oleh pengguna.



Gambar 3.3: Alur implementasi sistem analisis topik WhatsApp

Pada Gambar 3.3, sistem memungkinkan pengguna untuk mengunggah data ekspor WhatsApp, divalidasi formatnya, lalu diproses oleh backend dengan pipeline BERTopic. Pengguna dapat memantau progress pemrosesan di halaman progress, dan setelah selesai, hasil analisis topik ditampilkan dalam bentuk daftar topik dengan kata kunci representatif. Pengguna dapat memilih cluster tertentu untuk melihat pesan-pesan yang termasuk dalam topik tersebut, serta mengklik pesan individual untuk mendapatkan konteks pesan asli.

Implementasi dilakukan dengan arsitektur *client-server*, menggunakan Vue.js sebagai *client* (antarmuka pengguna) dan FastAPI sebagai *server* (layanan API). Pengembangan sistem berfokus pada aspek fungsionalitas, kemudahan penggunaan

(*usability*), dan efisiensi pemrosesan.

3.4.7 Evaluasi Sistem

Tahap evaluasi sistem dilakukan untuk mengukur kinerja dan efektivitas aplikasi yang telah dikembangkan. Evaluasi dilakukan dengan menggunakan metode black-box testing, di mana fokusnya adalah pada input dan output sistem tanpa memperhatikan proses internalnya. Pengujian dilakukan dengan menggunakan dataset percakapan grup WhatsApp yang berbeda dari dataset yang digunakan untuk pelatihan model, untuk memastikan bahwa sistem dapat bekerja secara umum dan tidak hanya pada data tertentu. Hasil evaluasi ini akan memberikan gambaran tentang seberapa baik sistem dapat mengidentifikasi dan merepresentasikan topik dalam percakapan grup WhatsApp secara otomatis, serta memberikan umpan balik untuk perbaikan lebih lanjut jika diperlukan.

3.4.8 Analisis Hasil

Tahap analisis hasil dilakukan terhadap seluruh keluaran dari pemodelan topik dan evaluasi model. Analisis dilakukan dengan membandingkan performa model berdasarkan metrik evaluasi yang telah ditentukan, serta menginterpretasikan topik-topik yang dihasilkan.

3.4.9 Penarikan Kesimpulan

Berdasarkan hasil analisis, dilakukan penarikan kesimpulan yang menjawab rumusan masalah penelitian serta penyusunan saran untuk pengembangan penelitian di masa mendatang.

3.5 Etika Penelitian

Penelitian ini mematuhi prinsip-prinsip etika penelitian, termasuk:

1. Anonimisasi

Data percakapan yang dikumpulkan dalam penelitian ini telah melalui proses anonimisasi pada tahap pra-pemrosesan untuk menghapus atau menyamarkan informasi yang dapat mengidentifikasi individu seperti nama pengirim, mention, dan nomor telepon sebelum dianalisis. Nama pengguna dan nomor telepon yang tercantum dalam pengirim pesan hanya diambil 3 karakter kemudian karakter selanjutnya diganti dengan tanda bintang (****). Untuk mention dipesan diganti dengan token anonim (@*USER*). Langkah ini diterapkan untuk memastikan bahwa data yang digunakan dalam proses analisis tidak dapat dikaitkan kembali kepada individu tertentu.

2. Informed Consent

3. Pembatasan Tujuan

Data yang dikumpulkan dan dianalisis dalam penelitian ini hanya digunakan untuk tujuan penelitian yang telah disepakati, yaitu analisis topik percakapan grup WhatsApp. Data tidak akan digunakan untuk tujuan lain, diperjualbelikan, atau disalahgunakan tanpa persetujuan lebih lanjut dari pihak terkait.

BAB 4. HASIL DAN PEMBAHASAN

4.1 Pengumpulan Data

Data yang digunakan dalam penelitian ini bersumber dari grup WhatsApp *Info Warga Jember*, sebuah grup komunitas daring yang aktif digunakan oleh warga di wilayah Kabupaten Jember sebagai sarana penyebaran informasi, diskusi, dan komunikasi sehari-hari. Pengumpulan data dilakukan melalui fitur ekspor percakapan yang tersedia secara bawaan pada aplikasi WhatsApp. Fitur ini memungkinkan pengguna yang memiliki akses administrator untuk mengunduh riwayat percakapan dalam dua format: berkas *.zip* yang menyertakan lampiran media, atau berkas *.txt* yang hanya memuat teks percakapan. Penelitian ini menggunakan format *.txt* karena komponen yang relevan untuk analisis topik adalah konten teks pesan, bukan lampiran media.

Berkas hasil ekspor selanjutnya diproses melalui tahap *parsing* untuk mengekstrak empat atribut utama dari setiap pesan, yaitu tanggal, waktu, nama pengirim, dan isi pesan, yang kemudian disusun dalam format CSV sebagai representasi terstruktur dari data mentah. Rentang waktu pengumpulan data mencakup periode dua tahun, terhitung sejak 19 Mei 2024 hingga 19 Mei 2026, guna memperoleh gambaran yang representatif terhadap dinamika percakapan dalam jangka panjang.

Sebelum digunakan dalam analisis, data melewati tahap penyaringan untuk menghilangkan pesan yang tidak mengandung konten linguistik yang bermakna. Kriteria eksklusi meliputi pesan sistem yang dihasilkan otomatis oleh aplikasi WhatsApp—seperti notifikasi penambahan atau penghapusan anggota, perubahan ikon atau nama grup—serta entri bertanda *<Media omitted>* yang menunjukkan lampiran tanpa teks penyerta. Setelah proses penyaringan tersebut, dataset final yang digunakan dalam penelitian ini terdiri dari **18.954 pesan** yang dikirim oleh **766 pengirim unik**, dengan rata-rata sekitar 26 pesan per hari sepanjang periode pengamatan.

4.2 Praproses Data

Uraikan langkah pra-pemrosesan yang dilakukan sesuai metodologi:

1. Pemfilteran pesan sistem dan pesan media
2. Normalisasi (lower-case, mention → @USER, URL → HTTP)
3. Transliteration emotikon dan normalisasi slang
4. Tokenisasi dan stopwords removal (Sastrawi + manual)

Berikan contoh before/after satu atau dua pesan untuk ilustrasi.

4.3 Pembuatan Model

Sajikan statistik deskriptif utama setelah pra-pemrosesan: mean, median, standar deviasi panjang pesan, frekuensi kata teratas, dan distribusi topik awal jika relevan.

4.3.1 Embedding dan Reduksi Dimensi

Jelaskan penggunaan IndoBERTweet untuk pembuatan embedding, parameter penting yang dipilih, dan hasil reduksi dimensi menggunakan UMAP. Sertakan visualisasi (scatter plot UMAP) dan interpretasi singkat.

4.3.2 Clustering dan Representasi Topik

Paparkan penggunaan BIRCH untuk clustering dan BM25 untuk representasi topik.

Untuk setiap topik utama, tampilkan:

- Kata kunci representatif (top-n)
- Jumlah dokumen per klaster
- Contoh pesan yang termasuk dalam topik

4.3.3 Evaluasi Kuantitatif Model

Tampilkan hasil metrik evaluasi yang digunakan: topic coherence, topic diversity, embedding density, dan intra-topic similarity. Sajikan hasil dalam tabel per skenario parameter (baseline vs modifikasi) dan beri interpretasi singkat.

4.3.4 Perbandingan Eksperimen (Baseline vs Modifikasi)

Bandingkan kinerja skenario berbeda (mis. HDBSCAN vs BIRCH, c-TF-IDF vs BM25, model embedding berbeda). Sertakan tabel ringkasan dan highlight perbedaan signifikan.

4.3.5 Uji Asumsi dan Analisis Inferensial

Jika relevan, laporkan uji normalitas, uji homogenitas, dan hasil pengujian hipotesis. Jelaskan metode statistik yang digunakan dan implikasinya terhadap interpretasi hasil.

4.3.6 Implementasi Sistem dan Evaluasi Fungsional

Laporkan hasil pengujian aplikasi berbasis web: keandalan upload, waktu proses end-to-end, pengalaman pengguna (jika ada pengujian usability), serta contoh tampilan hasil.

4.3.7 Analisis Hasil

Analisis sintesis hasil kuantitatif dan kualitatif: apakah topik yang dihasilkan bermakna, stabil, dan sesuai konteks grup WhatsApp. Kaitkan dengan tujuan penelitian.

4.4 Pembahasan

4.4.1 Interpretasi Temuan Utama

Paparkan penjelasan mendalam mengenai temuan utama, mengapa hasil tersebut muncul, dan bagaimana temuan ini menjawab rumusan masalah. Hubungkan temuan dengan teori dan tinjauan pustaka di Bab 2.

4.4.2 Analisis Kualitatif Topik

Bahas beberapa topik penting secara kualitatif: konteks sosialnya, contoh kutipan pesan, dan relevansi bagi pengguna.

4.4.3 Implikasi Praktis dan Rekomendasi Implementasi

Jelaskan implikasi untuk pengembangan sistem dan pengguna akhir, termasuk rekomendasi konfigurasi model, antarmuka, dan fitur tambahan.

4.4.4 Keterbatasan Penelitian

Sebutkan keterbatasan data, metode, dan eksperimen (mis. satu grup WhatsApp, potensi bias, keterbatasan anotasi) serta dampaknya pada generalisasi hasil.

4.4.5 Saran dan Pekerjaan Lanjutan

Rekomendasi teknis dan riset lanjutan: perluasan dataset, eksperimen model embedding lain, perbaikan pipeline pra-pemrosesan, atau pengujian usability yang lebih formal.

4.4.6 Ringkasan Hasil Utama

Ringkas temuan paling penting dalam 3–5 poin yang langsung menjawab rumusan masalah.

BAB 5. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian dan pembahasan, dapat disimpulkan sebagai berikut:

1. **Kesimpulan 1 (jawab RMP pertama):** Penelitian ini menunjukkan bahwa ... (Jelaskan jawaban dari rumusan masalah pertama di Bab 1 Section 1.2)
2. **Kesimpulan 2 (jawab RMP kedua):** Temuan utama adalah bahwa ... (Jelaskan jawaban dari rumusan masalah kedua)
3. **Kesimpulan 3 (jawab RMP ketiga):** Hasil analisis menunjukkan bahwa ... (Jelaskan jawaban dari rumusan masalah ketiga, jika ada)
4. **Kontribusi Utama:** Penelitian ini memberikan kontribusi teoritis dan praktis dalam ... (Jelaskan bagaimana penelitian ini berkontribusi pada ilmu pengetahuan dan praktik)

Secara keseluruhan, penelitian ini telah berhasil mengidentifikasi dan menganalisis ... (Ringkas temuan utama dalam 1-2 kalimat yang comprehensive).

5.2 Saran

Berdasarkan hasil penelitian, beberapa saran yang dapat diberikan adalah:

5.2.1 Saran untuk Penelitian Selanjutnya

Saran untuk penelitian di masa depan meliputi:

1. **Eksplorasi Variabel Tambahan:** Penelitian selanjutnya dapat menambahkan variabel ... untuk memberikan gambaran yang lebih lengkap tentang ... (Jelaskan variabel yang belum diteliti dan alasannya)

2. **Perluasan Scope Penelitian:** Penelitian dapat dilakukan dengan ... (Misal: lokasi yang berbeda, sampel yang lebih besar, periode waktu yang lebih panjang) untuk meningkatkan generalisabilitas hasil.
3. **Metode Penelitian Alternatif:** Menggunakan metode ... (mixed-method, longitudinal, q experimental design) untuk mendapatkan insight yang lebih dalam tentang ...
4. **Eksaminasi Mekanisme:** Penelitian lebih lanjut dapat membedah mekanisme yang mendasari ... untuk memahami HAL APA dan MENGAPA (explanatory research).

5.2.2 Saran untuk Praktisi dan Pengambil Kebijakan

Saran untuk implementasi praktis dari penelitian ini adalah:

1. **Rekomendasi 1:** ... (Jelaskan saran konkret untuk organisasi/perusahaan/pemerintah)
2. **Rekomendasi 2:** ... (Jelaskan saran kedua dengan action items yang jelas)
3. **Rekomendasi 3:** ... (Jelaskan saran ketiga dengan fokus pada implementasi)

Implementasi rekomendasi-rekomendasi ini diharapkan dapat ... (Jelaskan dampak positif yang diharapkan dari implementasi).

DAFTAR PUSTAKA

- Abdelrazek, A., Eid, Y., Gawish, E., Medhat, W., and Hassan, A. (2023). Topic modeling algorithms and applications: A survey. *Information Systems*, 112:102131.
- Alzu'bi, A. and Barham, M. (2022). Automatic birch thresholding with features transformation for hierarchical breast cancer clustering. *International Journal of Electrical and Computer Engineering (IJECE)*, 12(2):1498–1507.
- Banerjee, S. and Pan, A. (2024). From colonial legacies to linguistic inclusion: A bertopic enhanced bibliometric insight into global south higher education. *IEEE Access*, 12:117418–117435.
- Churchill, R. and Singh, L. (2022). The evolution of topic modeling. *ACM Comput. Surv.*, 54(10s).
- Dieng, A. B., Ruiz, F. J. R., and Blei, D. M. (2020). Topic modeling in embedding spaces. *Transactions of the Association for Computational Linguistics*, 8:439–453.
- Doogan, C. and Buntine, W. (2021). Topic model or topic twaddle? re-evaluating semantic interpretability measures. In Toutanova, K., Rumshisky, A., Zettlemoyer, L., Hakkani-Tur, D., Beltagy, I., Bethard, S., Cotterell, R., Chakraborty, T., and Zhou, Y., editors, *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 3824–3848, Online. Association for Computational Linguistics.
- Egger, R. and Yu, J. (2022). A topic modeling comparison between lda, nmf, top2vec, and bertopic to demystify twitter posts. *Frontiers in Sociology*, Volume 7 - 2022.
- Grootendorst, M. (2022). Bertopic: Neural topic modeling with a class-based tf-idf procedure.

- Janssens, W., Bogaert, M., and van den Poel, D. (2025). A comparative analysis of topic reduction techniques for bertopic. *IEEE Access*, 13:204087–204103.
- Jesse, M., Bauer, C., and Jannach, D. (2022). Intra-list similarity and human diversity perceptions of recommendations: the details matter. *User Modeling and User-Adapted Interaction*, 33(4):769–802.
- Jian, F., Huang, J. X., Zhao, J., Ying, Z., and Wang, Y. (2020). A topic-based term frequency normalization framework to enhance probabilistic information retrieval. *Computational Intelligence*, 36(2):486–521.
- Kharisudin, I. and Masri'an, H. (2022). Topic modeling on whatsapp user reviews using latent dirichlet allocation. *Scientific Journal of Informatics*, 9:51–62.
- Khodorchenko, M., Butakov, N., and Nasonov, D. (2022). Towards better evaluation of topic model quality. In *2022 32nd Conference of Open Innovations Association (FRUCT)*, pages 128–134.
- Koto, F., Lau, J. H., and Baldwin, T. (2021). Indobertweet: A pretrained language model for indonesian twitter with effective domain-specific vocabulary initialization. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP 2021)*.
- Koto, F., Rahimi, A., Lau, J., and Baldwin, T. (2020). Indolem and indobert: A benchmark dataset and pre-trained language model for indonesian nlp.
- Kumar, R. P. and Naik, N. M. (2023). Whatsapp chat analyzer using machine learning and natural language processing. In *2023 2nd International Conference on Futuristic Technologies (INCOFT)*, pages 1–6.
- Lau, J. H., Newman, D., and Baldwin, T. (2014). Machine reading tea leaves: Automatically evaluating topic coherence and topic model quality. In Wintner, S., Goldwater, S., and Riezler, S., editors, *Proceedings of the 14th Conference of the European Chapter of the Association for Computational Linguistics*, pages 530–539, Gothenburg, Sweden. Association for Computational Linguistics.
- McInnes, L., Healy, J., and Melville, J. (2018). Umap: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*.
- Mohta, A., Jain, A., Saluja, A., and Dahiya, S. (2020). Pre-processing and emoji

- classification of whatsapp chats for sentiment analysis. In *2020 Fourth International Conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud) (I-SMAC)*, pages 514–519.
- Muhajir, M., Gunardi, G., Danardono, D., and Rosadi, D. (2025). Integrating indobert and balanced iterative reducing and clustering using hierarchies of bertopic in indonesian short text. *IAES International Journal of Artificial Intelligence (IJ-AI)*, 14:4192.
- Prayogi, A., Novriyenny, N., and Prahmana, I. G. (2025). Dinamika sentimen komunikasi mahasiswa dan dosen dengan pemanfaatan analisis pesan whatsapp akademis menggunakan machine learning. *Repeater: Publikasi Teknik Informatika dan Jaringan*, 3(2):45–54.
- Rahimi, H., Mimno, D., Hoover, J., Naacke, H., Constantin, C., and Amann, B. (2024). Contextualized topic coherence metrics. In Graham, Y. and Purver, M., editors, *Findings of the Association for Computational Linguistics: EACL 2024*, pages 1760–1773, St. Julian’s, Malta. Association for Computational Linguistics.
- Rani, S. J., Prabhu, T., and Chellam, J. A. I. (2022). Whatsapp sentiment analysis using r. In *2022 3rd International Conference for Emerging Technology (INCET)*, pages 1–4. IEEE.
- Retna, V. A., Brundha, P., and RajKumar, G. (2021). People’s behaviour analysis in chat message using natural language processing. In *2021 Third International Conference on Intelligent Communication Technologies and Virtual Mobile Networks (ICICV)*, pages 1128–1133.
- Rushkin, I. (2020). Document similarity from vector space densities. *CoRR*, abs/2009.00672.
- Shan, X., Liu, C., Xia, Y., Chen, Q., Zhang, Y., Luo, A., and Luo, Y. (2020). BISON: bm25-weighted self-attention framework for multi-fields document search. *CoRR*, abs/2007.05186.
- Terragni, S., Fersini, E., Galuzzi, B. G., Tropeano, P., and Candelieri, A. (2021). Octis: Comparing and optimizing topic models is simple! In *Proceedings of the 16th Conference of the European Chapter of the Association for Computational*

Linguistics: System Demonstrations, pages 263–270.

WhatsApp Inc. (2026). Tentang whatsapp. Diakses pada 7 Januari 2026.

Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., and Purwarianti, A. (2020). Indonlu: Benchmark and resources for evaluating indonesian natural language understanding. In *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*.

Zhang, T., Ramakrishnan, R., and Livny, M. (1996). Birch: an efficient data clustering method for very large databases. *SIGMOD Rec.*, 25(2):103–114.

Zhang, T., Ramakrishnan, R., and Livny, M. (1997). Birch: A new data clustering algorithm and its applications. *Data Min. Knowl. Discov.*, 1(2):141–182.

Zhao, H., Du, L., Buntine, W., and Zhou, M. (2018). Inter and intra topic structure learning with word embeddings. In *International Conference on Machine Learning*, pages 5892–5901. PMLR.

LAMPIRAN A. LAMPIRAN

A.1 Lampiran A - Data Mentah

Data mentah dari penelitian ini dapat dilihat pada Tabel ?? di bawah ini. Namun, untuk menjaga ukuran dokumen, hanya sample data yang ditampilkan. Data lengkap tersedia pada file `data_raw.csv` yang disertakan.

A.2 Lampiran B - Instrumen Penelitian

A.2.1 Lampiran B.1 - Kuesioner

KUESIONER PENELITIAN

Petunjuk Pengisian:

- Bacalah setiap pertanyaan dengan cermat
- Jawab dengan jujur sesuai pendapat Anda
- Tidak ada jawaban yang benar atau salah
- Data Anda dijamin kerahasiaannya

A. DATA DEMOGRAFIS

1. Jenis Kelamin: Laki-laki ☐ Perempuan ☐
2. Usia: ... tahun
3. Pendidikan: ...
4. Pekerjaan: ...

B. PERTANYAAN PENELITIAN

Untuk pertanyaan berikut, berikan jawaban dengan skala 1-5:

- 1 = Sangat Tidak Setuju (STS)
- 2 = Tidak Setuju (TS)
- 3 = Netral (N)
- 4 = Setuju (S)
- 5 = Sangat Setuju (SS)

1. Pernyataan pertama: STS ☐ TS ☐ N ☐ S ☐ SS ☐
2. Pernyataan kedua: STS ☐ TS ☐ N ☐ S ☐ SS ☐
3. Pernyataan ketiga: STS ☐ TS ☐ N ☐ S ☐ SS ☐

Terima kasih atas partisipasi Anda

A.3 Lampiran C - Output Analisis Statistik

Output statistik lengkap dari software analisis tersimpan dalam folder `analysis_output`.
Beberapa hasil utama ditampilkan di bawah:

A.4 Lampiran D - Kode Sumber

Kode sumber lengkap tersedia di repository GitHub: <https://github.com/username>

Atau dalam file `source_code.py`, `analysis.R`, dll. yang disertakan.

A.5 Lampiran E - Dokumen Pendukung

Dokumen pendukung berikut disertakan dalam pengumpulan skripsi:

- Surat izin penelitian dari institusi
- Informed consent forms (ICF) yang ditandatangani responden
- Sertifikat ethical clearance (jika ada)
- Bukti publikasi draft di jurnal/conference (jika ada)
- Dokumen lain yang relevan

Dokumen-dokumen ini disimpan dalam folder `supporting_documents/` dan dapat diminta dari penulis jika diperlukan untuk verifikasi atau referensi.