



**SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB
MENGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH
CLUSTERING**

*Diajukan guna memenuhi salah satu syarat memperoleh gelar Sarjana pada
Program Studi Teknologi Informasi*

SKRIPSI

Oleh:

Moh. Yusril Maqoshidana

NIM 222410102064

**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN
TEKNOLOGI PROGRAM STUDI TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER
UNIVERSITAS JEMBER**

2026

PERSEMBAHAN

Halaman ini saya persembahkan kepada:

1. Allah SWT, atas segala rahmat, karunia, serta kemudahan yang diberikan sehingga penulis dapat menyelesaikan skripsi ini dengan baik.
2. Bapak Subono dan Ibu Marsidah yang selalu mendoakan yang terbaik, mendukung segala usaha, serta selalu sabar dan percaya hingga sampai penulis mampu menyelesaikan pendidikan.
3. Bapak Dr. Brian Rizqi Paradisiaca Darnoto, S.Kom., M.Kom selaku Dosen Pembimbing Utama yang telah meluangkan waktu, memberikan arahan, bimbingan, serta masukan yang berharga selama proses penyusunan skripsi ini.
4. Ibu Khoirunnisa' Afandi, S.Kom., M.Kom dan Bapak Dony Bahtera Firmawan, S.Kom., M.Kom selalu dosen penguji yang memberikan saran dan masukan dalam proses pengembangan skripsi.
5. Dosen Fakultas Ilmu Komputer, Universitas Jember yang telah memberikan ilmu dan pengalaman yang berharga selama masa perkuliahan.
6. Sahabat yang telah memberikan dukungan, semangat, serta bantuan selama proses penyusunan skripsi ini.

MOTTO

*“Tiada kekayaan yang lebih utama daripada akal,
tiada keadaan yang lebih menyedihkan daripada kebodohan,
dan tiada warisan yang lebih baik daripada pendidikan”*

(Ali bin Abi Thalib)

*“When you’re afraid of something, learn as much as you can about it.
Knowledge overcomes fear”*

(Edmund Burke)

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini:

Nama: Moh. Yusril Maqoshidana

NIM: 222410102064

Dengan ini menyatakan bahwa skripsi yang berjudul: *Sistem Analisis Topik Grup WhatsApp Berbasis Web Menggunakan BERTopic dengan IndoBERTweet dan BIRCH Clustering*

adalah benar-benar hasil karya saya sendiri. Saya juga menyatakan bahwa dalam skripsi ini tidak terdapat karya yang pernah diajukan untuk memperoleh gelar sarjana atau gelar lainnya di mana pun.

Saya bertanggung jawab atas kebenaran dan keorisinalan isi skripsi ini. Apabila dikemudian hari terbukti bahwa skripsi ini mengandung unsur plagiasi, maka saya siap menanggung akibat hukum yang berlaku.

Jember, 01 Juni 2026

Yang menyatakan,

Moh. Yusril Maqoshidana

NIM. 222410102064

HALAMAN PERSETUJUAN

Skripsi berjudul “*SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING*” telah diuji dan disetujui oleh Fakultas Ilmu Komputer Universitas Jember pada:

Hari : Minggu

Tanggal : 01 Juni 2026

Tempat : Fakultas Ilmu Komputer Universitas Jember

Pembimbing

Tanda Tangan

1. Pembimbing Utama

Nama : Dr. Brian Rizqi P. D., S.Kom., M.Kom

(.....)

NIP : 199804272024061001

Penguji

1. Penguji Utama

Nama : Khoirunnisa' Afandi, S.Kom., M.Kom

(.....)

NIP : 199412282024062001

2. Penguji Anggota 1

Nama : Dony Bahtera Firmawan, S.Kom., M.Kom

(.....)

NIP : 199711202024061001

ABSTRAK

Latar belakang penelitian ini adalah ... (Jelaskan konteks dan motivasi penelitian Anda di sini, minimal 2-3 kalimat).

Rumusan masalah dalam penelitian ini adalah ... (Jelaskan masalah utama yang ingin dipecahkan).

Tujuan penelitian ini adalah untuk ... (Jelaskan tujuan yang ingin dicapai dari penelitian Anda).

Metode penelitian yang digunakan adalah ... (Jelaskan metode penelitian secara ringkas: jenis penelitian, sampel, instrumen, teknik analisis).

Hasil penelitian menunjukkan bahwa ... (Jelaskan temuan utama dari penelitian Anda).

Kesimpulannya adalah ... (Berikan kesimpulan singkat dan implikasi dari penelitian).

Kata Kunci: *Kata Kunci Satu, Kata Kunci Dua, Kata Kunci Tiga*

ABSTRACT

The background of this research is ... (Explain the context and motivation of your research here, at least 2-3 sentences).

The research problem investigated in this study is ... (Explain the main problem to be solved).

The purpose of this research is to ... (Explain the objectives to be achieved from your research).

The research method used is ... (Explain the research method briefly: research type, sample, instruments, analysis techniques).

The research results show that ... (Explain the main findings from your research).

The conclusion is that ... (Provide a brief conclusion and implications of the research).

Keywords: *Kata Kunci Satu, Kata Kunci Dua, Kata Kunci Tiga*

RINGKASAN

Penelitian ini dilakukan dengan latar belakang ... (Jelaskan konteks, motivasi, dan pentingnya penelitian secara lebih detail dibanding abstrak.)

Dalam era ... (Tambahkan konteks temporal dan kontekstual penelitian Anda).

Masalah yang dihadapi adalah ... (Jelaskan masalah penelitian dan mengapa penting untuk diteliti). Oleh karena itu, penelitian ini bertujuan untuk ... (Jelaskan tujuan utama penelitian).

Metode penelitian yang digunakan adalah ... (Jelaskan dengan detail: pendekatan, design, populasi/sampel, instrumen, teknik pengumpulan data, dan analisis data).

Temuan penelitian menunjukkan bahwa ... (Jelaskan hasil utama, temuan penting, dan interpretasi awal).

Berdasarkan hasil penelitian, dapat disimpulkan bahwa ... (Berikan kesimpulan yang comprehensive). Penelitian ini diharapkan dapat memberikan manfaat bagi ... (Jelaskan kontribusi praktis dan akademis).

PRAKATA

Puji syukur kehadiran Allah SWT atas segala berkah dan rahmat yang telah diberikan sehingga penulis mampu menyelesaikan penelitian yang berjudul “*SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING*”. Penelitian ini merupakan salah satu syarat akademik dalam menyelesaikan pendidikan Strata Satu (S1) pada Program Studi Teknologi Informasi Fakultas Ilmu Komputer Universitas Jember.

Penulis menyadari bahwa dalam proses penelitian dan penulisan skripsi ini, banyak pihak yang telah memberikan bimbingan, dukungan, dan bantuan. Oleh karena itu, pada kesempatan ini penulis dengan sepuh hati mengucapkan terima kasih kepada:

1. Bapak Prof. Drs. Antonius Cahya Prihandoko, M.App.Sc., Ph.D., selaku Dekan Fakultas Ilmu Komputer Universitas Jember.
2. Dr. Brian Rizqi Paradisiaca Darnoto, S.Kom., M.Kom selaku Pembimbing Utama yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan bimbingan, diskusi, serta arahan yang sangat berharga sejak awal hingga skripsi ini selesai.
3. Ibu Khoirunnisa' Afandi, S.Kom., M.Kom dan Bapak Dony Bahtera Firmawan, S.Kom., M.Kom selaku Dosen Penguji yang telah memberikan ujian, saran, dan masukan yang konstruktif demi kesempurnaan laporan skripsi ini.
4. Bapak Yudha Alif Auliya, S.Kom., M.Kom. selaku Dosen Pembimbing Akademik yang telah memberikan bimbingan dan arahan selama masa studi di Program Studi Teknologi Informasi.
5. Para dosen dan staff Fakultas Ilmu Komputer, Universitas Jember yang telah membantu selama proses akademik.
6. Bapak Subono dan Ibu Marsidah selaku orang tua yang telah memberikan doa dan dukungan moral dan material selama penulis menempuh pendidikan

hingga menyelesaikan pendidikan jenjang S1.

7. Sahabat yang telah memberikan semangat, bantuan, dan dukungan selama proses penelitian ini.
8. Seluruh pihak dalam komunitas buku yang telah memberikan kepercayaan dan bantuan dalam proses penelitian ini.

Penulis menyadari bahwa skripsi ini masih memiliki berbagai kekurangan, baik dalam penulisan maupun isi. Oleh karena itu, penulis mengharapkan kritik dan saran yang sifatnya membangun dari pembaca untuk perbaikan di masa mendatang. Akhir kata, semoga penelitian ini dapat memberikan manfaat bagi kemajuan ilmu pengetahuan dan dapat dijadikan sebagai bahan referensi bagi penelitian-penelitian selanjutnya.

Jember, 01 Juni 2026

Moh. Yusril Maqoshidana

222410102064

DAFTAR ISI

PERSEMBAHAN	i
MOTTO	ii
PERNYATAAN ORISINALITAS	iii
HALAMAN PERSETUJUAN	iv
ABSTRAK	v
ABSTRACT	vi
RINGKASAN	vii
PRAKATA	viii
DAFTAR TABEL	xii
DAFTAR GAMBAR	xiii
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan Penelitian	3
1.4 Manfaat Penelitian	3
1.5 Batasan Penelitian	4
2 TINJAUAN PUSTAKA	5
2.1 Penelitian Terdahulu	5
2.2 Landasan Teori	6
2.2.1 Aplikasi WhatsApp	6
2.2.2 BERTopic	7
2.2.3 IndoBERTweet	8
2.2.4 BIRCH Clustering	9
2.2.5 Topic Representation Dengan BM25	10
2.2.6 Topic Coherence	12
2.2.7 Topic Diversity	12
2.2.8 Embedding Density	12
2.2.9 Intra-topic Similarity	13
3 METODOLOGI PENELITIAN	15
3.1 Jenis Penelitian	15

3.2	Objek Penelitian	15
3.3	Waktu Penelitian	15
3.4	Tahapan Penelitian	16
3.4.1	Identifikasi Masalah dan Studi Literatur	16
3.4.2	Pengumpulan Data	16
3.4.3	Praproses Data	17
3.4.4	Pembuatan Model	18
3.4.5	Evaluasi Model	20
3.4.6	Implementasi Sistem	20
3.4.7	Evaluasi Sistem	21
3.4.8	Analisis Hasil	21
3.4.9	Penarikan Kesimpulan	22
3.5	Etika Penelitian	22
4	HASIL DAN PEMBAHASAN	23
4.1	Pengumpulan Data	23
4.2	Praproses Data	24
4.2.1	Parsing Data Chat WhatsApp	24
4.2.2	Penghapusan Artefak Teks <...>	25
4.2.3	Penghapusan URL	26
4.2.4	Normalisasi Mention	27
4.2.5	Transliterasi Emoji	28
4.2.6	Normalisasi Kata Tawa	29
4.2.7	Anonimisasi Identitas Pengirim	30
4.2.8	Penghapusan Pesan Sistem dan File Kontak	31
4.2.9	Case Folding dan Normalisasi Karakter Unicode	32
4.2.10	Normalisasi Karakter Berulang (Elongasi) dan Spasi	33
4.2.11	Normalisasi Kata Tidak Baku (Slang Normalization)	33
4.2.12	Pembersihan Tanda Baca dan Stopword Removal	34
5	KESIMPULAN DAN SARAN	35
5.1	Kesimpulan	35
5.2	Saran	35
5.2.1	Saran untuk Penelitian Selanjutnya	35
5.2.2	Saran untuk Praktisi dan Pengambil Kebijakan	36
	DAFTAR PUSTAKA	36
	LAMPIRAN	40
.1	Surat Izin Penelitian dari Kampus	42
.2	Bukti Persetujuan Admin Grup WhatsApp	43

DAFTAR TABEL

2.1	Tinjauan Penelitian Terdahulu	5
2.2	Perbandingan Kinerja Model pada Tujuh Tugas	8
4.1	Contoh Hasil Parsing Data WhatsApp ke Format CSV	25
4.2	Contoh Hasil Penghapusan Artefak < . . . >	26
4.3	Contoh Hasil Penghapusan URL	27
4.4	Contoh Hasil Normalisasi Mention	28
4.5	Contoh Hasil Transliterasi Emoji	29
4.6	Contoh Hasil Normalisasi Kata Tawa	30
4.7	Contoh Hasil Anonimisasi Identitas Pengirim	31

DAFTAR GAMBAR

2.1	Framework BERTopic dengan modifikasi IndoBERT, BIRCH, dan BM25 (Muhajir et al., 2025)	7
3.1	Tahapan Penelitian	16
3.2	Rancangan framework BERTopic yang dimodifikasi pada tahap pembuatan model	19
1	Alur Implementasi Sistem	40
2	Alur Teknis Implementasi Sistem	41
3	Surat Izin Penelitian dari Kampus	42
4	Bukti Persetujuan Admin Grup WhatsApp Halaman 1	44
5	Bukti Persetujuan Admin Grup WhatsApp Halaman 2	45
6	Bukti Persetujuan Admin Grup WhatsApp Halaman 3	46

BAB 1. PENDAHULUAN

1.1 Latar Belakang

WhatsApp merupakan salah satu aplikasi pesan instan terpopuler di dunia yang banyak dimanfaatkan sebagai wadah diskusi komunitas, koordinasi tim, dan komunikasi organisasi (WhatsApp Inc., 2026). Pada grup WhatsApp yang sangat aktif dengan volume percakapan tinggi (mencapai 100 pesan atau lebih per hari), arus pertukaran informasi berlangsung sangat cepat dan dinamis. Akumulasi pesan yang masif ini kerap menimbulkan fenomena *information overload*, di mana pengguna mengalami kesulitan dalam mengikuti alur diskusi, menyaring informasi penting, maupun mengetahui topik yang sedang dibahas tanpa membaca keseluruhan riwayat obrolan secara manual (Rani et al., 2022). Oleh karena itu, diperlukan sistem yang mampu memodelkan dan mengekstraksi topik percakapan grup WhatsApp secara otomatis.

Topic modeling merupakan teknik dalam *Natural Language Processing* (NLP) untuk menemukan struktur tematik laten dari sekumpulan dokumen teks (Abdelrazek et al., 2023). Namun, penerapan pemodelan topik pada percakapan grup WhatsApp menghadapi tantangan besar akibat karakteristik data yang berupa teks pendek, tidak terstruktur, mengandung *noise* tinggi (seperti singkatan dan ekspresi tawa), serta sarat fenomena *code-mixing* dan bahasa informal (Churchill and Singh, 2022; Mohta et al., 2020; Egger and Yu, 2022).

Meskipun BERTopic terbukti unggul pada teks pendek dibandingkan metode berbasis *bag-of-words* seperti LDA dan NMF (Egger and Yu, 2022), algoritma klasifikasi bawaannya, yaitu HDBSCAN, secara inheren mengeliminasi dokumen yang tidak memenuhi ambang stabilitas kepadatan sebagai *outlier* (Janssens et al., 2025). Akibatnya, hingga 23%–24% pesan obrolan dapat terbuang dan tidak terpetakan ke dalam topik manapun (Muhajir et al., 2025).

Untuk mengatasi keterbatasan tersebut, penelitian acuan Muhajir et al. (2025)

mengusulkan modifikasi pada *framework* BERTopic dengan mengganti HDBSCAN menggunakan algoritma BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) dan mengganti c-TF-IDF dengan skema BM25. Algoritma BIRCH mampu mengelompokkan dokumen secara dinamis dan menugaskan hampir seluruh data ke klaster yang valid, sehingga menekan proporsi *outlier* hingga rentang 1%–5% pada teks pendek (Muhajir et al., 2025). Pada lapisan *embedding*, IndoBERTweet dimanfaatkan karena dilatih secara khusus pada korpus media sosial berbahasa Indonesia, sehingga mampu menangkap konteks semantik bahasa percakapan informal secara lebih optimal (Koto et al., 2021; Muhajir et al., 2025). Sementara itu, penerapan BM25 pada tahap representasi topik menyempurnakan c-TF-IDF dengan memperhitungkan saturasi frekuensi kata dan normalisasi panjang dokumen, sehingga kata-kata yang mendominasi frekuensi tidak mengaburkan kata kunci yang informatif (Muhajir et al., 2025).

Meskipun penelitian mengenai *topic modeling* WhatsApp telah dilakukan sebelumnya (Kharisudin and Masri'an, 2022; Kumar and Naik, 2023; Retna et al., 2021), integrasi IndoBERTweet, BIRCH, dan BM25 pada data percakapan WhatsApp berbahasa Indonesia yang interaktif dan bervolume tinggi belum banyak dieksplorasi. Selain itu, mayoritas penelitian sebelumnya masih terbatas pada kajian eksperimen teoritis tanpa menghadirkan sistem terapan yang siap digunakan langsung oleh pengguna.

Berdasarkan permasalahan tersebut, penelitian ini mengembangkan sistem analisis topik percakapan grup WhatsApp berbasis *web* dengan menerapkan arsitektur BERTopic yang memadukan IndoBERTweet, BIRCH, dan BM25. Sistem ini diharapkan membantu pengguna memahami topik pembicaraan pada grup aktif secara cepat dan akurat melalui antarmuka visual yang informatif.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana penerapan BERTopic dengan integrasi IndoBERTweet, BIRCH *clustering*, dan representasi topik BM25 untuk mengidentifikasi topik pada percakapan grup WhatsApp berbahasa Indonesia?
2. Bagaimana kualitas topik yang dihasilkan oleh BERTopic dengan IndoBERTweet, BIRCH *clustering*, dan BM25 berdasarkan evaluasi metrik *Topic Coherence*, *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity*?
3. Bagaimana merancang dan mengimplementasikan sistem berbasis *web* untuk analisis topik percakapan grup WhatsApp menggunakan BERTopic dengan IndoBERTweet, BIRCH *clustering*, dan BM25?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah tersebut, tujuan penelitian ini dirumuskan sebagai berikut:

1. Menerapkan BERTopic dengan model *embedding* IndoBERTweet, algoritma BIRCH sebagai metode *clustering*, dan skema BM25 sebagai representasi topik untuk mengidentifikasi topik pada percakapan grup WhatsApp berbahasa Indonesia.
2. Mengevaluasi kualitas topik yang dihasilkan oleh BERTopic dengan IndoBERTweet, BIRCH *clustering*, dan BM25 berdasarkan metrik *Topic Coherence*, *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity*.
3. Merancang dan mengimplementasikan sistem berbasis *web* untuk analisis topik percakapan grup WhatsApp yang memanfaatkan BERTopic dengan IndoBERTweet, BIRCH *clustering*, dan BM25 agar dapat digunakan secara praktis oleh pengguna akhir.

1.4 Manfaat Penelitian

Adapun manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan kontribusi dalam pengembangan ilmu di bidang *Natural Language Processing* (NLP), khususnya penerapan BERTopic dengan modifikasi

IndoBERTweet, BIRCH *clustering*, dan BM25 untuk analisis teks percakapan informal berbahasa Indonesia.

2. Menyediakan sistem berbasis *web* yang mampu menganalisis percakapan grup WhatsApp secara otomatis serta menyajikan ringkasan topik melalui visualisasi yang intuitif.
3. Menjadi referensi akademik bagi penelitian selanjutnya terkait ekstraksi dan pemodelan topik pada data teks pendek dan pesan instan.

1.5 Batasan Penelitian

Agar penelitian ini lebih terarah dan fokus, maka ditetapkan beberapa batasan penelitian sebagai berikut:

1. Sistem hanya menganalisis percakapan teks berbahasa Indonesia dari grup WhatsApp, tidak mencakup media gambar, video, audio, maupun dokumen.
2. Data masukan pada *website* berupa file ekspor chat WhatsApp format .txt atau .zip yang diperoleh dari perangkat Android.
3. Data yang digunakan merupakan riwayat percakapan grup Komunitas Buku pada periode 2023–2026 dengan jumlah pesan sebanyak 91,868.
4. Penelitian berfokus pada pemodelan topik dan tidak mencakup analisis sentimen, klasifikasi emosi, maupun prediksi perilaku pengguna.
5. Representasi topik menggunakan metode skema pembobotan BM25 sebagai pengganti skema representasi topik bawaan BERTopic, yaitu c-TF-IDF.
6. Evaluasi dilakukan menggunakan metrik Topic Coherence, Topic Diversity, Embedding Density, Intra-topic Similarity, serta pengujian fungsional black-box.

BAB 2. TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Tabel 2.1: Tinjauan Penelitian Terdahulu

No	Judul Penelitian	Hasil Penelitian	Celah (<i>Gap</i>)	Kontribusi
1	<i>A Topic Modeling Comparison Between LDA, NMF, Top2Vec, and BERTopic to Demystify Twitter Posts</i> (Egger and Yu, 2022) (Jurnal Q1)	Penelitian ini membandingkan BERTopic, NMF, LDA, dan Top2Vec pada data Twitter. BERTopic direkomendasikan untuk pendekatan berbasis <i>embedding</i> , sedangkan NMF menjadi alternatif tradisional yang lebih unggul untuk data media sosial.	Meskipun BERTopic menunjukkan performa yang baik, penggunaan <i>embedding</i> multilingual dan <i>clustering</i> default (HDBSCAN) masih memiliki keterbatasan dalam mengatasi <i>outlier</i> dan meningkatkan stabilitas topik. Belum ada sistem aplikatif yang dikembangkan.	Penelitian ini menggunakan IndoBERTweet sebagai model <i>embedding</i> khusus bahasa Indonesia serta BIRCH sebagai alternatif HDBSCAN untuk meningkatkan stabilitas <i>clustering</i> dan mengurangi <i>outlier</i> . Selain itu, dikembangkan sistem berbasis <i>web</i> untuk analisis percakapan WhatsApp.
2	<i>Integrating IndoBERT and BIRCH in BERTopic for Indonesian short text</i> (Muhajir et al., 2025) (Jurnal Q2)	Penelitian ini memodifikasi BERTopic dengan IndoBERT, BM25, dan BIRCH dengan dataset dari X, Google Reviews, dan YouTube yang bersifat teks monolog. Berhasil menurunkan <i>outlier</i> secara signifikan serta meningkatkan stabilitas topik pada teks pendek.	Pendekatan ini belum dieksplorasi pada data percakapan grup WhatsApp yang memiliki karakteristik lebih kompleks berupa <i>multi-turn dialogue</i> , evolusi percakapan yang cepat dan volume pesan yang tinggi. Selain itu, penelitian terdahulu belum menyediakan sistem aplikasi bagi pengguna akhir.	Penelitian ini mengimplementasikan BERTopic dengan IndoBERTweet dan BIRCH pada dataset WhatsApp yang diintegrasikan ke dalam sistem analisis interaktif untuk memvisualisasikan dinamika topik secara otomatis.
3	<i>BERTopic Enhanced Bibliometric Insight Into Global South Higher Education</i> (Banerjee and Pan, 2024) (Jurnal Q1)	Penelitian ini menyelidiki keragaman linguistik dan proses dekolonisasi dalam sistem pendidikan tinggi di wilayah Global South menggunakan kerangka kerja empiris tiga tingkat yang menggabungkan Analisis Ko-okurensi Bibliometrik (Bibliometric Co-occurrence Analysis), pemodelan topik LDA, dan pemodelan BERTopic. BERTopic menunjukkan performa lebih baik dibanding LDA dalam koherensi dan jumlah topik yang dihasilkan pada data akademik.	Penelitian tersebut belum mengeksplorasi alternatif algoritma klusterisasi yang dapat meminimalkan <i>outlier</i> sejak awal proses, serta belum menguji efektivitas BERTopic pada bahasa Indonesia dengan karakteristik teks percakapan informal yang memiliki noise tinggi dan fenomena <i>code-mixing</i> . Penelitian tersebut juga belum menyediakan sistem aplikasi bagi pengguna akhir.	Penelitian ini berkontribusi dengan mengganti HDBSCAN menggunakan BIRCH <i>clustering</i> yang mampu mengakomodasi dokumen <i>outlier</i> secara dinamis tanpa penghapusan, sekaligus menggunakan IndoBERTweet sebagai <i>embedding</i> untuk dataset percakapan berbahasa Indonesia yang banyak mengandung kata informal dan <i>code-mixing</i> . Penelitian ini juga menyediakan sistem aplikasi bagi pengguna akhir.

Berdasarkan penelitian terdahulu yang telah diulas pada tabel 2.1, dapat disimpulkan bahwa meskipun telah banyak penelitian yang membandingkan berba-

gai model *topic modeling* untuk analisis teks pendek, hasil penelitian terdahulu menunjukkan bahwa BERTopic cenderung lebih unggul dibandingkan pendekatan konvensional pada data media sosial dan data akademik, tetapi masih memiliki keterbatasan ketika menggunakan *embedding* multilingual dan algoritma *clustering* bawaan seperti HDBSCAN. Pada sejumlah penelitian tersebut, penggunaan model yang lebih spesifik terhadap bahasa dan domain, seperti IndoBERT, serta algoritma BIRCH sebagai alternatif klasterisasi, terbukti menjanjikan dalam mengurangi *outlier* dan meningkatkan stabilitas topik pada teks pendek. Selain itu, penelitian yang telah diulas belum banyak mengeksplorasi penerapan pipeline BERTopic pada percakapan grup WhatsApp berbahasa Indonesia yang bersifat *multi-turn*, tidak terstruktur, dan kaya *code-mixing*. Di sisi lain, mayoritas penelitian masih berfokus pada evaluasi metodologi tanpa menyediakan sistem aplikasi yang dapat digunakan langsung oleh pengguna akhir untuk menganalisis percakapan mereka sendiri.


2.2 Landasan Teori

2.2.1 Aplikasi WhatsApp

WhatsApp merupakan aplikasi pesan instan yang memungkinkan pengguna berkomunikasi melalui pesan teks, suara, gambar, video, serta fitur grup yang mendukung komunikasi banyak pengguna dalam satu ruang diskusi (Prayogi et al., 2025). Fitur grup memungkinkan pengguna tergabung dalam banyak kelompok sekaligus untuk kepentingan personal, bisnis, maupun keamanan, sehingga volume pesan sering menjadi besar dan tumpang tindih. Kondisi ini membuat percakapan grup bersifat tidak terstruktur, melibatkan banyak partisipan, dan topik pembahasan dapat berubah dengan cepat (Rani et al., 2022). Akibatnya, pengguna sering kesulitan mengikuti arah percakapan secara menyeluruh. Permasalahan inilah yang menjadi latar belakang penelitian ini, yaitu mengembangkan sistem analisis percakapan grup WhatsApp yang dapat mengidentifikasi dan memetakan topik pembahasan secara otomatis.

2.2.2 BERTopic

BERTopic adalah *framework topic modeling* berbasis *transformer* yang membentuk *embedding* dokumen dan merepresentasikan topik melalui prosedur TF-IDF berbasis kelas, sehingga dokumen dengan makna semantik serupa dapat dipetakan saling berdekatan dalam ruang vektor (Grootendorst, 2022). Pendekatan ini relevan untuk percakapan grup WhatsApp yang umumnya berupa teks pendek, berisik (*noisy*), dan tidak terstruktur, yang cenderung menimbulkan masalah kelangkaan data (*data sparsity*) pada metode pemodelan topik konvensional.



Gambar 2.1: Framework BERTopic dengan modifikasi IndoBERT, BIRCH, dan BM25 (Muhajir et al., 2025)

Berdasarkan Gambar 2.1, *framework* BERTopic terdiri dari empat tahap utama. Tahap pertama adalah *document embedding* yang mengubah dokumen menjadi representasi vektor numerik menggunakan model bahasa seperti IndoBERT-Tweet yang dikembangkan untuk variasi bahasa Indonesia pada ranah media sosial (Koto et al., 2021). Tahap kedua adalah *dimensionality reduction* menggunakan UMAP untuk mereduksi dimensi vektor hasil *embedding* agar proses klasterisasi

lebih efisien (McInnes et al., 2018). Tahap ketiga adalah *clustering* yang mengelompokkan dokumen berdasarkan kemiripan semantik, di mana setiap kluster merepresentasikan satu topik dengan dukungan model yang bersifat modular seperti HDBSCAN, BIRCH, dan K-Means. Tahap keempat adalah *topic representation* yang mengekstrak kata kunci paling representatif dari setiap kluster. Secara bawaan BERTopic menggunakan c-TF-IDF, namun tahap ini dapat dimodifikasi karena bersifat modular (Grootendorst, 2022). Dalam penelitian ini, komponen yang digunakan pada tiap tahap meliputi IndoBERTweet untuk *embedding*, BIRCH untuk klasterisasi, dan BM25 untuk representasi topik.

2.2.3 IndoBERTweet

Model IndoBERTweet merupakan model bahasa pra-latih berskala besar pertama yang dirancang khusus untuk memproses data Twitter (X) berbahasa Indonesia. Model ini dikembangkan melalui pendekatan *domain-adaptive pretraining* dengan fondasi IndoBERT yang semula dilatih pada korpus formal, kemudian diadaptasi ke domain Twitter yang lebih informal. Dalam proses adaptasi tersebut, peneliti melakukan penyesuaian kosakata domain-spesifik dan melaporkan 14.584 kosakata baru (46% dari total kosakata) yang tidak tercakup pada IndoBERT umum (Koto et al., 2021).

Tabel 2.2: Perbandingan Kinerja Model pada Tujuh Tugas

Model	Sentiment		Emotion	Hate Speech		NER		Average
	IndoLEM	SmSA	EmoT	HS1	HS2	Formal	Informal	
mBERT	76.6	84.7	67.5	85.1	75.1	85.2	83.2	79.6
malayBERT	82.0	84.1	74.2	85.0	81.9	81.9	81.3	81.5
IndoBERT (Wilie et al., 2020)	84.1	88.7	73.3	86.8	80.4	86.3	84.3	83.4
IndoBERT (Koto et al., 2020)	84.1	87.9	71.0	86.4	79.3	88.0	86.9	83.4
IndoBERTweet (1M steps from scratch) (Koto et al., 2021)	86.2	90.4	76.0	88.8	87.5	88.1	85.4	86.1
IndoBERT + Vocabulary adaptation + 200K steps (Koto et al., 2021)	86.6	92.7	79.0	88.4	84.0	87.7	86.9	86.5

Berdasarkan Tabel 2.2 yang diadaptasi dari Koto et al. (2021), model IndoBERTweet dan variannya subsecara konsisten mencapai performa tinggi pada tujuh tugas NLP berbahasa Indonesia, meliputi *sentiment analysis*, *emotion classification*, *hate speech detection*, dan *named entity recognition*. Hasil terbaik secara rata-rata ditunjukkan oleh varian IndoBERT dengan adaptasi kosakata dan pelatihan lanjutan 200K langkah (86,5), sedangkan IndoBERTweet yang dilatih dari awal juga menunjukkan kinerja kompetitif (86,1). Temuan ini memperkuat asumsi bahwa model berbasis domain media sosial berpotensi lebih sesuai untuk teks pendek, informal, dan bising seperti percakapan grup WhatsApp berbahasa Indonesia, meskipun efektivitas akhirnya tetap perlu divalidasi pada penelitian ini.

2.2.4 BIRCH Clustering

BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) merupakan algoritma *clustering* hierarkis yang dirancang untuk menangani dataset berskala besar secara efisien dengan cara meringkas data ke dalam struktur *Clustering Feature* (CF) yang disusun dalam CF-Tree di memori, sehingga mengurangi kebutuhan komputasi dibandingkan pendekatan yang memproses setiap titik data secara individual (Zhang et al., 1996). Algoritma ini memiliki keunggulan dalam efisiensi komputasi, penggunaan memori yang rendah, serta ketahanan terhadap *noise*, namun tetap memiliki keterbatasan, seperti sensitivitas terhadap parameter *threshold*, kesulitan dalam menangani kluster dengan bentuk kompleks, serta kurang optimal pada dataset berdimensi tinggi (Zhang et al., 1997). Dalam konteks framework BERTopic, keterbatasan terkait dimensi tinggi tersebut dapat diminimalkan melalui penerapan UMAP sebagai teknik reduksi dimensi sebelum proses klusterisasi dilakukan.

Pada implementasi BIRCH di *scikit-learn*, ringkasan tiap subkluster disimpan dalam bentuk *Clustering Feature* (CF) sebagaimana didefinisikan pada BIRCH orisinal dan dipaparkan kembali pada kajian implementasi matematis modern (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$CF = (N, LS, SS) \quad (2.1)$$

dengan N jumlah titik data, $LS = \sum_{i=1}^N x_i$, dan $SS = \sum_{i=1}^N \|x_i\|^2$.

Centroid subklaster dihitung sebagai:

$$\mu = \frac{LS}{N} \quad (2.2)$$

Radius subklaster digunakan sebagai dasar keputusan pemisahan/penggabungan node. Bentuk komputasional berikut ekuivalen dengan definisi radius BIRCH (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$R = \sqrt{\frac{SS}{N} - \left\| \frac{LS}{N} \right\|^2} \quad (2.3)$$

Ketika titik baru x ditambahkan ke subklaster, radius baru dihitung menggunakan prinsip aditivitas CF, lalu dibandingkan dengan *threshold* (T) (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$R' = \sqrt{\frac{SS + \|x\|^2}{N + 1} - \left\| \frac{LS + x}{N + 1} \right\|^2}, \quad R' \leq T \quad (2.4)$$

Parameter *branching factor* (B) mengontrol jumlah maksimum anak pada tiap node CF-Tree, sedangkan T mengontrol kekompakan subklaster.

2.2.5 Topic Representation Dengan BM25

Skema pembobotan BM25 adalah algoritma fungsi peringkat (*ranking function*) yang banyak digunakan dalam pencarian informasi (*information retrieval*) dan dapat diadaptasi untuk tahap representasi topik (Jian et al., 2020; Shan et al., 2020). c-TF-IDF kesulitan menangkap hubungan semantik secara utuh dan cenderung menghasilkan topik yang kurang koheren ketika distribusi frekuensi kata sangat timpang atau tidak merata (Muhajir et al., 2025). Oleh karena itu, sejumlah penelitian menerapkan BM25 pada tahap *topic representation*, baik sebagai pengganti penuh maupun sebagai modifikasi dari skema c-TF-IDF.

Pada penelitian Muhajir et al. (2025), c-TF-IDF bawaan BERTopic digantikan sepenuhnya dengan BM25 pada tingkat kluster. Skor representasi kata t untuk kluster C_k dirumuskan sebagai:

$$w_{t,C_k} = \text{BM25}(t, C_k) = \sum_{d \in C_k} \text{IDF}(t) \cdot \frac{f(t, d) \cdot (k_1 + 1)}{f(t, d) + k_1 \left(1 - b + b \cdot \frac{|d|}{\text{avgdl}} \right)}, \quad (2.5)$$

dengan fungsi *inverse document frequency* didefinisikan sebagai:

$$\text{IDF}(t) = \log \left(\frac{N - n(t) + 0.5}{n(t) + 0.5} \right). \quad (2.6)$$

Skor w_{t,C_k} pada Persamaan 2.5 dihitung dengan menjumlahkan kontribusi seluruh dokumen $d \in C_k$, yaitu himpunan dokumen anggota kluster ke- k . Untuk setiap dokumen tersebut, $f(t, d)$ menyatakan frekuensi kemunculan kata t di dalam dokumen d , sedangkan $|d|$ menyatakan panjang dokumen d yang dinormalisasi terhadap avgdl , yakni rata-rata panjang dokumen dalam korpus. Nilai $\text{IDF}(t)$ pada Persamaan 2.6 diperoleh dari $n(t)$, yaitu jumlah dokumen dalam korpus yang memuat kata t , dan N , yaitu jumlah total dokumen dalam korpus. Dua parameter tambahan, k_1 dan b , masing-masing berfungsi mengatur saturasi frekuensi istilah agar pengaruh kata yang berulang tidak meningkat secara linear, serta mengatur normalisasi panjang dokumen agar dokumen yang lebih panjang tidak secara otomatis memperoleh skor lebih tinggi. Perlu dicatat bahwa rumus IDF pada Persamaan 2.6 dapat menghasilkan nilai negatif apabila suatu kata muncul pada lebih dari separuh dokumen dalam korpus ($n(t) > N/2$), sehingga secara otomatis menekan peran kata-kata umum dalam representasi topik.

Dalam konteks studi tersebut, pendekatan ini dilaporkan memberikan representasi topik yang lebih stabil dibandingkan c-TF-IDF pada korpus teks pendek berbahasa Indonesia (Muhajir et al., 2025).

2.2.6 Topic Coherence

Topic coherence digunakan untuk mengukur keterkaitan semantik antar kata teratas dalam topik. Dari banyaknya *topic coherence*, penelitian ini menggunakan *Normalized Pointwise Mutual Information* (NPMI) karena memberikan korelasi tertinggi dengan penilaian manusia dalam konteks context vectors (Röder et al., 2015):

$$\text{NPMI}(w_i, w_j) = \frac{\log \frac{P(w_i, w_j)}{P(w_i) \cdot P(w_j)}}{-\log P(w_i, w_j)} \quad (2.7)$$

dengan $P(w_i, w_j)$ sebagai probabilitas ko-okurensi, serta $P(w_i)$ dan $P(w_j)$ sebagai probabilitas marjinal kemunculan kata. Nilai dari NPMI berkisar antara $[-1, 1]$, dengan nilai 1 menunjukkan keterkaitan semantik yang sempurna, 0 menunjukkan tidak ada keterkaitan, dan nilai negatif menunjukkan keterkaitan yang berlawanan (Janssens et al., 2025).

2.2.7 Topic Diversity

Topic diversity didefinisikan dengan keberagaman topik sebagai persentase kata unik dalam 25 kata teratas dari semua topik. Keberagaman mendekati 0 menunjukkan bahwa topik yang berlebihan dan keberagaman mendekati 1 menunjukkan topik yang beragam (Dieng et al., 2020). Nilainya dihitung melalui rumus berikut:

$$TD = \frac{|\text{unique words in top } N \text{ words of all topics}|}{N \times K} \quad (2.8)$$

2.2.8 Embedding Density

Embedding Density adalah metrik evaluasi yang mengukur kepadatan representasi *embedding* fitur/dokumen dalam suatu klaster dengan menggabungkan jarak spasial (fungsi kernel) dan bobot semantik (Rushkin, 2020). Kepadatan pada titik sampel z (misalnya *centroid* topik) dihitung dengan rumus:

$$\rho_k = \frac{\sum_{i=1}^{N_k} k\left(\frac{\bar{\mathbf{e}}_k - \mathbf{e}_i}{h}\right) w_{k,i}}{\sum_{i=1}^{N_k} k\left(\frac{\bar{\mathbf{e}}_k - \mathbf{e}_i}{h}\right)} \quad (2.9)$$

Keterangan variabel spasial:

- $\bar{\mathbf{e}}_k$: Vektor *centroid* topik ke- k (pengganti titik sampel z), dihitung sebagai rata-rata embedding dokumen dalam kluster tersebut.
- $\mathbf{e}_i$: Vektor *embedding* dokumen ke- i (pengganti x_i) dalam kluster k .
- $k(y)$: Fungsi kernel Gaussian, yaitu $k(y) = (2\pi)^{-d/2} \exp(-|y|^2/2)$, untuk mengukur kedekatan spasial.
- h : Parameter *bandwidth*. Dalam implementasi, digunakan estimasi berbasis volume (h_V) dengan kuantil radius 0.1 dan 0.9 untuk mengurangi sensitivitas terhadap *outlier*, serta mekanisme *fallback* Silverman jika terjadi degenerasi kluster.
- $w_{k,i}$: Bobot semantik dokumen ke- i terhadap topik ke- k . Nilai ini dihitung dari total skor representasi kata-kata topik (c-TF-IDF untuk BERTopic *default*, atau BM25 untuk BERTopic termodifikasi) yang muncul pada dokumen tersebut, kemudian dinormalisasi per topik ke rentang $[0, 1]$.

Penyebut pada persamaan berfungsi sebagai konstanta normalisasi sehingga nilai ρ_k tidak bergantung pada jumlah dokumen dalam kluster (Rushkin, 2020).

2.2.9 Intra-topic Similarity

Intra-topic similarity merupakan metrik evaluasi yang mengukur kemiripan semantik antar dokumen di dalam satu topik, diadaptasi dari konsep *intra-list similarity* (ILS) sebagai rata-rata kemiripan berpasangan seluruh item dalam sebuah daftar (Jesse et al., 2022). Zhao et al. (2018) menekankan bahwa struktur intra-topik berbasis *word embeddings* mampu menangkap aspek tematik yang lebih halus dan bermakna. Dalam konteks evaluasi model topik, intra-topic similarity untuk topik

k dengan N_k dokumen dirumuskan sebagai berikut:

$$\text{ITS}(k) = \frac{1}{N_k(N_k - 1)} \sum_{\substack{i,j=1 \\ i \neq j}}^{N_k} \cos(\mathbf{e}_i^{(k)}, \mathbf{e}_j^{(k)}) \quad (2.10)$$

di mana $\mathbf{e}_i^{(k)}$ dan $\mathbf{e}_j^{(k)}$ adalah embedding dokumen ke- i dan ke- j dalam topik k . Nilai akhir diperoleh dengan merata-ratakan $\text{ITS}(k)$ di seluruh K topik; semakin tinggi nilainya, semakin kohesif topik yang dihasilkan.

BAB 3. METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini termasuk kategori kuantitatif eksperimental dengan pendekatan Research and Development (R&D). Aspek R&D terletak pada pengembangan sistem analisis topik percakapan WhatsApp berbasis web, sedangkan aspek eksperimental kuantitatif digunakan untuk memvalidasi performa pipeline BERTopic dengan modifikasi IndoBERTweet sebagai model embedding dan BIRCH sebagai model clustering.

3.2 Objek Penelitian


Objek penelitian ini adalah data percakapan grup WhatsApp Komunitas Buku, yang berisi interaksi antarpengguna dalam Bahasa Indonesia dan telah memperoleh izin penggunaan untuk keperluan penelitian dari pihak terkait. Data diambil dari rentang 4 Juni 2023 hingga 20 Juni 2026 (1.113 hari), dengan 954 hari di antaranya tercatat aktif, menghasilkan total 91.868 pesan teks dari 1.307 partisipan. Grup ini dipilih karena merepresentasikan karakteristik percakapan informal yang umum dijumpai pada komunitas WhatsApp, yaitu teks pendek, struktur kalimat tidak baku, mengandung *noise* (seperti singkatan, elongasi huruf, dan emoji), serta fenomena *code-mixing*.

3.3 Waktu Penelitian

Waktu penelitian dilakukan pada bulan April 2026 hingga Agustus 2026, dengan tahapan-tahapan yang telah direncanakan secara sistematis untuk memastikan kelancaran proses penelitian.

3.4 Tahapan Penelitian

Tahapan penelitian yang dilakukan dalam penelitian ini secara keseluruhan digambarkan pada **Gambar 3.1**:



Gambar 3.1: Tahapan Penelitian

3.4.1 Identifikasi Masalah dan Studi Literatur

Tahap pertama dalam penelitian ini adalah identifikasi masalah dan studi literatur. Pada tahap identifikasi masalah, peneliti melakukan eksplorasi terhadap percakapan grup WhatsApp untuk memahami tantangan dalam menangkap topik pembicaraan secara menyeluruh, termasuk dinamika percakapan, karakteristik teks pendek, serta kebutuhan pengguna dalam mengelola informasi yang besar dan tidak terstruktur. Selanjutnya, studi literatur dilakukan untuk memperoleh landasan teoretis dan memahami perkembangan terkini terkait metode *topic modeling*, khususnya BERTopic, IndoBERTweet, BIRCH *clustering*, BM25, serta metrik evaluasi yang relevan. Hasil dari tahap ini digunakan sebagai dasar dalam mengidentifikasi *research gap*, merumuskan masalah penelitian, serta menentukan metode dan arsitektur sistem yang dikembangkan.

3.4.2 Pengumpulan Data

Tahap pengumpulan data dilakukan dengan mengekspor riwayat percakapan dari grup WhatsApp menggunakan fitur *export chat* yang tersedia secara bawaan pa-

da aplikasi WhatsApp. Data yang diekspor berupa file berformat *.txt* atau *.zip* yang memuat informasi tanggal, waktu, nama pengirim, dan isi pesan. Proses pengumpulan data memperhatikan aspek etika penelitian, termasuk permintaan izin kepada admin grup terkait, mengingat data percakapan bersifat personal dan sensitif.

3.4.3 Praproses Data

Tahap praproses data bertujuan untuk membersihkan dan mempersiapkan kolom pesan dari data mentah agar siap diolah oleh model *embedding* dengan tetap mempertahankan informasi semantik yang relevan. Proses ini dilakukan untuk mengurangi *noise*, menstandarkan format teks, serta meningkatkan kualitas representasi data sebelum memasuki tahap pemodelan topik.

Tahap praproses yang dilakukan mengikuti urutan *pipeline* sebagai berikut:

1. Parsing data mentah dengan mendeteksi format dan mengekstrak berkas riwayat percakapan WhatsApp (*.txt* atau *.zip*) ke dalam struktur data tabel (*dataframe*) dengan kolom *Timestamp*, *Sender*, dan *Message* untuk mempermudah pre-processing tahap selanjutnya.
2. Anonimisasi identitas pengirim dan mention dengan hash sha256 sehingga informasi nama atau nomor telepon pengirim serta penyebutan (*mention*) akun pengguna lain pada isi pesan terjaga kerahasiaan identitas dan mematuhi etika privasi data.
3. Memfilter dan mengeliminasi notifikasi sistem otomatis WhatsApp seperti pesan keluar/masuk grup, enkripsi keamanan, pesan yang dihapus, pesan yang diedit, dan notifikasi lainnya yang tidak memiliki nilai semantik bagi analisis topik.
4. Menghapus pranala luar (*hyperlink*), tag format HTML, simbol tagar (*hashtag*), serta teks metadata sistem yang dapat mengganggu representasi topik utama.
5. Mengubah seluruh huruf pada pesan menjadi huruf kecil (*lowercase*) untuk menyeragamkan format kata dan meminimalkan variasi bentuk kata akibat perbedaan penggunaan huruf kapital.

6. Unicode normalization dengan melakukan standarisasi representasi karakter Unicode guna mengeliminasi karakter tersembunyi, karakter kontrol, atau variasi bentuk simbol Unicode yang sering muncul pada pesan obrolan perangkat seluler.
7. Normalisasi (*elongation*) dengan menyederhanakan karakter yang ditulis secara berulang secara berlebihan (misalnya, “*bisaaa*” menjadi “*bisa*”) agar setiap kata memiliki bentuk yang konsisten dan dapat dikenali dengan benar oleh model.
8. Menerjemahkan karakter emoji dan emotikon yang terdapat dalam pesan menjadi kata atau teks deskriptif yang setara guna mempertahankan muatan ekspresif dan informasi semantik yang terkandung di dalamnya.
9. Menghapus karakter unik yang muncul akibat proses ekspor WhatsApp, menghapus spasi berlebih (ganda), menghapus baris pesan yang bernilai kosong (*null*), pesan duplikat tanpa informasi tambahan, serta lampiran berkas kontak WhatsApp (*.vcf*) karena tidak mengandung informasi tekstual yang relevan.


Melalui tahapan praproses tersebut, kolom pesan yang semula tidak terstruktur dapat diubah menjadi data tekstual yang lebih bersih, konsisten, dan representatif untuk mendukung proses pemodelan topik menggunakan BERTopic.

3.4.4 Pembuatan Model

Tahap pemodelan topik merupakan tahap inti dari penelitian ini, dengan data yang telah melalui pra-pemrosesan dianalisis menggunakan *framework* BERTopic yang telah dimodifikasi seperti pada Gambar 3.2. Penentuan parameter pada tiap komponen dilakukan dengan dua skenario, yaitu mengacu pada *baseline* dari penelitian terdahulu dan eksperimen penalaan parameter untuk memperoleh kinerja terbaik berdasarkan metrik evaluasi. Sebagaimana ditunjukkan pada Gambar 3.2, alur pembuatan model ini terdiri dari empat komponen utama:

1. *Document Embedding* menggunakan IndoBERTweet

Setiap dokumen (pesan) diubah menjadi representasi vektor numerik berdimensi tinggi menggunakan model IndoBERTweet yang telah diadaptasi untuk



Gambar 3.2: Rancangan framework BERTopic yang dimodifikasi pada tahap pembuatan model

teks media sosial berbahasa Indonesia. Representasi *embedding* ini mampu menangkap makna semantik dan konteks kata secara lebih akurat dibandingkan model *multilingual* (Koto et al., 2021).

2. *Dimensionality Reduction* menggunakan UMAP

Vektor *embedding* berdimensi tinggi direduksi menggunakan *Uniform Manifold Approximation and Projection* (UMAP) untuk mengurangi kompleksitas komputasi sambil mempertahankan struktur lokal dan global data dalam ruang berdimensi rendah (McInnes et al., 2018). Parameter UMAP yang digunakan meliputi *n_neighbors*, *n_components*, *min_dist*, dan *metric*.

3. *Clustering* menggunakan BIRCH Algorithm

Dokumen yang telah direduksi dimensinya dikelompokkan menggunakan algoritma BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) sebagai pengganti HDBSCAN standar. BIRCH dipilih karena ke-

mampuannya dalam mengalokasikan seluruh dokumen ke dalam kluster tanpa menghasilkan *outlier* dalam jumlah besar, serta efisiensi komputasi dan penggunaan memori yang lebih baik (Zhang et al., 1996; Muhajir et al., 2025). Parameter BIRCH yang digunakan meliputi *threshold*, *branching_factor*, dan *n_clusters*.

4. *Topic Representation* menggunakan BM25

Setiap kluster yang terbentuk direpresentasikan menggunakan skema pembobotan BM25 sebagai pengganti c-TF-IDF bawaan BERTopic. BM25 menerapkan saturasi frekuensi istilah dan normalisasi panjang dokumen, sehingga menghasilkan kata kunci representatif yang lebih relevan dan stabil secara semantik untuk setiap topik (Muhajir et al., 2025). Parameter BM25 yang digunakan meliputi *k1* dan *b*.

3.4.5 Evaluasi Model

Tahap evaluasi model bertujuan untuk mengukur kualitas topik yang dihasilkan oleh model BERTopic secara kuantitatif. Evaluasi dilakukan menggunakan empat metrik yang telah dijabarkan pada bagian 2.2 (Topic Coherence (NPMI), Topic Diversity, Embedding Density, dan Intra-topic Similarity). Keempat metrik tersebut dipilih karena saling melengkapi: dua metrik pertama menilai kualitas topik dari sisi representasi kata (*lexical*), sementara dua metrik berikutnya menilai kualitas topik dari sisi representasi semantik pada ruang *embedding*.

3.4.6 Implementasi Sistem

Tahap pengembangan sistem bertujuan untuk mengimplementasikan alur pemodelan topik ke dalam sebuah aplikasi berbasis web yang dapat digunakan secara praktis oleh pengguna, sekaligus menjadi validasi terhadap penerapan *pipeline* yang telah dirancang. Gambaran umum alur sistem disajikan pada Lampiran, Gambar 1.

Sistem dibangun dengan arsitektur *client-server*, menggunakan Vue.js sebagai *client* dan FastAPI sebagai *server* layanan API. Pemrosesan pemodelan topik

yang bersifat komputasional berat dijalankan sebagai *background job* menggunakan background task, sehingga proses analisis tidak memblokir permintaan pengguna dan status pemrosesan dapat dipantau secara asinkron dengan SSE (Server-Sent Event). Penyimpanan berkas data, baik sebelum maupun sesudah pra-pemrosesan, menggunakan local storage untuk menjaga efisiensi penyimpanan dan privasi data.

Desain sistem berpegang pada beberapa prinsip utama. Pertama, privasi pengguna dijaga dengan melakukan anonimisasi identitas pengirim pesan pada sisi *client* sebelum data dikirim ke *server*, sehingga identitas asli pengguna tidak pernah tersimpan di *server*. Kedua, *traceability* dijaga dengan mempertahankan kolom *Index* di sepanjang *pipeline*, sehingga setiap hasil topik dapat ditelusuri kembali ke pesan asli.

3.4.7 Evaluasi Sistem

Tahap evaluasi sistem dilakukan untuk mengukur kinerja dan efektivitas aplikasi yang telah dikembangkan. Evaluasi dilakukan dengan menggunakan metode black-box testing, di mana fokusnya adalah pada input dan output sistem tanpa memperhatikan proses internalnya. Pengujian dilakukan dengan menggunakan dataset percakapan grup WhatsApp yang berbeda dari dataset yang digunakan untuk pelatihan model, untuk memastikan bahwa sistem dapat bekerja secara umum dan tidak hanya pada data tertentu. Hasil evaluasi ini akan memberikan gambaran tentang seberapa baik sistem dapat mengidentifikasi dan merepresentasikan topik dalam percakapan grup WhatsApp secara otomatis, serta memberikan umpan balik untuk perbaikan lebih lanjut jika diperlukan.

3.4.8 Analisis Hasil

Tahap analisis hasil dilakukan terhadap keluaran model topik dan metrik evaluasi yang diperoleh dari tahap pengujian. Analisis kuantitatif dilakukan dengan membandingkan nilai metrik evaluasi (Embedding Density, Intra-topic Similarity, NPMI, dan Topic Diversity) antara metode modifikasi BERTopic dengan baseline

BERTopic. Perbandingan disajikan dalam bentuk tabel dan grafik tren untuk melihat konsistensi performa model seiring penambahan jumlah data.

3.4.9 Penarikan Kesimpulan

Berdasarkan hasil analisis, dilakukan penarikan kesimpulan yang menjawab rumusan masalah penelitian serta penyusunan saran untuk pengembangan penelitian di masa mendatang.

3.5 Etika Penelitian

Penelitian ini menggunakan data riwayat percakapan grup WhatsApp yang bersifat personal, sehingga proses pengumpulan data memperhatikan aspek etika dan perizinan. Pengambilan data dilakukan dengan terlebih dahulu mengajukan surat izin penelitian dari pihak kampus kepada admin grup WhatsApp yang menjadi sumber data, sebagaimana ditunjukkan pada Lampiran .1 (Gambar 3). Persetujuan admin grup untuk penggunaan data percakapan dalam penelitian ini didokumentasikan melalui tangkapan layar (*screenshot*), sebagaimana ditunjukkan pada Lampiran .2 (Gambar 4, Gambar 5, dan Gambar 6). Terdapat beberapa syarat yang diajukan oleh admin grup terkait penggunaan data, pesan tidak boleh disebarluaskan kepada pihak lain dan nama grup harus disamarkan.

BAB 4. HASIL DAN PEMBAHASAN

4.1 Pengumpulan Data

Data penelitian diperoleh dari grup WhatsApp komunitas buku setelah memperoleh izin dari admin grup sebagaimana dijelaskan pada Subbab 3.5. Pengumpulan data dilakukan menggunakan fitur *Export Chat* bawaan aplikasi WhatsApp, yang menghasilkan berkas dalam format *.zip* berisi riwayat percakapan dalam satu berkas *.txt* tanpa media. Berkas *.zip* tersebut terlebih dahulu diekstraksi untuk memperoleh file *.txt* yang selanjutnya digunakan sebagai sumber data utama penelitian. Data yang diekspor mencakup periode percakapan dari Juni 2023 hingga Juni 2026, dengan total pesan 91.868 sebelum proses pembersihan pesan dengan total partisipan 1307.

Sebagai ilustrasi, potongan data mentah hasil ekspor ditampilkan pada Listing 4.1. Secara umum, setiap baris percakapan mengikuti pola DD/MM/YY HH.MM - Pengirim: Pesan. Namun demikian, data mentah juga memuat variasi format lain seperti pesan sistem (misalnya anggota ditambahkan ke grup), placeholder media, tautan, dan penanda pesan yang telah diedit.

Listing 4.1: Contoh potongan data mentah hasil ekspor WhatsApp (nama disamarkan)

```
02/02/26 20.46 - User-1: Aku tadi searching sedikit tentang
    buku ini
02/02/26 20.47 - User-1: <Media tidak disertakan>
27/09/25 10.35 - User-3: sheesh
03/02/26 11.24 - User-4: https://link
28/09/25 09.48 - User-5: gara gara dapet evernight jadi
    pengen hyacine <Pesan ini diedit>
24/04/26 05.12 - User-7 sudah ditambahkan
```

Berdasarkan potongan data mentah pada Listing 4.1, terdapat beberapa karak-

teristik khas dari riwayat percakapan WhatsApp yang membedakannya dengan teks formal, antara lain:

1. Penggunaan Bahasa Campuran dan Slang: Adanya pencampuran bahasa (seperti kata “*searching*” dan “*sheesh*”) serta istilah khusus domain percakapan (seperti “*evernight*” dan “*hyacine*”).
2. Metadata Media: Penanda otomatis <Media tidak disertakan> disertakan oleh sistem WhatsApp untuk menunjukkan file multimedia (gambar, video, stiker, audio) yang tidak diekspor ke dalam file teks biasa.
3. Keberadaan Tautan (URL): Terdapat tautan web (<https://link>) yang dibagikan oleh anggota grup.
4. Penanda Pesan Diedit: Penanda metadata <Pesan ini diedit> di akhir pesan muncul secara otomatis ketika pengirim melakukan perubahan (*edit*) pada isi pesan yang dikirimkan.
5. Pesan Sistem (System Message): Baris terakhir memuat notifikasi otomatis sistem (seperti penambahan anggota baru) yang formatnya tidak diawali oleh nama pengirim biasa.

4.2 Praproses Data

4.2.1 Parsing Data Chat WhatsApp

Berkas *.txt* hasil ekspor chat selanjutnya diproses melalui tahap *parsing* menggunakan *Python* dan *regular expression*. Pada tahap ini, sistem terlebih dahulu mendeteksi format *timestamp* dari berkas masukan untuk mengakomodasi beberapa format ekspor *WhatsApp*, seperti format Android Indonesia 12 jam, Android Indonesia 24 jam, dan Android Inggris 12 jam.

Setelah format teridentifikasi, setiap baris data dinormalisasi dengan menghapus karakter tak terlihat (*invisible characters*) dan menyeragamkan karakter spasi agar pola pesan dapat dikenali secara konsisten. Selanjutnya, proses *parsing* dilakukan untuk mengekstraksi isi pesan pengguna (*user message*) serta memisahnya dari *system message* seperti notifikasi penambahan anggota atau media yang

tidak disertakan.

Pesan yang terdiri atas beberapa baris (*multiline message*) digabungkan kembali menjadi satu entri utuh untuk menjaga konteks pesan. Hasil akhir dari proses ini disimpan ke dalam format *CSV* dengan satu atribut utama, yaitu *Pesan*, yang kemudian digunakan sebagai masukan pada tahap pra-pemrosesan berikutnya.

Tabel 4.1: Contoh Hasil Parsing Data WhatsApp ke Format CSV

Pesan
Woi Katakan pada dunia hsr back sheesh https://link gara gara dapet evernight jadi pengen hyacine

4.2.2 Penghapusan Artefak Teks < . . . >

Pada tahap pra-pemrosesan, dilakukan pembersihan terhadap artefak teks yang ditandai dengan pola < . . . > menggunakan *regular expression*. Artefak ini umumnya berasal dari metadata bawaan hasil ekspor chat *WhatsApp*, seperti <Media omitted>, <Pesan ini diedit>, atau penanda sistem lainnya yang tidak merepresentasikan isi percakapan aktual antar pengguna.

Proses pembersihan dilakukan pada kolom *Pesan_Preprocessed*, yang merupakan salinan awal dari kolom *Pesan*. Selanjutnya, pola < . * ? > digunakan untuk mendeteksi sekaligus menghapus seluruh substring yang berada di antara simbol tanda kurung sudut (< >). Setelah pola tersebut dihapus, dilakukan *trimming* untuk menghilangkan spasi berlebih di awal maupun akhir teks.

Berdasarkan hasil identifikasi, dari total 91.868 baris data, ditemukan sebanyak 14.739 baris yang mengandung pola < . . . > atau setara dengan 16,04

Contoh hasil pembersihan ditunjukkan pada Tabel 4.2. Terlihat bahwa pesan yang semula hanya berisi metadata seperti <Media omitted> berubah menjadi string kosong setelah proses pembersihan. Hal ini menunjukkan bahwa artefak tersebut tidak mengandung informasi semantik yang relevan untuk analisis topik, sehingga perlu dihilangkan agar tidak menjadi *noise* pada tahap pemodelan topik.

Tabel 4.2: Contoh Hasil Penghapusan Artefak < . . . >

Pesan	Pesan_Preprocessed
<Media omitted>	
<Media omitted>	
<Media omitted>	
<Media omitted>	

4.2.3 Penghapusan URL

Pada tahap pra-pemrosesan, dilakukan penghapusan *Uniform Resource Locator* (URL) dari teks percakapan. URL umumnya berupa tautan menuju situs web, media sosial, video, atau artikel daring, seperti tautan *YouTube*, *Instagram*, *TikTok*, dan halaman web lainnya. Dalam konteks analisis topik, keberadaan URL cenderung tidak memberikan informasi semantik yang relevan terhadap isi percakapan karena lebih merepresentasikan referensi eksternal dibandingkan konten tekstual pesan itu sendiri.

Proses penghapusan URL dilakukan menggunakan *regular expression* dengan pola `https?://\S+ | www\.\S+`, yang dirancang untuk mendeteksi tautan yang diawali dengan `http://`, `https://`, maupun `[www] (http://www) ..`. Setiap URL yang terdeteksi kemudian dihapus dari kolom *Pesan_Preprocessed*. Setelah URL dihapus, spasi berlebih akibat proses penghapusan dinormalisasi agar teks tetap rapi dan konsisten.

Untuk mengevaluasi dampak proses ini, dilakukan perbandingan antara data sebelum dan sesudah pembersihan. Baris yang mengalami perubahan ditandai menggunakan *masking* logis, yaitu dengan membandingkan isi teks sebelum dan sesudah transformasi. Jumlah baris yang berubah merepresentasikan banyaknya pesan yang mengandung URL.

Contoh hasil penghapusan URL ditunjukkan pada Tabel 4.3. Terlihat bahwa terdapat beberapa jenis perubahan. Pada pesan yang hanya berisi URL, hasil pra-pemrosesan menjadi string kosong. Sementara itu, pada pesan yang memuat URL sekaligus teks tambahan, hanya bagian URL yang dihapus dan isi pesan

utama tetap dipertahankan. Pendekatan ini memastikan bahwa informasi tekstual yang masih relevan untuk analisis topik tetap terjaga, sementara komponen yang berpotensi menjadi *noise* berhasil dihilangkan.

Tabel 4.3: Contoh Hasil Penghapusan URL

Pesan	Pesan_Preprocessed
https://youtu.be/gu2Q1unqr7U	
https://vt.tiktok.com/... Malam semuaa...	Malam semuaa, izin motong bntr yaa...
https://instagram.com/... Gais, jangan lupa like...	Gais, jangan lupa like dan komen yaa
Kamu mau aku PC aja nggak? ... https://...	Kamu mau aku PC aja nggak? ...

4.2.4 Normalisasi Mention

Pada tahap pra-pemrosesan, dilakukan normalisasi terhadap *mention* atau penandaan pengguna yang diawali dengan simbol @. Dalam data percakapan *WhatsApp*, *mention* dapat muncul dalam berbagai format, seperti nomor telepon (misalnya @+62 895-xxxx-xxxx), nama pengguna, maupun *username* khusus. Elemen ini umumnya berfungsi sebagai penanda identitas pengguna, bukan sebagai representasi topik pembicaraan.

Keberadaan *mention* dalam teks dapat menimbulkan *noise* pada proses analisis topik karena model dapat menganggap nama atau nomor tertentu sebagai token penting, padahal informasi tersebut tidak memiliki makna semantik yang relevan terhadap isi percakapan. Selain itu, normalisasi *mention* juga membantu menjaga anonimitas data dengan mengurangi paparan identitas pengguna.

Proses normalisasi dilakukan menggunakan *regular expression* untuk mendeteksi dua pola utama, yaitu *mention* berbasis nomor telepon dan *mention* berbasis nama pengguna. Seluruh *mention* yang terdeteksi kemudian diganti dengan token seragam, yaitu @USER. Pendekatan ini memungkinkan informasi bahwa suatu pesan mengandung referensi kepada pengguna lain tetap dipertahankan, tanpa menyimpan identitas spesifik pengguna tersebut.

Untuk mengevaluasi hasil transformasi, dilakukan perbandingan antara teks sebelum dan sesudah normalisasi. Baris yang mengalami perubahan ditandai meng-

gunakan *masking* logis. Berdasarkan hasil identifikasi, dari total 91.868 baris data, ditemukan sebanyak 1.306 baris yang mengandung *mention*, atau setara dengan 1,42

Contoh hasil normalisasi ditunjukkan pada Tabel 4.4. Terlihat bahwa *mention* dalam bentuk nomor telepon maupun nama pengguna berhasil diganti menjadi token @USER. Dengan demikian, struktur percakapan tetap terjaga karena keberadaan referensi antarpengguna masih dapat dikenali, sementara identitas spesifik pengguna telah dianonimkan.

Tabel 4.4: Contoh Hasil Normalisasi Mention

Pesan	Pesan_Preprocessed
@+62 895-xxxx-xxxxx hai hai...	@USER hai hai...
@+62 813-xxxx-xxxx @+62 857-xxxx-xxxx	@USER @USER
summon @ Kamu Bertanya-tanyea?	summon @USER Bertanya-tanyea?
Btw thank you ya @+62 895-xxxx-xxxx	Btw thank you ya @USER

4.2.5 Transliterasi Emoji

Pada tahap pra-pemrosesan, dilakukan transliterasi emoji untuk mengubah simbol emoji menjadi representasi teks yang dapat dipahami oleh model pemrosesan bahasa alami. Emoji merupakan komponen penting dalam percakapan digital karena sering digunakan untuk mengekspresikan emosi, reaksi, maupun konteks nonverbal. Jika emoji dihapus secara langsung, sebagian informasi semantik yang terkandung dalam pesan berpotensi hilang.

Proses transliterasi dilakukan menggunakan pustaka *Python* emoji dan *regex*. Sebelum transliterasi, dilakukan normalisasi terhadap emoji yang muncul secara berulang menggunakan pola *grapheme cluster*. Langkah ini bertujuan untuk mereduksi rangkaian emoji identik yang berulang menjadi satu simbol saja, sehingga ekspresi seperti [emoji tertawa][emoji tertawa][emoji tertawa] atau [emoji tangan melipat][emoji tangan melipat] disederhanakan menjadi [emoji tertawa] dan [emoji tangan melipat]. Normalisasi ini membantu mengurangi redundansi token tanpa menghilangkan makna emosional utama dari pesan.

Setelah normalisasi, setiap emoji dikonversi menjadi deskripsi tekstual menggunakan fungsi *demojize*. Sebagai contoh, emoji [emoji tersenyum] ditransliterasikan menjadi token *smiling_face*. Setelah transliterasi selesai, spasi berlebih yang muncul akibat proses konversi dinormalisasi kembali agar format teks tetap konsisten.

Untuk mengevaluasi dampak transformasi, dilakukan perbandingan antara teks sebelum dan sesudah proses transliterasi. Baris yang mengalami perubahan ditandai menggunakan *masking* logis. Berdasarkan hasil identifikasi, dari total 91.868 baris data, terdapat 41.487 baris yang mengalami perubahan setelah proses transliterasi dan normalisasi, atau setara dengan 45,16

Contoh hasil transliterasi ditunjukkan pada Tabel 4.5. Terlihat bahwa emoji yang semula berupa simbol visual berhasil diubah menjadi token tekstual yang tetap mempertahankan makna emosionalnya. Pendekatan ini memungkinkan informasi emosional dalam percakapan tetap terwakili dalam bentuk token yang dapat diproses oleh model analisis topik.

Tabel 4.5: Contoh Hasil Transliterasi Emoji

Pesan	Pesan_Preprocessed
Welcome yusril! [emoji tersenyum]	Welcome yusril! smiling_face
Gais, jangan lupa like dan komen yaa [emoji tangan bentuk hati][emoji kilauan][emoji kilauan]	Gais, jangan lupa like dan komen yaa heart_hands sparkles
Makasih [emoji tangan melipat][emoji tangan melipat]	Makasih folded_hands

4.2.6 Normalisasi Kata Tawa

Pada tahap pra-pemrosesan, dilakukan normalisasi terhadap kata-kata yang merepresentasikan ekspresi tawa. Dalam percakapan informal berbasis teks, ekspresi tawa dapat muncul dalam berbagai variasi penulisan, seperti *wkwk*, *wkwwk*, *haha*, *hahaha*, *hehe*, *hihi*, *xixi*, *kwkwkw*, hingga bentuk serapan dari bahasa Inggris seperti *lol* dan *lmao*. Meskipun memiliki bentuk yang beragam, seluruh variasi tersebut pada dasarnya menyampaikan makna semantik yang serupa, yaitu

ekspresi tertawa atau humor.

Keberagaman bentuk penulisan kata tawa dapat meningkatkan sparsitas kosakata (*vocabulary sparsity*) karena model akan memperlakukan setiap variasi sebagai token yang berbeda. Hal ini dapat mengurangi kualitas representasi teks dan berpotensi memengaruhi hasil pemodelan topik. Oleh karena itu, seluruh variasi kata tawa dinormalisasi menjadi satu bentuk token standar, yaitu *wkwk*.

Proses normalisasi dilakukan menggunakan *regular expression* yang dirancang untuk mendeteksi berbagai pola kata tawa, termasuk pola berbasis pengulangan karakter maupun suku kata. Seluruh pola yang terdeteksi kemudian diganti dengan token *wkwk*. Setelah transformasi, spasi berlebih dinormalisasi kembali agar struktur teks tetap konsisten.

Untuk mengevaluasi dampak normalisasi, dilakukan perbandingan antara teks sebelum dan sesudah transformasi menggunakan *masking* logis. Berdasarkan hasil identifikasi, dari total 91.868 baris data, ditemukan 9.258 baris yang mengalami perubahan akibat proses normalisasi kata tawa, atau setara dengan 10,08

Contoh hasil normalisasi ditunjukkan pada Tabel 4.6. Terlihat bahwa berbagai bentuk ekspresi tawa seperti Haha, haha, dan hahaha berhasil diseragamkan menjadi token *wkwk*. Dengan demikian, informasi mengenai ekspresi humor tetap dipertahankan, namun variasi token yang tidak perlu dapat dikurangi.

Tabel 4.6: Contoh Hasil Normalisasi Kata Tawa

Pesan	Pesan_Preprocessed
Haha apaan tuh lara kanan kiri?	wkwk apaan tuh lara kanan kiri?
Semua orang tau haha	Semua orang tau wkwk
Jd unik, gampang diinget hahaha	Jd unik, gampang diinget wkwk
lol lucu banget	wkwk lucu banget

4.2.7 Anonimisasi Identitas Pengirim

Selain melakukan normalisasi terhadap penyebutan (*mention*) pengguna di dalam isi pesan, sistem juga melakukan anonimisasi terhadap identitas pengirim pesan asli pada sisi klien sebelum data dikirimkan ke server. Hal ini bertujuan

untuk memastikan kepatuhan terhadap regulasi privasi data pribadi.

Proses anonimisasi dilakukan dengan memanfaatkan algoritma *hashing* SHA-256 yang ditambahkan dengan garam pengaman (*salt*) berupa string "chat-analisis-v1". Formula untuk menghasilkan nama samaran (*pseudonym*) pengirim digambarkan sebagai berikut:

$$\text{Hash} = \text{SHA-256}(\text{"chat-analisis-v1"} \parallel \text{Pengirim_Normalisasi}) \quad (4.1)$$

Untuk kemudahan visualisasi pada antarmuka pengguna, nilai *hash* tersebut dipotong hingga menyisakan 4 karakter pertama (*truncated hash*) dengan awalan kata *User-*. Apabila format pengirim terdeteksi sebagai nomor telepon (misalnya diawali dengan tanda + atau digit angka berderet panjang), sistem akan mengekstrak 4 digit terakhir dari nomor telepon tersebut dan menyematkannya di belakang nilai *hash* dengan pemisah karakter titik tengah (*.*), sehingga menghasilkan format seperti *User-[hash].[4_digit_terakhir]*. Sementara itu, untuk pengirim berupa nama teks biasa, format yang dihasilkan adalah *User-[hash]*.

Contoh hasil anonimisasi identitas pengirim ditunjukkan pada Tabel 4.7. Hasil ini menunjukkan bahwa nama asli pengirim berhasil disamarkan secara permanen sebelum data meninggalkan perangkat pengguna, sehingga kerahasiaan identitas tetap terjamin tanpa mengorbankan kemampuan analisis relasi antarpengguna dalam grup.

Tabel 4.7: Contoh Hasil Anonimisasi Identitas Pengirim

Nama Pengirim Asli	Nama Pengirim Anonim
Yusril Maqoshidana	User-a8b3
+62 895-xxxx-xxxx	User-bc45-7890
Merpati Rent Car Jember	User-d9e2

4.2.8 Penghapusan Pesan Sistem dan File Kontak

Data mentah hasil ekspor obrolan *WhatsApp* sering kali memuat notifikasi sistem otomatis, seperti notifikasi keamanan enkripsi, notifikasi keluar/masuk anggota,

panggilan tak terjawab, serta lampiran kartu kontak (.vcf). Pesan-pesan tersebut tidak merepresentasikan konten komunikasi aktual antar-anggota grup dan tidak memiliki nilai informasi semantik untuk analisis topik, sehingga dikategorikan sebagai pencilan (*outlier*) atau *noise*.

Proses pembersihan dilakukan dengan mendeteksi berkas dengan ekstensi .vcf menggunakan pencocokan string dan langsung membuang baris data tersebut dari *dataframe*. Selanjutnya, untuk notifikasi sistem berupa teks, pembersihan dilakukan menggunakan daftar pola ekspresi reguler (*regular expression*) yang mencakup notifikasi sistem dalam Bahasa Indonesia dan Bahasa Inggris (misalnya "pesan ini telah dihapus", "missed voice call", atau "media tidak disertakan"). Pola-pola ini dideteksi secara *case-insensitive* pada isi pesan, lalu substring yang cocok digantikan dengan string kosong.

Berdasarkan hasil pemrosesan pada dataset, seluruh pesan sistem otomatis dan berkas kontak berhasil dibersihkan. Hal ini mencegah model *embedding* dari pembentukan kluster palsu yang hanya berisi pesan-pesan otomatis sistem.

4.2.9 Case Folding dan Normalisasi Karakter Unicode

Setelah pesan-pesan sistem dibersihkan, dilakukan langkah *case folding* untuk mengubah seluruh huruf kapital dalam teks menjadi huruf kecil (*lowercase*). Hal ini berfungsi untuk mereduksi variasi representasi kosakata akibat perbedaan penggunaan huruf kapital di awal kalimat atau pada penulisan yang tidak konsisten.

Bersamaan dengan *case folding*, dilakukan normalisasi karakter Unicode menggunakan skema NFKD (*Normalization Form Compatibility Decomposition*). Langkah ini mendekomposisi karakter-karakter Unicode khusus (seperti spasi dengan lebar berbeda, simbol emotikon non-standar, atau karakter kontrol tersembunyi yang sering dihasilkan oleh keyboard perangkat seluler) menjadi representasi karakter ASCII standar yang setara. Hasil dari langkah ini adalah teks yang bersih dari karakter-karakter asing tersembunyi yang dapat memicu galat (*error*) pada proses tokenisasi dan ekstraksi fitur.

4.2.10 Normalisasi Karakter Berulang (Elongasi) dan Spasi

Karakteristik utama dari bahasa informal pada percakapan *WhatsApp* adalah adanya gejala elongasi huruf atau pemanjangan karakter secara berlebihan untuk mengekspresikan penekanan emosi (misalnya penulisan "iyaaaa", "bisaaa", atau "okeeey"). Gejala ini menyebabkan peningkatan variasi kosakata (*vocabulary sparsity*) karena model komputer akan menganggap kata "iya" dan "iyaaaa" sebagai dua kata yang berbeda secara leksikal.

Sistem mengatasi masalah ini dengan menerapkan fungsi normalisasi karakter berulang menggunakan ekspresi reguler. Aturan yang diterapkan adalah mendeteksi adanya karakter yang berulang sebanyak tiga kali atau lebih secara berturut-turut, kemudian mereduksinya menjadi maksimal dua karakter berturut-turut. Sebagai contoh, kata "iyaaaa" akan direduksi menjadi "iyaa", yang kemudian akan dipetakan ke bentuk baku "ya" pada tahap normalisasi kata tidak baku berikutnya. Spasi berlebih di dalam teks juga dinormalisasi dengan mengganti spasi ganda atau tabulasi menjadi satu karakter spasi tunggal.

4.2.11 Normalisasi Kata Tidak Baku (Slang Normalization)

Tahap normalisasi kata tidak baku bertujuan untuk memetakan kata-kata informal, singkatan, slang, dan jargon percakapan mahasiswa ke dalam bentuk kata baku bahasa Indonesia. Proses ini dilakukan dengan mencocokkan setiap token kata di dalam pesan dengan kamus rujukan (*slang dictionary*) yang telah didefinisikan.

Kamus rujukan yang digunakan mencakup kata-kata gaul dan singkatan umum, seperti "yg" dipetakan menjadi "yang", "ga/gak/nggak/gk" menjadi "tidak", "aja/deh/sih/dong/kok/loh/lah/mah" menjadi "saja", "jg" menjadi "juga", serta ungkapan terima kasih seperti "thanks/thx/makasih/mksh" menjadi "terima kasih". Dengan adanya pemetaan ini, variasi token kata dapat ditekan secara signifikan, sehingga meningkatkan kerapatan semantik data saat diproses oleh model representasi topik.

4.2.12 Pembersihan Tanda Baca dan Stopword Removal

Tahap akhir praproses adalah pembersihan tanda baca dan penghapusan kata umum (*stopword removal*). Pada penelitian ini, tahapan praproses dibagi menjadi dua jalur berbeda untuk mengakomodasi kebutuhan komponen model yang berbeda:

1. **Jalur Pembersihan untuk Embedding (IndoBERTweet):** Tanda baca, struktur kalimat, dan kata hubung (*stopwords*) **tetap dipertahankan** agar konteks semantik dua arah (*bidirectional context*) tidak rusak saat diproses oleh model transformer IndoBERTweet. Jalur ini menghasilkan kolom `Pesan_Embedding`.
2. **Jalur Pembersihan untuk Representasi Topik (BM25):** Tanda baca dihapus sepenuhnya dengan ekspresi reguler `[^a-z\s]` untuk menyisakan huruf dan spasi saja. Selanjutnya, dilakukan penghapusan kata-kata umum (*stopword removal*) secara ketat menggunakan daftar *stopword* bawaan dari pustaka Sastrawi yang digabungkan dengan kata-kata umum spesifik domain percakapan (seperti "user", "amp", "wa", "whatsapp", "chat", "grup", "group"). Kata-kata dengan panjang kurang dari 2 karakter juga dihapus. Jalur ini menghasilkan kolom `Pesan_TFIDF`.

Setelah kedua jalur tersebut selesai, dilakukan penyaringan baris data secara ketat. Baris pesan yang memiliki jumlah kata kurang dari 3 kata pada kolom `Pesan_TFIDF` dihapus dari dataset karena dianggap terlalu pendek dan tidak memiliki informasi semantik yang cukup berharga untuk dikelompokkan ke dalam klaster topik.

BAB 5. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian dan pembahasan, dapat disimpulkan sebagai berikut:

1. **Kesimpulan 1 (jawab RMP pertama):** Penelitian ini menunjukkan bahwa ... (Jelaskan jawaban dari rumusan masalah pertama di Bab 1 Section 1.2)
2. **Kesimpulan 2 (jawab RMP kedua):** Temuan utama adalah bahwa ... (Jelaskan jawaban dari rumusan masalah kedua)
3. **Kesimpulan 3 (jawab RMP ketiga):** Hasil analisis menunjukkan bahwa ... (Jelaskan jawaban dari rumusan masalah ketiga, jika ada)
4. **Kontribusi Utama:** Penelitian ini memberikan kontribusi teoritis dan praktis dalam ... (Jelaskan bagaimana penelitian ini berkontribusi pada ilmu pengetahuan dan praktik)

Secara keseluruhan, penelitian ini telah berhasil mengidentifikasi dan menganalisis ... (Ringkas temuan utama dalam 1-2 kalimat yang comprehensive).

5.2 Saran

Berdasarkan hasil penelitian, beberapa saran yang dapat diberikan adalah:

5.2.1 Saran untuk Penelitian Selanjutnya

Saran untuk penelitian di masa depan meliputi:

1. **Eksplorasi Variabel Tambahan:** Penelitian selanjutnya dapat menambahkan variabel ... untuk memberikan gambaran yang lebih lengkap tentang ... (Jelaskan variabel yang belum diteliti dan alasannya)

2. **Perluasan Scope Penelitian:** Penelitian dapat dilakukan dengan ... (Misal: lokasi yang berbeda, sampel yang lebih besar, periode waktu yang lebih panjang) untuk meningkatkan generalisabilitas hasil.
3. **Metode Penelitian Alternatif:** Menggunakan metode ... (mixed-method, longitudinal, q experimental design) untuk mendapatkan insight yang lebih dalam tentang ...
4. **Eksaminasi Mekanisme:** Penelitian lebih lanjut dapat membedah mekanisme yang mendasari ... untuk memahami HAL APA dan MENGAPA (explanatory research).

5.2.2 Saran untuk Praktisi dan Pengambil Kebijakan

Saran untuk implementasi praktis dari penelitian ini adalah:

1. **Rekomendasi 1:** ... (Jelaskan saran konkret untuk organisasi/perusahaan/pemerintah)
2. **Rekomendasi 2:** ... (Jelaskan saran kedua dengan action items yang jelas)
3. **Rekomendasi 3:** ... (Jelaskan saran ketiga dengan fokus pada implementasi)

Implementasi rekomendasi-rekomendasi ini diharapkan dapat ... (Jelaskan dampak positif yang diharapkan dari implementasi).

DAFTAR PUSTAKA


- Abdelrazek, A., Eid, Y., Gawish, E., Medhat, W., and Hassan, A. (2023). Topic modeling algorithms and applications: A survey. *Information Systems*, 112:102131.
- Alzu'bi, A. and Barham, M. (2022). Automatic birch thresholding with features transformation for hierarchical breast cancer clustering. *International Journal of Electrical and Computer Engineering (IJECE)*, 12(2):1498–1507.
- Banerjee, S. and Pan, A. (2024). From colonial legacies to linguistic inclusion: A bertopic enhanced bibliometric insight into global south higher education. *IEEE Access*, 12:117418–117435.
- Churchill, R. and Singh, L. (2022). The evolution of topic modeling. *ACM Comput. Surv.*, 54(10s).
- Dieng, A. B., Ruiz, F. J. R., and Blei, D. M. (2020). Topic modeling in embedding spaces. *Transactions of the Association for Computational Linguistics*, 8:439–453.
- Egger, R. and Yu, J. (2022). A topic modeling comparison between lda, nmf, top2vec, and bertopic to demystify twitter posts. *Frontiers in Sociology*, Volume 7 - 2022.
- Grootendorst, M. (2022). Bertopic: Neural topic modeling with a class-based tf-idf procedure.
- Janssens, W., Bogaert, M., and van den Poel, D. (2025). A comparative analysis of topic reduction techniques for bertopic. *IEEE Access*, 13:204087–204103.
- Jesse, M., Bauer, C., and Jannach, D. (2022). Intra-list similarity and human diversity perceptions of recommendations: the details matter. *User Modeling and User-Adapted Interaction*, 33(4):769–802.
- Jian, F., Huang, J. X., Zhao, J., Ying, Z., and Wang, Y. (2020). A topic-based

- term frequency normalization framework to enhance probabilistic information retrieval. *Computational Intelligence*, 36(2):486–521.
- Kharisudin, I. and Masri'an, H. (2022). Topic modeling on whatsapp user reviews using latent dirichlet allocation. *Scientific Journal of Informatics*, 9:51–62.
- Koto, F., Lau, J. H., and Baldwin, T. (2021). Indobertweet: A pretrained language model for indonesian twitter with effective domain-specific vocabulary initialization. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP 2021)*.
- Koto, F., Rahimi, A., Lau, J., and Baldwin, T. (2020). Indolem and indobert: A benchmark dataset and pre-trained language model for indonesian nlp.
- Kumar, R. P. and Naik, N. M. (2023). Whatsapp chat analyzer using machine learning and natural language processing. In *2023 2nd International Conference on Futuristic Technologies (INCOFT)*, pages 1–6.
- McInnes, L., Healy, J., and Melville, J. (2018). Umap: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*.
- Mohta, A., Jain, A., Saluja, A., and Dahiya, S. (2020). Pre-processing and emoji classification of whatsapp chats for sentiment analysis. In *2020 Fourth International Conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud) (I-SMAC)*, pages 514–519.
- Muhajir, M., Gunardi, G., Danardono, D., and Rosadi, D. (2025). Integrating indobert and balanced iterative reducing and clustering using hierarchies of bertopic in indonesian short text. *IAES International Journal of Artificial Intelligence (IJ-AI)*, 14:4192.
- Prayogi, A., Novriyenny, N., and Prahmana, I. G. (2025). Dinamika sentimen komunikasi mahasiswa dan dosen dengan pemanfaatan analisis pesan whatsapp akademis menggunakan machine learning. *Repeater: Publikasi Teknik Informatika dan Jaringan*, 3(2):45–54.
- Rani, S. J., Prabhu, T., and Chellam, J. A. I. (2022). Whatsapp sentiment analysis using r. In *2022 3rd International Conference for Emerging Technology (INCET)*, pages 1–4. IEEE.

- Retna, V. A., Brundha, P., and RajKumar, G. (2021). People’s behaviour analysis in chat message using natural language processing. In *2021 Third International Conference on Intelligent Communication Technologies and Virtual Mobile Networks (ICICV)*, pages 1128–1133.
- Röder, M., Both, A., and Hinneburg, A. (2015). Exploring the space of topic coherence measures. In *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining, WSDM ’15*, page 399–408, New York, NY, USA. Association for Computing Machinery.
- Rushkin, I. (2020). Document similarity from vector space densities. *CoRR*, abs/2009.00672.
- Shan, X., Liu, C., Xia, Y., Chen, Q., Zhang, Y., Luo, A., and Luo, Y. (2020). BI-SON: bm25-weighted self-attention framework for multi-fields document search. *CoRR*, abs/2007.05186.
- WhatsApp Inc. (2026). Tentang whatsapp. Diakses pada 7 Januari 2026.
- Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., and Purwarianti, A. (2020). Indonlu: Benchmark and resources for evaluating indonesian natural language understanding. In *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*.
- Zhang, T., Ramakrishnan, R., and Livny, M. (1996). Birch: an efficient data clustering method for very large databases. *SIGMOD Rec.*, 25(2):103–114.
- Zhang, T., Ramakrishnan, R., and Livny, M. (1997). Birch: A new data clustering algorithm and its applications. *Data Min. Knowl. Discov.*, 1(2):141–182.
- Zhao, H., Du, L., Buntine, W., and Zhou, M. (2018). Inter and intra topic structure learning with word embeddings. In *International Conference on Machine Learning*, pages 5892–5901. PMLR.


LAMPIRAN

Lampiran - Alur Implementasi Sistem



Gambar 1: Alur Implementasi Sistem

Lampiran - Alur Teknis Implementasi Sistem Web



Gambar 2: Alur Teknis Implementasi Sistem

.1 Surat Izin Penelitian dari Kampus

Dokumen administratif berupa Surat Izin Penelitian resmi dari pihak kampus untuk permohonan pengambilan data percakapan grup WhatsApp Angkatan STAN Tahun 2022.



KEMENTERIAN PENDIDIKAN TINGGI,
SAINS, DAN TEKNOLOGI
UNIVERSITAS JEMBER
FAKULTAS ILMU KOMPUTER
Jalan Kalimantan No. 37, Kampus Bumi Tegal Boto, Jember 68121
Telp. (0331) 326911, Fax. (0331) 326911
Laman : <https://ilkom.unej.ac.id>

Nomor	: 3142/DST/UN25.B15/SP/2026	22 Juni 2026
Perihal	: Permohonan Izin Penelitian	

Kepada Yth. Komunitas Buku Book Clan pada Platform WhatsApp
di tempat

Dalam rangka penyelesaian skripsi mahasiswa Fakultas Ilmu Komputer Universitas Jember, kami mohon dengan hormat bapak/ibu dapat memberikan izin untuk melakukan kegiatan penelitian bagi mahasiswa yang nama dan kegiatan yang dilakukan tersebut dibawah ini :

Nama / NIM	: Moh. Yusril Maqoshidana (222410102064)
Program Studi	: Teknologi Informasi
No. HP	: 085161558904
Kegiatan	: Permintaan export data pesan whatsapp
Judul Skripsi	: SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING
Tempat Kegiatan	: Komunitas Buku Book Clan pada Platform WhatsApp
Periode Kegiatan	: Mei - Juli 2026

Demikian permohonan kami, atas perhatian dan kerjasamanya yang baik diucapkan terima kasih.



Wakil Dekan Bidang Akademik,

Achmad Maududie., ST., M.Sc
NIP. 197004221995121001



Gambar 3: Surat Izin Penelitian dari Kampus

.2 Bukti Persetujuan Admin Grup WhatsApp

Tangkapan layar persetujuan tertulis dari administrator grup WhatsApp Angkatan STAN Tahun 2022 untuk penggunaan riwayat percakapan sebagai dataset penelitian dengan syarat penyamaran identitas.

