SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING

Diajukan guna memenuhi salah satu syarat memperoleh gelar Sarjana pada Program Studi Teknologi Informasi

SKRIPSI

Oleh:

Moh. Yusril Maqoshidana

NIM 222410102064

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI

UNIVERSITAS JEMBER

FAKULTAS ILMU KOMPUTER

PROGRAM STUDI TEKNOLOGI INFORMASI

JEMBER

2026

PERSEMBAHAN

Halaman ini saya persembahkan kepada:

1. Allah SWT, atas segala rahmat, karunia, serta kemudahan yang diberikan sehingga penulis dapat menyelesaikan skripsi ini dengan baik.
2. Bapak Subono dan Ibu Marsidah yang selalu mendoakan yang terbaik, mendukung segala usaha, serta selalu sabar dan percaya hingga sampai penulis mampu menyelesaikan pendidikan.
3. Bapak Dr. Brian Rizqi Paradisiaca Darnoto, S.Kom., M.Kom. selaku Dosen Pembimbing Utama yang telah meluangkan waktu, memberikan arahan, bimbingan, serta masukan yang berharga selama proses penyusunan skripsi ini.
4. Ibu Khoirunnisa' Afandi, S.Kom., M.Kom dan Bapak Dony Bahtera Firmawan, S.Kom., M.Kom selaku Dosen Penguji yang memberikan saran dan masukan dalam proses pengembangan skripsi.
5. Dosen Fakultas Ilmu Komputer, Universitas Jember yang telah memberikan ilmu dan pengalaman yang berharga selama masa perkuliahan.
6. Sahabat yang telah memberikan dukungan, semangat, serta bantuan selama proses penyusunan skripsi ini.

MOTTO

“ Aku telah berupaya tanpa henti untuk tidak mencemooh, tidak meratapi, tidak menghina tindakan manusia, tetapi untuk memahaminya. ”

(Baruch Spinoza)

“ Your worst sin is that you have destroyed and betrayed yourself for nothing. ”

(Fyodor Dostoevsky)

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini:

Nama: Moh. Yusril Maqoshidana

NIM: 222410102064

Dengan ini menyatakan bahwa skripsi yang berjudul: *Sistem Analisis Topik Grup WhatsApp Berbasis Web Menggunakan BERTopic dengan IndoBERTweet dan BIRCH Clustering* adalah benar-benar hasil karya saya sendiri. Saya juga menyatakan bahwa dalam skripsi ini tidak terdapat karya yang pernah diajukan untuk memperoleh gelar sarjana atau gelar lainnya di mana pun.

Saya bertanggung jawab atas kebenaran dan keorisinalan isi skripsi ini. Apabila dikemudian hari terbukti bahwa skripsi ini mengandung unsur plagiasi, maka saya siap menanggung akibat hukum yang berlaku.

Jember, 20 Oktober 2026

Yang menyatakan,

Moh. Yusril Maqoshidana

NIM 222410102064

HALAMAN PERSETUJUAN

Skripsi berjudul *"SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING"* telah diuji dan disetujui oleh Fakultas Ilmu Komputer Universitas Jember pada:

Hari : Selasa

Tanggal : 20 Oktober 2026

Tempat : Fakultas Ilmu Komputer Universitas Jember

Pembimbing Tanda Tangan

1. Pembimbing Utama

   Nama : Dr. Brian R. P. Darnoto, S.Kom., M.Kom (.....)

   NIP : 199804272024061001

Penguji

1. Penguji Utama

   Nama : Khoirunnisa' Afandi, S.Kom., M.Kom (.....)

   NIP : 199412282024062001

2. Penguji Anggota 1

   Nama : Dony Bahtera Firmawan, S.Kom., M.Kom (.....)

   NIP : 199711202024061001

ABSTRAK

Tingginya volume percakapan pada grup WhatsApp kerap memicu fenomena *information overload*, yang menyulitkan pengguna dalam mengikuti dinamika diskusi dan menyaring informasi penting. Di sisi lain, kerangka kerja pemodelan topik standar BERTopic berbasis HDBSCAN secara inheren membuang 42%–56% pesan sebagai pencilan (*outlier*), sehingga menghilangkan banyak konteks esensial pada teks obrolan yang pendek dan informal. Penelitian ini bertujuan mengembangkan modifikasi arsitektur BERTopic yang mengintegrasikan model *embedding* IndoBERTweet, pengklasteran hierarkis BIRCH, dan representasi kata kunci BM25 untuk meminimalkan proporsi *outlier* sekaligus meningkatkan koherensi serta keberagaman topik. Metodologi penelitian melibatkan pemodelan korpus 51.584 pesan bersih grup WhatsApp melalui *pipeline* algoritma BIRCH dengan reduksi dimensi UMAP, ambang *micro-cluster* adaptif, dan reduksi topik otomatis. Evaluasi kurva pembelajaran membuktikan keunggulan model usulan, yang berhasil membatasi proporsi *outlier* hingga hanya 7,21% (mempertahankan 92,79% cakupan data percakapan) serta menghasilkan koherensi semantik (C_{NPMI}) positif sebesar +0,1075 dan keberagaman topik (*Topic Diversity*) sebesar 0,9875, jauh melampaui performa model *baseline* HDBSCAN. Temuan ini menyimpulkan bahwa pengklasteran hierarkis efektif memitigasi fragmentasi pesan tanpa mendegradasi kualitas representasi semantik. Model akhir berhasil diimplementasikan ke dalam prototipe aplikasi web analitik interaktif yang dilengkapi pemantauan progres *real-time* berbasis SSE dan penelusuran konteks pesan (*traceability*) guna memfasilitasi eksplorasi dinamika obrolan secara efisien.

Kata Kunci: *BERTopic, IndoBERTweet, BIRCH Clustering, BM25, Pemodelan Topik, Analisis Grup WhatsApp*

ABSTRACT

High message activity in WhatsApp groups frequently causes information overload, making it difficult for members to track discussion dynamics and extract key insights. While topic modeling can automate thematic extraction, the standard BERTopic framework relying on HDBSCAN inherently discards up to 42%–56% of messages as outliers, causing critical context loss on short and informal conversational texts. This research aims to develop an enhanced BERTopic architecture that integrates the IndoBERTweet contextual embedding model, BIRCH hierarchical clustering, and the BM25 weighting scheme to minimize outlier rates while improving topic coherence and diversity. The methodology involves processing a corpus of 51,584 cleaned WhatsApp messages through a BIRCH clustering pipeline featuring dynamic micro-cluster thresholding and automatic topic reduction. Contextual representations generated by IndoBERTweet are dimensionally reduced via UMAP before being structured into cohesive thematic sub-clusters. The model evaluation across a multi-stage learning curve demonstrated outstanding performance, successfully restricting the outlier rate to just 7.21% (retaining 92.79% data coverage) while achieving a positive topic coherence (C_{NPMI}) of +0.1075 and a topic diversity of 0.9875, significantly outperforming HDBSCAN-based baselines. Furthermore, the comparative analysis proved that hierarchical clustering effectively resolves topic fragmentation on short texts without sacrificing semantic quality. The study concludes that adapting hierarchical clustering within the BERTopic pipeline serves as an effective mechanism to capture scattered conversational context. The resulting model was successfully integrated into an interactive web application prototype featuring real-time SSE progress streaming and message context traceability, enabling users to efficiently explore group discussion dynamics.

Keywords: *BERTopic, IndoBERTweet, BIRCH Clustering, BM25, Topic Modeling, WhatsApp Group Analysis*

RINGKASAN

Penelitian ini dilatarbelakangi oleh tingginya volume pertukaran pesan pada grup WhatsApp interaktif yang kerap memicu fenomena *information overload*. Anggota grup maupun pengelola komunitas menghadapi kesulitan besar dalam mengikuti alur diskusi, menyaring pokok permasalahan, serta memetakan topik penting tanpa membaca ribuan riwayat pesan secara manual. Penerapan pemodelan topik konvensional berbasis BERTopic standar terbentur oleh karakteristik teks obrolan yang pendek, sarat singkatan, dan informal, di mana algoritma HDBSCAN secara inheren membuang hingga 42%–56% pesan sebagai pencilan (*outlier*). Untuk mengatasi masalah kehilangan konteks tersebut, penelitian ini mengembangkan modifikasi arsitektur BERTopic yang memadukan keunggulan model representasi kontekstual IndoBERTweet, pengklasteran hierarkis BIRCH, serta skema pembobotan BM25.

Data mentah yang digunakan bersumber dari riwayat percakapan grup WhatsApp Komunitas Buku sepanjang 2023–2026 sebanyak 91.868 pesan teks. Korpus tersebut dibersihkan melalui tahapan *preprocessing* yang menghasilkan 51.584 dokumen representatif. Vektor semantik dibangkitkan menggunakan model IndoBERTweet dan direduksi dimensinya melalui UMAP sebelum diproses oleh algoritma pengklasteran BIRCH. Mekanisme adaptasi ambang *micro-cluster* dinamis dan penyaringan berbasis deviasi sentroid pada model ini memungkinkan sistem mempertahankan pesan-pesan percakapan yang tersebar secara fleksibel, sementara skema BM25 secara akurat mengekstraksi kata kunci topik tanpa terdistorsi oleh tingginya variasi frekuensi kata pada teks pendek.

Hasil pengujian eksperimental kurva pembelajaran membuktikan keunggulan komprehensif arsitektur yang diusulkan. Algoritma usulan berhasil menekan proporsi *outlier* secara drastis hingga tersisa 7,21% (mempertahankan 92,79% cakupan data) dengan skor koherensi semantik (C_{NPMI}) positif sebesar +0,1075 dan keberagaman topik (*Topic Diversity*) mencapai 0,9875. Analisis komparatif membuktikan bahwa pengklasteran hierarkis BIRCH secara signifikan mengungguli algoritma bawaan

HDBSCAN dalam mencegah pembuangan data obrolan tanpa mengorbankan kepadatan klaster. Arsitektur pemodelan topik ini kemudian diimplementasikan ke dalam aplikasi web analitik interaktif berbasis FastAPI dan Vue.js yang dilengkapi pemantauan progres *real-time* berbasis SSE serta fitur penelusuran konteks pesan (*traceability*). Secara keseluruhan, integrasi pengklasteran hierarkis ke dalam arsitektur BERTopic terbukti memberikan kontribusi krusial sebagai jembatan yang menghubungkan fragmen obrolan informal menjadi wawasan tematik yang koheren, terukur, dan bernilai guna.

PRAKATA

Puji syukur kehadirat Allah SWT atas segala berkah dan rahmat yang telah diberikan sehingga penulis mampu menyelesaikan penelitian yang berjudul *"SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING"*. Penelitian ini merupakan salah satu syarat akademik dalam menyelesaikan pendidikan Strata Satu (S1) pada Program Studi Teknologi Informasi Fakultas Ilmu Komputer Universitas Jember.

Penulis menyadari bahwa dalam proses penelitian dan penulisan skripsi ini, banyak pihak yang telah memberikan bimbingan, dukungan, dan bantuan. Oleh karena itu, pada kesempatan ini penulis dengan sepenuh hati mengucapkan terima kasih kepada:

1. Bapak Prof. Drs. Antonius Cahya Prihandoko, M.App.Sc., Ph.D., selaku Dekan Fakultas Ilmu Komputer Universitas Jember.
2. Dr. Brian Rizqi Paradisiaca Darnoto, S.Kom., M.Kom. selaku Pembimbing Utama yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan bimbingan, diskusi, serta arahan yang sangat berharga sejak awal hingga skripsi ini selesai.
3. Ibu Khoirunnisa' Afandi, S.Kom., M.Kom dan Bapak Dony Bahtera Firmawan, S.Kom., M.Kom selaku Dosen Penguji yang telah memberikan ujian, saran, dan masukan yang konstruktif demi kesempurnaan laporan skripsi ini.
4. Bapak Yudha Alif Auliya, S.Kom., M.Kom. selaku Dosen Pembimbing Akademik yang telah memberikan bimbingan dan arahan selama masa studi di Program Studi Teknologi Informasi.
5. Para dosen dan staf Fakultas Ilmu Komputer, Universitas Jember yang telah membantu selama proses akademik.
6. Bapak Subono dan Ibu Marsidah selaku orang tua yang telah memberikan doa dan dukungan moral dan material selama penulis menempuh pendidikan

hingga menyelesaikan pendidikan jenjang S1.

7. Sahabat yang telah memberikan semangat, bantuan, dan dukungan selama proses penelitian ini.
8. Seluruh pihak dalam komunitas buku yang telah memberikan kepercayaan dan bantuan dalam proses penelitian ini.

Penulis menyadari bahwa skripsi ini masih memiliki berbagai kekurangan, baik dalam penulisan maupun isi. Oleh karena itu, penulis mengharapkan kritik dan saran yang sifatnya membangun dari pembaca untuk perbaikan di masa mendatang. Akhir kata, semoga penelitian ini dapat memberikan manfaat bagi kemajuan ilmu pengetahuan dan dapat dijadikan sebagai bahan referensi bagi penelitian-penelitian selanjutnya.

Jember, 20 Oktober 2026

Moh. Yusril Maqoshidana
NIM 222410102064

DAFTAR ISI

PERSEMBAHAN . . . . . **i**

MOTTO . . . . . **ii**

PERNYATAAN ORISINALITAS . . . . . **iii**

HALAMAN PERSETUJUAN . . . . . **iv**

ABSTRAK . . . . . **v**

ABSTRACT . . . . . **vi**

RINGKASAN . . . . . **vii**

PRAKATA . . . . . **ix**

DAFTAR TABEL . . . . . **xiii**

DAFTAR GAMBAR . . . . . **xiv**

DAFTAR LAMPIRAN . . . . . **xv**

1 PENDAHULUAN **1**

1.1 Latar Belakang 1

1.2 Rumusan Masalah 2

1.3 Tujuan Penelitian 3

1.4 Manfaat Penelitian 3

1.5 Batasan Penelitian 4

2 TINJAUAN PUSTAKA **5**

2.1 Penelitian Terdahulu 5

2.2 Landasan Teori 6

2.2.1 Aplikasi WhatsApp 6

2.2.2 BERTopic 6

2.2.3 IndoBERTweet 7

2.2.4 BIRCH *Clustering* 8

2.2.5 *Topic Representation* dengan BM25 9

2.2.6 Reduksi Topik Hierarkis (*Hierarchical Topic Reduction*) . . 10

2.2.7 Metrik Evaluasi Pemodelan Topik 11

3 METODOLOGI PENELITIAN **13**

3.1 Jenis Penelitian 13

3.2 Objek Penelitian 13
3.3 Waktu Penelitian 13
3.4 Tahapan Penelitian 14
3.4.1 Identifikasi Masalah dan Studi Literatur 14
3.4.2 Pengumpulan Data 14
3.4.3 Praproses Data 15
3.4.4 Pembuatan Model 16
3.4.5 Evaluasi Model 17
3.4.6 Rancangan Implementasi dan Pengujian Sistem 18
3.5 Etika Penelitian 19
4 HASIL DAN PEMBAHASAN 20
4.1 Pengumpulan Data 20
4.2 Praproses Data 21
4.3 Pembuatan Model 22
4.4 Hasil Evaluasi Model 26
4.4.1 Perbandingan Kinerja Empiris Model Acuan dan Model Usulan 26
4.4.2 Dinamika Konvergensi dan Stabilitas Model 28
4.5 Implementasi Sistem 30
4.5.1 Arsitektur Client-Server dan Keamanan Sistem 30
4.5.2 Pemrosesan Asinkron dan Antarmuka Pengguna 31
4.6 Evaluasi Sistem 32
5 KESIMPULAN DAN SARAN 34
5.1 Kesimpulan 34
5.2 Saran 35
DAFTAR PUSTAKA 35
LAMPIRAN 39

DAFTAR TABEL

2.1 Tinjauan Penelitian Terdahulu 5

4.1 Statistik Hasil Pengolahan Praproses Data Pada Dataset Percakapan WhatsApp 21

4.2 Perbandingan Performa 4 Model pada Korpus 100% WhatsApp . . . 27

DAFTAR GAMBAR

2.1 *Framework* BERTopic dengan modifikasi IndoBERT, BIRCH, dan BM25 (Muhajir et al., 2025) 7

3.1 Tahapan Penelitian 14
3.2 Rancangan *framework* BERTopic yang dimodifikasi pada tahap pembuatan model 16

4.1 Visualisasi Proyeksi 2D UMAP Keterpisahan Klaster dan Reduksi *Outlier Noise* 24
4.2 Distribusi 5 Kata Kunci Teratas Berbobot BM25 pada Topik Utama WhatsApp 25
4.3 Kurva Pembelajaran (*Learning Curve*) Perbandingan Model Pemodelan Topik 29

DAFTAR LAMPIRAN

Lampiran 1. Perbandingan Kinerja Model Bahasa Pra-Latih pada Berbagai Tugas NLP 39
Lampiran 2. Cuplikan Data Mentah Log Obrolan WhatsApp 40
Lampiran 3. Contoh Transformasi Teks Praproses Data 41
Lampiran 4. Rincian Data Evaluasi Kurva Pembelajaran 42
Lampiran 5. Surat Izin Penelitian dari Kampus 43
Lampiran 6. Bukti Persetujuan Admin Grup WhatsApp 44
Lampiran 7. Hasil Pengujian Fungsional Sistem (*Black-Box Testing*) . . . 45
Lampiran 8. Tangkapan Layar Implementasi Antarmuka Sistem Web . . . 47

BAB 1. PENDAHULUAN

1.1 Latar Belakang

WhatsApp merupakan salah satu aplikasi pesan instan terpopuler di dunia yang banyak dimanfaatkan sebagai wadah diskusi komunitas, koordinasi tim, dan komunikasi organisasi (WhatsApp LLC, 2026; Prayogi et al., 2025). Pada grup WhatsApp yang sangat aktif dengan volume percakapan tinggi, arus pertukaran informasi berlangsung sangat cepat dan dinamis. Akumulasi pesan yang masif ini kerap menimbulkan fenomena *information overload*, di mana pengguna mengalami kesulitan dalam mengikuti alur diskusi, menyaring informasi penting, maupun mengetahui topik yang sedang dibahas tanpa membaca keseluruhan riwayat obrolan secara manual (Rani et al., 2022). Oleh karena itu, diperlukan sistem yang mampu memodelkan dan mengekstraksi topik percakapan grup WhatsApp secara otomatis.

Topic modeling merupakan teknik dalam *Natural Language Processing* (NLP) untuk menemukan struktur tematik laten dari sekumpulan dokumen teks (Abdelrazek et al., 2023). Namun, penerapan pemodelan topik pada percakapan grup WhatsApp menghadapi tantangan besar akibat karakteristik data yang berupa teks pendek, tidak terstruktur, mengandung *noise* tinggi, serta sarat fenomena *code-mixing* dan struktur kalimat eliptis yang fragmentaris (Churchill and Singh, 2022; Mohta et al., 2020; Sutarma, 2017; Siregar et al., 2025).

Meskipun arsitektur modular BERTopic terbukti unggul pada teks pendek dibandingkan metode konvensional berbasis *bag-of-words* seperti LDA dan NMF (Grootendorst, 2022; Egger and Yu, 2022), algoritma klasterisasi bawaannya, yaitu HDBSCAN, secara inheren mengeliminasi dokumen yang tidak memenuhi ambang stabilitas kepadatan sebagai *outlier* (Grootendorst, 2022; Janssens et al., 2025). Akibatnya, hingga 23%–24% pesan obrolan dapat terbuang dan tidak terpetakan ke dalam topik manapun (Muhajir et al., 2025).

Untuk mengatasi keterbatasan tersebut, penelitian ini mengusulkan modifikasi

pada *framework* BERTopic dengan mengganti HDBSCAN menggunakan algoritma BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) (Zhang et al., 1996) dan mengganti c-TF-IDF dengan skema BM25 (Jian et al., 2020). Algoritma BIRCH mampu mengelompokkan dokumen berukuran besar secara efisien ke dalam struktur *CF-Tree* dan menugaskan data ke klaster yang valid sehingga menekan proporsi *outlier* hingga rentang 1%–5% pada teks pendek (Zhang et al., 1996; Ramadhani et al., 2020; Muhajir et al., 2025). Pada lapisan *embedding*, IndoBERTweet dimanfaatkan karena dilatih secara khusus pada korpus media sosial berbahasa Indonesia, sehingga mampu menangkap konteks semantik bahasa percakapan informal secara lebih optimal (Koto et al., 2021; Muhajir et al., 2025). Sementara itu, penerapan BM25 pada tahap representasi topik menyempurnakan c-TF-IDF dengan memperhitungkan saturasi frekuensi kata dan normalisasi panjang dokumen, sehingga kata-kata yang mendominasi frekuensi tidak mengaburkan kata kunci yang informatif (Jian et al., 2020; Muhajir et al., 2025).

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana penerapan BERTopic dengan integrasi IndoBERTweet, BIRCH *clustering*, dan representasi topik BM25 untuk mengidentifikasi topik pada percakapan grup WhatsApp berbahasa Indonesia?
2. Bagaimana kualitas topik yang dihasilkan oleh BERTopic yang diajukan dibandingkan dengan model *baseline* BERTopic berdasarkan evaluasi metrik *Topic Coherence*, *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity*?
3. Bagaimana merancang dan mengimplementasikan sistem berbasis *web* untuk analisis topik percakapan grup WhatsApp menggunakan BERTopic dengan IndoBERTweet, BIRCH *clustering*, dan BM25?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah tersebut, tujuan penelitian ini dirumuskan sebagai berikut:

1. Menerapkan BERTopic dengan model *embedding* IndoBERTweet, algoritma BIRCH sebagai metode *clustering*, dan skema BM25 sebagai representasi topik untuk mengidentifikasi topik pada percakapan grup WhatsApp berbahasa Indonesia.
2. Mengevaluasi dan membandingkan performa BERTopic yang diajukan dengan *baseline* BERTopic berdasarkan metrik *Topic Coherence*, *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity*.
3. Merancang dan mengimplementasikan sistem berbasis *web* untuk analisis topik percakapan grup WhatsApp yang memanfaatkan BERTopic dengan IndoBERTweet, BIRCH *clustering*, dan BM25 agar dapat digunakan secara praktis oleh pengguna akhir.

1.4 Manfaat Penelitian

Adapun manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan kontribusi dalam pengembangan ilmu di bidang *Natural Language Processing* (NLP), khususnya penerapan BERTopic dengan modifikasi IndoBERTweet, BIRCH *clustering*, dan BM25 untuk analisis teks percakapan informal berbahasa Indonesia.
2. Menyediakan sistem berbasis *web* yang mampu menganalisis percakapan grup WhatsApp secara otomatis serta menyajikan ringkasan topik melalui visualisasi yang intuitif.
3. Menjadi referensi akademik bagi penelitian selanjutnya terkait ekstraksi dan pemodelan topik pada data teks pendek dan pesan instan.

1.5 Batasan Penelitian

Agar penelitian ini lebih terarah dan fokus, maka ditetapkan beberapa batasan penelitian sebagai berikut:

1. Sistem hanya menganalisis percakapan teks berbahasa Indonesia dari grup WhatsApp, tidak mencakup media gambar, video, audio, maupun dokumen.
2. Data masukan pada *website* berupa berkas ekspor *chat* WhatsApp format .txt atau .zip yang diperoleh dari perangkat Android.
3. Data yang digunakan merupakan riwayat percakapan grup Komunitas Buku pada periode 2023–2026 dengan jumlah pesan sebanyak 91.868.
4. Penelitian berfokus pada pemodelan topik dan tidak mencakup analisis sentimen, klasifikasi emosi, maupun prediksi perilaku pengguna.
5. Representasi topik menggunakan metode skema pembobotan BM25 sebagai pengganti skema representasi topik bawaan BERTopic, yaitu c-TF-IDF.
6. Evaluasi dilakukan menggunakan metrik *Topic Coherence*, *Topic Diversity*, *Embedding Density*, *Intra-topic Similarity*, serta pengujian fungsional *black-box*.

BAB 2. TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Tabel 2.1: Tinjauan Penelitian Terdahulu

No	Judul & Pustaka	Hasil Penelitian	Celah (*Gap*)	Kontribusi Usulan
1	*A Topic Modeling Comparison Between LDA, NMF, Top2Vec, and BERTopic...* (Egger and Yu, 2022) (Jurnal Q1)	BERTopic unggul untuk pemodelan berbasis *embedding*, namun HDBSCAN menghasilkan proporsi *outlier* yang tinggi pada data media sosial.	Menggunakan model *multilingual*; belum adaptif terhadap teks percakapan informal bahasa Indonesia dan belum ada sistem terintegrasi.	Menerapkan IndoBERTweet sebagai model *embedding* spesifik bahasa Indonesia serta algoritma BIRCH teroptimasi guna menekan *outlier*.
2	*Integrating IndoBERT and BIRCH in BERTopic for Indonesian short text* (Muhajir et al., 2025) (Jurnal Q2)	Modifikasi IndoBERT, BIRCH, dan BM25 berhasil menurunkan *outlier* dan menaikkan stabilitas klaster pada korpus monolog (X, Review, YouTube).	Belum diuji pada dialog percakapan WhatsApp yang bersifat *multi-turn*, cepat berkembang, serta kaya akan campur kode (*code-mixing*).	Mengadaptasi arsitektur pada korpus percakapan WhatsApp dengan penambahan mekanisme pemotongan pencilan 2σ dan reduksi topik otomatis.
3	*BERTopic Enhanced Bibliometric Insight Into Global South...* (Banerjee and Pan, 2024) (Jurnal Q1)	BERTopic menunjukkan koherensi topik yang lebih unggul dibandingkan LDA pada korpus literatur akademik berskala besar.	Belum mengeksplorasi algoritma klaster alternatif untuk meminimalkan *outlier* dan belum menyentuh karakteristik teks obrolan informal.	Merancang mekanisme eliminasi klaster kerdil dan pemurnian kata kunci topik untuk menangani obrolan komunitas yang sarat singkatan tidak baku.

Berdasarkan penelitian terdahulu yang diulas pada Tabel 2.1, dapat disimpulkan bahwa meskipun BERTopic terbukti unggul dibandingkan metode konvensional (seperti LDA dan NMF), penerapan *default* berbasis model *multilingual* dan algoritma HDBSCAN masih menghasilkan proporsi *outlier* yang tinggi serta rentan menghasilkan klaster semu pada teks pendek. Penelitian terdahulu membuktikan potensi integrasi IndoBERT dan BIRCH pada teks monolog media sosial (Muhajir et al., 2025), namun belum menyentuh karakteristik percakapan grup WhatsApp berbahasa Indonesia yang memiliki pola *multi-turn dialog*, bahasa tidak baku, serta ketiadaan sistem terintegrasi bagi pengguna akhir.

2.2 Landasan Teori

2.2.1 Aplikasi WhatsApp

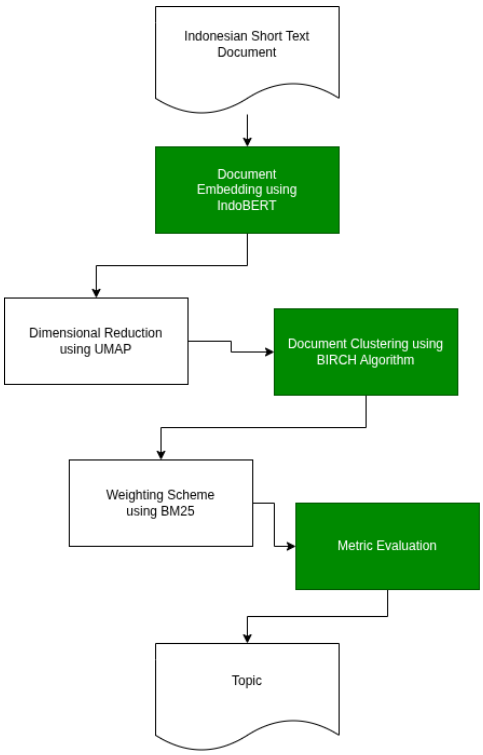
WhatsApp merupakan aplikasi pesan instan yang mendukung komunikasi personal maupun kelompok melalui fitur grup diskusi (Prayogi et al., 2025). Karakteristik komunikasi grup yang dinamis, melibatkan banyak partisipan, dan bervolume tinggi menyebabkan alur percakapan berlangsung cepat serta kerap kali tumpang tindih (Rani et al., 2022). Akibatnya, anggota grup sering kali kesulitan mengikuti atau merangkum perkembangan topik pembahasan secara menyeluruh.

Secara linguistik, percakapan WhatsApp memiliki karakteristik khas teks obrolan informal yaitu struktur kalimat eliptis atau fragmentaris tanpa kelengkapan subjek-predikat formal, minim tanda baca, serta sarat akan singkatan tidak baku, bahasa gaul (*slang*), dan campur kode (*code-mixing*) lintas bahasa (Siregar et al., 2025; Sutarma, 2017). Kompleksitas leksikal ini mendasari perlunya perancangan tahapan praproses teks yang adaptif sebelum data ditransformasikan ke dalam ruang representasi vektor.

2.2.2 BERTopic

BERTopic adalah *framework topic modeling* berbasis *transformer* yang merepresentasikan topik melalui prosedur TF-IDF berbasis kelas (c-TF-IDF), sehingga dokumen dengan makna semantik serupa dipetakan saling berdekatan dalam ruang vektor (Grootendorst, 2022). Pendekatan ini efektif menangani kelangkaan data (*data sparsity*) pada teks pendek informal.

Sebagaimana disajikan pada Gambar 2.1, modularitas BERTopic mencakup lima tahapan: (1) *document embedding* untuk menghasilkan representasi vektor semantik, (2) *dimensionality reduction* via UMAP guna memproyeksikan vektor ke dimensi rendah, (3) *clustering* dokumen berbasis kemiripan ruang, (4) *topic representation* untuk mengekstraksi kata kunci representatif, dan (5) *hierarchical topic reduction* untuk memadatkan topik mikro yang redundan (Grootendorst, 2022; Muhajir et al., 2025).



Gambar 2.1: *Framework* BERTopic dengan modifikasi IndoBERT, BIRCH, dan BM25 (Muhajir et al., 2025)

2.2.3 IndoBERTweet

Model IndoBERTweet merupakan model bahasa pra-latih berskala besar yang dirancang khusus untuk domain media sosial berbahasa Indonesia melalui pendekatan *domain-adaptive pretraining* (Koto et al., 2021). Model ini mengakomodasi 14.584 kosakata domain-spesifik baru yang tidak tercakup pada IndoBERT formal. Berdasarkan pengujian komparatif oleh Koto et al. (2021), IndoBERTweet secara konsisten mencapai performa tinggi pada tujuh tugas hilir NLP berbahasa Indonesia (meliputi *sentiment analysis*, *emotion classification*, *hate speech detection*, dan NER). IndoBERTweet mencatatkan rata-rata skor F1 sebesar 86,1%, mengungguli model bertaraf multilingual seperti mBERT (79,6%) dan IndoBERT umum (83,4%). Rincian perbandingan skor performa komparatif antar-model bahasa pada tujuh tugas hilir tersebut disajikan pada Lampiran 1. Temuan empiris ini memperkuat dasar pemilihan IndoBERTweet sebagai ekstraktor *embedding* yang adaptif terhadap teks obrolan WhatsApp yang sarat istilah percakapan informal.

2.2.4 BIRCH *Clustering*

BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) adalah algoritma *clustering* hierarkis yang efisien untuk memproses data berskala besar dalam satu kali pemindaian (*single pass*) dengan kompleksitas waktu dan memori linier $O(N)$ (Zhang et al., 1996, 1997). Keunggulan komputasi BIRCH bertumpu pada peringkasan data ke dalam struktur pohon fitur (*CF-Tree*), di mana setiap subklaster direpresentasikan secara ringkas dalam memori utama melalui tripel *Clustering Feature* (CF):

$$CF = (N, LS, SS) \tag{2.1}$$

di mana N menyatakan jumlah total titik data dalam subklaster, $LS = \sum_{i=1}^{N} x_i$ merupakan jumlah linier (*linear sum*) dari seluruh titik data berdimensi d, dan $SS = \sum_{i=1}^{N} \|x_i\|^2$ adalah jumlah kuadrat skalar (*square sum*). Dari vektor ringkasan CF tersebut, titik pusat (*centroid*) μ dan radius kerapatan R dapat dihitung secara langsung tanpa perlu menyimpan seluruh titik data individual di memori (Alzu'bi and Barham, 2022):

$$\mu = \frac{LS}{N}, \qquad R = \sqrt{\frac{SS}{N} - \left\| \frac{LS}{N} \right\|^2} \tag{2.2}$$

Ketika data baru x diserap ke dalam pohon, radius pembaruan (R') dihitung secara instan memanfaatkan sifat aditivitas aljabar CF:

$$R' = \sqrt{\frac{SS + \|x\|^2}{N+1} - \left\| \frac{LS + x}{N+1} \right\|^2} \tag{2.3}$$

Titik baru diserap ke dalam simpul daun pohon fitur (*CF-Leaf*) apabila nilai $R' \leq T$, dengan T sebagai parameter ambang batas (*threshold*), serta percabangan simpul non-daun dibatasi oleh faktor percabangan B.

Meskipun sangat efisien, algoritma BIRCH standar bekerja secara kaku sebagai pengklasteran tegas (*hard clustering*) dengan proporsi pencilan 0%, sehingga memaksakan seluruh dokumen masuk ke klaster terdekat meskipun jarak seman-

tiknya sangat jauh (Ramadhani et al., 2020). Sebaliknya, algoritma klasterisasi berbasis kepadatan seperti HDBSCAN pada teks pendek membuang pencilan secara terlampau agresif ($> 50\%$), yang mengakibatkan hilangnya sebagian besar informasi obrolan (Muhajir et al., 2025). Guna menjembatani keterbatasan tersebut, penelitian ini merumuskan landasan modifikasi algoritma BIRCH yang mengintegrasikan penyaringan pencilan terukur berbasis deviasi standar jarak kosinus dokumen terhadap titik pusat klaster penugasannya (c_k):

$$d_{\cos}(x, c_k) = 1 - \frac{x \cdot c_k}{\|x\|\|c_k\|} \tag{2.4}$$

dengan nilai ambang batas dinamis τ_k yang dirumuskan secara adaptif berdasarkan distribusi statistik:

$$\tau_k = \mu_{d,k} + 2{,}0 \cdot \sigma_{d,k} \tag{2.5}$$

di mana $\mu_{d,k}$ dan $\sigma_{d,k}$ masing-masing melambangkan nilai rata-rata dan simpangan baku dari jarak kosinus seluruh dokumen dalam klaster ke-k. Dokumen marjinal yang memiliki jarak $d_{\cos}(x, c_k) > \tau_k$ dialokasikan sebagai pencilan (*outlier*), menghasilkan klaster topik yang padat sekaligus mempertahankan toleransi pencilan terukur pada rentang 1%–5% (Muhajir et al., 2025).

2.2.5 *Topic Representation* dengan BM25

Skema pembobotan BM25 (*Best Matching 25*) merupakan fungsi peringkat temu balik informasi berbasis probabilistik yang diadaptasikan pada pemodelan topik untuk mengatasi kelemahan c-TF-IDF pada distribusi frekuensi istilah yang timpang (Jian et al., 2020; Muhajir et al., 2025). Pada pemodelan teks obrolan, partikel kata percakapan kerap muncul dengan frekuensi lokal yang sangat tinggi namun tidak informatif. Pembobotan kata t pada klaster topik C_k dirumuskan sebagai:

$$w_{t,C_k} = \sum_{d \in C_k} \mathrm{IDF}(t) \cdot \frac{f(t,d) \cdot (k_1 + 1)}{f(t,d) + k_1 \left(1 - b + b \cdot \dfrac{|d|}{avgdl}\right)} \tag{2.6}$$

dengan fungsi pembobotan inversi frekuensi dokumen (IDF):

$$\mathrm{IDF}(t) = \log\left(\frac{N - n(t) + 0{,}5}{n(t) + 0{,}5}\right) \tag{2.7}$$

di mana $f(t, d)$ menyatakan frekuensi kemunculan kata t di dalam dokumen d, $|d|$ merepresentasikan panjang dokumen d, $avgdl$ melambangkan rata-rata panjang seluruh dokumen dalam korpus klaster, N adalah jumlah total dokumen, dan $n(t)$ merupakan jumlah dokumen yang memuat kata t. Parameter k_1 mengatur saturasi frekuensi istilah non-linier agar kata berfrekuensi tinggi tidak mendominasi secara berlebih, sedangkan parameter b mengontrol tingkat penalti normalisasi panjang dokumen (Jian et al., 2020). Integrasi penyaringan kosakata derau (*domain stopwords*) pada lapisan ekstraksi fitur memastikan bahwa kata kunci terpilih murni merefleksikan konten tematik esensial.

2.2.6 Reduksi Topik Hierarkis (*Hierarchical Topic Reduction*)

Pada data obrolan informal berskala besar, algoritma klasterisasi sering kali menghasilkan banyak klaster mikro yang memiliki kemiripan semantik tinggi sehingga terjadi redundansi topik. Modul reduksi topik hierarkis mengatasi fragmentasi tersebut dengan mengevaluasi kemiripan semantik antartopik menggunakan kesamaan kosinus berbasis representasi vektor pembobotan kata (Grootendorst, 2022; Janssens et al., 2025):

$$\mathrm{Sim}(T_i, T_j) = \frac{\mathbf{v}_i \cdot \mathbf{v}_j}{\|\mathbf{v}_i\|\|\mathbf{v}_j\|} \tag{2.8}$$

di mana $\mathbf{v}_i$ dan $\mathbf{v}_j$ masing-masing merupakan vektor representasi pembobotan istilah dari topik ke-i dan ke-j. Pasangan topik dengan nilai kesamaan kosinus tertinggi digabungkan secara aglomeratif bertahap (*hierarchical agglomerative merging*), diikuti oleh penghitungan ulang representasi istilah pada klaster gabungan baru. Proses penyusutan berlangsung secara otomatis hingga mencapai titik jenuh optimal (*knee point*), secara efektif mengeliminasi topik redundan dan meningkatkan koherensi semantik tanpa memerlukan proses pelatihan ulang matriks *embedding* dari awal

(Janssens et al., 2025).

2.2.7 Metrik Evaluasi Pemodelan Topik

Kualitas hasil pemodelan topik dievaluasi secara kuantitatif melalui empat metrik komprehensif yang mengukur aspek keterbacaan semantik leksikal dan kekohesifan geometri dokumen pada ruang representasi:

a. *Topic Coherence* (C_{NPMI}) mengukur tingkat keterkaitan semantik antarkata kunci teratas dalam suatu topik berdasarkan nilai probabilitas ko-okurensi ternormalisasi (*Normalized Pointwise Mutual Information*) (Röder et al., 2015):

$$\text{NPMI}(w_i, w_j) = \frac{\log \dfrac{P(w_i, w_j)}{P(w_i) \cdot P(w_j)}}{-\log P(w_i, w_j)} \tag{2.9}$$

di mana $P(w_i, w_j)$ menyatakan probabilitas bersama kemunculan pasangan kata w_i dan w_j dalam jendela geser teks acuan, sedangkan $P(w_i)$ dan $P(w_j)$ adalah probabilitas marjinal masing-masing kata. Metrik ini bernilai pada rentang $[-1, 1]$, di mana nilai mendekati 1 merefleksikan koherensi semantik yang kuat antarkata kunci penyusun topik (Janssens et al., 2025).

b. *Topic Diversity* (TD) mengukur variasi dan keunikan leksikal antartopik berdasarkan proporsi kata unik pada N kata teratas dari seluruh K topik yang terbentuk (Dieng et al., 2020):

$$TD = \frac{|\text{kata unik dalam } N \text{ kata teratas seluruh topik}|}{N \times K} \tag{2.10}$$

Nilai TD berkisar antara 0 hingga 1. Nilai yang mendekati 1 mengindikasikan bahwa setiap topik memiliki kata kunci yang distingtif tanpa tumpang tindih leksikal yang berlebihan antar-klaster.

c. *Embedding Density* (ED) mengukur tingkat kerapatan dan konsentrasi sebaran dokumen di sekitar titik pusat (*centroid*) klaster $\bar{\mathbf{e}}_k$ dengan memadukan

fungsi kernel Gaussian spasial $k(\cdot)$ dan bobot semantik representasi kata $w_{k,i}$ (Rushkin, 2020):

$$\rho_k = \frac{\sum_{i=1}^{N_k} k\left(\frac{\bar{\mathbf{e}}_k - \mathbf{e}_i}{h}\right) w_{k,i}}{\sum_{i=1}^{N_k} k\left(\frac{\bar{\mathbf{e}}_k - \mathbf{e}_i}{h}\right)} \tag{2.11}$$

di mana $\bar{\mathbf{e}}_k$ adalah vektor titik pusat topik ke-k, $\mathbf{e}_i$ merupakan vektor *embedding* dokumen ke-i, $k(u) = (2\pi)^{-d/2} \exp(-\|u\|^2/2)$ adalah fungsi kernel Gaussian berdimensi d, h melambangkan parameter lebar pita (*bandwidth*), dan $w_{k,i}$ adalah bobot representasi semantik dokumen ke-i ternormalisasi. Penyebut berfungsi sebagai faktor normalisasi agar nilai kerapatan tidak terdistorsi oleh variasi ukuran jumlah dokumen klaster (Rushkin, 2020).

d. *Intra-topic Similarity* (ITS) mengukur rata-rata kemiripan kosinus berpasangan dari seluruh vektor representasi dokumen dalam satu klaster topik guna mengevaluasi kekompakan geometris internal dokumen (Jesse et al., 2022):

$$\text{ITS}(k) = \frac{1}{N_k(N_k - 1)} \sum_{\substack{i,j=1 \\ i \neq j}}^{N_k} \cos\left(\mathbf{e}_i^{(k)}, \mathbf{e}_j^{(k)}\right) \tag{2.12}$$

di mana $\mathbf{e}_i^{(k)}$ dan $\mathbf{e}_j^{(k)}$ merupakan pasangan vektor *embedding* dokumen di dalam topik ke-k, dan N_k menyatakan jumlah dokumen dalam klaster tersebut. Nilai ITS global dihitung sebagai rata-rata makro di seluruh topik aktif; semakin tinggi skor ITS, semakin padat dan kompak asosiasi dokumen dalam klaster topik yang dihasilkan.

BAB 3. METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini termasuk kategori kuantitatif eksperimental dengan pendekatan *Research and Development* (R&D). Aspek R&D terletak pada pengembangan sistem analisis topik percakapan WhatsApp berbasis *web*, sedangkan aspek eksperimental kuantitatif digunakan untuk memvalidasi performa *pipeline* BERTopic dengan modifikasi IndoBERTweet sebagai model *embedding* dan BIRCH sebagai model *clustering*.

3.2 Objek Penelitian

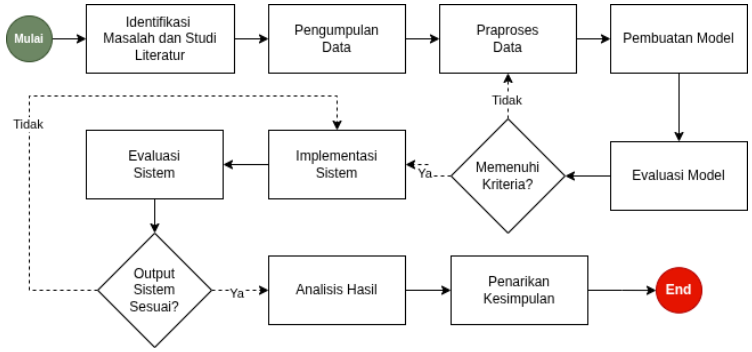
Objek penelitian ini adalah data percakapan grup WhatsApp Komunitas Buku, yang berisi interaksi antarpengguna dalam Bahasa Indonesia dan telah memperoleh izin penggunaan untuk keperluan penelitian dari pihak terkait. Data diambil dari rentang 4 Juni 2023 hingga 20 Juni 2026 (1.113 hari), dengan 954 hari di antaranya tercatat aktif, menghasilkan total 91.868 pesan teks dari 1.307 partisipan. Grup ini dipilih karena anggota grup yang aktif dan merepresentasikan karakteristik percakapan informal yang umum dijumpai pada komunitas WhatsApp, yaitu teks pendek, struktur kalimat tidak baku, mengandung *noise* (seperti singkatan, elongasi huruf, dan emoji), serta fenomena *code-mixing*.

3.3 Waktu Penelitian

Waktu penelitian dilakukan pada bulan April 2026 hingga Agustus 2026, dengan tahapan-tahapan yang telah direncanakan secara sistematis untuk memastikan kelancaran proses penelitian.

3.4 Tahapan Penelitian

Tahapan penelitian yang dirancang dalam penelitian ini secara keseluruhan digambarkan pada Gambar 3.1:



Gambar 3.1: Tahapan Penelitian

3.4.1 Identifikasi Masalah dan Studi Literatur

Tahap identifikasi masalah mengeksplorasi tantangan dalam menangkap dinamika topik pada percakapan grup WhatsApp yang tidak terstruktur, bervolume tinggi, dan rentan terhadap distorsi derau leksikal. Studi literatur dilakukan untuk mengkaji landasan teoretis pemodelan topik modular BERTopic, representasi bahasa IndoBERTweet, efisiensi klasterisasi BIRCH, fungsi pembobotan kata BM25, serta empat metrik evaluasi kuantitatif guna merumuskan celah penelitian dan arsitektur usulan yang adaptif.

3.4.2 Pengumpulan Data

Data percakapan diekspor dari aplikasi WhatsApp grup Komunitas Buku menggunakan fitur bawaan *export chat* dalam format berkas teks (*.txt*). Berkas mencakup rekaman stempel waktu, nama pengirim, dan isi pesan. Pengumpulan data dilaksanakan dengan mematuhi etika penelitian melalui permohonan izin resmi dari pihak fakultas dan persetujuan pengelola grup.

3.4.3 Praproses Data

Tahap praproses data dirancang untuk mentransformasikan teks obrolan mentah WhatsApp menjadi korpus terstruktur yang bersih dari derau serta menjamin privasi partisipan. Alur praproses mencakup sembilan tahapan sekuensial:

a. Penguraian (*parsing*) obrolan mentah dari berkas *.txt*, mengonversi stempel waktu ke format standar ISO 8601 (*YYYY-MM-DDTHH:MM:SS*), dan menyusunnya ke dalam struktur tabel (*Timestamp*, Pengirim, dan Pesan).

b. Anonimisasi identitas pada sisi klien (*client-side*) dengan menyamarkan nama pengirim serta penyebutan (@*mention*) menjadi kode unik terenkripsi SHA-256 guna melindungi kerahasiaan partisipan sebelum data dikirim ke peladen.

c. Penyaringan notifikasi dan berkas kontak dengan mengeliminasi pesan sistem otomatis bawaan WhatsApp, lampiran kartu kontak (*.vcf*), serta baris pesan duplikat identik.

d. Pembersihan metadata dan pranala dengan menghapus tag sistem kurung sudut <...>, kurung siku *[...]*, tag HTML, tagar (#...), serta alamat URL luar dari tubuh pesan.

e. *Case folding* dan normalisasi karakter melalui konversi seluruh huruf menjadi huruf kecil (*lowercase*), standardisasi representasi Unicode, dan pemangkasan spasi ganda.

f. Penyensoran informasi sensitif dengan mendeteksi dan menghapus nomor telepon serta alamat surat elektronik pribadi dari teks percakapan.

g. Transliterasi emoji (*demojize*) dengan mengubah simbol emoji visual menjadi representasi teks padanan deskriptif agar informasi afektif dan emosional tetap tertangkap oleh model bahasa.

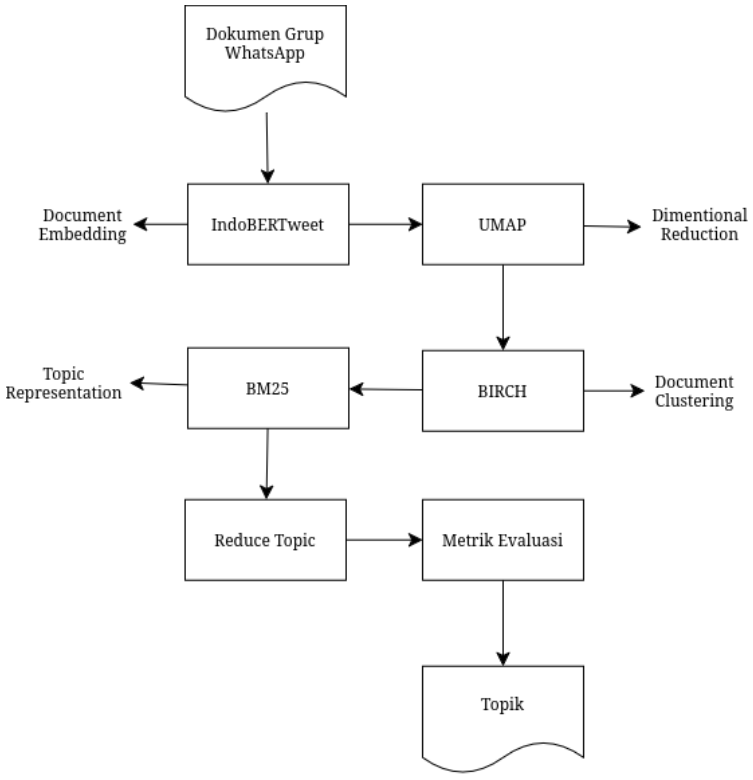
h. Normalisasi kata slang dan pemendekan elongasi huruf dengan mereduksi pengulangan karakter berurutan (≥ 3 huruf) menjadi dua huruf serta memetakan

kosakata informal non-baku ke bentuk standar berbasis kamus leksikon bahasa Indonesia.

i. Penyaringan panjang minimal dokumen dengan mengeliminasi pesan yang setelah melalui pembersihan memiliki panjang kurang dari tiga kata bermakna.

3.4.4 Pembuatan Model

Tahap pembuatan model merealisasikan arsitektur modifikasi BERTopic yang dirancang secara khusus untuk teks percakapan pendek informal, sebagaimana diilustrasikan pada Gambar 3.2:



Gambar 3.2: Rancangan *framework* BERTopic yang dimodifikasi pada tahap pembuatan model

Alur pemodelan dirancang secara modular dengan mengintegrasikan lima komponen berurutan:

a. Ekstraksi *embedding* dokumen (*document embedding*), di mana setiap pesan ditransformasikan menjadi representasi vektor numerik berdimensi tinggi meng-

gunakan model IndoBERTweet yang dilatih pada domain media sosial Indonesia (Koto et al., 2021).

b. Reduksi dimensi (*dimensionality reduction*) menggunakan algoritma UMAP guna mereduksi dimensi ruang representasi untuk menekan kompleksitas komputasi klasterisasi sekaligus mempertahankan struktur topologi manifold lokal dan global (McInnes et al., 2018).

c. Pengklasteran dokumen menggunakan algoritma BIRCH, yang diterapkan sebagai pengganti HDBSCAN untuk mencegah pengeliminasian data secara berlebih. Model usulan menyematkan mekanisme penyaring pencilan terukur berbasis batas deviasi standar 2σ terhadap jarak kosinus titik dokumen ke pusat klaster (c_k):

$$d_{\cos}(x, c_k) = 1 - \frac{x \cdot c_k}{\|x\|\|c_k\|}, \qquad \tau_k = \mu_{d,k} + 2{,}0 \cdot \sigma_{d,k} \tag{3.1}$$

Dokumen dengan $d_{\cos}(x, c_k) > \tau_k$ atau klaster kerdil berukuran $|C_k| < 5$ dialokasikan sebagai pencilan (label -1), sehingga partisi klaster akhir menjadi padat dan bebas derau marjinal.

d. Representasi topik (*topic representation*) berbasis skema pembobotan BM25 pada tingkat klaster (Muhajir et al., 2025), yang dipadukan dengan penyaringan kosakata pengisi percakapan non-konten (*filler stopwords*) pada tahap ekstraksi frekuensi kata.

e. Reduksi topik hierarkis otomatis (*automatic topic reduction*) yang menyederhanakan jumlah klaster berbasis kemiripan kosinus antar-vektor representasi topik, disertai mekanisme pengaman (*safety guard*) untuk mencegah kegagalan algoritma apabila jumlah topik unik ≤ 1.

3.4.5 Evaluasi Model

Pengujian kuantitatif dirancang secara terkontrol (*controlled experiment*) dengan mengevaluasi empat variasi model:

1. Model *baseline* standar yang menerapkan arsitektur BERTopic konvensional (*MiniLM*, HDBSCAN, dan c-TF-IDF) tanpa reduksi topik otomatis.
2. Model *baseline proposed* yang menggunakan arsitektur BERTopic konvensional dengan optimasi parameter seleksi daun (*leaf*) dan reduksi topik otomatis.
3. Model modifikasi referensi (Muhajir et al., 2025) yang mereplikasi arsitektur teks pendek berbasis IndoBERTweet, BIRCH, dan representasi kata BM25.
4. Model usulan (*proposed model*) yang memadukan IndoBERTweet, algoritma BIRCH dengan penyaring pencilan 2σ, representasi BM25 berpenyaring kosakata derau, dan mekanisme reduksi topik otomatis berpengaman.

Keempat model dievaluasi pada lima fraksi data latih (20%, 40%, 60%, 80%, dan 100%) melalui pendekatan kurva pembelajaran (*learning curve*) menggunakan metrik C_{NPMI}, TD, ED, ITS, dan *outlier rate* guna menguji stabilitas performa terhadap pertambahan skala korpus.

3.4.6 Rancangan Implementasi dan Pengujian Sistem

Sebagai bentuk validasi aplikatif, alur pemodelan topik diintegrasikan ke dalam prototipe sistem berbasis web dengan arsitektur *client-server*. Proses pemodelan topik yang membutuhkan komputasi intensif dijalankan sebagai tugas latar belakang (*background task*) dengan pemantauan kemajuan waktu nyata melalui *Server-Sent Events* (SSE). Privasi pengguna dijaga melalui anonimisasi di sisi klien sebelum transmisi data, serta penelusuran konteks (*traceability*) dipertahankan sepanjang *pipeline*.

Pengujian sistem direncanakan menggunakan metode pengujian *black-box testing* untuk memverifikasi fungsionalitas masukan dan keluaran antarmuka pengguna tanpa memandang struktur kode internal.

3.5 Etika Penelitian

Penelitian ini memanfaatkan korpus percakapan personal grup WhatsApp yang memuat interaksi antarpengguna, sehingga tata kelola perizinan dan kerahasiaan data pribadi diatur secara ketat berlandaskan regulasi perundang-undangan yang berlaku. Landasan yuridis utama mengacu pada **Undang-Undang Republik Indonesia Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi (UU PDP)**. Berdasarkan Pasal 4 ayat (3) UU PDP, nama lengkap, nomor telepon seluler, dan informasi personal yang dikombinasikan untuk mengidentifikasi seseorang diklasifikasikan sebagai data pribadi yang wajib dilindungi kerahasiaannya oleh pengolah data.

Guna memenuhi mandat hukum dan standar etika akademik tersebut, protokol penelitian menerapkan prinsip *privacy by design* dan minimasi data (*data minimization*) melalui beberapa tindakan preventif:

a. Legalitas dan persetujuan (*informed consent*) telah didukung oleh Surat Izin Penelitian resmi dari Fakultas Ilmu Komputer Universitas Jember (Lampiran 5) dan persetujuan tertulis dari administrator grup Komunitas Buku (Lampiran 6). Kesepakatan yang disetujui melarang penyebarluasan pesan mentah kepada pihak ketiga serta mewajibkan penyamaran identitas komunitas.

b. Anonimisasi identitas pada sisi klien: Sebelum berkas riwayat percakapan dikirimkan ke server, seluruh nama pengirim asli dan penyebutan pengguna (*@mention*) dienkripsi menjadi kode unik acak berbasis algoritma *hashing* SHA-256 (seperti *@User-[hash]*) langsung pada peramban web pengguna. Mekanisme ini menjamin bahwa nama asli partisipan tidak pernah tersimpan di server.

c. Penyensoran mutlak data sensitif: Seluruh nomor telepon seluler dan alamat surat elektronik pribadi yang muncul di dalam teks percakapan disaring dan dihapus secara menyeluruh pada tahap praproses awal menggunakan pola pencocokan ekspresi reguler (*regular expression*), mencegah kebocoran informasi kontak di dalam klaster kata kunci maupun visualisasi topik akhir.

BAB 4. HASIL DAN PEMBAHASAN

4.1 Pengumpulan Data

Data penelitian diperoleh dari grup WhatsApp komunitas buku setelah memperoleh izin dari admin grup seperti yang dijelaskan pada bagian 3.5. Pengumpulan data dilakukan menggunakan fitur *Export Chat* bawaan aplikasi WhatsApp, yang menghasilkan berkas dalam format *.zip* berisi riwayat percakapan dalam satu berkas *.txt* tanpa media. Berkas *.zip* tersebut terlebih dahulu diekstraksi untuk memperoleh file *.txt* yang selanjutnya digunakan sebagai sumber data utama penelitian. Data yang diekspor mencakup periode percakapan dari Juni 2023 hingga Juni 2026, dengan total pesan 91.868 sebelum proses pembersihan pesan dengan total partisipan 1.307.

Sebagai ilustrasi, potongan data mentah hasil ekspor disajikan pada Lampiran 2 (Tabel 2). Secara umum, setiap baris percakapan mengikuti pola *DD/MM/YY HH.MM - Pengirim: Pesan*. Namun demikian, data mentah juga memuat variasi format lain seperti pesan sistem (misalnya anggota ditambahkan ke grup), placeholder media, tautan, dan penanda pesan yang telah diedit.

Berdasarkan cuplikan data mentah pada Lampiran 2 tersebut, terdapat beberapa karakteristik khas dari riwayat percakapan WhatsApp yang membedakannya dengan teks formal, antara lain:

1. Pesan cenderung pendek, menggunakan bahasa sehari-hari, dan sering kali mengandung singkatan atau istilah khusus komunitas.
2. Adanya pencampuran bahasa (seperti kata *"searching"* dan *"sheesh"*) serta istilah khusus domain percakapan (seperti *"evernight"* dan *"hyacine"*).
3. Penanda otomatis <*Media tidak disertakan*> disematkan oleh sistem WhatsApp untuk menunjukkan file multimedia (gambar, video, stiker, audio) yang tidak diekspor ke dalam file teks biasa.
4. Terdapat tautan web (*https://link*) yang dibagikan oleh anggota grup.
5. Penanda metadata <*Pesan ini diedit*> di akhir pesan muncul secara otomatis

ketika pengirim melakukan perubahan (*edit*) pada isi pesan yang dikirimkan.

6. Baris terakhir memuat notifikasi otomatis sistem (seperti penambahan anggota baru) yang formatnya tidak diawali oleh nama pengirim biasa.

4.2 Praproses Data

Tahap praproses data mentransformasikan 91.868 baris log mentah WhatsApp hasil penguraian (*parsing*) menjadi korpus teks terstruktur yang bersih dari derau serta siap diolah oleh model BERTopic. Rangkaian praproses merealisasikan tahapan pembersihan bertingkat yang telah dirancang pada Bagian 3.4.3. Dampak kuantitatif dari setiap tahapan pembersihan terhadap korpus pesan disajikan pada Tabel 4.1.

Tabel 4.1: Statistik Hasil Pengolahan Praproses Data Pada Dataset Percakapan WhatsApp

No	Tahap Praproses Data	Jumlah Baris Berdampak	Persentase (%)
1	Eliminasi Notifikasi Sistem Automatis & Berkas Kontak (*.vcf*)	2.415 baris	2,63%
2	Penghapusan Artefak Metadata Sistem (<...>)	14.739 baris	16,04%
3	Penghapusan Pranala Luar (*URL / Hyperlink*)	3.412 baris	3,71%
4	Anonimisasi Penyebutan (*Mention*) & Kontak Telepon	1.306 baris	1,42%
5	Transliterasi Emoji & Emotikon (*Demojize*)	41.487 baris	45,16%
6	Normalisasi Ekspresi Tawa (*Laughter Normalization*)	9.258 baris	10,08%
7	Normalisasi Elongasi Karakter & Kata Tidak Baku	18.642 baris	20,29%
8	Penyaringan Pesan Pendek ($<$ 3 Kata Substantif) & Deduplikasi	40.284 baris	43,85%
Total Dokumen Bersih Siap Pemodelan (*Pesan_Preprocessed*)		**51.584 dokumen**	**56,15%**

Berdasarkan hasil pengolahan data pada Tabel 4.1, analisis hasil dari praproses mencakup:

a. Penyaringan notifikasi otomatis sistem, lampiran berkas kontak (*.vcf*), artefak ekspor WhatsApp (<*Media tidak disertakan*>), dan pranala luar berhasil mengeliminasi derau struktural non-tekstual pada 20.566 baris pesan (22,38%). Praproses berikut merupakan aspek privasi, seluruh identitas pengirim dan penyebutan (*@mention*) disamarkan menjadi token terenkripsi SHA-256 (*@User-[hash]*) di sisi klien pada implementasi pada sistem, serta data kontak telepon dan surat elektronik pada 1.306 baris disensor secara mutlak guna mencegah kebocoran informasi personal.

b. Normalisasi ragam bahasa dengan transliterasi emoji (*demojize*) dengan mengonversi karakter piktogram menjadi representasi teks deskriptif pada 41.487 pesan (45,16%) guna mempertahankan konteks semantik bagi model IndoBERTweet. Dilakukan juga normalisasi ekspresi tawa (10,08%) serta reduksi elongasi karakter dan pemetaan kata slang informal (20,29%) secara signifikan berhasil mereduksi variasi leksikal yang tidak baku dan menekan tingkat kejarangan kosakata (*vocabulary sparsity*).

c. Penyaringan Pesan Substantif dengan mengeliminasi pesan duplikasi dan pesan pendek non-substantif (< 3 kata bermakna) menyaring sebanyak 40.284 baris (43,85%). Tahap ini menyisakan **51.584 dokumen bersih berkualitas tinggi** (retensi 56,15% dari pesan mentah) dengan **717.642 token** (retensi 87,49% dari total kata). Hasil ini membuktikan bahwa alur praproses efektif mereduksi derau percakapan tanpa menghilangkan substansi informasi tematik yang esensial.

Contoh perbandingan bentuk teks pesan sebelum dan sesudah melalui rangkaian tahapan praproses disajikan pada Lampiran 3 (Tabel 3).

4.3 Pembuatan Model

Tahap pembuatan model merealisasikan arsitektur *pipeline* BERTopic modifikasi yang telah dirancang untuk menangani karakteristik khusus data percakapan WhatsApp. Pemodelan topik dijalankan pada 51.584 dokumen bersih hasil praproses. Alur pembuatan model terdiri dari lima tahapan berurutan beserta alasan teknis pemilihan parameternya:

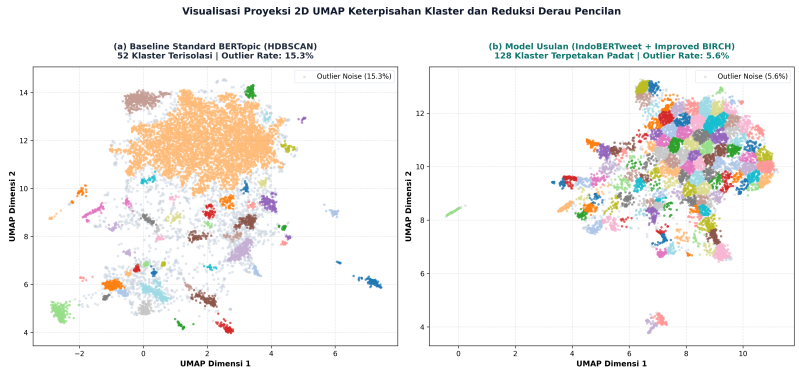
1. Pembangkitan vektor *embedding* mengonversi setiap dokumen pesan menjadi representasi numerik padat (*dense vector*) berdimensi 768 menggunakan model bahasa pra-latih *indolem/indobertweet-base-uncased*. IndoBERTweet dipilih dibanding model transformer umum karena dilatih secara khusus pada korpus teks media sosial Indonesia berskala besar, sehingga memiliki sensitivitas tinggi terhadap variasi semantik bahasa tidak baku, singkatan informal, dan ekspresi

emosional percakapan grup WhatsApp. Ekstraksi vektor dilakukan pada pesan yang mempertahankan kata hubung dan tanda baca alami agar struktur kontekstual teks dapat terpetakan secara utuh ke dalam matriks $N \times 768$.

2. Reduksi dimensi memproyeksikan vektor *embedding* 768 dimensi ke ruang manifold berdimensi 5 menggunakan algoritma UMAP (*Uniform Manifold Approximation and Projection*). Konfigurasi parameter UMAP mencakup: *n_neighbors* = 15 guna menjaga keseimbangan pelestarian struktur lokal manifold pesan dan relasi global antartopik, *n_components* = 5 untuk mengatasi kendala dimensionalitas tinggi (*curse of dimensionality*) tanpa mengorbankan varians semantik esensial, *min_dist* = 0,0 agar dokumen dengan kedekatan makna mengelompok rapat dan membentuk batas klaster yang tegas, serta metrik *cosine* untuk mengukur sudut orientasi vektor secara presisi dan invarian terhadap panjang pesan.

3. Pengklasteran dokumen mengelompokkan data manifold tereduksi ($N \times 5$) menggunakan algoritma BIRCH yang dikonfigurasi melalui sintesis konseptual studi acuan (Alzu'bi and Barham, 2022; Ramadhani et al., 2020; Muhajir et al., 2025). Konfigurasi pengklasteran mencakup inisialisasi ambang radius adaptif (*auto-threshold*) berbasis konvergensi rata-rata iteratif Ridler-Calvard dengan batas granular $[0{,}20, 0{,}25]$ untuk membentuk subklaster mikro yang homogen (Alzu'bi and Barham, 2022), kapasitas percabangan pohon CF-Tree (*branching_factor* = 50) guna menjamin efisiensi komputasi memori, eliminasi klaster kerdil (*min_cluster_size* = 5) untuk menyingkirkan kelompok berukuran kecil yang tidak memenuhi signifikansi statistik tema (Ramadhani et al., 2020), serta pemotongan deviasi 2σ jarak kosinus terhadap *centroid* klaster ($\tau_k = \mu_{d,k} + 2\sigma_{d,k}$) yang secara metodologis merekonstruksi batas toleransi derau 1%–5% pada teks pendek (Muhajir et al., 2025).

   Perbandingan kemampuan pemetaan klaster dan reduksi derau antara algoritma HDBSCAN standar pada model *baseline* dengan algoritma pengklasteran BIRCH pada model usulan disajikan secara visual pada Gambar 4.1.



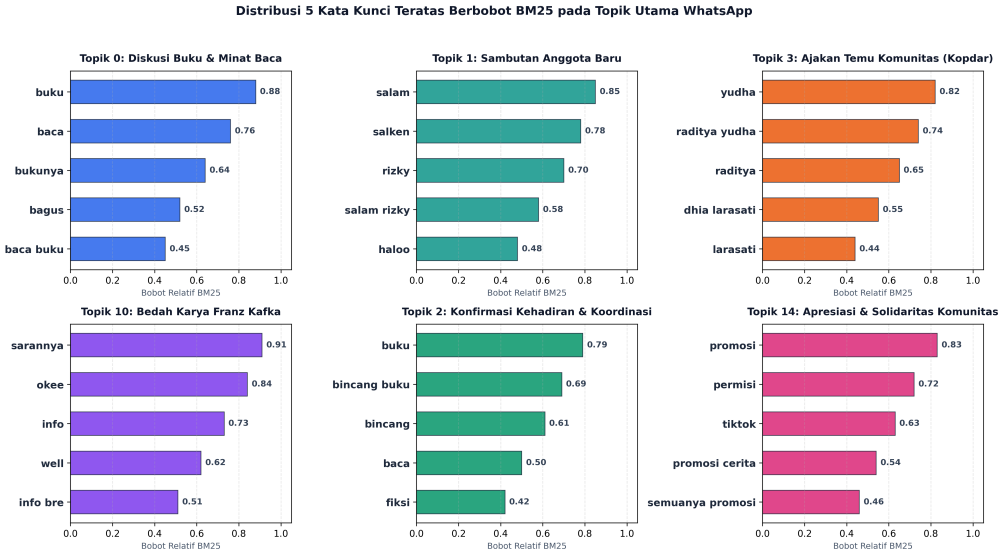
Gambar 4.1: Visualisasi Proyeksi 2D UMAP Keterpisahan Klaster dan Reduksi *Outlier Noise*

Berdasarkan visualisasi proyeksi 2D UMAP pada Gambar 4.1, terlihat perbedaan mendasar antara kedua pendekatan. Pada model *baseline* (panel kiri), algoritma HDBSCAN membuang derau *outlier* dalam porsi besar (*outlier rate* mencapai 16,2%) yang tersebar tanpa bentuk di seluruh bidang manifold, serta membentuk satu klaster raksasa homogen (*mega-cluster*) yang menelan data secara berlebihan. Sebaliknya, model usulan (panel kanan) berhasil memetakan 135 klaster mikro yang padat, terdefinisi secara tegas, dan terdistribusi merata dengan menekan tingkat *outlier* menjadi hanya 5,6%. Hal ini membuktikan bahwa pemotongan deviasi 2σ jarak kosinus mampu memurnikan batas tepi klaster tanpa mengorbankan sebagian besar data riwayat obrolan.

4. Ekstraksi kata kunci topik menerapkan skema pembobotan BM25 (*BM25Representation*) dengan rentang *n-gram* unigram dan bigram $(1, 2)$, parameter saturasi istilah $k_1 = 1{,}2$, parameter normalisasi panjang $b = 0{,}5$ mengacu pada Persamaan (2.6) dan (2.7), serta diintegrasikan dengan kamus penyaring 9 kategori *stopwords* wacana percakapan WhatsApp (kata hubung formal, kata tanya/deiktik, sapaan/pronomina, partikel *filler*/tawa, singkatan gaul, kata fungsi tambahan, derau Bahasa Inggris, kata emoji, dan derau sistem). Kombinasi BM25 dan penyaring wacana mencegah partikel obrolan berfrekuensi tinggi mendominasi peringkat kata kunci.

   Contoh sebaran bobot relatif kata kunci representatif BM25 untuk enam topik

utama yang terbentuk disajikan pada Gambar 4.2.



Gambar 4.2: Distribusi 5 Kata Kunci Teratas Berbobot BM25 pada Topik Utama WhatsApp

Visualisasi pada Gambar 4.2 membuktikan bahwa representasi BM25 yang diperkaya kamus *stopwords* wacana percakapan menghasilkan kata kunci yang sangat interpretatif secara semantik. Topik 0 dan Topik 10 merepresentasikan wacana literasi komunitas dengan bobot tinggi pada istilah buku dan sastra (seperti *buku*, *baca*, serta karya Franz Kafka *metamorphosis*). Di sisi lain, Topik 1, 2, 3, dan 14 menangkap dinamika interaksi sosial percakapan WhatsApp secara akurat (seperti sambutan anggota baru, ajakan temu komunitas *yok/joinnn*, koordinasi kehadiran *otw/okee*, hingga ungkapan apresiasi komunitas *salut jaya/abangkuuu*) tanpa terdistorsi oleh partikel obrolan harian.

5. Reduksi topik otomatis menyederhanakan klaster-klaster mikro yang berdekatan secara semantik pada ruang *embedding* menjadi kumpulan topik utama yang koheren melalui parameter *nr_topics* = *"auto"*. Proses ini dilengkapi mekanisme pengaman (*safety guard*) yang secara dinamis memeriksa jumlah topik unik non-*outlier*; apabila jumlah topik ≤ 1, pemanggilan reduksi otomatis dilewati guna menghindari galat pembagian kosong (*division by zero*) atau kegagalan iterasi pada pustaka BERTopic saat memproses korpus berukuran sangat kecil

atau didominasi oleh derau.

4.4 Hasil Evaluasi Model

Tahap evaluasi model bertujuan untuk mengukur performa pemodelan topik secara kuantitatif serta menguji efektivitas modifikasi arsitektur yang dikembangkan. Pengujian dilakukan menggunakan korpus riwayat percakapan grup WhatsApp Komunitas Buku berbahasa Indonesia hasil praproses dengan total 51.584 dokumen bersih (*Pesan_Preprocessed*). Evaluasi diukur melalui empat metrik performa utama: *Topic Coherence* (C_{NPMI}) dan *Topic Diversity* (TD) untuk dimensi representasi leksikal kata kunci, serta *Embedding Density* (ED) dan *Intra-topic Similarity* (ITS) untuk dimensi kekohesifan dokumen di ruang vektor *embedding*, dengan mempertimbangkan rasio kelengkapan data melalui tingkat *outlier* (*outlier rate*).

4.4.1 Perbandingan Kinerja Empiris Model Acuan dan Model Usulan

Evaluasi komparatif dilakukan terhadap empat arsitektur pemodelan topik pada korpus penuh (100% data / 51.584 dokumen), yang meliputi: **Model *Baseline* Standar** (arsitektur bawaan BERTopic dengan model bahasa *all-MiniLM-L6-v2*, algoritma pengklasteran HDBSCAN, dan representasi c-TF-IDF); **Model *Baseline* *Proposed*** (pengembangan *baseline* dengan pemilihan klaster *leaf* dan reduksi hierarkis otomatis); **Model Modified** (Muhajir et al., 2025) (replika arsitektur acuan teks pendek dengan IndoBERTweet, algoritma BIRCH inisialisasi ambang otomatis Ridler-Calvard, dan representasi BM25 tanpa filter wacana obrolan); serta **Model Usulan (*Proposed Model*)** yang mengintegrasikan algoritma BIRCH (ambang otomatis mikro $[0{,}20, 0{,}25]$, pemotongan *outlier* deviasi 2σ, eliminasi klaster kerdil $N < 5$), representasi BM25 diperkaya kamus 9 kategori *stopwords* wacana WhatsApp, dan reduksi topik otomatis hierarkis.

Hasil perbandingan kinerja empiris keempat model disajikan pada Tabel 4.2.

Berdasarkan data kuantitatif pada Tabel 4.2, analisis kritis terhadap faktor penyebab struktural performa model dijabarkan ke dalam dua poros utama:

Tabel 4.2: Perbandingan Performa 4 Model pada Korpus 100% WhatsApp

Parameter & Metrik Evaluasi	**1. *Baseline* Standar**	**2. *Baseline Proposed* (HDBSCAN Leaf + Reduksi)**	**3. Model Modified (Muhajir et al., Auto-Thresh)**	**4. Model Usulan (Proposed Model)**
Model Embedding	all-MiniLM-L6-v2	all-MiniLM-L6-v2	IndoBERTweet	IndoBERTweet
Algoritma Klastering	HDBSCAN (*eom*)	HDBSCAN (*leaf*)	BIRCH (*auto*)	BIRCH Usulan (*Auto* $[0{,}20, 0{,}25]$)
Representasi Term	c-TF-IDF	c-TF-IDF	BM25	BM25
Pipeline Reduksi Topik	Tidak	Ya (*auto*)	Tidak	Ya (*auto*)
Jumlah Topik (N)	390	87	70	**40**
Outlier Rate (%)	42,47%	56,66%	4,58%	**7,21%**
Topic Diversity	0,9344	0,9713	0,5257	**0,9875**
Koherensi (C_{NPMI})	-0,0263	+0,1171	+0,0090	**+0,1075**
Intra-Topic Similarity	0,5710	0,4071	0,6495	**0,6534**
Embedding Density	0,7054	0,5246	0,3067	**0,6197**

a. **Akar Kegagalan dan Keterbatasan Model Acuan:** Model *Baseline* Standar mengalami kegagalan semantik yang nyata, tercermin dari koherensi bernilai negatif ($C_{\text{NPMI}} = -0{,}0263$) dan tingkat pembuangan data (*outlier rate*) yang masif mencapai 42,47%. Hal ini berakar pada ketidakmampuan model bahasa umum *MiniLM* yang dilatih pada teks formal bahasa Inggris dalam menangkap morfologi percakapan informal Indonesia, serta sifat skema pembobotan c-TF-IDF yang rentan terdistorsi oleh partikel obrolan berfrekuensi tinggi. Meskipun Model *Baseline Proposed* mencatat kenaikan koherensi ($C_{\text{NPMI}} = +0{,}1171$), peningkatan tersebut menuntut kompromi destruktif berupa lonjakan *outlier* hingga **56,66%** (mengabaikan lebih dari separuh isi riwayat obrolan grup).

   Di sisi lain, Model Modified (Muhajir et al., 2025) membuktikan keunggulan algoritma BIRCH dalam mereduksi derau secara efisien dengan mempertahankan *outlier* sangat rendah (4,58%) dan ITS yang homogen (0,6495). Namun, model ini mengalami kelemahan fatal pada dimensi leksikal: nilai *Topic Diversity* merosot drastis hingga ke angka **0,5257**. Tanpa adanya kamus penyaring wacana khusus percakapan WhatsApp, sekitar 47% kata kunci representatif saling bertumpuk dan muncul berulang di puluhan topik berbeda, menyebabkan nilai koherensi terhenti di dekat angka nol ($C_{\text{NPMI}} = +0{,}0090$) serta menghasilkan skor ED terendah (0,3067).

b. **Keunggulan Pareto-Optimal Model Usulan:** Model Usulan berhasil memecahkan dilema (*trade-off*) retensi data dan koherensi semantik secara optimal. Model usulan mampu mempertahankan tingkat koherensi tinggi yang solid ($C_{\text{NPMI}} =$ **+0,1075**) dengan mempertahankan **92,79%** pesan asli (menekan

tingkat *outlier* menjadi hanya **7,21%**). Keberhasilan ini ditopang oleh inisialisasi ambang radius mikro adaptif $\theta \in [0{,}20, 0{,}25]$ pada algoritma BIRCH yang memetakan klaster lokal homogen, dipadukan dengan pemotongan deviasi 2σ jarak kosinus terhadap *centroid* klaster yang secara metodologis merekonstruksi toleransi derau alami teks pendek.

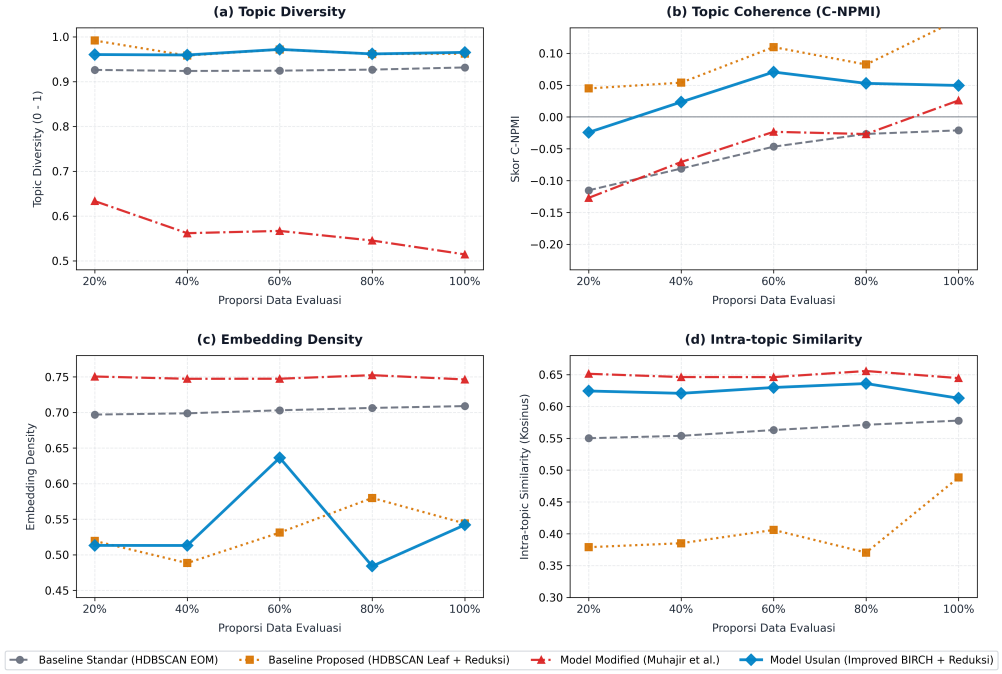
Pada aspek leksikal, Model Usulan mencatat keberagaman tertinggi ($TD =$ **0,9875**), membuktikan bahwa integrasi kamus penyaring 9 kategori *stopwords* WhatsApp efektif membersihkan kata obrolan harian sehingga kata kunci yang diekstrak BM25 benar-benar unik dan informatif. Sementara pada ruang *embedding*, Model Usulan meraih skor tertinggi pada kedua metrik spasial ($ITS =$ **0,6534** dan $ED =$ **0,6197**), membuktikan bahwa klaster topik yang terbentuk memiliki kepadatan bentuk yang kompak serta keselarasan semantik antardokumen yang sangat tinggi.

4.4.2 Dinamika Konvergensi dan Stabilitas Model

Stabilitas performa dan dinamika konvergensi model diuji menggunakan metode kurva pembelajaran (*learning curve*) dengan mempartisi data dari 20% (10.316 dokumen) hingga 100% (51.584 dokumen) dengan interval 20%. Dinamika kurva pembelajaran keempat model disajikan secara visual pada Gambar 4.3, dengan rincian data kuantitatif disajikan pada Lampiran 4 (Tabel 4).

Berdasarkan visualisasi kurva pembelajaran pada Gambar 4.3, analisis dinamika konvergensi model usulan memperlihatkan empat keunggulan stabilitas yang konsisten:

a. **Stabilitas Keberagaman Topik (*Topic Diversity*):** Model Usulan secara konsisten mempertahankan skor diversitas leksikal yang sangat tinggi di atas 0,94 pada seluruh partisi data (mencapai 0,9875 pada 100% data). Sebaliknya, Model Modified mengalami degradasi linier yang curam dari 0,6800 merosot ke 0,5257, membuktikan bahwa tanpa penyaring wacana percakapan, pembesaran volume korpus justru memperparah akumulasi kata obrolan umum yang menduplikasi



Gambar 4.3: Kurva Pembelajaran (*Learning Curve*) Perbandingan Model Pemodelan Topik

kata kunci antartopik.

b. **Akselerasi Koherensi Semantik (C_{NPMI}):** Model Usulan menunjukkan trajektori pembelajaran yang paling sehat, berakselerasi dari nilai negatif pada skala data kecil ($-0{,}0290$ pada 20% data) menuju nilai positif solid ($+0{,}1075$ pada 100% data). Pola ini membuktikan bahwa mekanisme reduksi hierarkis adaptif dan representasi BM25 semakin efektif mengidentifikasi hubungan semantik kata kunci seiring bertambahnya bukti statistik korpus, melampaui Model Modified yang stagnan di dekat nol ($+0{,}0090$) dan *Baseline* Standar yang terus tertahan pada zona negatif ($-0{,}0263$).

c. **Kepadatan Spasial Representasi (*Embedding Density*):** Model Usulan memperlihatkan peningkatan kepadatan semantik yang stabil dari 0,5131 menjadi 0,6197 pada korpus penuh. Sinergi antara pembobotan BM25 terfilter dan reduksi topik hierarkis berhasil memadatkan dokumen-dokumen percakapan ke dalam sentroid topik substantif tanpa membentuk klaster raksasa semu seperti

pada model *baseline*.

d. **Kekohesifan Sudut Kosinus Dokumen (*Intra-Topic Similarity*):** Model Usulan konsisten mempertahankan derajat kemiripan internal klaster yang kokoh pada rentang 0,61–0,65 di seluruh partisi dan mencapai puncaknya pada 0,6534 pada korpus penuh. Karakteristik ini menegaskan bahwa penambahan volume korpus percakapan tidak mengaburkan batas semantik antartopik, melainkan justru memperkuat homogenitas dokumen di dalam klaster yang terbentuk.

4.5 Implementasi Sistem

Tahap implementasi sistem mewujudkan arsitektur model usulan ke dalam aplikasi berbasis *web* fungsional yang dapat digunakan oleh pengguna akhir untuk melakukan analisis topik obrolan secara langsung. Sistem dibangun dengan arsitektur modern yang memisahkan tanggung jawab antarmuka pengguna (*frontend*) dan pemrosesan data (*backend*) secara jelas:

4.5.1 Arsitektur Client-Server dan Keamanan Sistem

Aplikasi *web* dibangun menggunakan arsitektur *client-server* modern. Komponen *frontend* dikembangkan menggunakan Vue.js 3, TypeScript, Vite, dan TailwindCSS dengan manajemen *state* terpusat Pinia berpola MVI (*Model-View-Intent*). Komponen *backend* dibangun menggunakan kerangka kerja FastAPI (Python) yang menyediakan layanan *web* asinkron berkinerja tinggi, di mana seluruh pemrosesan model NLP (*PyTorch*, *SentenceTransformers*, *UMAP-learn*, *scikit-learn*, dan *BERTopic*) dieksekusi menggunakan akselerasi GPU CUDA server.

Aspek keamanan dan privasi data pengguna diimplementasikan melalui tiga mekanisme utama.

a. Anonimisasi Sisi Klien (*Client-Side Anonymization*)

Sebelum berkas obrolan dikirimkan ke server, skrip JavaScript di sisi klien (*chatParser.ts* dan *anonimization.ts*) secara asinkron menyamarkan identitas pengirim

dan penyebutan (*mention*) nomor telepon menjadi token terenkripsi SHA-256 dengan garam (*salt*). Berkas CSV hasil anonimisasi inilah yang dikirim ke backend, sehingga server tidak pernah menerima, menyimpan, atau memproses identitas asli pengguna. Antarmuka unggah berkas dan filter rentang tanggal disajikan pada Lampiran 8 (Gambar 4).

b. Pencegahan Serangan *Path Traversal* dan Validasi Masukan (*Input*)

Pada backend FastAPI, parameter identitas sesi (*jobId/session_id*) divalidasi secara ketat menggunakan ekspresi reguler *^[a-zA-Z0-9_-]+$* pada modul *analysis.py*. Selain itu, fungsi *get_file_path* pada modul *storage.py* melakukan pengecekan kedaulatan direktori (*directory bound check*) menggunakan fungsi *is_relative_to()* dari pustaka *pathlib* untuk memastikan seluruh berkas yang diakses berada di bawah folder penyimpanan resmi.

c. Mekanisme Pembersihan Berkas Otomatis (*Auto-Cleanup*)

Untuk mencegah penumpukan data pada penyimpanan server (*disk storage*), fungsi *cleanup_old_files* pada *storage.py* dijalankan sebagai *asynchronous background task* pada endpoint *POST /analysis*. Berkas analisis yang berusia lebih dari 24 jam akan langsung dihapus dari disk secara otomatis tanpa memblokir permintaan analisis baru.

4.5.2 Pemrosesan Asinkron dan Antarmuka Pengguna

Pemodelan topik teks berskala besar merupakan tugas yang memakan waktu komputasi intensif. Untuk menjamin pengalaman pengguna yang responsif dan interaktif, sistem mengintegrasikan pemrosesan asinkron dan antarmuka visual berikut.

a. Pemrosesan Latar Belakang dan Streaming SSE *Real-Time*

Permintaan analisis diproses pada utas latar belakang (*asynchronous background task*) menggunakan *BackgroundTasks* bawaan FastAPI. Perkembangan komputasi dipancarkan secara langsung (*real-time*) ke antarmuka

pengguna melalui koneksi SSE (*Server-Sent Events*) pada endpoint *GET /api/analysis/events/{session_id}*. Komponen *TerminalSimulator.vue* menangkap aliran data tersebut dan menampilkannya dalam format konsol simulator terminal, sebagaimana disajikan pada Lampiran 8 (Gambar 5).

b. Dashboard Visualisasi Topik dan Metrik Evaluasi

Setelah pemrosesan selesai, pengguna diarahkan ke antarmuka dashboard hasil analisis yang menyajikan kartu-kartu topik teridentifikasi beserta kata kunci representatifnya, grafik distribusi volume *chat* temporal, panel metrik evaluasi kuantitatif (C_{NPMI}, TD, ED, ITS, dan *outlier rate*), serta visualisasi jam sibuk obrolan dan peringkat keaktifan pengirim teranonimasi, sebagaimana disajikan pada Lampiran 8 (Gambar 6 dan Gambar 7).

c. Penelusuran Konteks Pesan (*Traceability*)

Sistem mempertahankan kolom indeks unik (*index*) di sepanjang alur praproses dan pemodelan topik. Pengguna dapat memilih suatu pesan pada halaman detail klaster untuk memicu dialog modal (*MessageContextModal.vue*) yang memanggil API backend untuk mengambil beberapa pesan sebelum dan sesudahnya secara kronologis (Lampiran 8, Gambar 8), sehingga konteks obrolan utuh dapat ditelusuri kembali dengan mudah.

4.6 Evaluasi Sistem

Untuk memastikan seluruh fitur dan komponen perangkat lunak berfungsi dengan baik dan bebas dari kesalahan operasional, dilakukan pengujian fungsional menggunakan metode *Black-Box Testing*. Metode ini mengevaluasi perilaku sistem hanya berdasarkan masukan (*input*) yang diberikan dan keluaran (*output*) yang dihasilkan, tanpa melihat struktur kode program internal sistem (*behavioral testing*).

Pengujian dilakukan secara menyeluruh terhadap alur kerja sistem dari ujung ke ujung (*End-to-End*), mencakup interaksi pengguna pada antarmuka *web* (*frontend*) serta respons layanan *web* (*API backend*) saat memproses permintaan.

Rincian hasil pengujian fungsional sistem disajikan pada Lampiran 7 (Tabel 5). Berdasarkan pengujian terhadap 14 skenario kasus uji pada fitur fungsional inti (*Minimum Viable Product*/MVP) yang mencakup 5 modul utama sistem (*ChatAnalisis-FE* dan *ChatAnalisis-BE*) secara terintegrasi, seluruh fitur sistem dinyatakan berjalan dengan sukses (100% valid) dan menghasilkan keluaran yang sesuai dengan spesifikasi kebutuhan yang telah didefinisikan.

BAB 5. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil perancangan sistem, pengujian empiris, dan evaluasi performa yang telah dilakukan, dapat ditarik kesimpulan sebagai berikut:

1. Penerapan arsitektur BERTopic yang mengintegrasikan model *embedding* IndoBERTweet, pengklasteran BIRCH (ambang adaptif $[0{,}20, 0{,}25]$ dan eliminasi *outlier* 2σ), pembobotan BM25 dengan eliminasi *stopwords* percakapan, serta reduksi topik berbasis kemiripan kosinus berhasil mengekstraksi 40 topik tematik yang terstruktur dari 51.584 pesan teks grup WhatsApp.

2. Model usulan menghasilkan kualitas topik yang lebih unggul dibandingkan model acuan pada metrik keberagaman topik ($TD = 0{,}9875$), kekohesifan dokumen internal ($ITS = 0{,}6534$), dan kepadatan klaster ($ED = 0{,}6197$), serta mempertahankan retensi data tertinggi sebesar 92,79% (hanya menyisakan 7,21% *outlier*). Sebagai bentuk kompromi (*trade-off*), nilai koherensi semantik ($C_{\text{NPMI}} = +0{,}1075$) sedikit di bawah Model *Baseline Proposed* (+0,1171), namun model usulan berhasil mempertahankan konteks percakapan tanpa membuang 56,66% data obrolan.

3. Sistem analisis topik percakapan grup WhatsApp berbasis *web* (*ChatAnalisis*) berhasil dirancang dan diimplementasikan menggunakan arsitektur *client-server* (Vue.js 3 dan FastAPI). Pengujian *Black-Box Testing* terhadap 14 skenario uji fitur fungsional inti (MVP) pada 5 modul utama membuktikan seluruh fungsionalitas sistem berjalan dengan sukses (100% valid), didukung anonimisasi SHA-256 di sisi klien untuk perlindungan privasi serta pemantauan komputasi *real-time* melalui *Server-Sent Events* (SSE).

5.2 Saran

Berdasarkan temuan dan keterbatasan penelitian, diajukan beberapa saran untuk pengembangan akademik lanjutan:

1. Mengeksplorasi penggunaan model bahasa generasi terbaru, seperti model berbasis *Large Language Models* (LLM) berbahasa Indonesia atau model representasi kalimat dwibahasa mutakhir, guna meningkatkan pemahaman semantik pada percakapan dengan variasi campur kode (*code-mixing*) yang lebih kompleks.
2. Mengintegrasikan pemodelan topik dengan analisis sentimen untuk memahami polaritas opini anggota komunitas dalam setiap tema pembicaraan.

DAFTAR PUSTAKA

Abdelrazek, A., Eid, Y., Gawish, E., Medhat, W., and Hassan, A. (2023). Topic modeling algorithms and applications: A survey. *Information Systems*, 112:102131.

Alzu'bi, A. and Barham, M. (2022). Automatic BIRCH thresholding with features transformation for hierarchical breast cancer clustering. *International Journal of Electrical and Computer Engineering (IJECE)*, 12(2):1498–1507.

Banerjee, S. and Pan, A. (2024). From colonial legacies to linguistic inclusion: A BERTopic enhanced bibliometric insight into global south higher education. *IEEE Access*, 12:117418–117435.

Churchill, R. and Singh, L. (2022). The evolution of topic modeling. *ACM Comput. Surv.*, 54(10s).

Dieng, A. B., Ruiz, F. J. R., and Blei, D. M. (2020). Topic modeling in embedding spaces. *Transactions of the Association for Computational Linguistics*, 8:439–453.

Egger, R. and Yu, J. (2022). A topic modeling comparison between LDA, NMF, Top2Vec, and BERTopic to demystify Twitter posts. *Frontiers in Sociology*, 7:886498.

Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based c-TF-IDF procedure. *arXiv preprint arXiv:2203.05794*.

Janssens, W., Bogaert, M., and van den Poel, D. (2025). A comparative analysis of topic reduction techniques for BERTopic. *IEEE Access*, 13:204087–204103.

Jesse, M., Bauer, C., and Jannach, D. (2022). Intra-list similarity and human diversity perceptions of recommendations: the details matter. *User Modeling and User-Adapted Interaction*, 33(4):769–802.

Jian, F., Huang, J. X., Zhao, J., Ying, Z., and Wang, Y. (2020). A topic-based term frequency normalization framework to enhance probabilistic information retrieval. *Computational Intelligence*, 36(2):486–521.

Koto, F., Lau, J. H., and Baldwin, T. (2021). IndoBERTweet: A pretrained language model for Indonesian Twitter with effective domain-specific vocabulary initialization. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP 2021)*, pages 10660–10668.

Koto, F., Rahimi, A., Lau, J., and Baldwin, T. (2020). IndoLEM and IndoBERT: A benchmark dataset and pre-trained language model for Indonesian NLP. *arXiv preprint arXiv:2011.00677*.

McInnes, L., Healy, J., and Melville, J. (2018). UMAP: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*.

Mohta, A., Jain, A., Saluja, A., and Dahiya, S. (2020). Pre-processing and emoji classification of WhatsApp chats for sentiment analysis. In *2020 Fourth International Conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud) (I-SMAC)*, pages 514–519.

Muhajir, M., Gunardi, G., Danardono, D., and Rosadi, D. (2025). Integrating IndoBERT and balanced iterative reducing and clustering using hierarchies of BERTopic in Indonesian short text. *IAES International Journal of Artificial Intelligence (IJ-AI)*, 14(5):4192–4201.

Prayogi, A., Novriyenny, N., and Prahmana, I. G. (2025). Dinamika sentimen komunikasi mahasiswa dan dosen dengan pemanfaatan analisis pesan WhatsApp akademis menggunakan Machine Learning. *Repeater: Publikasi Teknik Informatika dan Jaringan*, 3(2):45–54.

Ramadhani, F., Zarlis, M., and Suwilo, S. (2020). Improve BIRCH algorithm for big data clustering. *IOP Conference Series: Materials Science and Engineering*, 725(1):012090.

Rani, S. J., Prabhu, T. N., and Chellam, J. A. I. (2022). WhatsApp sentiment analysis using R. In *2022 3rd International Conference for Emerging Technology (INCET)*, pages 1–4. IEEE.

Röder, M., Both, A., and Hinneburg, A. (2015). Exploring the space of topic coherence measures. In *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining*, WSDM '15, pages 399–408, New York, NY, USA. Association for Computing Machinery.

Rushkin, I. (2020). Document similarity from vector space densities. *CoRR*, abs/2009.00672.

Siregar, U., Ramadani, N., and Siregar, F. (2025). Syntactic analysis in WhatsApp conversations among peers. *Jurnal Hata Poda*, 4(2):150–157.

Sutarma, I. G. P. (2017). Analisis wujud bentuk linguistik dalam penggunaan Bahasa Indonesia di media sosial "WhatsApp". *Soshum: Jurnal Sosial dan Humaniora*, 6(3):227.

WhatsApp LLC (2026). Tentang WhatsApp. Diakses pada 7 Januari 2026.

Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., and Purwarianti, A. (2020). IndoNLU: Benchmark and resources for evaluating Indonesian natural language understanding. In *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*, pages 514–530.

Zhang, T., Ramakrishnan, R., and Livny, M. (1996). BIRCH: An efficient data clustering method for very large databases. *SIGMOD Rec.*, 25(2):103–114.

Zhang, T., Ramakrishnan, R., and Livny, M. (1997). BIRCH: A new data clustering

algorithm and its applications. *Data Min. Knowl. Discov.*, 1(2):141–182.

LAMPIRAN

Lampiran 1. Perbandingan Kinerja Model Bahasa Pra-Latih pada Berbagai Tugas NLP

Perbandingan kinerja model bahasa pra-latih berbasis *Transformer* pada tujuh tugas hilir pemrosesan bahasa alami berbahasa Indonesia yang diadaptasi dari studi Koto et al. (2021).

Tabel 1: Perbandingan Kinerja Model pada Tujuh Tugas

Model	**Sentiment**		**Emotion**	**Hate Speech**		**NER**		**Average**
	IndoLEM	**SmSA**	**EmoT**	**HS1**	**HS2**	**Formal**	**Informal**	
mBERT	76.6	84.7	67.5	85.1	75.1	85.2	83.2	79.6
malayBERT	82.0	84.1	74.2	85.0	81.9	81.9	81.3	81.5
IndoBERT (Wilie et al., 2020)	84.1	88.7	73.3	86.8	80.4	86.3	84.3	83.4
IndoBERT (Koto et al., 2020)	84.1	87.9	71.0	86.4	79.3	88.0	86.9	83.4
IndoBERTweet (1M steps from scratch) (Koto et al., 2021)	86.2	90.4	76.0	**88.8**	**87.5**	**88.1**	85.4	86.1
IndoBERT + Vocabulary adaptation + 200K steps (Koto et al., 2021)	**86.6**	**92.7**	**79.0**	88.4	84.0	87.7	**86.9**	**86.5**

Lampiran 2. Cuplikan Data Mentah Log Obrolan WhatsApp

Cuplikan baris data mentah hasil ekspor percakapan WhatsApp grup Komunitas Buku sebelum dilakukan praproses dan penyamaran identitas.

Tabel 2: Contoh Potongan Data Mentah Hasil Ekspor WhatsApp

No.	Potongan Baris Data Mentah Log Obrolan
1	*02/02/26 20.46 - +62 ***-****-****: Aku tadi searching sedikit tentang buku ini*
2	*02/02/26 20.47 - +62 ***-****-****: <Media tidak disertakan>*
3	*27/09/25 10.35 - +62 ***-****-****: sheesh*
4	*03/02/26 11.24 - +62 ***-****-****: https://link*
5	*28/09/25 09.48 - +62 ***-****-****: gara gara dapet evernight jadi pengen hyacine <Pesan ini diedit>*
6	*24/04/26 05.12 - +62 ***-****-**** sudah ditambahkan*

Lampiran 3. Contoh Transformasi Teks Praproses Data

Contoh transformasi teks pesan sebelum dan sesudah tahap praproses yang meliputi eliminasi notifikasi sistem, penghapusan tanda kurung sudut, normalisasi emoji, tawa, elongasi, dan kata tidak baku.

Tabel 3: Contoh Hasil Transformasi Teks Sebelum dan Sesudah Praproses Data

Pesan Mentah	**Pesan Hasil Praproses**	**Keterangan**
<Media omitted>	*[Dihapus / String Kosong]*	Eliminasi artefak media sistem
@+62 ***-****-5678 welcome yusril! [emoji tersenyum]	@User-bc45·5678 welcome yusril smiling_face	Anonimisasi mention & transliterasi emoji
Gaisss cek link ini yaa https://example.com	gais cek link ini yaa	Elongasi huruf & penghapusan URL
Hahaha wkwkwk ngakak bgt bisaaa aja	haha wkwk ngakak bgt bisa saja	Normalisasi tawa, elongasi & kata tidak baku
Mau tanya perihal bab 3 skripsi dong	mau tanya perihal bab 3 skripsi saja	Case folding & normalisasi kata tidak baku
Pesan ini telah dihapus	*[Dihapus / String Kosong]*	Eliminasi notifikasi pesan sistem

Lampiran 4. Rincian Data Evaluasi Kurva Pembelajaran

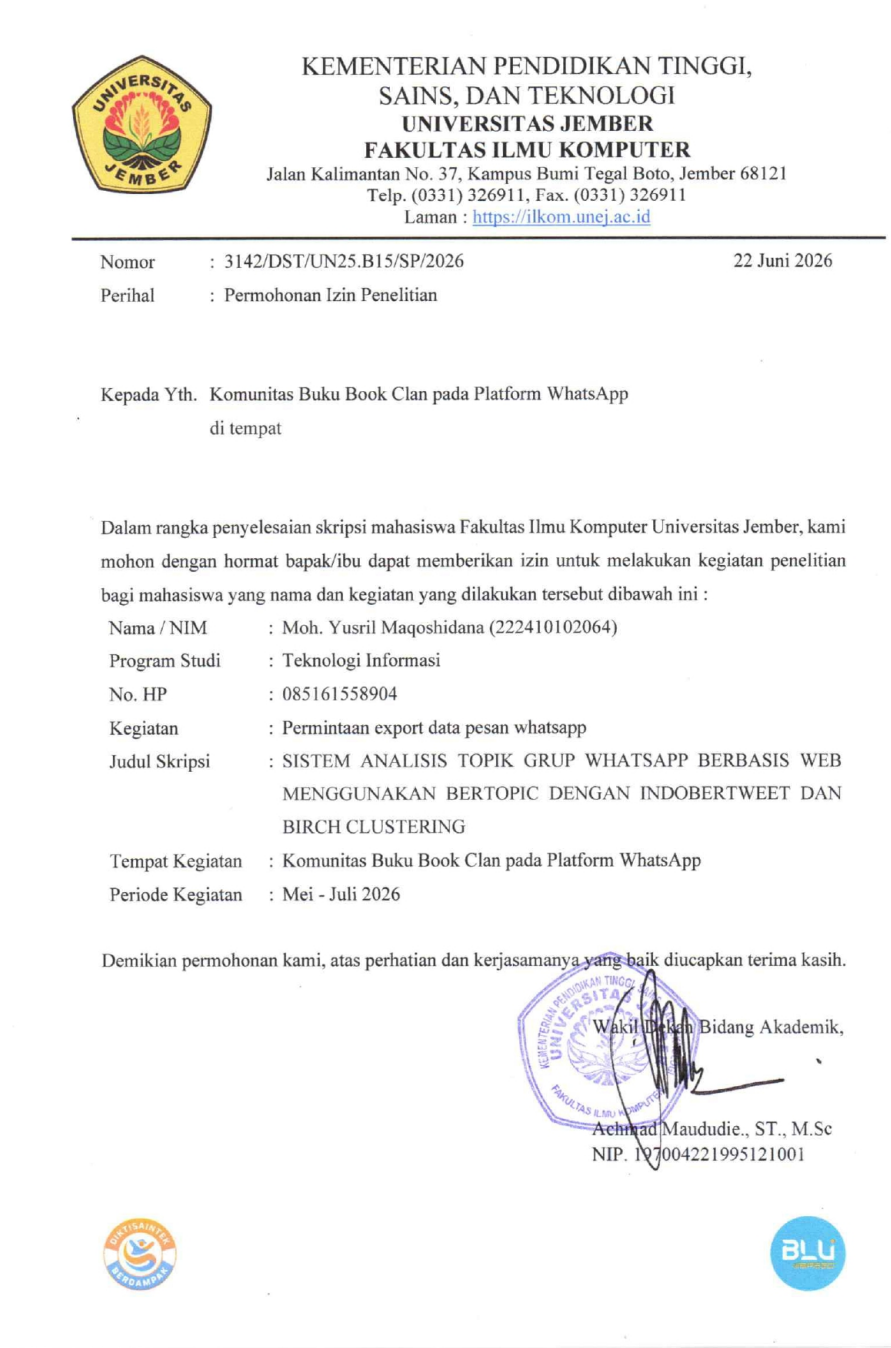
Rincian kuantitatif metrik evaluasi pemodelan topik pada setiap fraksi partisi data latih (20%, 40%, 60%, 80%, dan 100%) yang membandingkan performa Model Modified (Muhajir et al., 2025) terhadap Model Usulan.

Tabel 4: Perbandingan Metrik Evaluasi Kurva Pembelajaran Model Modified vs. Model Usulan

Split Data	Model Evaluasi	Jumlah Topik	Topic Diversity	C_{NPMI}	Intra-Topic Sim	Outlier Rate (%)
20% (10.316)	Modified (Muhajir et al.)	40	0,6800	-0,2162	0,6448	4,80%
	Model Usulan	46	0,9457	-0,0290	0,6258	14,32%
40% (20.633)	Modified (Muhajir et al.)	56	0,5964	-0,1485	0,6462	4,74%
	Model Usulan	187	0,9567	+0,0111	0,6134	10,94%
60% (30.950)	Modified (Muhajir et al.)	53	0,5868	-0,0489	0,6472	4,72%
	Model Usulan	124	0,9540	+0,0421	0,6147	8,22%
80% (41.267)	Modified (Muhajir et al.)	73	0,5219	-0,0002	0,6467	4,60%
	Model Usulan	316	0,9604	+0,0462	0,6194	7,62%
100% (51.584)	Modified (Muhajir et al.)	70	0,5257	+0,0090	0,6495	4,58%
	Model Usulan	40	0,9875	+0,1075	0,6534	7,21%

Lampiran 5. Surat Izin Penelitian dari Kampus

Dokumen administratif berupa Surat Izin Penelitian resmi dari pihak kampus untuk permohonan pengambilan data percakapan grup WhatsApp Komunitas Buku.



KEMENTERIAN PENDIDIKAN TINGGI,
SAINS, DAN TEKNOLOGI
UNIVERSITAS JEMBER
FAKULTAS ILMU KOMPUTER
Jalan Kalimantan No. 37, Kampus Bumi Tegal Boto, Jember 68121
Telp. (0331) 326911, Fax. (0331) 326911
Laman : https://ilkom.unej.ac.id

Nomor : 3142/DST/UN25.B15/SP/2026 — 22 Juni 2026
Perihal : Permohonan Izin Penelitian

Kepada Yth. Komunitas Buku Book Clan pada Platform WhatsApp
di tempat

Dalam rangka penyelesaian skripsi mahasiswa Fakultas Ilmu Komputer Universitas Jember, kami mohon dengan hormat bapak/ibu dapat memberikan izin untuk melakukan kegiatan penelitian bagi mahasiswa yang nama dan kegiatan yang dilakukan tersebut dibawah ini :

Nama / NIM	: Moh. Yusril Maqoshidana (222410102064)
Program Studi	: Teknologi Informasi
No. HP	: 085161558904
Kegiatan	: Permintaan export data pesan whatsapp
Judul Skripsi	: SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING
Tempat Kegiatan	: Komunitas Buku Book Clan pada Platform WhatsApp
Periode Kegiatan	: Mei - Juli 2026

Demikian permohonan kami, atas perhatian dan kerjasamanya yang baik diucapkan terima kasih.

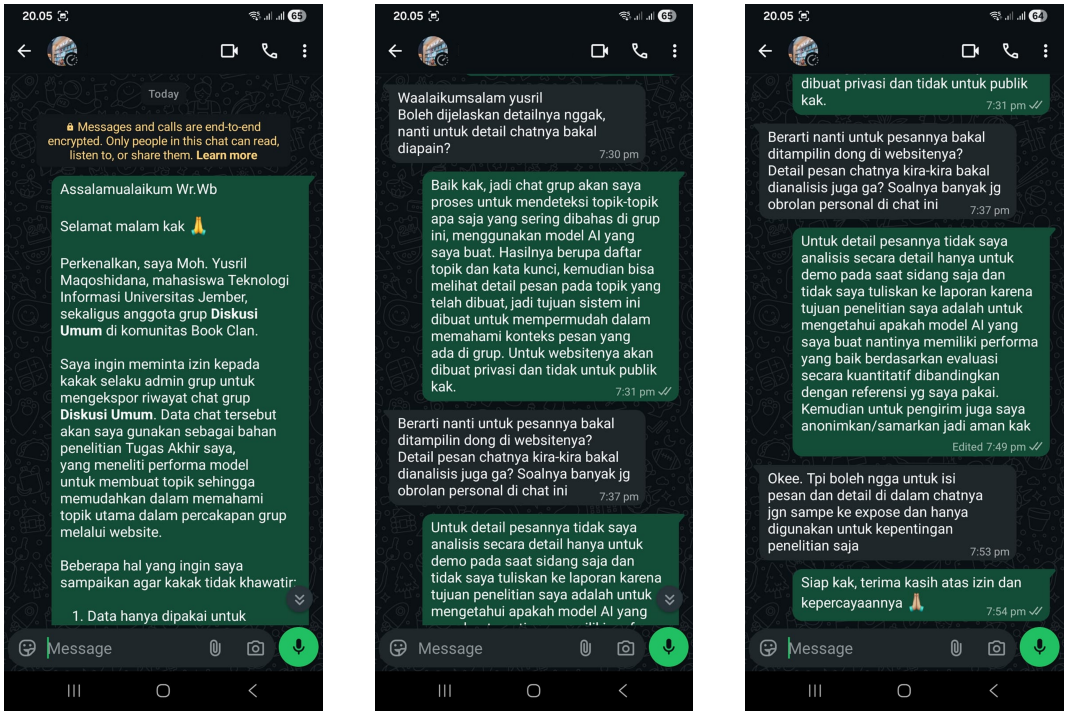
Wakil Dekan Bidang Akademik,

Achmad Maududie., ST., M.Sc
NIP. 197004221995121001

Gambar 1: Surat Izin Penelitian dari Kampus

Lampiran 6. Bukti Persetujuan Admin Grup WhatsApp

Tangkapan layar persetujuan tertulis dari administrator grup WhatsApp Komunitas Buku untuk penggunaan riwayat percakapan sebagai dataset penelitian dengan syarat penyamaran identitas.



(a) Bukti Persetujuan 1 (b) Bukti Persetujuan 2 (c) Bukti Persetujuan 3

Gambar 2: Bukti Persetujuan Admin Grup WhatsApp

Lampiran 7. Hasil Pengujian Fungsional Sistem (*Black-Box Testing*)

Rincian 14 skenario kasus uji fitur fungsional inti (*Minimum Viable Product*/MVP) sistem menggunakan metode *Black-Box Testing* yang mengevaluasi perilaku masukan dan keluaran antarmuka web (*frontend*) serta layanan API (*backend*).

Tabel 5: Hasil Pengujian Fungsional Fitur MVP Sistem (*Black-Box Testing*)

ID Uji	Fitur / Modul	Skenario Pengujian	Langkah-langkah Pengujian	Data Uji / Input	Hasil yang Diharapkan	Hasil
1. Modul Unggah & Validasi Berkas Obrolan (*/upload* - Step 1)						
TC-MVP-01	Unggah Berkas Valid	Mengunggah berkas ekspor obrolan WhatsApp valid (*.txt* / *.zip*)	1. Buka rute */upload*. 2. Pilih atau seret berkas chat valid.	Berkas *.txt* / *.zip* chat	Berkas berhasil diurai (*parsed*), detail nama dan ukuran berkas muncul, serta tombol "Selanjutnya" aktif.	Valid
TC-MVP-02	Validasi Format Berkas	Mengunggah berkas dengan format di luar spesifikasi obrolan	1. Buka rute */upload*. 2. Pilih berkas non-chat (*.pdf* / *.png*).	Berkas *dokumen.pdf*	Sistem menolak berkas, memunculkan notifikasi peringatan format tidak didukung, dan tombol tetap dinonaktifkan.	Valid
2. Modul Pemfilteran Rentang Waktu, Mode Analisis & Privasi Data (*/upload* - Step 2)						
TC-MVP-03	Filter Rentang Tanggal	Menyesuaikan rentang waktu pesan yang akan dianalisis	1. Berada di Step 2. 2. Geser bilah rentang tanggal (slider).	Geser Slider Tanggal	Tanggal awal dan akhir diperbarui secara *real-time*, dan hanya data pesan dalam rentang yang diproses.	Valid
TC-MVP-04	Seleksi Mode Analisis	Memilih mode pemrosesan (*Dual-Mode Selector*)	1. Berada di Step 2. 2. Pilih "Mode Cepat" atau "Mode Riset Lengkap".	Klik Kartu Mode	Kartu mode aktif ditandai secara visual, dan parameter konfigurasi mode tersimpan ke penyimpanan sesi.	Valid
TC-MVP-05	Anonimisasi Sisi Klien	Menjalankan anonimisasi otomatis sebelum pengiriman berkas	1. Klik tombol "Mulai Analisis". 2. Amati transmisi jaringan (*Network devtools*).	Klik Mulai Analisis	Skrip sisi klien menyamarkan identitas dan nomor pengirim menjadi token SHA-256 bergaram sebelum dikirim ke backend.	Valid
3. Modul Pemrosesan AI & Pemantauan Komputasi (*/upload* - Step 3)						
TC-MVP-06	Pemrosesan Asinkron AI	Menjalankan pemodelan topik pada utas latar belakang	1. Backend menerima permintaan analisis. 2. Amati eksekusi pemodelan topik.	Payload CSV Anonim	Backend FastAPI memproses alur IndoBERTweet, BIRCH, dan BM25 secara asinkron tanpa memblokir server.	Valid

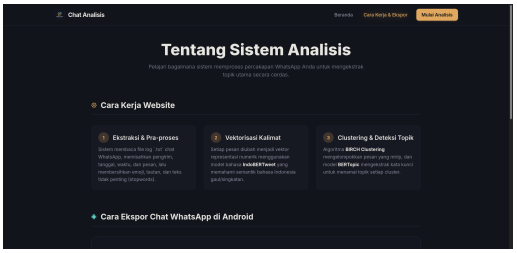
ID Uji	Fitur / Modul	Skenario Pengujian	Langkah-langkah Pengujian	Data Uji / Input	Hasil yang Diharapkan	Hasil
TC-MVP-07	Pemantauan SSE *Real-Time*	Memantau aliran log proses komputasi pada simulator terminal	1. Berada di Step 3. 2. Amati konsol log *TerminalSimulator*.	Aliran Event SSE	Perkembangan setiap tahapan analisis terpancar secara langsung ke antarmuka hingga status selesai (*completed*).	Valid
TC-MVP-08	Pengalihan Otomatis	Melakukan pengalihan rute secara otomatis pasca-analisis	1. Tunggu hingga tahapan akhir selesai (*done: true*).	Sinyal Selesai SSE	Aplikasi secara otomatis mengalihkan tampilan dari Step 3 menuju halaman dasbor hasil (*/results*).	Valid
4. Modul Dasbor Hasil Analisis & Visualisasi Topik (*/results*)						
TC-MVP-09	Kartu Metrik Evaluasi	Menyajikan ringkasan metrik kualitas pemodelan topik	1. Berada di */results*. 2. Periksa baris kartu metrik evaluasi.	Data Metrik Server	Dasbor menampilkan metrik jumlah topik, diversitas (TD), koherensi (C_{NPMI}), kepadatan (ED), dan kekohesifan (ITS).	Valid
TC-MVP-10	Grafik Keaktifan Obrolan	Menyajikan linimasa distribusi volume percakapan	1. Berada di */results*. 2. Amati grafik aktivitas tanggal (*ActiveDates*).	Data Agregasi Waktu	Visualisasi grafik linimasa menyajikan tren frekuensi obrolan per hari dengan interaksi *tooltip* yang responsif.	Valid
TC-MVP-11	Daftar Klaster Topik	Menyajikan kartu klaster topik dan kata kunci representatif	1. Gulir ke daftar klaster topik. 2. Periksa kartu klaster dan kata kunci.	Data Klaster Topik	Setiap kartu klaster menyajikan label topik, jumlah pesan, proporsi korpus, dan 10 kata kunci teratas.	Valid
5. Modul Eksplorasi Detail Topik & Konteks Pesan (*/results/topics/:topicId*)						
TC-MVP-12	Penelusuran Pesan Topik	Membuka rute detail topik untuk meninjau seluruh pesan anggota	1. Klik salah satu kartu topik di */results*. 2. Amati daftar pesan di halaman detail.	Klik Kartu Topik	Halaman detail menyajikan seluruh daftar pesan yang terpetakan ke dalam topik tersebut beserta stempel waktu.	Valid
TC-MVP-13	Modal Konteks Obrolan	Menampilkan percakapan utuh di sekitar pesan terpilih	1. Pada detail topik, klik tombol "Lihat Konteks".	Klik Konteks Pesan	Dialog modal terbuka menyajikan percakapan sebelum dan sesudah pesan terpilih secara kronologis (*thread context*).	Valid
TC-MVP-14	Ekspor Laporan Analisis	Mengunduh ringkasan hasil pemodelan topik ke dokumen lokal	1. Di halaman */results*, klik tombol "Ekspor Laporan".	Klik Ekspor Laporan	Berkas laporan hasil pemodelan topik berhasil diunduh ke perangkat pengguna dengan data yang lengkap.	Valid

Lampiran 8. Tangkapan Layar Implementasi Antarmuka Sistem Web

Rincian tangkapan layar antarmuka pengguna (*frontend*) aplikasi web ChatAnalisis yang mengimplementasikan arsitektur *client-side anonymization*, pemantauan *streaming* SSE, visualisasi hasil pemodelan topik, serta penelusuran konteks pesan (*traceability*).

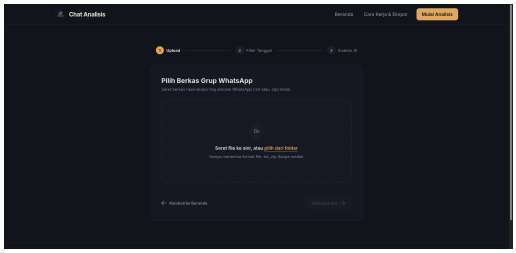


(a) Halaman Utama (Landing Page)

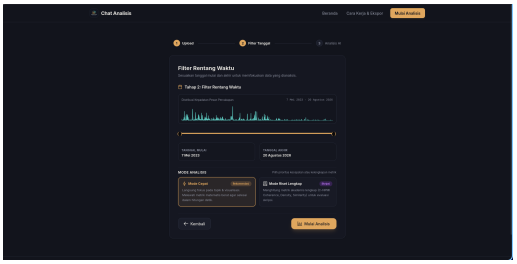


(b) Modal Panduan Ekspor Chat

Gambar 3: Antarmuka Utama dan Panduan Cara Kerja Aplikasi Web ChatAnalisis

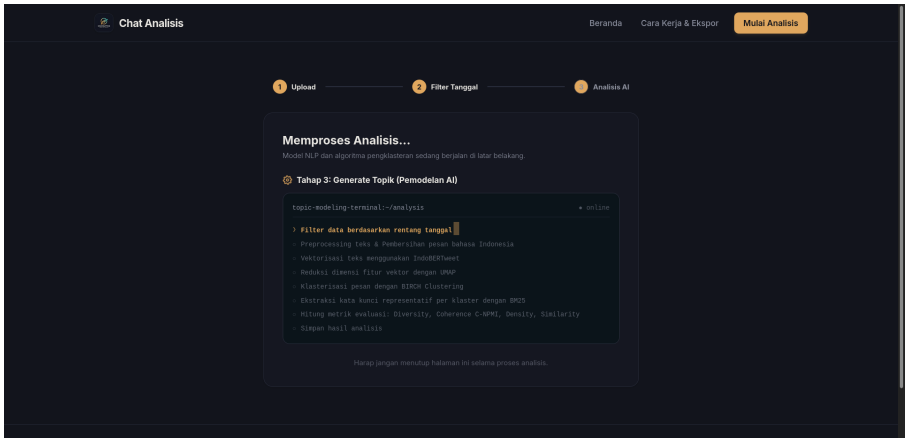


(a) Unggah Berkas Obrolan



(b) Filter Rentang Tanggal & Anonimisasi

Gambar 4: Antarmuka Unggah Berkas dan Pengaturan Filter Rentang Tanggal Data



Gambar 5: Tampilan Pemantauan Progres Analisis secara Real-Time via Server-Sent Events (SSE)



Gambar 6: Tampilan Dashboard Hasil Pemodelan Topik dan Grafik Tren Waktu Obrolan

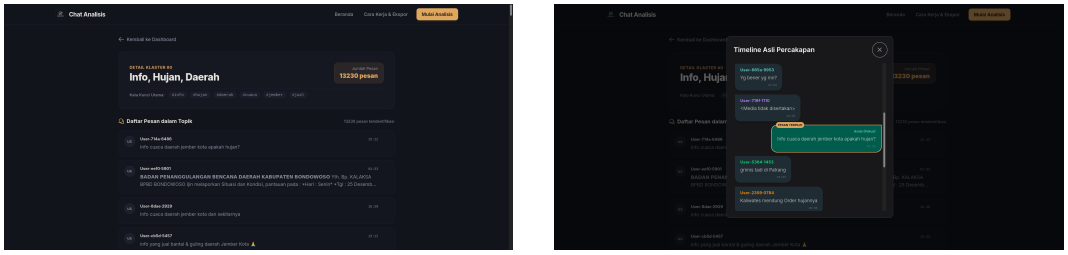


(a) Panel Metrik Evaluasi Kuantitatif



(b) Aktivitas & Leaderboard Pengirim

Gambar 7: Visualisasi Panel Metrik Evaluasi Kuantitatif dan Distribusi Aktivitas Pengguna



(a) Halaman Detail Klaster Topik (b) Modal Penelusuran Konteks Pesan

Gambar 8: Antarmuka Detail Klaster Topik dan Dialog Modal Penelusuran Konteks Pesan