



**SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB
MENGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH
CLUSTERING**

*Diajukan guna memenuhi salah satu syarat penelitian untuk memenuhi kelulusan
Program Studi Teknologi Informasi*

SKRIPSI

Oleh:

Moh. Yusril Maqoshidana

NIM 222410102064

**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN
TEKNOLOGI PROGRAM STUDI TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER
UNIVERSITAS JEMBER**

2026

PERSEMBAHAN

Halaman ini saya persembahkan kepada:

1. Allah SWT, atas segala rahmat, karunia, serta kemudahan yang diberikan sehingga penulis dapat menyelesaikan skripsi ini dengan baik.
2. Orang tua tercinta, atas doa, kasih sayang, dukungan, dan segala pengorbanan yang telah diberikan sehingga penulis dapat menyelesaikan pendidikan sarjana ini.
3. Bapak Dr. Brian Rizqi Paradisiaca Darnoto, S.Kom., M.Kom selaku Dosen Pembimbing Utama yang telah meluangkan waktu, memberikan arahan, bimbingan, serta masukan yang berharga selama proses penyusunan skripsi ini.
4. Seluruh dosen yang telah membagikan ilmu, wawasan, dan pengalaman selama masa perkuliahan sehingga menjadi bekal dalam penyusunan skripsi ini.
5. Sahabat, teman seperjuangan, dan seluruh pihak yang telah memberikan dukungan, semangat, serta bantuan selama proses penyusunan skripsi ini.
6. Kepada diri sendiri, atas perjuangan dalam menghadapi berbagai rintangan selama proses penyusunan skripsi ini.

MOTTO

*“Tiada kekayaan yang lebih utama daripada akal,
tiada keadaan yang lebih menyedihkan daripada kebodohan,
dan tiada warisan yang lebih baik daripada pendidikan”*

(Ali bin Abi Thalib)

“When you’re afraid of something, learn as much as you can about it.

Knowledge overcomes fear”

(Edmund Burke)

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini:

Nama: Moh. Yusril Maqoshidana

NIM: 222410102064

Dengan ini menyatakan bahwa skripsi yang berjudul: *Sistem Analisis Topik Grup WhatsApp Berbasis Web Menggunakan BERTopic dengan IndoBERTweet dan BIRCH Clustering*

adalah benar-benar hasil karya saya sendiri. Saya juga menyatakan bahwa dalam skripsi ini tidak terdapat karya yang pernah diajukan untuk memperoleh gelar sarjana atau gelar lainnya di mana pun.

Saya bertanggung jawab atas kebenaran dan keorisinalan isi skripsi ini. Apabila dikemudian hari terbukti bahwa skripsi ini mengandung unsur plagiasi, maka saya siap menanggung akibat hukum yang berlaku.

Jember, 01 Juni 2026

Yang menyatakan,

Moh. Yusril Maqoshidana

NIM. 222410102064

HALAMAN PERSETUJUAN

Skripsi berjudul “*SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING*” telah diuji dan disetujui oleh Fakultas Ilmu Komputer Universitas Jember pada:

Hari : Minggu

Tanggal : 01 Juni 2026

Tempat : Fakultas Ilmu Komputer Universitas Jember

Pembimbing

Tanda Tangan

1. Pembimbing Utama

Nama : Dr. Brian Rizqi P. D., S.Kom., M.Kom

(.....)

NIP : 199804272024061001

Penguji

1. Penguji Utama

Nama : Khoirunnisa' Afandi, S.Kom., M.Kom

(.....)

NIP : 199412282024062001

2. Penguji Anggota 1

Nama : Dony Bahtera Firmawan, S.Kom., M.Kom

(.....)

NIP : 199711202024061001

ABSTRAK

Latar belakang penelitian ini adalah ... (Jelaskan konteks dan motivasi penelitian Anda di sini, minimal 2-3 kalimat).

Rumusan masalah dalam penelitian ini adalah ... (Jelaskan masalah utama yang ingin dipecahkan).

Tujuan penelitian ini adalah untuk ... (Jelaskan tujuan yang ingin dicapai dari penelitian Anda).

Metode penelitian yang digunakan adalah ... (Jelaskan metode penelitian secara ringkas: jenis penelitian, sampel, instrumen, teknik analisis).

Hasil penelitian menunjukkan bahwa ... (Jelaskan temuan utama dari penelitian Anda).

Kesimpulannya adalah ... (Berikan kesimpulan singkat dan implikasi dari penelitian).

Kata Kunci: *Kata Kunci Satu, Kata Kunci Dua, Kata Kunci Tiga*

ABSTRACT

The background of this research is ... (Explain the context and motivation of your research here, at least 2-3 sentences).

The research problem investigated in this study is ... (Explain the main problem to be solved).

The purpose of this research is to ... (Explain the objectives to be achieved from your research).

The research method used is ... (Explain the research method briefly: research type, sample, instruments, analysis techniques).

The research results show that ... (Explain the main findings from your research).

The conclusion is that ... (Provide a brief conclusion and implications of the research).

Keywords: *Kata Kunci Satu, Kata Kunci Dua, Kata Kunci Tiga*

RINGKASAN

Penelitian ini dilakukan dengan latar belakang ... (Jelaskan konteks, motivasi, dan pentingnya penelitian secara lebih detail dibanding abstrak.)

Dalam era ... (Tambahkan konteks temporal dan kontekstual penelitian Anda).

Masalah yang dihadapi adalah ... (Jelaskan masalah penelitian dan mengapa penting untuk diteliti). Oleh karena itu, penelitian ini bertujuan untuk ... (Jelaskan tujuan utama penelitian).

Metode penelitian yang digunakan adalah ... (Jelaskan dengan detail: pendekatan, design, populasi/sampel, instrumen, teknik pengumpulan data, dan analisis data).

Temuan penelitian menunjukkan bahwa ... (Jelaskan hasil utama, temuan penting, dan interpretasi awal).

Berdasarkan hasil penelitian, dapat disimpulkan bahwa ... (Berikan kesimpulan yang comprehensive). Penelitian ini diharapkan dapat memberikan manfaat bagi ... (Jelaskan kontribusi praktis dan akademis).

PRAKATA

Puji syukur kehadiran Allah SWT atas segala berkah dan rahmat yang telah diberikan sehingga penulis mampu menyelesaikan penelitian yang berjudul “*SISTEM ANALISIS TOPIK GRUP WHATSAPP BERBASIS WEB MENGGUNAKAN BERTOPIC DENGAN INDOBERTWEET DAN BIRCH CLUSTERING*”. Penelitian ini merupakan salah satu syarat akademik dalam menyelesaikan pendidikan Strata Satu (S1) pada Program Studi Teknologi Informasi Fakultas Ilmu Komputer Universitas Jember.

Penulis menyadari bahwa dalam proses penelitian dan penulisan skripsi ini, banyak pihak yang telah memberikan bimbingan, dukungan, dan bantuan. Oleh karena itu, pada kesempatan ini penulis dengan sepuh hati mengucapkan terima kasih kepada:

1. Bapak Prof. Drs. Antonius Cahya Prihandoko, M.App.Sc., Ph.D., selaku Dekan Fakultas Ilmu Komputer Universitas Jember.
2. Dr. Brian Rizqi Paradisiaca Darnoto, S.Kom., M.Kom selaku Pembimbing Utama yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan bimbingan, diskusi, serta arahan yang sangat berharga sejak awal hingga skripsi ini selesai.
3. Bapak Priza Pandunata, S.Kom., M.Sc. yang telah memberikan saran dan membantu penulis dalam menentukan topik penelitian ketika penulis mengalami kesulitan dalam memilih topik skripsi.
4. Ibu Khoirunnisa' Afandi, S.Kom., M.Kom dan Bapak Dony Bahtera Firmawan, S.Kom., M.Kom selaku Dosen Penguji yang telah memberikan ujian, saran, dan masukan yang konstruktif demi kesempurnaan laporan skripsi ini.
5. Bapak Yudha Alif Auliya, S.Kom., M.Kom. selaku Dosen Pembimbing Akademik yang telah memberikan bimbingan dan arahan selama masa studi di Program Studi Teknologi Informasi.
6. Para dosen dan staf Program Studi Teknologi Informasi yang telah membantu

selama proses akademik.

7. Orang tua dan keluarga besar yang telah memberikan doa dan dukungan moral dan material selama penulis menempuh pendidikan hingga menyelesaikan skripsi ini.
8. Sahabat dan teman-teman seperjuangan yang telah memberikan semangat, bantuan, dan dukungan selama proses penelitian ini.

Penulis menyadari bahwa skripsi ini masih memiliki berbagai kekurangan, baik dalam penulisan maupun isi. Oleh karena itu, penulis mengharapkan kritik dan saran yang sifatnya membangun dari pembaca untuk perbaikan di masa mendatang. Akhir kata, semoga penelitian ini dapat memberikan manfaat bagi kemajuan ilmu pengetahuan dan dapat dijadikan sebagai bahan referensi bagi penelitian-penelitian selanjutnya.

Jember, 01 Juni 2026

Moh. Yusril Maqoshidana

222410102064

DAFTAR ISI

PERSEMBAHAN	i
MOTTO	ii
PERNYATAAN ORISINALITAS	iii
HALAMAN PERSETUJUAN	iv
ABSTRAK	v
ABSTRACT	vi
RINGKASAN	vii
PRAKATA	viii
DAFTAR TABEL	xiii
DAFTAR GAMBAR	xiv
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	4
1.4 Manfaat Penelitian	4
1.5 Batasan Penelitian	5
2 TINJAUAN PUSTAKA	6
2.1 Penelitian Terdahulu	6
2.2 Landasan Teori	7
2.2.1 Aplikasi WhatsApp	7
2.2.2 BERTopic	8
2.2.3 IndoBERTweet	9
2.2.4 BIRCH Clustering	10
2.2.5 Topic Representation Dengan BM25	11
2.2.6 Topic Coherence	12
2.2.7 Topic Diversity	13
2.2.8 Embedding Density	13
2.2.9 Intra-topic Similarity	14
3 METODOLOGI PENELITIAN	15
3.1 Jenis Penelitian	15

3.2	Objek Penelitian	15
3.3	Waktu Penelitian	15
3.4	Tahapan Penelitian	15
3.4.1	Identifikasi Masalah dan Studi Literatur	16
3.4.2	Pengumpulan Data	16
3.4.3	Praproses Data	17
3.4.4	Pembuatan Model	17
3.4.5	Evaluasi Model	19
3.4.6	Implementasi Sistem	20
3.4.7	Evaluasi Sistem	21
3.4.8	Analisis Hasil	21
3.4.9	Penarikan Kesimpulan	21
3.5	Etika Penelitian	21
4	HASIL DAN PEMBAHASAN	23
4.1	Pengumpulan Data	23
4.2	Praproses Data	24
4.3	Pembuatan Model	24
4.3.1	Embedding dan Reduksi Dimensi	24
4.3.2	Clustering dan Representasi Topik	24
4.3.3	Evaluasi Kuantitatif Model	24
4.3.4	Perbandingan Eksperimen (Baseline vs Modifikasi)	25
4.3.5	Uji Asumsi dan Analisis Inferensial	25
4.3.6	Implementasi Sistem dan Evaluasi Fungsional	25
4.3.7	Analisis Hasil	25
4.4	Pembahasan	25
4.4.1	Interpretasi Temuan Utama	25
4.4.2	Analisis Kualitatif Topik	25
4.4.3	Implikasi Praktis dan Rekomendasi Implementasi	26
4.4.4	Keterbatasan Penelitian	26
4.4.5	Saran dan Pekerjaan Lanjutan	26
4.4.6	Ringkasan Hasil Utama	26
5	KESIMPULAN DAN SARAN	27
5.1	Kesimpulan	27
5.2	Saran	27
5.2.1	Saran untuk Penelitian Selanjutnya	27
5.2.2	Saran untuk Praktisi dan Pengambil Kebijakan	28
	DAFTAR PUSTAKA	28
A	LAMPIRAN	32
A.1	Lampiran A - Data Mentah	32
A.2	Lampiran B - Instrumen Penelitian	33
A.2.1	Lampiran B.1 - Kuesioner	33

A.3	Lampiran C - Output Analisis Statistik	34
A.4	Lampiran D - Kode Sumber	35
A.5	Lampiran E - Dokumen Pendukung	36

DAFTAR TABEL

2.1	Tinjauan Penelitian Terdahulu	6
2.2	Perbandingan Kinerja Model pada Tujuh Tugas	9

DAFTAR GAMBAR

2.1	Framework BERTopic dengan modifikasi IndoBERT, BIRCH, dan BM25 (Muhajir et al., 2025)	8
3.1	Tahapan Penelitian	16
3.2	Rancangan framework BERTopic yang dimodifikasi pada tahap pembuatan model	18
3.3	Alur implementasi sistem analisis topik WhatsApp	20

BAB 1. PENDAHULUAN

1.1 Latar Belakang

WhatsApp telah menjadi salah satu aplikasi pesan instan paling populer di dunia, dengan lebih dari 3 miliar pengguna aktif di lebih dari 180 negara (WhatsApp Inc., 2026). Selain digunakan untuk komunikasi personal, fitur grup pada WhatsApp berperan penting sebagai wadah diskusi komunitas, koordinasi tim, pembelajaran daring, serta komunikasi organisasi. Percakapan yang terjadi dalam grup WhatsApp menghasilkan data teks yang sangat potensial untuk dianalisis guna memahami topik diskusi, pola komunikasi, dan dinamika interaksi antaranggota. Namun, seiring meningkatnya volume pesan dalam grup, pengguna sering mengalami kesulitan dalam mengikuti alur percakapan, menemukan informasi penting, maupun memahami topik yang sedang dibahas (Rani et al., 2022). Oleh karena itu, diperlukan suatu sistem yang mampu menganalisis topik percakapan grup WhatsApp secara otomatis.

Topic modeling sudah banyak digunakan pada penelitian terdahulu untuk menganalisis percakapan grup WhatsApp untuk menghasilkan atau menyimpulkan topik yang paling sesuai dari seluruh dokumen obrolan tersebut, sehingga pengguna dapat memahami secara garis besar apa yang sedang dibicarakan (Retna et al., 2021). *Topic modeling* merupakan teknik dalam NLP untuk mengidentifikasi topik laten dari sekumpulan dokumen berdasarkan pola kemunculan kata (Abdelrazek et al., 2023). Kompleksitas analisis percakapan grup WhatsApp semakin meningkat mengingat karakteristik data yang berupa teks pendek, tidak terstruktur, mengandung noise tinggi, disertai fenomena code-mixing yang masif, volume data yang besar, dan dinamika evolusi topik yang berlangsung cepat (Churchill and Singh, 2022; Mohta et al., 2020; Egger and Yu, 2022). Kondisi tersebut mengakibatkan pemilihan model *topic modeling* yang tepat menjadi faktor krusial dalam menghasilkan kluster topik yang akurat dan koheren.

Penelitian sebelumnya membandingkan beberapa model *topic modeling* seperti LDA, NMF, Top2Vec, dan BERTopic untuk menganalisis data media sosial Twitter (X) yang banyak mengandung teks pendek, dan menemukan bahwa BERTopic memberikan performa terbaik untuk model berbasis *embedding* (Egger and Yu, 2022). Namun, penelitian tersebut juga menunjukkan bahwa model berbasis *embedding* memiliki masalah dalam menghadapi *outlier* (dokumen bising yang tidak masuk ke kluster manapun). Hal ini karena HDBSCAN sebagai algoritma klusterisasi berbasis kepadatan dalam BERTopic secara inheren mengklasifikasikan dokumen yang tidak memenuhi kriteria stabilitas kluster sebagai outlier (Janssens et al., 2025).

Pada penelitian Muhajir et al. (2025), penulis mengusulkan modifikasi BERTopic dengan mengganti model HDBSCAN dengan BIRCH untuk mengatasi masalah *outlier* dan menggunakan IndoBERTweet sebagai model *embedding*. Algoritma BIRCH dipilih sebagai metode *clustering* karena kemampuannya membentuk kluster secara dinamis dan menugaskan hampir seluruh dokumen ke dalam kluster yang valid, sehingga mampu menekan proporsi *outlier* hingga 1%–5%, jauh lebih rendah dibandingkan HDBSCAN yang dapat membuang hingga 23%–24% dokumen sebagai data bising pada teks pendek yang bersifat *sparse* (Muhajir et al., 2025). IndoBERTweet dipilih karena model bahasa pra-latih (*pretrained language model*) berskala besar pertama yang dirancang dan dilatih secara khusus untuk menangani dan memproses data X (Twitter) berbahasa Indonesia, sehingga pendekatan ini memungkinkan model memahami karakteristik linguistik unik, bahasa sehari-hari, dan kosakata spesifik domain yang umum pada teks pendek berbahasa Indonesia, serta menghasilkan *contextualized embeddings* berkualitas tinggi untuk meningkatkan pemahaman semantik pada percakapan grup WhatsApp (Koto et al., 2021; Muhajir et al., 2025). Dengan demikian, kombinasi BIRCH dan IndoBERTweet memiliki landasan metodologis yang kuat untuk digunakan pada analisis topik percakapan WhatsApp.

Meskipun penelitian mengenai *topic modeling* pada percakapan grup WhatsApp telah dilakukan sebelumnya (Kharisudin and Masri'an, 2022; Kumar and

Naik, 2023; Retna et al., 2021), masih terdapat beberapa *research gap*. Pertama, penggunaan IndoBERTweet sebagai model *embedding* dalam *framework* BERTopic untuk percakapan grup WhatsApp berbahasa Indonesia masih terbatas. Kedua, pemanfaatan BIRCH sebagai pengganti HDBSCAN pada BERTopic belum banyak dieksplorasi, padahal berpotensi meningkatkan stabilitas *clustering* dan mengurangi *outlier*. Ketiga, mayoritas penelitian sebelumnya berfokus pada eksperimen metodologis tanpa menyediakan sistem yang dapat digunakan langsung oleh pengguna akhir.

Berdasarkan permasalahan tersebut, penelitian ini bertujuan mengembangkan sistem analisis topik percakapan grup WhatsApp berbasis *web* dengan fokus pada integrasi IndoBERTweet dan algoritma BIRCH dalam *framework* BERTopic. Sistem ini diharapkan membantu pengguna memahami topik utama percakapan grup secara otomatis tanpa harus membaca seluruh pesan secara manual. Selain memberikan kontribusi akademik pada pengembangan metode *topic modeling* untuk data percakapan berbahasa Indonesia, penelitian ini juga menghasilkan solusi praktis yang dapat dimanfaatkan oleh administrator grup, komunitas, peneliti sosial, maupun pengguna umum melalui antarmuka *web* yang mudah diakses dan informatif.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut berikut merupakan masalah yang dapat dirumuskan dalam penelitian ini:

1. Bagaimana penerapan BERTopic dengan IndoBERTweet dan BIRCH *clustering* untuk mengidentifikasi topik pada percakapan grup WhatsApp berbahasa Indonesia?
2. Bagaimana kualitas topik yang dihasilkan oleh BERTopic dengan IndoBERTweet dan BIRCH *clustering* berdasarkan metrik *Topic Coherence*, *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity*?
3. Bagaimana merancang dan mengimplementasikan sistem berbasis web untuk

analisis topik percakapan grup WhatsApp menggunakan BERTopic dengan IndoBERTweet dan BIRCH *clustering*?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah tersebut, tujuan penelitian ini dirumuskan sebagai berikut:

1. Menerapkan BERTopic dengan model *embedding* IndoBERTweet dan algoritma BIRCH sebagai metode *clustering* untuk mengidentifikasi topik pada percakapan grup WhatsApp berbahasa Indonesia.
2. Mengevaluasi kualitas topik yang dihasilkan oleh BERTopic yang menggunakan IndoBERTweet dan BIRCH *clustering* berdasarkan metrik *Topic Coherence*, *Topic Diversity*, *Embedding Density*, dan *Intra-topic Similarity*.
3. Merancang dan mengimplementasikan sistem berbasis *web* untuk analisis topik percakapan grup WhatsApp yang memanfaatkan BERTopic dengan IndoBERTweet dan BIRCH *clustering*, sehingga dapat digunakan langsung oleh pengguna akhir.

1.4 Manfaat Penelitian

Adapun manfaat yang diharapkan dari penelitian ini dapat diuraikan sebagai berikut:

1. Memberikan kontribusi dalam pengembangan ilmu di bidang *Natural Language Processing* (NLP), khususnya penerapan BERTopic dengan IndoBERTweet dan BIRCH *clustering* untuk analisis topik pada teks percakapan berbahasa Indonesia.
2. Menyediakan sistem berbasis *web* yang mampu menganalisis percakapan grup WhatsApp secara otomatis dan menyajikan hasil dalam bentuk visualisasi topik yang mudah dipahami.
3. Menjadi referensi bagi penelitian selanjutnya terkait penerapan *topic modeling* pada data teks pendek dan percakapan informal berbahasa Indonesia.

1.5 Batasan Penelitian

Agar penelitian ini lebih terarah dan fokus, maka ditetapkan beberapa batasan penelitian sebagai berikut:

1. Sistem hanya menganalisis percakapan teks berbahasa Indonesia dari grup WhatsApp, tidak mencakup media gambar, video, audio, maupun dokumen.
2. Data masukan pada *website* berupa file ekspor chat WhatsApp format .txt atau .zip yang diperoleh dari perangkat Android maupun iOS.
3. Data yang digunakan merupakan riwayat percakapan grup angkatan STAN 2022 pada periode 2022—2026.
4. Penelitian berfokus pada pemodelan topik dan tidak mencakup analisis sentimen, klasifikasi emosi, maupun prediksi perilaku pengguna.
5. Penelitian ini hanya menganalisis pesan teks hasil praproses yang mencakup anonimisasi data, penghapusan notifikasi sistem, penghapusan pesan dengan jumlah kata kurang dari 3, penghapusan tautan, normalisasi teks, transliterasi emoji ke bentuk teks, normalisasi kata tidak baku dan ekspresi tawa, serta eliminasi pesan duplikat. Identitas pengguna tidak menjadi bagian dari analisis.
6. Representasi topik menggunakan metode skema pembobotan BM25 sebagai pengganti skema representasi topik bawaan BERTopic, yaitu c-TF-IDF.
7. Evaluasi dilakukan menggunakan metrik Topic Coherence, Topic Diversity, Embedding Density, Intra-topic Similarity, serta pengujian fungsional black-box.

BAB 2. TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Tabel 2.1: Tinjauan Penelitian Terdahulu

No	Judul Penelitian	Hasil Penelitian	Celah (<i>Gap</i>)	Kontribusi
1	<i>A Topic Modeling Comparison Between LDA, NMF, Top2Vec, and BERTopic to Demystify Twitter Posts</i> (Egger and Yu, 2022) (Jurnal Q1)	Penelitian ini membandingkan BERTopic, NMF, LDA, dan Top2Vec pada data Twitter. BERTopic direkomendasikan untuk pendekatan berbasis <i>embedding</i> , sedangkan NMF menjadi alternatif tradisional yang lebih unggul untuk data media sosial.	Meskipun BERTopic menunjukkan performa yang baik, penggunaan <i>embedding</i> multilingual dan <i>clustering</i> default (HDBSCAN) masih memiliki keterbatasan dalam mengatasi <i>outlier</i> dan meningkatkan stabilitas topik. Belum ada sistem aplikatif yang dikembangkan.	Penelitian ini menggunakan IndoBERTweet sebagai model <i>embedding</i> khusus bahasa Indonesia serta BIRCH sebagai alternatif HDBSCAN untuk meningkatkan stabilitas <i>clustering</i> dan mengurangi <i>outlier</i> . Selain itu, dikembangkan sistem berbasis <i>web</i> untuk analisis percakapan WhatsApp.
2	<i>Integrating IndoBERT and BIRCH in BERTopic for Indonesian short text</i> (Muhajir et al., 2025) (Jurnal Q2)	Penelitian ini memodifikasi BERTopic dengan IndoBERT, BM25, dan BIRCH dengan dataset dari X, Google Reviews, dan YouTube yang bersifat teks monolog. Berhasil menurunkan <i>outlier</i> secara signifikan serta meningkatkan stabilitas topik pada teks pendek.	Pendekatan ini belum dieksplorasi pada data percakapan grup WhatsApp yang memiliki karakteristik lebih kompleks berupa <i>multi-turn dialogue</i> , evolusi percakapan yang cepat dan volume pesan yang tinggi. Selain itu, penelitian terdahulu belum menyediakan sistem aplikasi bagi pengguna akhir.	Penelitian ini mengimplementasikan BERTopic dengan IndoBERTweet dan BIRCH pada dataset WhatsApp yang diintegrasikan ke dalam sistem analisis interaktif untuk memvisualisasikan dinamika topik secara otomatis.
3	<i>BERTopic Enhanced Bibliometric Insight Into Global South Higher Education</i> (Banerjee and Pan, 2024) (Jurnal Q1)	Penelitian ini menyelidiki keragaman linguistik dan proses dekolonisasi dalam sistem pendidikan tinggi di wilayah Global South menggunakan kerangka kerja empiris tiga tingkat yang menggabungkan Analisis Ko-okurensi Bibliometrik (Bibliometric Co-occurrence Analysis), pemodelan topik LDA, dan pemodelan BERTopic. BERTopic menunjukkan performa lebih baik dibanding LDA dalam koherensi dan jumlah topik yang dihasilkan pada data akademik.	Penelitian tersebut belum mengeksplorasi alternatif algoritma klusterisasi yang dapat meminimalkan <i>outlier</i> sejak awal proses, serta belum menguji efektivitas BERTopic pada bahasa Indonesia dengan karakteristik teks percakapan informal yang memiliki noise tinggi dan fenomena <i>code-mixing</i> . Penelitian tersebut juga belum menyediakan sistem aplikasi bagi pengguna akhir.	Penelitian ini berkontribusi dengan mengganti HDBSCAN menggunakan BIRCH <i>clustering</i> yang mampu mengakomodasi dokumen <i>outlier</i> secara dinamis tanpa penghapusan, sekaligus menggunakan IndoBERTweet sebagai <i>embedding</i> untuk dataset percakapan berbahasa Indonesia yang banyak mengandung kata informal dan <i>code-mixing</i> . Penelitian ini juga menyediakan sistem aplikasi bagi pengguna akhir.

Berdasarkan penelitian terdahulu yang telah diulas pada tabel 2.1, dapat disimpulkan bahwa meskipun telah banyak penelitian yang membandingkan berba-

gai model *topic modeling* untuk analisis teks pendek, hasil penelitian terdahulu menunjukkan bahwa BERTopic cenderung lebih unggul dibandingkan pendekatan konvensional pada data media sosial dan data akademik, tetapi masih memiliki keterbatasan ketika menggunakan *embedding* multilingual dan algoritma *clustering* bawaan seperti HDBSCAN. Pada sejumlah penelitian tersebut, penggunaan model yang lebih spesifik terhadap bahasa dan domain, seperti IndoBERT, serta algoritma BIRCH sebagai alternatif klasterisasi, terbukti menjanjikan dalam mengurangi *outlier* dan meningkatkan stabilitas topik pada teks pendek. Selain itu, penelitian yang telah diulas belum banyak mengeksplorasi penerapan pipeline BERTopic pada percakapan grup WhatsApp berbahasa Indonesia yang bersifat *multi-turn*, tidak terstruktur, dan kaya *code-mixing*. Di sisi lain, mayoritas penelitian masih berfokus pada evaluasi metodologi tanpa menyediakan sistem aplikasi yang dapat digunakan langsung oleh pengguna akhir untuk menganalisis percakapan mereka sendiri.


2.2 Landasan Teori

2.2.1 Aplikasi WhatsApp

WhatsApp merupakan aplikasi pesan instan yang memungkinkan pengguna berkomunikasi melalui pesan teks, suara, gambar, video, serta fitur grup yang mendukung komunikasi banyak pengguna dalam satu ruang diskusi (Prayogi et al., 2025). Fitur grup memungkinkan pengguna tergabung dalam banyak kelompok sekaligus untuk kepentingan personal, bisnis, maupun keamanan, sehingga volume pesan sering menjadi besar dan tumpang tindih. Kondisi ini membuat percakapan grup bersifat tidak terstruktur, melibatkan banyak partisipan, dan topik pembahasan dapat berubah dengan cepat (Rani et al., 2022). Akibatnya, pengguna sering kesulitan mengikuti arah percakapan secara menyeluruh. Permasalahan inilah yang menjadi latar belakang penelitian ini, yaitu mengembangkan sistem analisis percakapan grup WhatsApp yang dapat mengidentifikasi dan memetakan topik pembahasan secara otomatis.

2.2.2 BERTopic

BERTopic adalah *framework topic modeling* berbasis *transformer* yang membentuk *embedding* dokumen dan merepresentasikan topik melalui prosedur TF-IDF berbasis kelas, sehingga dokumen dengan makna semantik serupa dapat dipetakan saling berdekatan dalam ruang vektor (Grootendorst, 2022). Pendekatan ini relevan untuk percakapan grup WhatsApp yang umumnya berupa teks pendek, berisik (*noisy*), dan tidak terstruktur, yang cenderung menimbulkan masalah kelangkaan data (*data sparsity*) pada metode pemodelan topik konvensional.



Gambar 2.1: Framework BERTopic dengan modifikasi IndoBERT, BIRCH, dan BM25 (Muhajir et al., 2025)

Berdasarkan Gambar 2.1, *framework* BERTopic terdiri dari empat tahap utama. Tahap pertama adalah *document embedding* yang mengubah dokumen menjadi representasi vektor numerik menggunakan model bahasa seperti IndoBERT-Tweet yang dikembangkan untuk variasi bahasa Indonesia pada ranah media sosial (Koto et al., 2021). Tahap kedua adalah *dimensionality reduction* menggunakan UMAP untuk mereduksi dimensi vektor hasil *embedding* agar proses klasterisasi

lebih efisien (McInnes et al., 2018). Tahap ketiga adalah *clustering* yang mengelompokkan dokumen berdasarkan kemiripan semantik, di mana setiap kluster merepresentasikan satu topik dengan dukungan model yang bersifat modular seperti HDBSCAN, BIRCH, dan K-Means. Tahap keempat adalah *topic representation* yang mengekstrak kata kunci paling representatif dari setiap kluster. Secara bawaan BERTopic menggunakan c-TF-IDF, namun tahap ini dapat dimodifikasi karena bersifat modular (Grootendorst, 2022). Dalam penelitian ini, komponen yang digunakan pada tiap tahap meliputi IndoBERTweet untuk *embedding*, BIRCH untuk klasterisasi, dan BM25 untuk representasi topik.

2.2.3 IndoBERTweet

Model IndoBERTweet merupakan model bahasa pra-latih berskala besar pertama yang dirancang khusus untuk memproses data Twitter (X) berbahasa Indonesia. Model ini dikembangkan melalui pendekatan *domain-adaptive pretraining* dengan fondasi IndoBERT yang semula dilatih pada korpus formal, kemudian diadaptasi ke domain Twitter yang lebih informal. Dalam proses adaptasi tersebut, peneliti melakukan penyesuaian kosakata domain-spesifik dan melaporkan 14.584 kosakata baru (46% dari total kosakata) yang tidak tercakup pada IndoBERT umum (Koto et al., 2021).

Tabel 2.2: Perbandingan Kinerja Model pada Tujuh Tugas

Model	Sentiment		Emotion	Hate Speech		NER		Average
	IndoLEM	SmSA	EmoT	HS1	HS2	Formal	Informal	
mBERT	76.6	84.7	67.5	85.1	75.1	85.2	83.2	79.6
malayBERT	82.0	84.1	74.2	85.0	81.9	81.9	81.3	81.5
IndoBERT (Wilie et al., 2020)	84.1	88.7	73.3	86.8	80.4	86.3	84.3	83.4
IndoBERT (Koto et al., 2020)	84.1	87.9	71.0	86.4	79.3	88.0	86.9	83.4
IndoBERTweet (1M steps from scratch) (Koto et al., 2021)	86.2	90.4	76.0	88.8	87.5	88.1	85.4	86.1
IndoBERT + Vocabulary adaptation + 200K steps (Koto et al., 2021)	86.6	92.7	79.0	88.4	84.0	87.7	86.9	86.5

Berdasarkan Tabel 2.2 yang diadaptasi dari Koto et al. (2021), model IndoBERTweet dan variannya subsecara konsisten mencapai performa tinggi pada tujuh tugas NLP berbahasa Indonesia, meliputi *sentiment analysis*, *emotion classification*, *hate speech detection*, dan *named entity recognition*. Hasil terbaik secara rata-rata ditunjukkan oleh varian IndoBERT dengan adaptasi kosakata dan pelatihan lanjutan 200K langkah (86,5), sedangkan IndoBERTweet yang dilatih dari awal juga menunjukkan kinerja kompetitif (86,1). Temuan ini memperkuat asumsi bahwa model berbasis domain media sosial berpotensi lebih sesuai untuk teks pendek, informal, dan bising seperti percakapan grup WhatsApp berbahasa Indonesia, meskipun efektivitas akhirnya tetap perlu divalidasi pada penelitian ini.

2.2.4 BIRCH Clustering

BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) merupakan algoritma *clustering* hierarkis yang dirancang untuk menangani dataset berskala besar secara efisien dengan cara meringkas data ke dalam struktur *Clustering Feature* (CF) yang disusun dalam CF-Tree di memori, sehingga mengurangi kebutuhan komputasi dibandingkan pendekatan yang memproses setiap titik data secara individual (Zhang et al., 1996). Algoritma ini memiliki keunggulan dalam efisiensi komputasi, penggunaan memori yang rendah, serta ketahanan terhadap *noise*, namun tetap memiliki keterbatasan, seperti sensitivitas terhadap parameter *threshold*, kesulitan dalam menangani kluster dengan bentuk kompleks, serta kurang optimal pada dataset berdimensi tinggi (Zhang et al., 1997). Dalam konteks framework BERTopic, keterbatasan terkait dimensi tinggi tersebut dapat diminimalkan melalui penerapan UMAP sebagai teknik reduksi dimensi sebelum proses klusterisasi dilakukan.

Pada implementasi BIRCH di *scikit-learn*, ringkasan tiap subkluster disimpan dalam bentuk *Clustering Feature* (CF) sebagaimana didefinisikan pada BIRCH orisinal dan dipaparkan kembali pada kajian implementasi matematis modern (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$CF = (N, LS, SS) \quad (2.1)$$

dengan N jumlah titik data, $LS = \sum_{i=1}^N x_i$, dan $SS = \sum_{i=1}^N \|x_i\|^2$.

Centroid subklaster dihitung sebagai:

$$\mu = \frac{LS}{N} \quad (2.2)$$

Radius subklaster digunakan sebagai dasar keputusan pemisahan/penggabungan node. Bentuk komputasional berikut ekuivalen dengan definisi radius BIRCH (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$R = \sqrt{\frac{SS}{N} - \left\| \frac{LS}{N} \right\|^2} \quad (2.3)$$

Ketika titik baru x ditambahkan ke subklaster, radius baru dihitung menggunakan prinsip aditivitas CF, lalu dibandingkan dengan *threshold* (T) (Zhang et al., 1996; Alzu'bi and Barham, 2022):

$$R' = \sqrt{\frac{SS + \|x\|^2}{N + 1} - \left\| \frac{LS + x}{N + 1} \right\|^2}, \quad R' \leq T \quad (2.4)$$

Parameter *branching factor* (B) mengontrol jumlah maksimum anak pada tiap node CF-Tree, sedangkan T mengontrol kekompakan subklaster.

2.2.5 Topic Representation Dengan BM25

Skema pembobotan BM25 adalah algoritma fungsi peringkat (ranking function) yang banyak digunakan dalam pencarian informasi (information retrieval) dan dapat diadaptasi untuk tahap representasi topik (Jian et al., 2020; Shan et al., 2020). c-TF-IDF kesulitan menangkap hubungan semantik secara utuh dan cenderung menghasilkan topik yang kurang koheren ketika distribusi frekuensi kata sangat timpang atau tidak merata (Muhajir et al., 2025). Oleh karena itu, sejumlah penelitian menerapkan BM25 pada tahap *topic representation*, baik sebagai pengganti penuh maupun sebagai modifikasi dari skema c-TF-IDF.

Pada penelitian (Muhajir et al., 2025), c-TF-IDF bawaan BERTopic digantikan sepenuhnya dengan BM25 pada level klaster, dengan skor kata dirumuskan sebagai:

$$w_{t,c_k} = \sum_{d \in C_k} IDF(t) \cdot \frac{f(t,d)(k_1 + 1)}{f(t,d) + k_1 \left(1 - b + b \cdot \frac{|d|}{avgdl}\right)}, \quad (2.5)$$

dengan fungsi *inverse document frequency* didefinisikan sebagai $IDF(t) = \log \left(\frac{N - n(t) + 0.5}{n(t) + 0.5} \right)$. Skor w_{t,c_k} pada persamaan tersebut dihitung dengan menjumlahkan kontribusi seluruh dokumen d yang menjadi anggota himpunan dokumen pada klaster ke- k , yang dinotasikan sebagai C_k . Untuk setiap dokumen tersebut, $f(t,d)$ menyatakan frekuensi kemunculan kata t di dalam dokumen d , sementara $|d|$ menyatakan panjang dokumen d yang kemudian dinormalisasi terhadap $avgdl$, yaitu rata-rata panjang dokumen dalam korpus. Adapun nilai $IDF(t)$ diperoleh dari $n(t)$, yang menyatakan jumlah dokumen dalam korpus yang memuat kata t , serta N yang menyatakan jumlah total dokumen dalam korpus tersebut. Dua parameter tambahan, k_1 dan b , masing-masing berfungsi mengatur tingkat saturasi frekuensi istilah agar pengaruh kata yang berulang tidak meningkat secara linear, dan mengatur normalisasi panjang dokumen agar dokumen yang lebih panjang tidak secara otomatis memperoleh skor yang lebih tinggi.

Dalam konteks studi tersebut, pendekatan ini dilaporkan memberikan representasi topik yang lebih stabil dibandingkan c-TF-IDF pada korpus teks pendek berbahasa Indonesia (Muhajir et al., 2025).

2.2.6 Topic Coherence

Topic coherence digunakan untuk mengukur keterkaitan semantik antar kata teratas dalam topik. Dari banyaknya *topic coherence*, penelitian ini menggunakan *Normalized Pointwise Mutual Information* (NPMI) karena memberikan korelasi tertinggi dengan penilaian manusia dalam konteks context vectors (Röder et al., 2015):

$$\text{NPMI}(w_i, w_j) = \frac{\log \frac{P(w_i, w_j)}{P(w_i) \cdot P(w_j)}}{-\log P(w_i, w_j)} \quad (2.6)$$

dengan $P(w_i, w_j)$ sebagai probabilitas ko-okurensi, serta $P(w_i)$ dan $P(w_j)$ sebagai probabilitas marginal kemunculan kata. Nilai dari NPMI berkisar antara $[-1, 1]$, dengan nilai 1 menunjukkan keterkaitan semantik yang sempurna, 0 menunjukkan tidak ada keterkaitan, dan nilai negatif menunjukkan keterkaitan yang berlawanan (Janssens et al., 2025).

2.2.7 Topic Diversity

Topic diversity didefinisikan dengan keberagaman topik sebagai persentase kata unik dalam 25 kata teratas dari semua topik. Keberagaman mendekati 0 menunjukkan bahwa topik yang berlebihan dan keberagaman mendekati 1 menunjukkan topik yang beragam (Dieng et al., 2020). Nilainya dihitung melalui rumus berikut:

$$TD = \frac{|\text{unique words in top } N \text{ words of all topics}|}{N \times K} \quad (2.7)$$

2.2.8 Embedding Density

Embedding Density adalah metrik evaluasi yang mengukur tingkat kekompakan (*compactness*) representasi embedding dokumen di dalam suatu kluster atau topik (Rushkin, 2020). Metrik ini dihitung menggunakan fungsi kernel dengan bobot sebagai berikut:

$$\rho_k(z) = \frac{\sum_{i=1}^{N_k} K\left(\frac{z - \mathbf{e}_i^{(k)}}{h}\right) w_{k,i}}{\sum_{i=1}^{N_k} K\left(\frac{z - \mathbf{e}_i^{(k)}}{h}\right)} \quad (2.8)$$

dengan z adalah titik embedding evaluasi, yang dalam penelitian ini ditetapkan sebagai centroid embedding topik k ($z = \bar{\mathbf{e}}^{(k)}$); $\mathbf{e}_i^{(k)}$ adalah vektor embedding dokumen ke- i dalam topik k ; N_k adalah jumlah dokumen dalam topik k ; $K(\cdot)$ adalah

fungsi kernel Gaussian; h adalah parameter *bandwidth*; dan $w_{k,i}$ adalah bobot representativitas dokumen ke- i terhadap topik k , yang dihitung berdasarkan *cosine similarity* antara embedding dokumen dan centroid embedding topik tersebut. Semakin tinggi nilai kepadatan yang diperoleh, semakin kohesif dan bermakna topik yang dihasilkan (Rushkin, 2020).

2.2.9 Intra-topic Similarity

Intra-topic similarity merupakan metrik evaluasi yang mengukur kemiripan semantik antar dokumen di dalam satu topik, diadaptasi dari konsep *intra-list similarity* (ILS) sebagai rata-rata kemiripan berpasangan seluruh item dalam sebuah daftar (Jesse et al., 2022). Zhao et al. (2018) menekankan bahwa struktur intra-topik berbasis *word embeddings* mampu menangkap aspek tematik yang lebih halus dan bermakna. Dalam konteks evaluasi model topik, intra-topic similarity untuk topik k dengan N_k dokumen dirumuskan sebagai berikut:

$$\text{ITS}(k) = \frac{1}{N_k(N_k - 1)} \sum_{\substack{i,j=1 \\ i \neq j}}^{N_k} \cos(\mathbf{e}_i^{(k)}, \mathbf{e}_j^{(k)}) \quad (2.9)$$

di mana $\mathbf{e}_i^{(k)}$ dan $\mathbf{e}_j^{(k)}$ adalah embedding dokumen ke- i dan ke- j dalam topik k . Nilai akhir diperoleh dengan merata-ratakan $\text{ITS}(k)$ di seluruh K topik; semakin tinggi nilainya, semakin kohesif topik yang dihasilkan.

BAB 3. METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini termasuk kategori kuantitatif eksperimental dengan pendekatan Research and Development (R&D). Aspek R&D terletak pada pengembangan sistem analisis topik percakapan WhatsApp berbasis web, sedangkan aspek eksperimental kuantitatif digunakan untuk memvalidasi performa pipeline BERTopic dengan modifikasi IndoBERTweet sebagai model embedding dan BIRCH sebagai model clustering.

3.2 Objek Penelitian


Objek penelitian fokus pada data percakapan grup WhatsApp dari komunitas *Book Clan* dengan nama grup *Diskusi Umum*, yang berisi interaksi antar pengguna dalam bahasa Indonesia. Data ini dipilih karena memiliki volume percakapan yang tinggi dan dapat mewakili karakteristik percakapan yang umumnya berupa teks pendek, tidak terstruktur, mengandung *noise*, serta fenomena *code-mixing*.

3.3 Waktu Penelitian

Waktu penelitian dilakukan pada bulan April 2026 hingga Juni 2026, dengan tahapan-tahapan yang telah direncanakan secara sistematis untuk memastikan kelancaran proses penelitian.

3.4 Tahapan Penelitian

Tahapan penelitian yang dilakukan dalam penelitian ini secara keseluruhan digambarkan pada **Gambar 3.1**:



Gambar 3.1: Tahapan Penelitian

3.4.1 Identifikasi Masalah dan Studi Literatur

Tahap pertama dalam penelitian ini adalah identifikasi masalah dan studi literatur. Peneliti melakukan eksplorasi awal terhadap fenomena percakapan grup WhatsApp untuk memahami tantangan dalam menangkap topik pembicaraan secara menyeluruh, mencakup dinamika percakapan, karakteristik teks, serta kebutuhan pengguna dalam mengelola informasi yang besar dan tidak terstruktur.

Studi literatur kemudian dilakukan untuk membangun landasan teori dan memahami perkembangan terkini di bidang *topic modeling* berbahasa Indonesia melalui kajian jurnal ilmiah dan dokumentasi teknis terkait BERTopic, IndoBERTweet, BIRCH *clustering*, BM25, serta metrik evaluasi pemodelan topik. Hasil gabungan tahap ini digunakan untuk mengidentifikasi *research gap*, merumuskan masalah penelitian secara spesifik, dan menentukan metode serta arsitektur sistem yang akan dikembangkan.

3.4.2 Pengumpulan Data

Tahap pengumpulan data dilakukan dengan mengeksport riwayat percakapan dari grup WhatsApp menggunakan fitur *export chat* yang tersedia secara bawaan pada aplikasi WhatsApp. Data yang diekspor berupa file teks (.txt) atau format .zip yang memuat informasi tanggal, waktu, nama pengirim, dan isi pesan. Data percakapan yang dikumpulkan hanya bersumber dari satu grup WhatsApp, dengan

rentang waktu maksimal satu tahun data terbaru untuk memastikan relevansi topik dan menjaga fokus analisis pada dinamika percakapan yang aktual.

3.4.3 Praproses Data


Tahap praproses data bertujuan membersihkan dan mempersiapkan data mentah agar siap diolah oleh model *embedding* dengan tetap mempertahankan makna semantik. Prosesnya meliputi:

1. Pemfilteran pesan sistem, yaitu menghapus notifikasi bawaan WhatsApp seperti pesan bergabung, keluar grup, perubahan keamanan, serta pesan media yang tidak disertakan.
2. Konversi teks menjadi huruf kecil (*lower-case*).
3. Normalisasi *mention* dan URL, dengan mengganti nama pengguna menjadi *@USER* dan URL menjadi *HTTP*.
4. Transliterasi emotikon.
5. Normalisasi kata slang dan pemanjangan kata.

Apabila hasil evaluasi model menunjukkan performa yang kurang optimal, maka dilakukan eksperimen tambahan pada tahap praproses data. Eksperimen tersebut dapat berupa penambahan, pengurangan, maupun modifikasi teknik praproses untuk mengetahui pengaruhnya terhadap kualitas representasi teks dan peningkatan performa model. Dengan demikian, proses praproses dilakukan secara iteratif hingga diperoleh hasil evaluasi model yang lebih baik.

3.4.4 Pembuatan Model

Tahap pemodelan topik merupakan tahap inti dari penelitian ini, di mana data yang telah melalui pra-pemrosesan dianalisis menggunakan *framework* BERTopic yang telah dimodifikasi. Penentuan parameter pada tiap komponen dilakukan dengan dua skenario, yaitu mengacu pada *baseline* dari penelitian terdahulu dan eksperimen penalaan parameter untuk memperoleh kinerja terbaik berdasarkan metrik evaluasi. Alur pembuatan model ini terdiri dari empat komponen utama:



Gambar 3.2: Rancangan framework BERTopic yang dimodifikasi pada tahap pembuatan model

1. *Document Embedding* menggunakan IndoBERTweet

Setiap dokumen (pesan) diubah menjadi representasi vektor numerik berdimensi tinggi menggunakan model IndoBERTweet yang telah diadaptasi untuk teks media sosial berbahasa Indonesia. Representasi *embedding* ini mampu menangkap makna semantik dan konteks kata secara lebih akurat dibandingkan model *multilingual* (Koto et al., 2021).

2. *Dimensionality Reduction* menggunakan UMAP

Vektor *embedding* berdimensi tinggi direduksi menggunakan *Uniform Manifold Approximation and Projection* (UMAP) untuk mengurangi kompleksitas komputasi sambil mempertahankan struktur lokal dan global data dalam ru-

ang berdimensi rendah. Parameter UMAP yang digunakan meliputi $n_neighbors$, $n_components$, min_dist , dan $metric$.

3. Clustering menggunakan BIRCH Algorithm

Dokumen yang telah direduksi dimensinya dikelompokkan menggunakan algoritma BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) sebagai pengganti HDBSCAN standar. BIRCH dipilih karena kemampuannya dalam mengalokasikan seluruh dokumen ke dalam kluster tanpa menghasilkan *outlier* dalam jumlah besar, serta efisiensi komputasi dan penggunaan memori yang lebih baik. Parameter BIRCH yang digunakan meliputi $threshold$, $branching_factor$, dan $n_clusters$.

4. Topic Representation menggunakan BM25

Setiap kluster yang terbentuk direpresentasikan menggunakan skema pembobotan BM25 sebagai pengganti c-TF-IDF bawaan BERTopic. BM25 menerapkan saturasi frekuensi istilah dan normalisasi panjang dokumen, sehingga menghasilkan kata kunci representatif yang lebih relevan dan stabil secara semantik untuk setiap topik. Parameter BM25 yang digunakan meliputi $k1$ dan b .

3.4.5 Evaluasi Model

Tahap evaluasi model bertujuan untuk mengukur kualitas topik yang dihasilkan oleh model BERTopic secara kuantitatif. Evaluasi dilakukan menggunakan empat metrik utama, yaitu:

1. Topic Coherence

Topic Coherence digunakan untuk mengukur sejauh mana kata-kata teratas dalam setiap topik memiliki hubungan semantik satu sama lain. Nilai yang lebih tinggi menunjukkan topik yang lebih koheren.

2. Topic Diversity

Topic Diversity digunakan untuk mengukur keunikan kata-kata teratas antar topik. Nilai mendekati 1 menunjukkan tidak ada tumpang tindih kata antar topik.

3. *Embedding Density*


Embedding Density digunakan untuk mengukur tingkat kekompakan dokumen dalam tiap klaster pada ruang *embedding*. Nilai yang lebih tinggi menunjukkan klaster yang semakin padat.

4. *Intra-topic Similarity*

Intra-topic Similarity digunakan untuk mengukur rata-rata kesamaan semantik antar dokumen dalam satu topik. Nilai yang lebih tinggi menunjukkan homogenitas topik yang lebih baik.

3.4.6 Implementasi Sistem

Tahap pengembangan sistem bertujuan untuk mengimplementasikan seluruh alur pemodelan topik ke dalam sebuah aplikasi berbasis web yang dapat digunakan secara praktis oleh pengguna.



Gambar 3.3: Alur implementasi sistem analisis topik WhatsApp

Pada Gambar 3.3, sistem memungkinkan pengguna untuk mengunggah data ekspor WhatsApp, divalidasi formatnya, lalu diproses oleh backend dengan pipeline BERTopic. Pengguna dapat memantau progress pemrosesan di halaman progress, dan setelah selesai, hasil analisis topik ditampilkan dalam bentuk daftar topik dengan kata kunci representatif. Pengguna dapat memilih cluster tertentu untuk melihat pesan-pesan yang termasuk dalam topik tersebut, serta mengklik pesan individual untuk mendapatkan konteks pesan asli.

Implementasi dilakukan dengan arsitektur *client-server*, menggunakan Vue.js sebagai *client* (antarmuka pengguna) dan FastAPI sebagai *server* (layanan API). Pengembangan sistem berfokus pada aspek fungsionalitas, kemudahan penggunaan

(*usability*), dan efisiensi pemrosesan.

3.4.7 Evaluasi Sistem

Tahap evaluasi sistem dilakukan untuk mengukur kinerja dan efektivitas aplikasi yang telah dikembangkan. Evaluasi dilakukan dengan menggunakan metode black-box testing, di mana fokusnya adalah pada input dan output sistem tanpa memperhatikan proses internalnya. Pengujian dilakukan dengan menggunakan dataset percakapan grup WhatsApp yang berbeda dari dataset yang digunakan untuk pelatihan model, untuk memastikan bahwa sistem dapat bekerja secara umum dan tidak hanya pada data tertentu. Hasil evaluasi ini akan memberikan gambaran tentang seberapa baik sistem dapat mengidentifikasi dan merepresentasikan topik dalam percakapan grup WhatsApp secara otomatis, serta memberikan umpan balik untuk perbaikan lebih lanjut jika diperlukan.

3.4.8 Analisis Hasil

Tahap analisis hasil dilakukan terhadap seluruh keluaran dari pemodelan topik dan evaluasi model. Analisis dilakukan dengan membandingkan performa model berdasarkan metrik evaluasi yang telah ditentukan, serta menginterpretasikan topik-topik yang dihasilkan.

3.4.9 Penarikan Kesimpulan

Berdasarkan hasil analisis, dilakukan penarikan kesimpulan yang menjawab rumusan masalah penelitian serta penyusunan saran untuk pengembangan penelitian di masa mendatang.

3.5 Etika Penelitian

Penelitian ini mematuhi prinsip-prinsip etika penelitian, termasuk:

1. Anonimisasi

Data percakapan yang dikumpulkan dalam penelitian ini telah melalui proses anonimisasi pada tahap pra-pemrosesan untuk menghapus atau menyamarkan informasi yang dapat mengidentifikasi individu seperti nama pengirim, mention, dan nomor telepon sebelum dianalisis. Nama pengguna dan nomor telepon yang tercantum dalam pengirim pesan hanya diambil 3 karakter kemudian karakter selanjutnya diganti dengan tanda bintang (****). Untuk mention dipesan diganti dengan token anonim (@*USER*). Langkah ini diterapkan untuk memastikan bahwa data yang digunakan dalam proses analisis tidak dapat dikaitkan kembali kepada individu tertentu.

2. Informed Consent

3. Pembatasan Tujuan

Data yang dikumpulkan dan dianalisis dalam penelitian ini hanya digunakan untuk tujuan penelitian yang telah disepakati, yaitu analisis topik percakapan grup WhatsApp. Data tidak akan digunakan untuk tujuan lain, diperjualbelikan, atau disalahgunakan tanpa persetujuan lebih lanjut dari pihak terkait.

BAB 4. HASIL DAN PEMBAHASAN

4.1 Pengumpulan Data

Data yang digunakan dalam penelitian ini bersumber dari grup WhatsApp *Info Warga Jember*, sebuah grup komunitas daring yang aktif digunakan oleh warga di wilayah Kabupaten Jember sebagai sarana penyebaran informasi, diskusi, dan komunikasi sehari-hari. Pengumpulan data dilakukan melalui fitur ekspor percakapan yang tersedia secara bawaan pada aplikasi WhatsApp. Fitur ini memungkinkan pengguna yang memiliki akses administrator untuk mengunduh riwayat percakapan dalam dua format: berkas *.zip* yang menyertakan lampiran media, atau berkas *.txt* yang hanya memuat teks percakapan. Penelitian ini menggunakan format *.txt* karena komponen yang relevan untuk analisis topik adalah konten teks pesan, bukan lampiran media.

Berkas hasil ekspor selanjutnya diproses melalui tahap *parsing* untuk mengekstrak empat atribut utama dari setiap pesan, yaitu tanggal, waktu, nama pengirim, dan isi pesan, yang kemudian disusun dalam format CSV sebagai representasi terstruktur dari data mentah. Rentang waktu pengumpulan data mencakup periode dua tahun, terhitung sejak 19 Mei 2024 hingga 19 Mei 2026, guna memperoleh gambaran yang representatif terhadap dinamika percakapan dalam jangka panjang.

Sebelum digunakan dalam analisis, data melewati tahap penyaringan untuk menghilangkan pesan yang tidak mengandung konten linguistik yang bermakna. Kriteria eksklusi meliputi pesan sistem yang dihasilkan otomatis oleh aplikasi WhatsApp—seperti notifikasi penambahan atau penghapusan anggota, perubahan ikon atau nama grup—serta entri bertanda *<Media omitted>* yang menunjukkan lampiran tanpa teks penyerta. Setelah proses penyaringan tersebut, dataset final yang digunakan dalam penelitian ini terdiri dari **18.954 pesan** yang dikirim oleh **766 pengirim unik**, dengan rata-rata sekitar 26 pesan per hari sepanjang periode pengamatan.

4.2 Praproses Data

Uraikan langkah pra-pemrosesan yang dilakukan sesuai metodologi:

1. Pemfilteran pesan sistem dan pesan media
2. Normalisasi (lower-case, mention → @USER, URL → HTTP)
3. Transliteration emotikon dan normalisasi slang
4. Tokenisasi dan stopwords removal (Sastrawi + manual)

Berikan contoh before/after satu atau dua pesan untuk ilustrasi.

4.3 Pembuatan Model

Sajikan statistik deskriptif utama setelah pra-pemrosesan: mean, median, standar deviasi panjang pesan, frekuensi kata teratas, dan distribusi topik awal jika relevan.

4.3.1 Embedding dan Reduksi Dimensi

Jelaskan penggunaan IndoBERTweet untuk pembuatan embedding, parameter penting yang dipilih, dan hasil reduksi dimensi menggunakan UMAP. Sertakan visualisasi (scatter plot UMAP) dan interpretasi singkat.

4.3.2 Clustering dan Representasi Topik

Paparkan penggunaan BIRCH untuk clustering dan BM25 untuk representasi topik.

Untuk setiap topik utama, tampilkan:

- Kata kunci representatif (top-n)
- Jumlah dokumen per klaster
- Contoh pesan yang termasuk dalam topik

4.3.3 Evaluasi Kuantitatif Model

Tampilkan hasil metrik evaluasi yang digunakan: topic coherence, topic diversity, embedding density, dan intra-topic similarity. Sajikan hasil dalam tabel per skenario parameter (baseline vs modifikasi) dan beri interpretasi singkat.

4.3.4 Perbandingan Eksperimen (Baseline vs Modifikasi)

Bandingkan kinerja skenario berbeda (mis. HDBSCAN vs BIRCH, c-TF-IDF vs BM25, model embedding berbeda). Sertakan tabel ringkasan dan highlight perbedaan signifikan.

4.3.5 Uji Asumsi dan Analisis Inferensial

Jika relevan, laporkan uji normalitas, uji homogenitas, dan hasil pengujian hipotesis. Jelaskan metode statistik yang digunakan dan implikasinya terhadap interpretasi hasil.

4.3.6 Implementasi Sistem dan Evaluasi Fungsional

Laporkan hasil pengujian aplikasi berbasis web: keandalan upload, waktu proses end-to-end, pengalaman pengguna (jika ada pengujian usability), serta contoh tampilan hasil.

4.3.7 Analisis Hasil

Analisis sintesis hasil kuantitatif dan kualitatif: apakah topik yang dihasilkan bermakna, stabil, dan sesuai konteks grup WhatsApp. Kaitkan dengan tujuan penelitian.

4.4 Pembahasan

4.4.1 Interpretasi Temuan Utama

Paparkan penjelasan mendalam mengenai temuan utama, mengapa hasil tersebut muncul, dan bagaimana temuan ini menjawab rumusan masalah. Hubungkan temuan dengan teori dan tinjauan pustaka di Bab 2.

4.4.2 Analisis Kualitatif Topik

Bahas beberapa topik penting secara kualitatif: konteks sosialnya, contoh kutipan pesan, dan relevansi bagi pengguna.

4.4.3 Implikasi Praktis dan Rekomendasi Implementasi

Jelaskan implikasi untuk pengembangan sistem dan pengguna akhir, termasuk rekomendasi konfigurasi model, antarmuka, dan fitur tambahan.

4.4.4 Keterbatasan Penelitian

Sebutkan keterbatasan data, metode, dan eksperimen (mis. satu grup WhatsApp, potensi bias, keterbatasan anotasi) serta dampaknya pada generalisasi hasil.

4.4.5 Saran dan Pekerjaan Lanjutan

Rekomendasi teknis dan riset lanjutan: perluasan dataset, eksperimen model embedding lain, perbaikan pipeline pra-pemrosesan, atau pengujian usability yang lebih formal.

4.4.6 Ringkasan Hasil Utama

Ringkas temuan paling penting dalam 3–5 poin yang langsung menjawab rumusan masalah.

BAB 5. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian dan pembahasan, dapat disimpulkan sebagai berikut:

1. **Kesimpulan 1 (jawab RMP pertama):** Penelitian ini menunjukkan bahwa ... (Jelaskan jawaban dari rumusan masalah pertama di Bab 1 Section 1.2)
2. **Kesimpulan 2 (jawab RMP kedua):** Temuan utama adalah bahwa ... (Jelaskan jawaban dari rumusan masalah kedua)
3. **Kesimpulan 3 (jawab RMP ketiga):** Hasil analisis menunjukkan bahwa ... (Jelaskan jawaban dari rumusan masalah ketiga, jika ada)
4. **Kontribusi Utama:** Penelitian ini memberikan kontribusi teoritis dan praktis dalam ... (Jelaskan bagaimana penelitian ini berkontribusi pada ilmu pengetahuan dan praktik)

Secara keseluruhan, penelitian ini telah berhasil mengidentifikasi dan menganalisis ... (Ringkas temuan utama dalam 1-2 kalimat yang comprehensive).

5.2 Saran

Berdasarkan hasil penelitian, beberapa saran yang dapat diberikan adalah:

5.2.1 Saran untuk Penelitian Selanjutnya

Saran untuk penelitian di masa depan meliputi:

1. **Eksplorasi Variabel Tambahan:** Penelitian selanjutnya dapat menambahkan variabel ... untuk memberikan gambaran yang lebih lengkap tentang ... (Jelaskan variabel yang belum diteliti dan alasannya)

2. **Perluasan Scope Penelitian:** Penelitian dapat dilakukan dengan ... (Misal: lokasi yang berbeda, sampel yang lebih besar, periode waktu yang lebih panjang) untuk meningkatkan generalisabilitas hasil.
3. **Metode Penelitian Alternatif:** Menggunakan metode ... (mixed-method, longitudinal, q experimental design) untuk mendapatkan insight yang lebih dalam tentang ...
4. **Eksaminasi Mekanisme:** Penelitian lebih lanjut dapat membedah mekanisme yang mendasari ... untuk memahami HAL APA dan MENGAPA (explanatory research).

5.2.2 Saran untuk Praktisi dan Pengambil Kebijakan

Saran untuk implementasi praktis dari penelitian ini adalah:

1. **Rekomendasi 1:** ... (Jelaskan saran konkret untuk organisasi/perusahaan/pemerintah)
2. **Rekomendasi 2:** ... (Jelaskan saran kedua dengan action items yang jelas)
3. **Rekomendasi 3:** ... (Jelaskan saran ketiga dengan fokus pada implementasi)

Implementasi rekomendasi-rekomendasi ini diharapkan dapat ... (Jelaskan dampak positif yang diharapkan dari implementasi).

DAFTAR PUSTAKA

- Abdelrazek, A., Eid, Y., Gawish, E., Medhat, W., and Hassan, A. (2023). Topic modeling algorithms and applications: A survey. *Information Systems*, 112:102131.
- Alzu'bi, A. and Barham, M. (2022). Automatic birch thresholding with features transformation for hierarchical breast cancer clustering. *International Journal of Electrical and Computer Engineering (IJECE)*, 12(2):1498–1507.
- Banerjee, S. and Pan, A. (2024). From colonial legacies to linguistic inclusion: A bertopic enhanced bibliometric insight into global south higher education. *IEEE Access*, 12:117418–117435.
- Churchill, R. and Singh, L. (2022). The evolution of topic modeling. *ACM Comput. Surv.*, 54(10s).
- Dieng, A. B., Ruiz, F. J. R., and Blei, D. M. (2020). Topic modeling in embedding spaces. *Transactions of the Association for Computational Linguistics*, 8:439–453.
- Egger, R. and Yu, J. (2022). A topic modeling comparison between lda, nmf, top2vec, and bertopic to demystify twitter posts. *Frontiers in Sociology*, Volume 7 - 2022.
- Grootendorst, M. (2022). Bertopic: Neural topic modeling with a class-based tf-idf procedure.
- Janssens, W., Bogaert, M., and van den Poel, D. (2025). A comparative analysis of topic reduction techniques for bertopic. *IEEE Access*, 13:204087–204103.
- Jesse, M., Bauer, C., and Jannach, D. (2022). Intra-list similarity and human diversity perceptions of recommendations: the details matter. *User Modeling and User-Adapted Interaction*, 33(4):769–802.
- Jian, F., Huang, J. X., Zhao, J., Ying, Z., and Wang, Y. (2020). A topic-based

- term frequency normalization framework to enhance probabilistic information retrieval. *Computational Intelligence*, 36(2):486–521.
- Kharisudin, I. and Masri'an, H. (2022). Topic modeling on whatsapp user reviews using latent dirichlet allocation. *Scientific Journal of Informatics*, 9:51–62.
- Koto, F., Lau, J. H., and Baldwin, T. (2021). Indobertweet: A pretrained language model for indonesian twitter with effective domain-specific vocabulary initialization. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP 2021)*.
- Koto, F., Rahimi, A., Lau, J., and Baldwin, T. (2020). Indolem and indobert: A benchmark dataset and pre-trained language model for indonesian nlp.
- Kumar, R. P. and Naik, N. M. (2023). Whatsapp chat analyzer using machine learning and natural language processing. In *2023 2nd International Conference on Futuristic Technologies (INCOFT)*, pages 1–6.
- McInnes, L., Healy, J., and Melville, J. (2018). Umap: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*.
- Mohta, A., Jain, A., Saluja, A., and Dahiya, S. (2020). Pre-processing and emoji classification of whatsapp chats for sentiment analysis. In *2020 Fourth International Conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud) (I-SMAC)*, pages 514–519.
- Muhajir, M., Gunardi, G., Danardono, D., and Rosadi, D. (2025). Integrating indobert and balanced iterative reducing and clustering using hierarchies of bertopic in indonesian short text. *IAES International Journal of Artificial Intelligence (IJ-AI)*, 14:4192.
- Prayogi, A., Novriyenny, N., and Prahmana, I. G. (2025). Dinamika sentimen komunikasi mahasiswa dan dosen dengan pemanfaatan analisis pesan whatsapp akademis menggunakan machine learning. *Repeater: Publikasi Teknik Informatika dan Jaringan*, 3(2):45–54.
- Rani, S. J., Prabhu, T., and Chellam, J. A. I. (2022). Whatsapp sentiment analysis using r. In *2022 3rd International Conference for Emerging Technology (INCET)*, pages 1–4. IEEE.

- Retna, V. A., Brundha, P., and RajKumar, G. (2021). People’s behaviour analysis in chat message using natural language processing. In *2021 Third International Conference on Intelligent Communication Technologies and Virtual Mobile Networks (ICICV)*, pages 1128–1133.
- Röder, M., Both, A., and Hinneburg, A. (2015). Exploring the space of topic coherence measures. In *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining, WSDM ’15*, page 399–408, New York, NY, USA. Association for Computing Machinery.
- Rushkin, I. (2020). Document similarity from vector space densities. *CoRR*, abs/2009.00672.
- Shan, X., Liu, C., Xia, Y., Chen, Q., Zhang, Y., Luo, A., and Luo, Y. (2020). BI-SON: bm25-weighted self-attention framework for multi-fields document search. *CoRR*, abs/2007.05186.
- WhatsApp Inc. (2026). Tentang whatsapp. Diakses pada 7 Januari 2026.
- Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., and Purwarianti, A. (2020). Indonlu: Benchmark and resources for evaluating indonesian natural language understanding. In *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*.
- Zhang, T., Ramakrishnan, R., and Livny, M. (1996). Birch: an efficient data clustering method for very large databases. *SIGMOD Rec.*, 25(2):103–114.
- Zhang, T., Ramakrishnan, R., and Livny, M. (1997). Birch: A new data clustering algorithm and its applications. *Data Min. Knowl. Discov.*, 1(2):141–182.
- Zhao, H., Du, L., Buntine, W., and Zhou, M. (2018). Inter and intra topic structure learning with word embeddings. In *International Conference on Machine Learning*, pages 5892–5901. PMLR.

LAMPIRAN A. LAMPIRAN

A.1 Lampiran A - Data Mentah

Data mentah dari penelitian ini dapat dilihat pada Tabel ?? di bawah ini. Namun, untuk menjaga ukuran dokumen, hanya sample data yang ditampilkan. Data lengkap tersedia pada file `data_raw.csv` yang disertakan.

A.2 Lampiran B - Instrumen Penelitian

A.2.1 Lampiran B.1 - Kuesioner

KUESIONER PENELITIAN

Petunjuk Pengisian:

- Bacalah setiap pertanyaan dengan cermat
- Jawab dengan jujur sesuai pendapat Anda
- Tidak ada jawaban yang benar atau salah
- Data Anda dijamin kerahasiaannya

A. DATA DEMOGRAFIS

1. Jenis Kelamin: Laki-laki ☐ Perempuan ☐
2. Usia: ... tahun
3. Pendidikan: ...
4. Pekerjaan: ...

B. PERTANYAAN PENELITIAN

Untuk pertanyaan berikut, berikan jawaban dengan skala 1-5:

- 1 = Sangat Tidak Setuju (STS)
- 2 = Tidak Setuju (TS)
- 3 = Netral (N)
- 4 = Setuju (S)
- 5 = Sangat Setuju (SS)

1. Pernyataan pertama: STS ☐ TS ☐ N ☐ S ☐ SS ☐
2. Pernyataan kedua: STS ☐ TS ☐ N ☐ S ☐ SS ☐
3. Pernyataan ketiga: STS ☐ TS ☐ N ☐ S ☐ SS ☐

Terima kasih atas partisipasi Anda

A.3 Lampiran C - Output Analisis Statistik

Output statistik lengkap dari software analisis tersimpan dalam folder `analysis_output/`. Beberapa hasil utama ditampilkan di bawah:

A.4 Lampiran D - Kode Sumber

Kode sumber lengkap tersedia di repository GitHub: <https://github.com/username/1>
Atau dalam file `source_code.py`, `analysis.R`, dll. yang disertakan.

A.5 Lampiran E - Dokumen Pendukung

Dokumen pendukung berikut disertakan dalam pengumpulan skripsi:

- Surat izin penelitian dari institusi
- Informed consent forms (ICF) yang ditandatangani responden
- Sertifikat ethical clearance (jika ada)
- Bukti publikasi draft di jurnal/conference (jika ada)
- Dokumen lain yang relevan

Dokumen-dokumen ini disimpan dalam folder `supporting_documents/` dan dapat diminta dari penulis jika diperlukan untuk verifikasi atau referensi.